KỊCH BẢN THUYẾT TRÌNH

Báo cáo cuối kỳ môn Phân tích dữ liệu lớn

Pipeline dự đoán RUL trên NASA C-MAPSS

FD001–FD004

Học viên thực hiện:	Phan Nguyễn Mai Phương
Mã số học viên:	25002711
Ngành:	Khoa học máy tính

Tháng 9 năm 2026

Contents

Hướng dẫn sử dụng 1

Slide 1 – Bìa 2

Slide 2 – Bài toán nghiên cứu 3

Slide 3 – Dữ liệu C-MAPSS và ranh giới nhãn 4

Slide 4 – Quy trình xử lý dữ liệu 5

Slide 5 – Sensor thay đổi theo vòng đời 6

Slide 6 – Từ chuỗi sensor đến đặc trưng 7

Slide 7 – Đánh giá theo engine 8

Slide 8 – Lựa chọn model 9

Slide 9 – Kết quả chính trên FD001 10

Slide 10 – Phân tích lỗi 11

Slide 11 – Health Index và ARIMA 12

Slide 12 – Cảnh báo sớm 13

Slide 13 – ETL và khả năng tái lập 14

Slide 14 – Kết luận và giới hạn 15

Slide 15 – Transfer giữa các subset C-MAPSS 16

Kết thúc 16

Câu hỏi phản biện thường gặp 17

Hướng dẫn sử dụng

Tài liệu này bám theo deck 15 slide tại `slides/cmapss_fd001_presentation.pptx`. Phần trình bày chính dùng FD001 với trailing window 30 cycles. Slide 15 trình bày ma trận bổ sung dùng window 10 cycles cho FD001–FD004; hai nhóm metric phải được nói tách biệt. Tổng thời lượng mục tiêu khoảng 10–12 phút, chưa tính phần hỏi đáp.

Slide 1 – Bìa

Thời lượng gợi ý: 20 giây

Mở deck ở slide 1.

Kính chào thầy/cô và các bạn. Em tên là Phan Nguyễn Mai Phương. Hôm nay em xin trình bày báo cáo cuối kỳ môn Phân tích dữ liệu lớn về pipeline dự đoán Remaining Useful Life, viết tắt là RUL, trên bộ dữ liệu NASA C-MAPSS.

Mục tiêu của báo cáo là xây dựng một quy trình có thể kiểm tra và tái lập từ raw data đến kết quả RUL. Phần chính dùng FD001. Sau đó, em bổ sung một ma trận đánh giá trên FD002, FD003 và FD004 để kiểm tra model có chuyển sang điều kiện vận hành hoặc fault mode khác được hay không.

Slide 2 – Bài toán nghiên cứu

Thời lượng gợi ý: 45 giây

Giải thích ví dụ RUL trên slide.

RUL là số cycle vận hành còn lại trước khi engine đi đến failure. Đây là bài toán supervised regression vì đầu ra là một giá trị số.

Trong train, nếu engine kết thúc ở cycle 200 thì nhãn tại cycle 170 là 30 cycles. Trong test, trajectory bị cắt trước failure nên không được tự lấy cycle cuối quan sát làm nhãn. Model chỉ tạo một dự đoán tại cycle cuối quan sát, sau đó mới ghép nhãn NASA tương ứng để đánh giá.

RUL được tính theo cycle, không quy đổi thành giờ hoặc ngày vì dữ liệu không có thông tin quy đổi lịch vận hành.

Slide 3 – Dữ liệu C-MAPSS và ranh giới nhãn

Thời lượng gợi ý: 50 giây

Nêu FD001 là protocol chính và FD002–FD004 là phần bổ sung.

Kho raw hiện có đủ bốn subset C-MAPSS. FD001 có một operating condition và một fault mode. FD002 có sáu operating conditions, FD003 có hai fault modes, còn FD004 có cả sáu conditions và hai fault modes.

Phần chính của báo cáo dùng FD001: 100 train engines với 20.631 observations và 100 test engines với 13.096 observations. Mỗi observation có engine ID, cycle, ba operational settings và 21 sensor measurements.

Điểm kiểm soát quan trọng là nhãn test của từng subset chỉ được đọc sau khi final predictions đã được ghi. Nhờ vậy, test labels không tham gia EDA, feature engineering hoặc model selection.

Slide 4 – Quy trình xử lý dữ liệu

Thời lượng gợi ý: 45 giây

Đọc sơ đồ pipeline từ trái sang phải.

Raw files được đọc và kiểm tra schema, kiểu dữ liệu, khóa duy nhất và cycle continuity. ETL tạo các bảng Silver và Gold. Từ observations, pipeline tạo trailing features theo từng engine.

Nhánh modeling dùng GroupKFold để chọn model, sau đó refit trên toàn bộ train và tạo final predictions. Nhánh Health Index dùng PCA–ARIMA là phân tích phụ. Cuối cùng, các artifact được dùng cho metric, hình minh họa, dashboard và báo cáo.

Slide 5 – Sensor thay đổi theo vòng đời

Thời lượng gợi ý: 45 giây

Nêu rõ đây là phân tích train-only, không phải feature selection.

Em so sánh mean của 30 cycles đầu và 30 cycles cuối trong cùng một train engine. Chênh lệch được tính theo từng sensor, sau đó dùng bootstrap theo engine, Wilcoxon signed-rank và hiệu chỉnh Benjamini–Hochberg cho 21 sensor.

Theo protocol này, 15 sensor có bằng chứng bác bỏ giả thuyết không sau hiệu chỉnh. Kết quả mô tả thay đổi đầu và cuối vòng đời. Nó không chứng minh quan hệ nhân quả và không được dùng như bằng chứng rằng sensor đó sẽ tổng quát tốt trên engine mới.

Slide 6 – Từ chuỗi sensor đến đặc trưng

Thời lượng gợi ý: 45 giây

Giải thích window 30 và sáu phép tóm tắt.

Với protocol chính, mỗi dòng feature dùng 30 cycles gần nhất của cùng engine. Ví dụ, tại cycle 170, window dùng cycles 141 đến 170 và không dùng cycle tương lai.

Mỗi trong 21 sensor tạo sáu đặc trưng: giá trị cuối, mean, sample standard deviation, min, max và linear slope. Như vậy có 126 feature columns. Window không đi qua engine khác, không dùng test labels và không padding engine ngắn.

Artifact FD001 chính có 17.731 train windows và 10.196 test windows.

Slide 7 – Đánh giá theo engine

Thời lượng gợi ý: 50 giây

Nhấn mạnh lý do dùng GroupKFold.

Em dùng 5-fold GroupKFold với engine ID làm group key. Mọi window của cùng một engine nằm trong cùng một fold. Cách chia này cần thiết vì các cycle liên tiếp trong một engine có phụ thuộc thời gian; chia ngẫu nhiên theo row sẽ làm metric lạc quan.

Trong training fold, tổng sample weight của mỗi engine bằng 1 để engine có nhiều window không chi phối loss chỉ vì trajectory dài hơn.

Sau model selection, model được refit trên toàn bộ train và chỉ tạo một dự đoán cho cycle cuối của mỗi test engine.

Slide 8 – Lựa chọn model

Thời lượng gợi ý: 50 giây

Đọc bảng so sánh ba model.

Ba ứng viên là median baseline, Ridge regression và HistGradientBoostingRegressor. Metric chọn model là mean engine-level MAE.

Median baseline đạt 46,9543 cycles. Ridge đạt 23,9922 cycles. HistGradientBoosting đạt 20,2143 cycles và được chọn trong cross-validation.

Kết quả này chỉ nói rằng boosting tốt nhất trong ba ứng viên và trong protocol đã chốt. Nó không phải tuyên bố rằng đây là model tốt nhất cho mọi dataset.

Slide 9 – Kết quả chính trên FD001

Thời lượng gợi ý: 70 giây

Dùng slide 9 để trình bày metric chính.

Sau khi chọn model, pipeline refit HistGradientBoosting trên toàn bộ 17.731 train windows và tạo đúng 100 final predictions.

Trên 100 FD001 test engines, mean engine MAE là 15,3490 cycles, RMSE là 20,5413 cycles và NASA score là 1.513,2577. Bootstrap theo engine với 10.000 lần resampling cho khoảng tin cậy 95

Đây là kết quả chính của báo cáo với window 30 cycles. Slide 15 dùng window 10 cho một câu hỏi khác, nên hai con số đó không được so trực tiếp.

Slide 10 – Phân tích lỗi

Thời lượng gợi ý: 45 giây

Chỉ vào các trường hợp sai lớn trên hình.

Trong FD001 test, 74 dự đoán cao hơn RUL thật và 26 dự đoán thấp hơn. Engine 23 có RUL thật 113 nhưng model dự đoán 170,4768, sai 57,4768 cycles.

Ví dụ này cho thấy metric trung bình không mô tả đầy đủ failure mode của model. Các trường hợp dự đoán cao hơn RUL thật đóng góp đáng kể vào NASA score vì NASA score phạt bất đối xứng sai số dự đoán trễ.

Slide 11 – Health Index và ARIMA

Thời lượng gợi ý: 45 giây

Nhắc rõ đây là phân tích phụ.

Health Index được xây từ sensor sau StandardScaler và PCA. Scaler và PCA fit trên 90 train engines, còn 10 engine được chọn chỉ được transform. ARIMA fit 70chuỗi và forecast 30

Trên 10 holdout trajectories, ARIMA có MAE trung bình 0,4110, thấp hơn drift 0,7469 và last-value 0,9478. Coverage khoảng dự đoán dao động từ 21,4397,03forecast và không thay thế model RUL.

Slide 12 – Cảnh báo sớm

Thời lượng gợi ý: 45 giây

Nêu điều kiện OOF và giới hạn của warning.

Ngưỡng cảnh báo được cố định ở RUL nhỏ hơn hoặc bằng 30 cycles. Trên OOF train, 44 engine được cảnh báo trước ngưỡng thật, 7 đúng ngưỡng và 49 sau ngưỡng nhưng vẫn trước failure. Lead time có trung vị 30 cycles, miền 19 đến 55 cycles.

Đây là phân tích timing nội bộ. OOF đã được dùng để chọn model, nên kết quả chưa phải đánh giá độc lập về utility bảo trì. Vì mọi train trajectory đều đi đến failure, false-alarm rate cấp toàn trajectory không xác định theo định nghĩa hiện tại.

Slide 13 – ETL và khả năng tái lập

Thời lượng gợi ý: 45 giây

Nêu ngắn gọn bằng chứng kỹ thuật.

Pandas và PySpark cho kết quả khớp tại ba boundary Silver/Gold, với sai khác tuyệt đối lớn nhất bằng 0 trong phép parity đã chạy. Benchmark runtime hiện chỉ đo Pandas in-memory trên dữ liệu nhân bản, không phải benchmark cluster.

Pipeline được kiểm tra lại bằng full test suite. Lần chạy hiện tại đạt 154 tests. Raw files, config, metric và provenance được lưu thành artifact để người đọc có thể truy vết kết quả.

Slide 14 – Kết luận và giới hạn

Thời lượng gợi ý: 45 giây

Tóm tắt trước khi chuyển sang slide transfer.

Kết luận chính là HistGradientBoosting dự đoán RUL trên FD001 trong protocol window 30 với MAE 15,3490 cycles. Pipeline kiểm soát data leakage bằng group split, trailing window và late test-label join.

Giới hạn gồm dữ liệu mô phỏng, một điểm cắt cho mỗi test engine, không có cost, downtime hoặc intervention records, và warning OOF chưa độc lập với model selection.

Slide 15 – Transfer giữa các subset C-MAPSS

Thời lượng gợi ý: 80 giây

Đây là phần bổ sung mới. Chỉ rõ window 10 trước khi đọc bảng.

Để kiểm tra khả năng chuyển miền, em chạy cùng pipeline với window 10 cycles cho cả FD001, FD002, FD003 và FD004. Window 10 được chọn vì test FD004 có engine ngắn nhất 19 cycles. Metric này không thay thế metric chính FD001 dùng window 30.

Evaluation nội bộ cho MAE 21,9258 trên FD001, 22,3556 trên FD002, 28,3255 trên FD003 và 27,2218 trên FD004. Đây là trường hợp train và test cùng subset.

Sau đó, em giữ model fit trên toàn bộ train FD001 và áp dụng trực tiếp sang test subset khác. MAE tăng lên 60,3215 trên FD002, 47,3949 trên FD003 và 58,5731 trên FD004. Kết quả cho thấy operating-condition shift và fault-mode shift làm giảm khả năng chuyển model.

Kết luận thực tế của thí nghiệm là model FD001 không nên dùng trực tiếp cho FD002–FD004 nếu chưa retraining hoặc domain adaptation. Đây là negative result nhưng có giá trị vì nó trả lời trực tiếp câu hỏi model có tổng quát sang dataset khác hay không.

Kết thúc

Em xin cảm ơn thầy/cô và các bạn đã chú ý lắng nghe. Em xin sẵn sàng nhận câu hỏi phản biện.

Câu hỏi phản biện thường gặp

1. Vì sao chia GroupKFold theo engine? Vì các window trong cùng engine có phụ thuộc thời gian. Nếu chia ngẫu nhiên theo row, window rất gần nhau có thể nằm ở cả train và validation, làm metric lạc quan. GroupKFold bảo đảm một engine chỉ thuộc một fold validation.

2. Có data leakage không? Pipeline không dùng tương lai trong trailing window, giữ mọi window của engine trong cùng fold và chỉ đọc test labels sau khi final predictions đã được ghi.

3. Vì sao không áp dụng model FD001 trực tiếp cho FD002–FD004? Kết quả transfer cho thấy MAE tăng từ khoảng 22–28 cycles trong evaluation nội bộ lên 47–60 cycles khi giữ model FD001 cố định. Dataset shift làm model mất độ chính xác, nên cần retraining hoặc domain adaptation.

4. Vì sao window 10 và window 30 không so trực tiếp? Window 30 cung cấp lịch sử dài hơn và là protocol chính của FD001. Window 10 được dùng để mọi subset đều có đủ test windows, đặc biệt FD004. Thay đổi window làm thay đổi input và metric.

5. ARIMA có dự báo RUL không? Không. ARIMA forecast Health Index chuẩn hóa từ PCA. Health Index không phải countdown RUL và chỉ là phân tích phụ.

6. Kết quả có áp dụng cho động cơ thực tế không? Chưa thể kết luận. C-MAPSS là dữ liệu mô phỏng và không có chi phí bảo trì, downtime hoặc intervention records. Cần dữ liệu thực tế và evaluation ngoài miền trước khi triển khai.

7. Big Data nằm ở đâu khi dữ liệu gốc nhỏ? Đóng góp Big Data nằm ở ETL, Parquet, parity Pandas/PySpark, provenance và thử nghiệm scale nhân tạo. Repository không tuyên bố FD001 tự thân là workload production-scale.