Dự đoán tuổi thọ còn lại và kiểm tra chuyển miền

NASA C-MAPSS FD001–FD004

Báo cáo cuối kỳ môn Phân tích dữ liệu lớn

Phan Nguyễn Mai Phương | MSHV 25002711

Bài toán nghiên cứu

Đầu vào

Chuỗi đo của 21 sensor theo từng cycle và từng engine.

Đầu ra

Remaining Useful Life (RUL): số cycle còn lại trước failure.

Ví dụ tạo nhãn train

Nếu engine kết thúc ở cycle 200 thì tại cycle 170:

$$\mathrm{RUL} = 200 - 170 = 30 \text{ cycles.}$$

Test bị cắt trước failure; nhãn test chỉ dùng sau khi ghi dự đoán cuối.

Nguồn: `report/sections/problem-data.tex;data/CONTRACTS.md`

Dữ liệu C-MAPSS và ranh giới nhãn

Subset	Train engines	Test engines	Điều kiện / fault mode
FD001	100	100	1 condition / 1 fault mode
FD002	260	259	6 conditions / 1 fault mode
FD003	100	100	1 condition / 2 fault modes
FD004	249	248	6 conditions / 2 fault modes

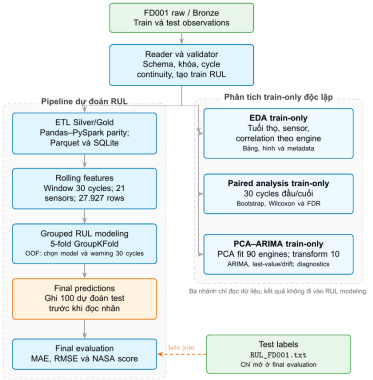
Protocol chính dùng FD001: 20.631 train observations và 13.096 test observations.

Data leakage boundary

Test labels của từng subset chỉ được đọc sau khi final predictions đã được ghi.

Nguồn: `data/raw/DATA_SOURCE.md;NASAC-MAPSSmetadata`

Quy trình xử lý dữ liệu



Raw validation → Silver/Gold ETL → rolling features → GroupKFold → final evaluation

Nguồn: `assets/diagrams/fd001-pipeline.png;outputs/modeling/tables/evaluation_protocol.csv`

Sensor thay đổi theo vòng đời

Protocol

So sánh mean của 30 cycles đầu và 30 cycles cuối trong cùng một train engine.

Bootstrap theo engine, Wilcoxon signed-rank và Benjamini–Hochberg cho 21 sensor.

Kết quả

15 sensor bác bỏ giả thuyết không sau hiệu chỉnh BH.

Kết quả mô tả thay đổi đầu/cuối vòng đời. Kết quả chưa phải bằng chứng nhân quả hoặc feature selection cho engine mới.

Nguồn: `outputs/statistics/tables/sensor_inference.csv`

Từ chuỗi sensor đến đặc trưng

Trailing window 30 cycles

Tại cycle 170, window dùng cycles 141–170 của cùng engine; không dùng quan sát tương lai.

Đặc trưng	Vai trò
Giá trị cuối	Trạng thái tại cycle hiện tại
Mean, sample standard deviation	Mức và biến thiên trong window
Min, max, linear slope	Biên và xu hướng tăng/giảm

21 sensor × 6 phép tóm tắt = 126 feature columns

Nguồn: `outputs/features/run_info.json;report/sections/methodology.tex`

Đánh giá theo engine

Giai đoạn	Dữ liệu	Mục đích
5-fold GroupKFold	100 train engines	Chọn model bằng mean engine MAE
Refit	Toàn bộ train	Tạo model cuối
Final test	100 test engines	Một dự đoán tại cycle cuối mỗi engine

Vì sao chia theo engine?

Các window trong cùng engine có phụ thuộc thời gian. Chia ngẫu nhiên theo row có thể đưa window gần nhau vào cả train và validation, làm metric lạc quan.

Nguồn: `outputs/modeling/tables/evaluation_protocol.csv`

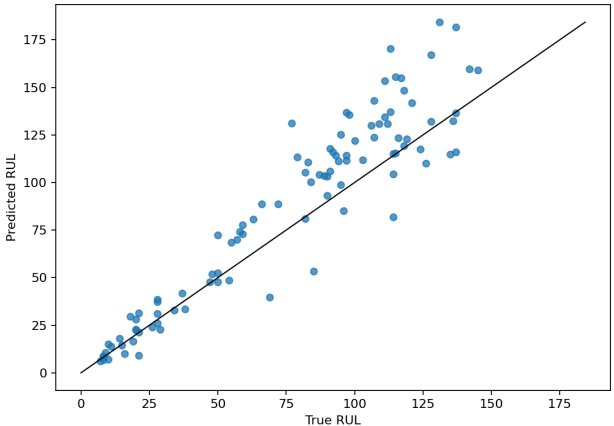
Lựa chọn model

Model	Mean engine MAE	Vai trò
Median baseline	46,9543	Mốc dự đoán hằng
Ridge	23,9922	Quan hệ tuyến tính
HistGradientBoosting	20,2143	Được chọn

HistGradientBoosting được chọn vì có MAE thấp nhất trong ba ứng viên và trong protocol cross-validation đã định trước.

Nguồn: `outputs/modeling/tables/model_metrics.csv`

Kết quả chính trên FD001



MAE 15,3490 cycles

RMSE 20,5413 cycles

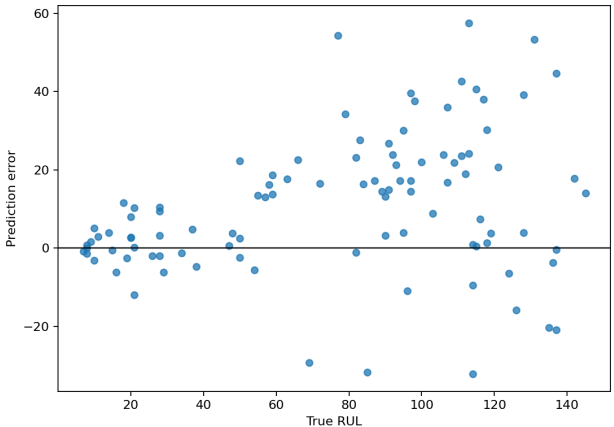
NASA score 1.513,2577

CI 95% của MAE: [12,7286; 18,0866].

Kết quả chính dùng window 30 cycles trên 100 FD001 test engines.

Nguồn: `outputs/modeling/tables/final_metrics.json`

Phân tích lỗi



74 dự đoán cao hơn RUL thật; 26 dự đoán thấp hơn.

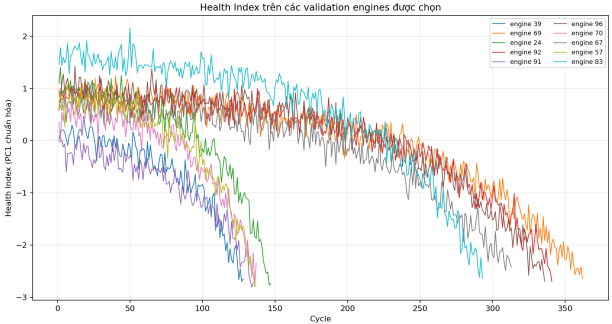
Trường hợp sai lớn

Engine 23: RUL thật 113; dự đoán 170,4768; absolute error 57,4768 cycles.

Metric trung bình không thay thế việc xem các failure case.

Nguồn: `outputs/modeling/figures/final_residuals_by_rul.png`

Phân tích phụ: Health Index và ARIMA



Dự báo	MAE	RMSE
ARIMA	0,4110	0,5027
Drift	0,7469	0,9128
Last-value	0,9478	1,1553

ARIMA forecast Health Index, không phải RUL. Coverage prediction interval thay đổi từ 21,43% đến 97,03%.

Nguồn: `outputs/timeseries/tables/baseline_metrics.csv;outputs/timeseries/tables/forecast_metrics.csv`

Cảnh báo sớm từ RUL dự đoán

Ngưỡng cảnh báo cố định: $\mathrm{RUL} \leq 30$ cycles trên selected-model OOF train.

Timing	Số engine
Trước ngưỡng	44
Đúng ngưỡng	7
Sau ngưỡng nhưng trước failure	49

Lead time có trung vị 30 cycles, miền 19–55 cycles. OOF đã dùng để chọn model, nên đây là mô tả nội bộ, chưa phải đánh giá độc lập về utility bảo trì.

Nguồn: `outputs/modeling/tables/warning_summary.json`

ETL và khả năng tái lập

Parity ETL

Pandas và PySpark khớp tại ba boundary Silver/Gold; sai khác tuyệt đối lớn nhất bằng 0.

Benchmark

Benchmark runtime chỉ đo Pandas in-memory trên dữ liệu nhân bản; chưa phải benchmark cluster.

Kiểm chứng

Full test suite hiện tại đạt 154 tests. Artifact lưu config, raw hash, metric và provenance.

Nguồn: `outputs/etl/parity.json;outputs/etl/benchmark.json`

Kết luận và giới hạn

Kết quả chính

HistGradientBoosting đạt MAE 15,3490 cycles trên FD001 với window 30.

Giới hạn

FD001 là dữ liệu mô phỏng; test đánh giá một điểm cắt mỗi engine; warning OOF chưa độc lập với model selection; không có cost, downtime hoặc intervention records.

Bước tiếp theo

Retraining hoặc domain adaptation cho subset mới, sau đó đánh giá warning bằng outer split theo engine.

Nguồn: `report/sections/conclusion.tex;outputs/cross_dataset/matrix.json`

Transfer giữa các subset C-MAPSS

Ma trận bổ sung dùng window 10 cycles vì test FD004 có engine ngắn nhất 19 cycles.

Train → Test	Loại	MAE	RMSE
FD001 → FD001	Nội bộ	21,9258	29,5936
FD002 → FD002	Nội bộ	22,3556	31,3077
FD003 → FD003	Nội bộ	28,3255	41,7606
FD004 → FD004	Nội bộ	27,2218	36,9311
FD001 → FD002	Transfer	60,3215	70,4603
FD001 → FD003	Transfer	47,3949	59,2140
FD001 → FD004	Transfer	58,5731	69,8148

Model fit trên FD001 không nên dùng trực tiếp cho subset khác nếu chưa retraining hoặc domain adaptation. Metric chính FD001 trên các slide trước dùng window 30, nên không so trực tiếp với ma trận window 10.

Nguồn: `outputs/cross_dataset/matrix.json;outputs/cross_dataset/README.md`