TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP. HỒ CHÍ MINH

# BÁO CÁO CUỐI KỲ

Môn học: Phân tích dữ liệu lớn

# Phân tích dữ liệu cảm biến, dự đoán RUL và cảnh báo sớm

NASA C-MAPSS FD001–FD004

Đề tài 8: Phân tích dữ liệu IoT và bảo trì dự đoán


| | |
|---|---|
| Học viên thực hiện: | Phan Nguyễn Mai Phương |
| Mã số học viên: | 25002711 |
| Ngành: | Khoa học máy tính |


TP. Hồ Chí Minh, tháng 9 năm 2026

# Tóm tắt

Báo cáo nghiên cứu một pipeline phân tích dữ liệu cảm biến và ước lượng Remaining Useful Life (RUL, tuổi thọ hữu ích còn lại) trên bộ dữ liệu mô phỏng NASA C-MAPSS FD001–FD004, trong đó FD001 là subset chính cho phân tích chi tiết. Mục tiêu là kiểm tra tính hợp lệ của dữ liệu, xây dựng biểu diễn trailing window, đánh giá mô hình hồi quy theo đơn vị động cơ và mô tả diễn biến cảm biến bằng phân tích thống kê cùng PCA–ARIMA. Phương pháp gồm kiểm tra data contract, ETL qua các lớp Silver/Gold, tạo đặc trưng từ window 30 cycles, GroupKFold theo engine và đánh giá cuối trên 100 test engines của FD001. Mô hình HistGradientBoosting đạt mean engine-level MAE bằng 15,3490 cycles, RMSE bằng 20,5413 cycles và NASA score bằng 1.513,2577 trong evaluation protocol được xác định trước. Phân tích PCA–ARIMA tạo 704 dự báo Health Index trên 10 engine train được chọn trước; phân tích này được xem là nhánh phụ và không phải mô hình dự báo RUL. Với đầu ra cảnh báo sớm minh họa, ngưỡng cố định RUL $\leq 30$ cycles trên OOF train tạo cảnh báo ở 100/100 engine: 44 trước ngưỡng thật, 7 đúng ngưỡng và 49 sau ngưỡng. Lead time có trung vị 30 cycles và miền 19–55. Cùng OOF đã dùng để chọn model, nên đây là mô tả nội bộ, không phải đánh giá độc lập về hiệu quả cảnh báo hoặc lịch bảo trì tối ưu.

Thực nghiệm bổ sung dùng cùng window 10 cycles cho FD001–FD004 để giữ đủ các test engines. Với model train trên FD001 và áp dụng trực tiếp sang dataset khác, mean engine MAE lần lượt là 60,3215 cycles trên FD002, 47,3949 trên FD003 và 58,5731 trên FD004. Các giá trị này cao hơn evaluation nội bộ trên từng subset theo cùng protocol window 10, cho thấy khả năng chuyển miền của model FD001 còn hạn chế. Metric bổ sung không được so trực tiếp với kết quả chính dùng window 30 cycles.

Kết quả cho thấy pipeline có thể tái lập từ raw FD001 và ma trận bổ sung FD002–FD004 giữ nguyên ranh giới train/test trong quá trình xử lý. Tuy nhiên, FD001 chỉ đại diện cho một điều kiện vận hành và một dạng suy giảm; kết quả transfer cho thấy khác biệt giữa các subset trong môi trường mô phỏng. Vì dữ liệu không cung cấp chi phí bảo trì, downtime hoặc quy đổi cycle sang thời gian lịch, các kết quả chưa đủ để suy ra chính sách bảo trì hoặc khả năng khái quát cho động cơ thực tế.

Thực nghiệm cải thiện bổ sung dùng nested GroupKFold để so sánh window 10/20/30, 24 cấu hình HGB và ba phương án trọng số. MAE RUL thấp trên vòng đánh giá ngoài chưa giảm (3,6676 so với 3,6730 cycles), còn số cảnh báo trễ tăng từ 49 lên 53 engines. Cấu hình được chọn cuối trùng baseline, nên kết quả test giữ nguyên. Báo cáo trình bày các đánh đổi quan sát được và giữ model hiện tại theo tiêu chí đã xác định trước.

**Từ khóa:** NASA C-MAPSS FD001–FD004; RUL; early warning; rolling window; GroupKFold; ETL; Health Index; PCA–ARIMA.

# Mục lục

**Tóm tắt** i

**Bảng thuật ngữ và chữ viết tắt** iv

**1 Mở đầu: bài toán, mục tiêu và phạm vi** 1
1.1 Bài toán nghiên cứu . . . 1
1.2 Mục tiêu và câu hỏi nghiên cứu . . . 1
1.3 Đóng góp và phạm vi của báo cáo . . . 2

**2 Dữ liệu và kiểm soát chất lượng** 2
2.1 Nguồn dữ liệu và lý do lựa chọn . . . 2
2.2 Từ điển dữ liệu và ý nghĩa cột . . . 3
2.3 Hồ sơ cột trên tập train . . . 4
2.4 Đánh giá phân bố và cách xử lý dữ liệu . . . 5
2.5 Các kiểm tra đã triển khai và lý do . . . 6
2.6 Tính toàn vẹn và giới hạn của validation . . . 6

**3 Cơ sở lý thuyết và nghiên cứu liên quan** 7
3.1 Prognostics và RUL . . . 7
3.2 Định vị nghiên cứu . . . 7
3.3 Metric RUL và NASA score . . . 8
3.4 Biểu diễn chuỗi bằng trailing window . . . 8
3.5 Paired analysis, bootstrap và nhiều kiểm định . . . 9
3.6 Spark, lưu trữ và giới hạn benchmark . . . 10
3.7 Health Index và ARIMA . . . 10

**4 Thiết kế phương pháp và lý do lựa chọn** 11
4.1 Luồng xử lý . . . 11
4.2 Quan hệ dữ liệu và các phép transform . . . 13
4.3 Vai trò của thành phần Big Data . . . 14
4.4 EDA theo đơn vị động cơ . . . 14
4.5 Đặc trưng từ trailing window . . . 14
4.6 Mô hình và cấu hình đánh giá RUL . . . 15
4.7 Protocol đánh giá chuyển miền bổ sung . . . 15
4.8 Suy luận thống kê . . . 17

**5 Đọc, truy vấn và biến đổi dữ liệu** 18
5.1 Từ file raw đến observations . . . 18
5.2 Các boundary lưu trữ và truy vấn . . . 18
5.3 Transform và time window . . . 18
5.4 Chuẩn hóa và feature columns . . . 19
5.5 Quan hệ và ranh giới join . . . 19
5.6 Phạm vi Big Data . . . 20

**6 Protocol suy luận thống kê** **21**
6.1 Mục tiêu và phạm vi . . . 21
6.2 Định nghĩa cặp đầu/cuối và ví dụ . . . 21
6.3 Đại lượng cần báo cáo và điều kiện diễn giải . . . 22
6.4 Cấu hình suy luận . . . 23

**7 Kết quả và diễn giải** **25**
7.1 Kiểm tra dữ liệu . . . 25
7.2 Tuổi thọ động cơ trên train . . . 25
7.3 Sensor hằng và correlation theo engine . . . 26
7.4 Suy luận đầu/cuối vòng đời trên train . . . 27
7.5 Rolling features . . . 30
7.6 Mô hình RUL và đánh giá cuối . . . 30
7.7 Đánh giá bổ sung trên FD002–FD004 . . . 32
7.7.1 Phân tích lỗi theo engine . . . 33
7.8 Cảnh báo sớm minh họa từ OOF . . . 33
7.9 Phân tích PCA–ARIMA trên Health Index . . . 34
7.10 ETL Silver/Gold và benchmark . . . 36
7.11 Dashboard đọc kết quả . . . 37

**8 Thảo luận, giới hạn và hướng phát triển** **38**
8.1 Diễn giải các kết quả chính . . . 38
8.2 Giới hạn phương pháp . . . 39
8.3 Hướng nghiên cứu tiếp theo . . . 39

**9 Kết luận** **40**

**Tài liệu tham khảo** **41**

# Bảng thuật ngữ và chữ viết tắt

| Thuật ngữ | Ý nghĩa trong báo cáo |
|---|---|
| Remaining Useful Life (RUL) | Tuổi thọ hữu ích còn lại, tính bằng số cycle trước khi động cơ hỏng. |
| NASA C-MAPSS / FD001–FD004 | Bộ dữ liệu mô phỏng chuỗi vận hành turbofan; FD001 là subset chính, FD002–FD004 dùng cho đánh giá chuyển miền. FD001 có một điều kiện vận hành và một dạng suy giảm HPC. |
| Engine / `engine_id` | Đơn vị động cơ và ranh giới của các phép ghép cặp, window và tổng hợp. |
| Cycle | Bước vận hành rời rạc trong lịch sử một engine; không quy đổi thành giờ hoặc ngày. |
| Sensor | Kênh đo tín hiệu; mỗi subset có 21 sensor trong mỗi observation. |
| Train / test | Train có lịch sử đến khi hỏng để tạo nhãn RUL; test bị cắt trước khi hỏng và có nhãn đánh giá tách riêng. |
| Data contract | Tập điều kiện hợp lệ của schema, kiểu số, khóa duy nhất, split và cycle continuity. |
| Exploratory Data Analysis (EDA) | Phân tích khám phá phân phối, biến thiên và tín hiệu trước khi xây dựng feature. |
| Extract, Transform, Load (ETL) | Quy trình đọc, biến đổi và ghi dữ liệu qua các lớp lưu trữ. |
| Bronze / Silver / Gold | Bronze giữ raw; Silver lưu observations và train targets đã kiểm tra; Gold lưu engine summary và rolling features. |
| Trailing window | Đoạn quan sát liên tiếp gần nhất của một engine tại cycle đang xét; báo cáo dùng 30 cycles. |
| Feature | Biến được tạo từ observations; mỗi sensor có last, mean, sample standard deviation, min, max và slope. |
| Metric | Đại lượng định lượng dùng để đánh giá hoặc so sánh kết quả, chẳng hạn MAE, RMSE và NASA score. |
| Artifact | Tệp kết quả có schema và metadata được ghi ra để đọc lại, kiểm tra hoặc tái lập. |
| Provenance | Thông tin truy nguyên nguồn input, cấu hình, phiên bản và trạng thái tạo artifact. |
| Parity | Đối chiếu hai implementation trên cùng input để kiểm tra schema, số dòng và giá trị kết quả. |
| Dataset shift | Khác biệt phân bố giữa các subset hoặc điều kiện dữ liệu; trong báo cáo được kiểm tra qua đánh giá transfer. |
| Estimand | Đại lượng cần ước lượng trong một phép đánh giá; cần tách rõ đơn vị phân tích, split và metric. |

Tiếp tục ở trang sau

| Thuật ngữ | Ý nghĩa trong báo cáo |
|---|---|
| Outer evaluation | Đánh giá vòng ngoài dùng để ước lượng cả quy trình chọn model, không chỉ model sau khi đã chọn. |
| Domain adaptation | Điều chỉnh mô hình hoặc biểu diễn để xử lý khác biệt giữa dữ liệu nguồn và dữ liệu đích. |
| Lead time | Số cycle báo trước theo định nghĩa cảnh báo; không tự động là thời gian bảo trì. |
| Out-of-fold (OOF) | Dự đoán của một engine được tạo khi engine đó không nằm trong phần dữ liệu dùng để huấn luyện. |
| Model selection | Quy trình chọn mô hình dựa trên metric của validation; trong báo cáo dùng mean engine-level MAE. |
| Holdout | Đoạn dữ liệu được giữ lại để đánh giá sau khi fit; PCA–ARIMA dùng 30% cuối chuỗi làm holdout. |
| Trajectory | Toàn bộ chuỗi diễn biến của một engine theo cycle; metric cuối chỉ đánh giá tại một điểm cắt. |
| Paired analysis | Ghép hai phép đo của cùng một engine; protocol dùng 30 cycles đầu và 30 cycles cuối. |
| Bootstrap | Lấy mẫu lại có hoàn lại để ước lượng độ bất định; engine là đơn vị lấy mẫu. |
| Wilcoxon signed-rank test | Kiểm định phi tham số cho dữ liệu ghép cặp dựa trên thứ hạng và dấu chênh lệch. |
| Benjamini–Hochberg FDR | Hiệu chỉnh nhiều p-value trong họ 21 sensor để kiểm soát False Discovery Rate. |
| Parquet / SQLite | Parquet lưu bảng phân tích; SQLite cung cấp lớp truy vấn local cho engine summary. |
| Spark / PySpark | Framework xử lý dữ liệu phân tán và API Python dùng để đối chiếu ETL với Pandas. |
| Health Index | Điểm tổng hợp PC1 sau chuẩn hóa 21 sensor; dùng để mô tả diễn biến sensor và không phải RUL. |
| Principal Component Analysis (PCA) | Phương pháp giảm chiều tuyến tính; báo cáo dùng PC1 để tạo Health Index từ train sensor. |
| ARIMA | Mô hình chuỗi thời gian tự hồi quy tích hợp trung bình trượt, dùng như phân tích phụ trên Health Index. |
| Augmented Dickey–Fuller (ADF) | Kiểm định nghiệm đơn vị, được dùng để đánh giá bằng chứng về tính dừng của đoạn huấn luyện Health Index. |
| Ljung–Box | Kiểm định chẩn đoán tự tương quan của residual sau khi fit ARIMA. |

# Danh mục hình

1 Luồng xử lý dữ liệu đã thực hiện . . . 12
2 Protocol thống kê đầu/cuối vòng đời . . . 22
3 Phân phối tuổi thọ động cơ trên train . . . 25
4 Phân phối correlation Spearman sensor–RUL theo động cơ . . . 26
5 Phân phối chênh lệch sensor đầu/cuối theo engine . . . 28
6 Chênh lệch cặp trung bình và khoảng tin cậy bootstrap . . . 29
7 RUL thật và RUL dự đoán trên test . . . 31
8 Sai số dự đoán theo RUL thật . . . 32
9 Ví dụ cảnh báo sớm trên OOF train . . . 34
10 Dự báo Health Index trên 10 engine . . . 36

# Danh mục bảng

2 Quy mô các subset C-MAPSS đã ghi nhận trong artifact validation. . . . 3
3 Data dictionary của FD001 trong repository. . . . 3
4 Hồ sơ nhóm cột trên train FD001. . . . 4
5 Profile 21 sensor trên train FD001. . . . 5
6 Đặc điểm phân bố dữ liệu và cách xử lý. . . . 6
7 Định vị báo cáo so với một số nguồn tham khảo. . . . 7
8 Công cụ và đầu ra tại từng bước xử lý . . . 13
9 Cấu hình mô hình và evaluation protocol. . . . 16
10 Quan hệ dữ liệu đã triển khai trong một subset . . . 19
11 Thống kê tuổi thọ của 100 động cơ train . . . 25
12 Correlation Spearman theo engine: các dòng minh họa . . . 26
13 Ví dụ kết quả suy luận sensor đầu/cuối . . . 27
14 Rolling features theo split . . . 30
15 Cross-validation mô hình RUL . . . 30
16 Metric cuối trên NASA test FD001 . . . 31
17 Đánh giá nội bộ và transfer trên C-MAPSS . . . 33
18 Năm test engine có absolute error lớn nhất. . . . 33
19 Phân phối lead time tại cảnh báo đầu tiên trên 100 engine OOF train, đơn vị cycles. 34
20 Kết quả dự báo Health Index theo engine . . . 35
21 Benchmark Pandas tạo engine summary . . . 36

# 1 Mở đầu: bài toán, mục tiêu và phạm vi

## 1.1 Bài toán nghiên cứu

Báo cáo xem bài toán dự báo RUL là một bài toán supervised regression trên chuỗi cảm biến động cơ. Tại cycle $t$, mô hình chỉ được phép sử dụng các quan sát đã xuất hiện đến cycle đó; biến mục tiêu là số cycle còn lại trước khi động cơ hỏng. Phạm vi nghiên cứu gồm kiểm tra dữ liệu, exploratory data analysis (EDA), ETL, xây dựng rolling features, suy luận thống kê đầu/cuối vòng đời, phân tích PCA–ARIMA trên Health Index và đánh giá mô hình RUL.

Đối với train, đặt $T_i$ là cycle cuối của động cơ $i$ trong lịch sử đầy đủ đến khi hỏng. Nhãn RUL được xác định bởi:

$$y_{i,t} = T_i - t, \qquad 1 \le t \le T_i. \tag{1}$$

Trong đó:

+ $i$: engine đang được xét; đây là đơn vị độc lập trong split train.
+ $t$: cycle đang xét của engine $i$, tính theo số cycle vận hành rời rạc.
+ $T_i$: cycle cuối của engine $i$ trong tập train, cũng tính bằng cycle.
+ $y_{i,t}$: RUL của engine $i$ tại cycle $t$, tính bằng cycle.

Công thức 1 được dùng vì train của các subset C-MAPSS là run-to-failure history: chuỗi train kết thúc tại thời điểm hỏng, còn mục tiêu của bộ dữ liệu là dự đoán số operational cycles còn lại trước khi hỏng [7, 10]. Đây là định nghĩa nhãn từ dữ liệu, không phải công thức dự đoán do mô hình học ra. Độ tin cậy của nhãn train phụ thuộc vào giả định của nguồn dữ liệu rằng train đã đi đến failure; vì vậy validator chỉ áp dụng công thức này cho train và không áp dụng cho test.

Ví dụ, nếu lịch sử train của một động cơ kết thúc ở cycle 200 thì nhãn tại cycle 170 là 30 cycles, còn nhãn tại cycle 200 là 0. Ví dụ này chỉ minh họa cách tạo nhãn từ lịch sử đã biết; nó không phải là một dự đoán của mô hình.

Lịch sử test bị cắt trước khi hỏng nên không được lấy cycle cuối quan sát của test làm $T_i$. Mục tiêu đánh giá cuối là một dự đoán tại cycle cuối quan sát cho mỗi test engine. Bộ nhãn chính thức được tách khỏi quá trình lựa chọn mô hình.

## 1.2 Mục tiêu và câu hỏi nghiên cứu

Mục tiêu tổng quát là xây dựng và kiểm chứng một quy trình tái lập để chuyển dữ liệu cảm biến NASA C-MAPSS, lấy FD001 làm subset chính và dùng FD002–FD004 cho đánh giá bổ sung, thành dữ liệu phân tích và kết quả RUL có thể truy ngược về nguồn dữ liệu. Mục tiêu cụ thể gồm:

1. kiểm tra data contract và mô tả cấu trúc, chất lượng của FD001–FD004;
2. xây dựng ETL cùng trailing features mà không làm rò rỉ thông tin từ cycle tương lai;
3. so sánh một số mô hình hồi quy bằng GroupKFold theo engine và đánh giá mô hình được

chọn trên test set theo cùng evaluation protocol;

4. mô tả thay đổi của sensor giữa đầu và cuối vòng đời, đồng thời khảo sát Health Index bằng PCA–ARIMA như một phân tích phụ.
5. chuyển OOF prediction thành cảnh báo RUL thấp theo engine với ngưỡng được khai báo trước, đồng thời ghi lead time và giới hạn diễn giải.

Từ các mục tiêu trên, báo cáo trả lời năm câu hỏi chính: (i) dữ liệu có đáp ứng contract để phân tích hay không; (ii) các sensor biến đổi như thế nào giữa hai đoạn đầu/cuối vòng đời; (iii) ETL Pandas và PySpark có cho kết quả tương đương trên cùng input hay không; và (iv) trailing window 30 cycles cùng mô hình được chọn cho kết quả RUL nào trong protocol đánh giá theo engine; (v) OOF prediction có thể tạo cảnh báo RUL thấp minh bạch đến mức nào khi ngưỡng được cố định trước. Một câu hỏi bổ sung là model fit trên FD001 chuyển sang FD002–FD004 như thế nào khi dùng protocol window 10 cycles chung.

### 1.3 Đóng góp và phạm vi của báo cáo

Đóng góp chính của báo cáo là một quy trình có ranh giới dữ liệu rõ ràng: raw được giữ bất biến, các bước train-only được tách khỏi đánh giá test, và nhãn test chỉ được ghép sau khi đã ghi final predictions. Báo cáo mô tả rõ các bước kiểm tra và điều kiện tái lập để người đọc đối chiếu từng kết quả với nguồn tương ứng. Các đóng góp này nhằm bảo đảm tính minh bạch của quy trình; chúng không được diễn giải thành bằng chứng rằng mô hình đã sẵn sàng triển khai ngoài môi trường mô phỏng.

Các subset C-MAPSS không cung cấp chi phí bảo trì, downtime hoặc lịch can thiệp. Vì vậy, RUL chỉ là mục tiêu dự báo trong đơn vị cycle, chưa phải quyết định thời điểm bảo trì. Cycle cũng không được chuyển sang giờ hoặc ngày vì không có thông tin quy đổi tương ứng.

## 2 Dữ liệu và kiểm soát chất lượng

### 2.1 Nguồn dữ liệu và lý do lựa chọn

NASA C-MAPSS mô phỏng các chuỗi vận hành đến khi hỏng của động cơ turbofan. Nguồn dữ liệu được ghi nhận tại NASA Open Data [7]; tài liệu nền tảng đi kèm bộ dữ liệu là công trình của Saxena và cộng sự [10]. FD001 có một điều kiện vận hành và một dạng suy giảm High-Pressure Compressor (HPC, máy nén áp suất cao); FD002–FD004 mở rộng điều kiện vận hành và dạng lỗi để kiểm tra khác biệt phân bố giữa các subset.

FD001 được chọn làm tập chính vì có lịch sử train đầy đủ đến khi hỏng, test bị cắt và nhãn đánh giá tách riêng, phù hợp với cách xây dựng bài toán RUL. Tập trung vào một subset giúp kiểm soát phạm vi phân tích chính và làm rõ từng bước xử lý. FD002–FD004 được dùng riêng trong thực nghiệm bổ sung để kiểm tra khả năng chuyển miền của model FD001; cả bốn subset đều là dữ liệu mô phỏng, nên kết quả chưa cho phép khẳng định hiệu quả trên động cơ thực tế.

**Bảng 2:** Quy mô các subset C-MAPSS đã ghi nhận trong artifact validation.

| Subset | Train | Test | Train engines | Test engines | Test labels |
|---|---|---|---|---|---|
| FD001 | 20.631 | 13.096 | 100 | 100 | 100 |
| FD002 | 53.759 | 33.991 | 260 | 259 | 259 |
| FD003 | 24.720 | 16.596 | 100 | 100 | 100 |
| FD004 | 61.249 | 41.214 | 249 | 248 | 248 |

Mỗi dòng raw của cả bốn subset có 26 trường: engine ID, cycle, 3 operational settings và 21 sensors. Reader bổ sung cột `split`, tạo bảng observations có 27 cột. Khóa là bộ ba (`split, engine_id, cycle`): train engine 1 và test engine 1 không phải cùng một thực thể. Nhãn test chỉ được kiểm tra cấu trúc riêng trong báo cáo integrity; việc này không phải đánh giá mô hình.

## 2.2 Từ điển dữ liệu và ý nghĩa cột

Dữ liệu train/test gốc không có header; tên cột trong báo cáo được đặt theo contract của repository. Bảng 3 mô tả vai trò từng nhóm cột và cách sử dụng trong phân tích. Nguồn NASA chỉ mô tả các trường sensor là "sensor measurement", không cung cấp tên vật lý, đơn vị đo hoặc mapping chi tiết cho từng sensor. Vì vậy, báo cáo giữ tên `sensor_1` đến `sensor_21`; không tự diễn giải một sensor cụ thể là nhiệt độ, áp suất hoặc tốc độ nếu chưa có nguồn xác nhận.

**Bảng 3:** Data dictionary của FD001 trong repository.

| Cột hoặc nhóm cột | Ý nghĩa | Kiểu/miền đã kiểm tra | Vai trò trong báo cáo |
|---|---|---|---|
| `split` | Cột do reader bổ sung để phân biệt nguồn dữ liệu. | Chuỗi `train` hoặc `test`. | Giữ ranh giới train/test trong khóa dữ liệu và validation; không có trong raw text gốc. |
| `engine_id` | Mã chuỗi động cơ trong từng split. | Số nguyên dương; FD001 có engine ID 1–100 ở cả train và test. | Đơn vị độc lập cho tuổi thọ, ghép cặp đầu/cuối, GroupKFold và đánh giá theo engine. |
| `cycle` | Thứ tự vận hành rời rạc của một engine. | Số nguyên dương, bắt đầu từ 1 và liên tục trong từng engine. | Trục thời gian rời rạc; dùng để tạo RUL train, window 30 cycles và phân tích đầu/cuối vòng đời. |
| `setting_1`–`setting_3` | Ba operational settings ảnh hưởng đến điều kiện vận hành. | `float64`; trên train, `setting_3` hằng ở 100. | Biến bối cảnh vận hành; không thuộc nhóm sensor được phân tích thống kê. |
| `sensor_1`–`sensor_21` | Hai mươi mốt phép đo sensor trong mỗi cycle. | `float64` hữu hạn; không có missing trong train. | Nguồn tín hiệu chính cho EDA, paired analysis và feature engineering. |

| Cột hoặc nhóm cột | Ý nghĩa | Kiểu/miền đã kiểm tra | Vai trò trong báo cáo |
|---|---|---|---|
| `rul` trong train targets | Nhãn RUL được suy ra từ lịch sử train đầy đủ đến khi hỏng. | Số nguyên không âm; trên train hiện có miền 0–361 cycles. | Biến mục tiêu cho supervised regression; không phải cột raw. |
| `RUL_FD001.txt` | Nhãn RUL chính thức tại cycle cuối quan sát của mỗi engine test. | 100 số nguyên không âm, ánh xạ dòng $i$ sang test engine $i$. | Chỉ được ghép sau khi đã tạo 100 dự đoán test cuối cùng; không dùng trong EDA hoặc model selection. |

Nhãn kết cục của bài toán là RUL, tức số cycle còn lại trước khi engine hỏng. Trong train, nhãn được suy ra từ cycle cuối của từng chuỗi; trong test, nhãn chỉ có tại cycle cuối quan sát và nằm trong file riêng `RUL_FD001.txt`. Do đó, mỗi dòng train có thể có một nhãn RUL, còn mỗi engine test chỉ có một nhãn đánh giá cuối. Báo cáo không chuyển RUL thành nhãn phân loại hỏng/không hỏng vì nguồn dữ liệu và protocol hiện tại đánh giá sai số theo số cycle.

Ví dụ đọc một dòng raw: dòng đầu tiên của `train_FD001.txt` có `engine_id=1`, `cycle=1`, ba settings lần lượt là $-0{,}0007$, $-0{,}0004$, $100{,}0$, sau đó là 21 giá trị sensor. Engine 1 trong train kết thúc ở cycle 192, nên sau khi tạo nhãn, dòng này có `rul=191`. Đây là nhãn hồi cứu của train, không phải dự đoán của mô hình.

## 2.3 Hồ sơ cột trên tập train

Bảng 4 tóm tắt các nhóm cột sau khi ghép RUL train. Các thống kê dùng để mô tả cấu trúc dữ liệu trước khi xây feature, không phải bằng chứng về hiệu quả dự đoán.

**Bảng 4:** Hồ sơ nhóm cột trên train FD001.

| Nhóm cột | Số cột | Missing | Nhận xét chính |
|---|---|---|---|
| Khóa `engine_id`, `cycle` | 2 | 0 | 20.631 quan sát, 100 engine; không có khóa trùng, cycle liên tục trong từng engine. |
| Operational settings | 3 | 0 | `setting_1` có 158 giá trị khác nhau, `setting_2` có 13 giá trị, `setting_3` hằng bằng 100. |
| Sensors | 21 | 0 | Sáu sensor hằng toàn train; `sensor_6` chỉ có hai giá trị và hằng trong 38 engine. |
| Nhãn `rul` train | 1 | 0 | Miền 0–361 cycles; trung vị theo observation là 103 cycles. |

**Bảng 5:** Profile 21 sensor trên train FD001.

| Sensor | Số giá trị khác nhau | Min–max | Ghi chú |
|---|---|---|---|
| sensor_1 | 1 | 518,67–518,67 | Hằng toàn train. |
| sensor_2 | 310 | 641,21–644,53 | Biến thiên trên train. |
| sensor_3 | 3.012 | 1.571,04–1.616,91 | Biến thiên trên train. |
| sensor_4 | 4.051 | 1.382,25–1.441,49 | Biến thiên trên train; có chênh lệch đầu/cuối lớn. |
| sensor_5 | 1 | 14,62–14,62 | Hằng toàn train. |
| sensor_6 | 2 | 21,60–21,61 | Biến thiên toàn train nhưng hằng trong 38/100 engine. |
| sensor_7 | 513 | 549,85–556,06 | Biến thiên trên train. |
| sensor_8 | 53 | 2.387,90–2.388,56 | Biến thiên thấp, nhưng không hằng. |
| sensor_9 | 6.403 | 9.021,73–9.244,59 | Biến thiên mạnh; phân phối theo engine không đồng nhất hoàn toàn. |
| sensor_10 | 1 | 1,30–1,30 | Hằng toàn train. |
| sensor_11 | 159 | 46,85–48,53 | Biến thiên; Spearman median với RUL âm trong EDA. |
| sensor_12 | 427 | 518,69–523,38 | Biến thiên; Spearman median với RUL dương trong EDA. |
| sensor_13 | 56 | 2.387,88–2.388,56 | Biến thiên thấp, nhưng không hằng. |
| sensor_14 | 6.078 | 8.099,94–8.293,72 | Biến thiên mạnh theo giá trị gốc. |
| sensor_15 | 1.918 | 8,3249–8,5848 | Biến thiên trên train. |
| sensor_16 | 1 | 0,03–0,03 | Hằng toàn train. |
| sensor_17 | 13 | 388–400 | Biến thiên rời rạc trên train. |
| sensor_18 | 1 | 2.388–2.388 | Hằng toàn train. |
| sensor_19 | 1 | 100–100 | Hằng toàn train. |
| sensor_20 | 120 | 38,14–39,43 | Biến thiên trên train. |
| sensor_21 | 4.745 | 22,8942–23,6184 | Biến thiên trên train. |

Các cột hằng toàn train không có correlation Spearman xác định với RUL và không thể tạo chênh lệch đầu/cuối khác 0 trong paired analysis. Báo cáo vẫn giữ chúng trong bảng thống kê để thể hiện đầy đủ phạm vi 21 sensor.

## 2.4 Đánh giá phân bố và cách xử lý dữ liệu

Dữ liệu FD001 tương đối sạch về mặt schema: không có missing trong các cột đã đọc, khóa `(split, engine_id, cycle)` không trùng và cycle liên tục trong từng engine. Tuy nhiên, dữ liệu không hoàn toàn thuận lợi cho mọi phân tích: độ dài chuỗi giữa các engine khác nhau, sáu sensor hằng trên toàn train, một số sensor có rất ít mức giá trị, và tài liệu gốc không cung cấp đơn vị vật lý cho từng sensor. Bảng 6 tóm tắt các điểm này và cách xử lý trong báo cáo.

**Bảng 6:** Đặc điểm phân bố dữ liệu và cách xử lý.

| Đặc điểm | Ý nghĩa | Cách xử lý trong báo cáo |
|---|---|---|
| Không có missing và khóa hợp lệ | Dữ liệu đủ sạch để tạo EDA, ETL và đặc trưng mà không cần impute. | Không tự điền dữ liệu; validator dừng khi schema, khóa hoặc cycle continuity sai. |
| Độ dài chuỗi khác nhau giữa engine | Engine sống lâu tạo nhiều observations và nhiều rolling windows hơn. | Báo cáo tách thống kê theo observation và theo engine; cross-validation và metric chính dùng engine làm đơn vị. |
| Sensor hằng hoặc ít biến thiên | Một số correlation hoặc kiểm định không xác định; sensor hằng không tạo chênh lệch đầu/cuối. | Giữ đủ 21 sensor trong bảng, gắn trạng thái không xác định hoặc all-zero; không xóa sensor chỉ để làm kết quả đẹp hơn. |
| Không có đơn vị vật lý cho sensor | Không thể diễn giải `sensor_k` là nhiệt độ, áp suất hoặc tốc độ cụ thể. | Dùng tên ẩn danh `sensor_1`– `sensor_21`; mọi chênh lệch được hiểu theo đơn vị gốc của sensor đó. |
| Test labels tách riêng | Nếu đọc nhãn test trước khi chọn mô hình sẽ gây data leakage. | Chỉ ghép `RUL_FD001.txt` sau khi đã ghi final predictions. |

## 2.5 Các kiểm tra đã triển khai và lý do

Reader và validator thực hiện kiểm tra số trường, schema, kiểu số hữu hạn, bảng không rỗng, split hợp lệ, khóa duy nhất và cycle liên tục trong từng động cơ. Profile FD001 đối chiếu thêm số dòng, ID động cơ và cycle bắt đầu. Với train targets, validator kiểm tra đủ khóa và đối chiếu Công thức 1.

Các kiểm tra được đặt trước EDA vì dữ liệu sai có thể tạo ra thống kê hợp lệ về mặt tính toán nhưng sai về ý nghĩa. Chẳng hạn, chuỗi cycle $1, 2, 4$ không được coi là ba bước liên tiếp khi xây window. Hai dòng cùng khóa cũng không được giữ lại như hai phép đo độc lập. Khi phát hiện lỗi, package báo `ContractError`; không tự điền dữ liệu, xóa dòng hoặc chỉnh raw để làm validation đạt.

## 2.6 Tính toàn vẹn và giới hạn của validation

Báo cáo JSON lưu SHA-256 của input để nhận biết phiên bản dữ liệu đã đọc. Dấu vân tay này chỉ hỗ trợ đối chiếu; tự tính checksum không chứng minh nguồn gốc file là chính xác. Việc kiểm tra row count và cycle continuity cũng không đủ phát hiện mọi thay đổi giá trị sensor.

Đặc biệt, một chuỗi train bị cắt đuôi nhưng vẫn liên tục có thể tạo ra RUL sai nếu bị hiểu nhầm là lịch sử đầy đủ. Vì vậy, raw được giữ bất biến, nguồn dữ liệu được ghi nhận và test labels được tách khỏi các phân tích train.

# 3 Cơ sở lý thuyết và nghiên cứu liên quan

## 3.1 Prognostics và RUL

Prognostics nghiên cứu diễn biến suy giảm của một hệ thống và thời gian còn lại trước khi hệ thống đạt trạng thái hỏng. Trong C-MAPSS, chuỗi train của mỗi subset kết thúc tại failure nên có thể dùng để suy ra nhãn RUL; chuỗi test bị cắt trước failure và chỉ có nhãn đánh giá ở cycle cuối quan sát. Saxena và cộng sự mô tả cơ chế mô phỏng suy giảm và bài toán đánh giá prognostics [10]. Ramasso và Saxena chỉ ra rằng kết quả trên C-MAPSS phụ thuộc mạnh vào subset dữ liệu và evaluation protocol [8]; đây là lý do báo cáo giữ FD001 làm subset chính và đánh giá FD002–FD004 bằng một ma trận protocol riêng.

## 3.2 Định vị nghiên cứu

Các nghiên cứu về RUL thường sử dụng feature engineering, mô hình hồi quy hoặc deep learning để ánh xạ lịch sử cảm biến thành thời gian còn lại [5, 6, 18]. Báo cáo này tập trung vào một pipeline có thể kiểm tra ở từng ranh giới dữ liệu: contract được kiểm tra trước EDA, feature chỉ dùng lịch sử đến cycle hiện tại, và GroupKFold giữ toàn bộ window của một engine trong cùng một fold. Vì mục tiêu của môn học là phân tích dữ liệu lớn có khả năng tái lập, phần triển khai nhấn mạnh nguồn gốc dữ liệu và đối chiếu kết quả ETL; mô hình được dùng để đánh giá pipeline trên FD001 và kiểm tra chuyển miền, không phải để tuyên bố trạng thái tiên tiến của bài toán RUL.

**Bảng 7:** Định vị báo cáo so với một số nguồn tham khảo.

| Nguồn | Phạm vi | Hướng tiếp cận | Liên hệ với báo cáo |
|---|---|---|---|
| Saxena và cộng sự [10] | Mô phỏng suy giảm động cơ run-to-failure | Cơ sở dữ liệu và bài toán prognostics | Nguồn nền cho cách hiểu FD001 và nhãn RUL. |
| Ramasso và Saxena [8] | Các thuật toán trên C-MAPSS | Tổng quan và phân tích protocol | Cơ sở để giữ rõ subset, split và metric. |
| Lei và cộng sự [5] | Tổng quan machinery prognostics | Từ thu nhận dữ liệu đến RUL prediction | Đặt pipeline của báo cáo trong bối cảnh rộng hơn. |
| Li và cộng sự [6] | RUL estimation | Deep convolutional neural network và biểu diễn window | Nguồn đối chiếu độ dài window; báo cáo dùng feature-based model đơn giản hơn. |
| Zheng và cộng sự [18] | RUL estimation | Long Short-Term Memory network | Cho thấy một hướng deep learning khác; không được tái lập trong phạm vi hiện tại. |
| Saxena và cộng sự [9] | Offline prognostic evaluation | Metric và cách đánh giá | Cơ sở để phân biệt điểm cắt với toàn bộ trajectory. |

Một dự đoán tại cycle cuối của mỗi test engine chỉ đo chất lượng tại điểm cắt, không đại

diện cho sai số trên toàn bộ trajectory [9]. Các subset C-MAPSS cũng không có chi phí can thiệp hoặc downtime, nên RUL không trực tiếp xác định lịch bảo trì tối ưu.

Điểm khác biệt trong thiết kế thực nghiệm ở đây là cách biểu diễn dữ liệu và phạm vi kết luận. Thay vì tái lập neural network của các nghiên cứu trong Bảng 7, báo cáo cố định 126 đặc trưng tổng hợp từ window 30 cycles và so sánh baseline hằng, tuyến tính, phi tuyến. Cách làm này cho phép kiểm tra lợi ích của model trong cùng split, nhưng chưa trả lời liệu representation học trực tiếp từ chuỗi có tốt hơn hay không. Không xếp hạng metric của báo cáo với metric trong paper khi chưa đồng nhất target, split, preprocessing và điểm đánh giá.

## 3.3 Metric RUL và NASA score

MAE đo sai số tuyệt đối trung bình, còn RMSE tăng trọng số cho các sai số lớn. Báo cáo bổ sung NASA score để phản ánh chi phí bất đối xứng của sai số RUL. Với $e = \hat{y} - y$, score của một dự đoán được định nghĩa bởi:

$$S(e) = \begin{cases} \exp(-e/13) - 1, & e < 0, \\ \exp(e/10) - 1, & e \geq 0. \end{cases} \tag{2}$$

Trong đó $y$ là RUL thật và $\hat{y}$ là RUL dự đoán. Hai mẫu số khác nhau làm cho score phạt hai hướng sai số ở mức khác nhau; vì vậy NASA score không thể được đọc như một đơn vị cycle và chỉ có ý nghĩa khi so sánh trên cùng protocol. Trong báo cáo, cross-validation dùng tổng score trên các validation windows để so sánh ứng viên, còn metric cuối dùng 100 dự đoán tại điểm cắt của test engines.

## 3.4 Biểu diễn chuỗi bằng trailing window

Tại cycle $t$, một mẫu chỉ chứa các quan sát hiện có của cùng engine:

$$W_{i,t} = [\mathbf{x}_{i,t-w+1}, \ldots, \mathbf{x}_{i,t}]^{\mathsf{T}} \in \mathbb{R}^{w \times p}, \qquad t \geq w. \tag{3}$$

Trong đó:

+ $i$: engine đang được xét.
+ $t$: cycle cuối của window, tính bằng cycle vận hành.
+ $w$: số cycle trong window, với cấu hình hiện tại $w = 30$.
+ $p$: số sensor, với cấu hình hiện tại $p = 21$.
+ $\mathbf{x}_{i,t}$: vector sensor của engine $i$ tại cycle $t$; mỗi phần tử giữ đơn vị gốc ẩn danh của sensor tương ứng.
+ $W_{i,t}$: ma trận đầu vào có $w$ hàng và $p$ cột, tức $30 \times 21$ trong cấu hình hiện tại.

Công thức 3 là định nghĩa biểu diễn được triển khai trong báo cáo, không phải công thức dự

đoán RUL do một nguồn bên ngoài đề xuất. Độ dài 30 cycles được đối chiếu với một cấu hình window từng xuất hiện trong nghiên cứu trước, nhưng không được xem là giá trị tối ưu phổ quát [6]. Tại cycle $t$, chỉ dữ liệu quá khứ và hiện tại được phép đi vào feature; điều kiện này ngăn data leakage từ cycle tương lai. Validator kiểm tra rằng mỗi window có đủ 30 cycle liên tiếp, thuộc cùng một engine và không nối qua ranh giới engine. Chẳng hạn, mẫu tại cycle 170 dùng cycles 141–170 và không dùng cycle 171.

Mỗi sensor trong window được tóm tắt bằng giá trị cuối, mean, sample standard deviation, min, max và linear slope. Với dãy $z_1, \ldots, z_w$ của một sensor, slope được tính bởi

$$b = \frac{\sum_{k=1}^{w}(k-\bar{k})(z_k-\bar{z})}{\sum_{k=1}^{w}(k-\bar{k})^2}. \tag{4}$$

Trong đó:

+ $k$: vị trí cycle trong window, chạy từ 1 đến $w$.
+ $w$: độ dài window, hiện bằng 30 cycles.
+ $z_k$: giá trị sensor tại vị trí $k$, giữ đơn vị gốc của sensor đó.
+ $\bar{k}$: mean của các vị trí cycle trong window.
+ $\bar{z}$: mean của các giá trị sensor trong window.
+ $b$: mức thay đổi tuyến tính ước lượng trên mỗi cycle, có đơn vị "đơn vị sensor trên một cycle".

Slope trong Công thức 4 là hệ số hồi quy tuyến tính một biến theo ordinary least squares (OLS, bình phương tối thiểu thông thường) của sensor trên vị trí cycle trong window [4]. Đặc trưng này bổ sung hướng thay đổi cục bộ mà giá trị cuối và mean không thể hiện đầy đủ. Tuy nhiên, một slope có thể tái lập không đồng nghĩa với giá trị dự đoán; giá trị này chỉ được đánh giá gián tiếp qua cross-validation của mô hình.

## 3.5 Paired analysis, bootstrap và nhiều kiểm định

Paired analysis ghép hai phép đo của cùng một engine để loại bỏ một phần khác biệt nền giữa các engine. Mean paired difference mô tả mức thay đổi theo đơn vị gốc; Wilcoxon signed-rank dùng thứ hạng và dấu của chênh lệch để kiểm định trung vị chênh lệch bằng 0 dưới giả định phân phối chênh lệch đối xứng [16, 14]. Do đó, Wilcoxon không phải là kiểm định trực tiếp cho mean paired difference.

Bootstrap lấy mẫu lại engine có hoàn lại và giữ cặp đầu/cuối cùng nhau để ước lượng độ bất định [3, 12]. Với 21 sensor, Benjamini–Hochberg điều chỉnh p-value nhằm kiểm soát False Discovery Rate (FDR, tỷ lệ phát hiện sai kỳ vọng) trong họ kiểm định đã xác định [2, 13]. Khoảng tin cậy riêng từng sensor không trở thành simultaneous interval chỉ vì p-value đã được hiệu chỉnh.

## 3.6 Spark, lưu trữ và giới hạn benchmark

RDD là abstraction nền tảng của Spark cho xử lý phân tán và khả năng phục hồi tính toán [17]. Với dữ liệu có schema, Spark SQL/DataFrame cung cấp các phép xử lý có cấu trúc [1]. Báo cáo dùng Pandas làm reference implementation và PySpark để đối chiếu kết quả ETL, không mặc định rằng Spark nhanh hơn trên FD001.

Bronze giữ dữ liệu nguồn; Silver lưu observations và train targets đã kiểm tra; Gold lưu engine summary và rolling features. Parquet phục vụ lưu bảng phân tích, SQLite phục vụ truy vấn local. Dữ liệu nhân bản chỉ dùng cho benchmark xử lý và không tăng số mẫu khoa học độc lập.

## 3.7 Health Index và ARIMA

Health Index trong báo cáo là điểm PC1 sau khi chuẩn hóa 21 sensor bằng StandardScaler và fit Principal Component Analysis (PCA, phân tích thành phần chính) trên train [11]. PCA tìm hướng tuyến tính giải thích nhiều phương sai nhất; điểm PC1 được đổi hướng theo tương quan với cycle để có quy ước giảm theo thời gian. Đây là biểu diễn tổng hợp của sensor, không phải nhãn RUL và không mang đơn vị cycle.

Với chuỗi Health Index $h_t$, ARIMA$(p, d, q)$ mô hình hóa sai phân bậc $d$ và phần tự hồi quy, trung bình trượt:

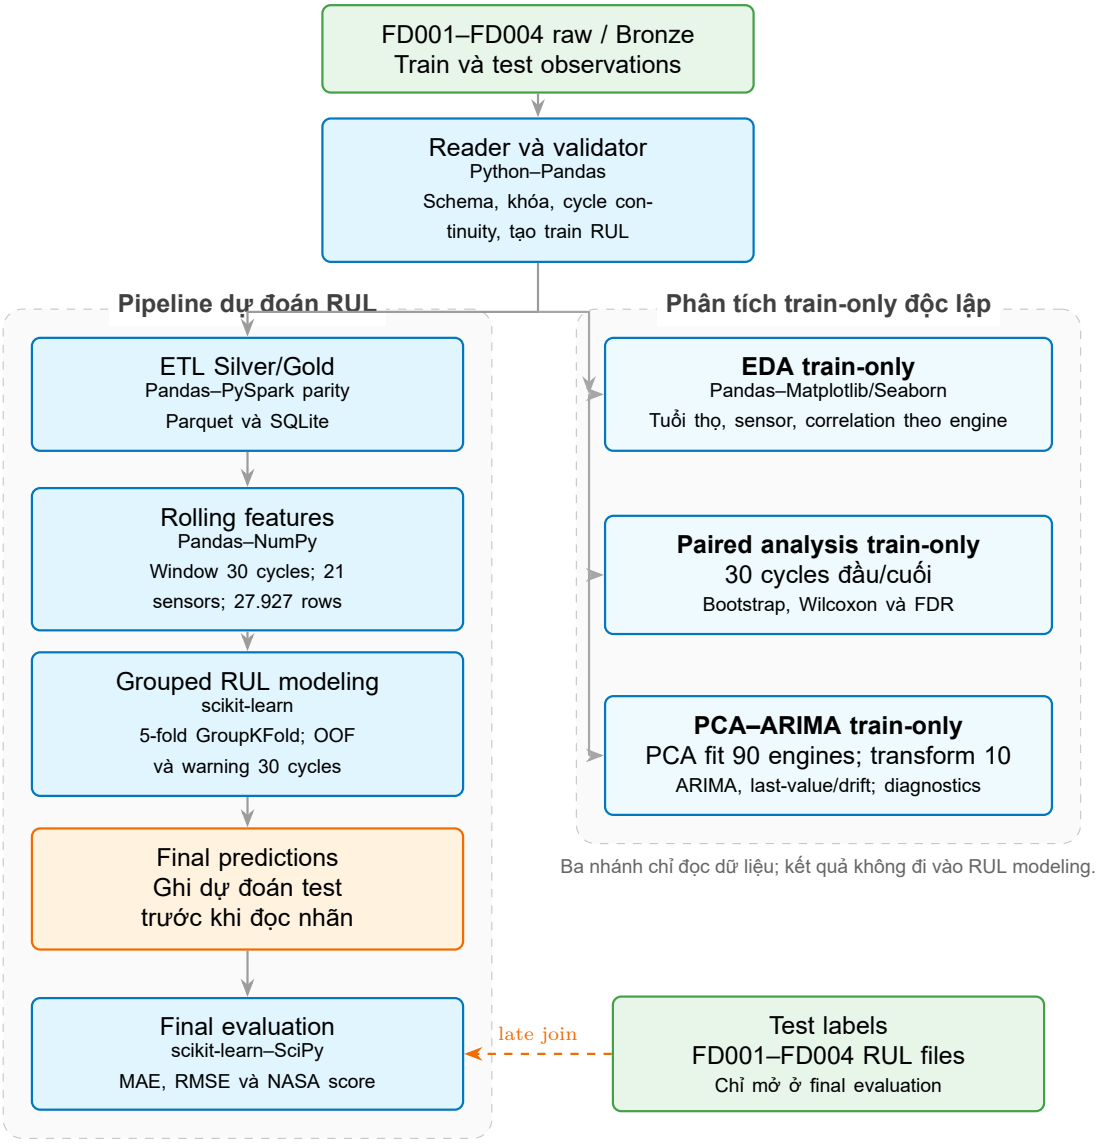
$$\phi(B)(1 - B)^d h_t = c + \theta(B)\varepsilon_t, \tag{5}$$

trong đó $B$ là toán tử trễ, $p$ và $q$ là bậc tự hồi quy và trung bình trượt, $d$ là bậc sai phân, còn $\varepsilon_t$ là phần dư [4]. Pipeline chọn order bằng AIC trên 70% đầu chuỗi của từng engine, rồi đánh giá 30% còn lại; không dùng kết quả holdout để chọn order hoặc engine. ADF được ghi để chẩn đoán tính dừng [15] và Ljung–Box để kiểm tra tự tương quan phần dư. Các chẩn đoán này chỉ mô tả độ phù hợp của dự báo Health Index trong FD001; chúng không chứng minh quan hệ nhân quả, không thay thế GroupKFold RUL model và không xác định lịch bảo trì.

# 4 Thiết kế phương pháp và lý do lựa chọn

## 4.1 Luồng xử lý

Hình 1 mô tả pipeline từ raw FD001–FD004 đến các kết quả đầu ra. Nhánh phân tích chi tiết và kết quả chính dùng FD001; ma trận transfer dùng cả bốn subset theo protocol riêng. Sau khi reader và validator kiểm tra dữ liệu, pipeline tách thành hai nhánh. Nhánh chính thực hiện ETL, xây dựng rolling features, huấn luyện và đánh giá RUL. Nhánh phụ gồm EDA, suy luận thống kê đầu/cuối và PCA–ARIMA trên Health Index; các phân tích này chỉ dùng train và không cung cấp feature cho mô hình RUL. Việc tách nhánh làm rõ dependency dữ liệu và ngăn kết quả mô tả bị hiểu nhầm là đầu vào của bước modeling.




**Hình 1:** Luồng xử lý từ dữ liệu FD001–FD004 đến EDA, suy luận thống kê, ETL, rolling features, PCA–ARIMA train-only và đánh giá RUL. Lane train-only không đi vào RUL modeling; nhãn test chỉ được ghép sau khi final predictions đã được ghi.

Dữ liệu raw được giữ bất biến. Reader và validator tạo observations cùng nhãn RUL train trong bộ nhớ; EDA và suy luận thống kê chỉ đọc phần train. ETL ghi observations và train targets vào Silver Parquet, sau đó tạo engine summary trong Gold Parquet và SQLite. Rolling features được xây dựng từ Silver observations và ghi vào Gold. Modeling ghép rolling features train với train targets, ghi final predictions cho test, rồi mới đọc nhãn test để tính metric cuối. Ranh giới này giúp kiểm tra việc mất hoặc nhân bản dòng và ngăn test labels đi vào model selection.

## 4.2 Quan hệ dữ liệu và các phép transform

Mỗi observation được định danh bởi bộ khóa $(split, engine_id, cycle)$. Một `engine_id` có nhiều cycle; tại mỗi cycle có 3 operational settings, 21 sensor readings và một nhãn RUL đối với train. Quan hệ thời gian nằm trong cùng engine: trạng thái ở cycle sau kế thừa lịch sử của các cycle trước, vì vậy không được trộn các window của cùng engine giữa train và validation.

Nhãn RUL train được tạo theo công thức $RUL_{e,t} = T_e - t$, trong đó $T_e$ là cycle cuối của engine $e$ và $t$ là cycle hiện tại. Ví dụ, nếu engine kết thúc ở cycle 200 thì observation tại cycle 170 có RUL bằng 30. Với rolling window, observation tại cycle 170 lấy 30 cycle từ 141 đến 170 của cùng engine. Sáu phép tóm tắt trên mỗi sensor (last, mean, standard deviation, min, max và slope) biến 21 cột sensor theo thời gian thành 126 feature columns. Đây là transform từ bảng quan sát dài sang bảng mẫu cho model; không phải mọi dòng sensor đều trở thành một mẫu độc lập.

Bảng 8 ghi rõ công cụ ở từng boundary. Pandas là đường tham chiếu cho reader, ETL, feature và modeling preparation; PySpark tái hiện các boundary ETL để kiểm tra khả năng chuyển sang xử lý phân tán. Parquet là định dạng lưu trữ cột cho Silver/Gold, scikit-learn thực hiện modeling, còn Matplotlib/Seaborn và Streamlit chỉ tạo đầu ra trực quan và giao diện đọc kết quả.

**Bảng 8:** Công cụ và đầu ra tại từng bước xử lý

| Bước | Công cụ | Đầu ra / vai trò |
|---|---|---|
| Đọc và kiểm tra | Python, Pandas | Schema, khóa, cycle continuity, train RUL |
| ETL Silver/Gold | Pandas, PySpark, Parquet, SQLite | Dữ liệu typed, engine summary và parity |
| Rolling features | Pandas, NumPy | Window 30 cycles, 126 features |
| Modeling | scikit-learn | GroupKFold, Ridge, HistGradientBoostingRegressor |
| Đánh giá | scikit-learn, SciPy | MAE, RMSE, NASA score, bootstrap CI |
| Trực quan hóa | Matplotlib, Seaborn | Histogram, sensor plots, error plots |
| Trình bày | Streamlit, LaTeX | Dashboard và báo cáo có thể truy vết |

PCA–ARIMA đọc cùng Silver observations nhưng chỉ giữ train. Pipeline chọn 10 engine theo fold và vị trí lifetime cách đều trước khi xem dự báo. Để giữ ranh giới đánh giá theo thời gian, StandardScaler, PCA một thành phần, hướng PC1 theo tương quan với cycle và tham số chuẩn hóa Health Index được fit trên 90 train engines còn lại; 10 engine được chọn chỉ được transform. Mỗi chuỗi được chia theo thứ tự cycle: 70% đầu dùng để huấn luyện ARIMA và 30% cuối dùng để đánh giá. Bậc ARIMA được chọn bằng grid AIC trên đoạn huấn luyện của từng engine; đầu ra gồm MAE, RMSE, tỷ lệ bao phủ của khoảng dự đoán 95%, ADF và Ljung–Box với bậc tự do điều chỉnh theo $p + q$. Dự báo Health Index chỉ mô tả diễn biến cảm biến trong train và không đọc test labels.

Pandas là implementation tham chiếu. PySpark tái hiện ba boundary và bộ đối chiếu schema, khóa, số dòng và giá trị số; sai khác tuyệt đối lớn nhất bằng 0 trong lần chạy local có JRE. Benchmark chỉ đo chi phí tạo engine summary trên dữ liệu nhân bản, vì vậy không tạo thêm engine độc lập và không được dùng để kết luận về khả năng mở rộng của hệ thống phân tán.

## 4.3 Vai trò của thành phần Big Data

FD001 có 33.727 observations sau khi ghép train và test; toàn bộ bốn subset có 265.256 observations trong các file observations. Đây vẫn chưa phải khối lượng dữ liệu đủ lớn để kết luận về tốc độ xử lý trên cụm máy. Thành phần Big Data của báo cáo được thể hiện ở ba lớp. Thứ nhất, data contract và validation kiểm soát độ tin cậy của dữ liệu trước khi dữ liệu đi vào phân tích. Thứ hai, ETL tổ chức dữ liệu qua Bronze, Silver và Gold; Parquet giữ bảng phân tích còn SQLite cung cấp truy vấn local. Thứ ba, PySpark tái hiện các boundary ETL và bộ đối chiếu kết quả với Pandas. Benchmark $1\times$, $10\times$ và $100\times$ chỉ là phép đo cục bộ trên dữ liệu nhân bản; nó minh họa cách kiểm tra chi phí theo quy mô, không thay thế thử nghiệm khả năng mở rộng trên cụm máy hoặc dữ liệu streaming.

Dashboard Streamlit chỉ đọc các kết quả modeling và PCA–ARIMA đã ghi. Loader kiểm tra sự tồn tại và schema của file trước khi dựng view; dashboard không huấn luyện lại model, không chạy lại dự báo và không mở `RUL_FD001.txt`. Các view gồm metric final evaluation, chi tiết một test engine, Health Index/ARIMA của một validation engine và nguồn gốc của hai lần chạy. Đây là lớp trình bày kết quả, không phải một bước mới trong evaluation protocol.

## 4.4 EDA theo đơn vị động cơ

EDA chỉ sử dụng train. Phân phối tuổi thọ được tính một lần cho mỗi engine, trong khi histogram RUL theo observation chịu ảnh hưởng của việc các engine có độ dài chuỗi khác nhau. Hai phép tổng hợp trả lời hai câu hỏi khác nhau và phải được diễn giải riêng.

Correlation giữa sensor và RUL được tính bằng Spearman riêng trong từng engine, sau đó tóm tắt bằng phân phối giữa các engine. Cách tính này giữ engine là đơn vị tổng hợp và tránh để chuỗi dài có trọng số quá lớn. Correlation chỉ có vai trò mô tả; nó không chứng minh quan hệ nhân quả hoặc hiệu quả dự đoán ngoài mẫu.

Sensor hằng có correlation không xác định và được giữ dưới dạng NaN. Ba động cơ minh họa được chọn gần các tứ phân vị tuổi thọ, không dựa trên hình dạng sensor; chúng không đại diện cho toàn bộ phân phối.

## 4.5 Đặc trưng từ trailing window

Biểu diễn đã triển khai là trailing window dài 30 cycles, chỉ chứa hiện tại và quá khứ của cùng một động cơ. Ví dụ, mẫu tại cycle 170 dùng cycles 141–170. Mỗi dòng được định danh bởi `(split, engine_id, cycle)`; engine có dưới 30 cycles bị loại khỏi bước tạo window, không padding hoặc rút ngắn window.

Với mỗi 21 sensor, pipeline tạo sáu đặc trưng: giá trị cuối, mean, sample standard deviation (`ddof=1`), min, max và linear slope theo vị trí 1–30. Vì vậy, mỗi dòng có 126 feature columns và ba cột khóa. Tập dữ liệu gồm 17.731 train windows và 10.196 test windows. Bước này chưa

ghép test labels; các lựa chọn phụ thuộc dữ liệu được giữ ở bước modeling riêng để tránh data leakage.

## 4.6 Mô hình và cấu hình đánh giá RUL

Modeling dùng 17.731 train windows và 126 feature columns từ tập rolling features dài 30 cycles. Tập validation được chia bằng GroupKFold 5-fold theo `engine_id`; mọi window của cùng một engine nằm trong cùng một fold validation. Trong training fold, tổng sample weight của mỗi engine bằng 1 để engine dài không chi phối loss chỉ vì có nhiều window hơn.

Weighted median baseline dự đoán một hằng số học từ training fold, với tổng trọng số mỗi engine bằng 1. Ridge chuẩn hóa đặc trưng trong training fold rồi học quan hệ tuyến tính bằng sai số bình phương có trọng số và phạt L2 với $\alpha = 1$. Trong implementation, sample weight truyền cho bước Ridge, không truyền cho StandardScaler. HistGradientBoosting xây dựng một tổ hợp cộng các cây hồi quy qua 200 iterations với learning rate 0,05; mỗi cây có tối đa 31 leaf nodes và tối thiểu 20 samples/leaf. Các cấu hình này giữ cố định giữa fold; khác biệt metric phản ánh ba ứng viên trong cấu hình đã chạy, không phải kết quả tối ưu hyperparameter đầy đủ.

Ba ứng viên được so sánh là median baseline, Ridge regression và HistGradientBoostingRegressor. Ridge đặt StandardScaler trong pipeline để scaler chỉ fit trên training fold. Metric chọn mô hình là mean engine-level MAE; RMSE và NASA asymmetric score được ghi kèm. Sau khi chọn mô hình, pipeline refit trên toàn bộ train windows và ghi đúng một dự đoán tại cycle cuối của mỗi test engine. File nhãn `RUL_FD001.txt` chỉ được đọc trong bước final evaluation sau khi final predictions đã được ghi.

Để tránh trộn các đại lượng cần ước lượng, kết quả được báo cáo tách theo đơn vị phân tích, group key, split, metric và vai trò của từng phép đo. OOF dùng cho model selection trên train; final evaluation dùng 100 test engines sau khi model đã được chọn; dự báo Health Index là phân tích chuỗi phụ trên 10 train engines và không được dùng để xếp hạng model RUL.

## 4.7 Protocol đánh giá chuyển miền bổ sung

Ma trận bổ sung dùng cùng trailing window 10 cycles cho FD001–FD004, bởi test FD004 có engine ngắn nhất 19 cycles. Với mỗi subset, pipeline tạo train targets chỉ từ lịch sử train, chọn model bằng GroupKFold theo engine, refit và đánh giá một dự đoán tại cycle cuối của mỗi test engine. Trong phép transfer, model đã chọn và fit trên toàn bộ train FD001 được giữ cố định khi dự đoán test FD002–FD004; không fit lại trên target dataset. Test labels của từng target chỉ được đọc sau khi final predictions đã được ghi. Mean engine MAE, RMSE và NASA score được tính trên cùng tập test của mỗi target, kèm bootstrap CI theo engine. Vì window 10 khác window 30 của kết quả FD001 chính, hai nhóm metric được trình bày riêng.

Đầu ra hỗ trợ quyết định được giới hạn ở một cảnh báo minh họa: với model được chọn, mỗi engine train được tổng hợp từ OOF predictions và phát cảnh báo đầu tiên khi predicted RUL

$\leq 30$ cycles. Ngưỡng được khai báo trước, không tối ưu trên 100 test labels. Lead time được ghi bằng RUL thật tại thời điểm cảnh báo, tức proxy số cycle còn lại đến endpoint run-to-failure của FD001; đây không phải lịch bảo trì hoặc false-alarm rate có tính vận hành.

Đặt $a_i = \min\{t : \hat{y}_{i,t} \leq 30\}$ và $b_i = \min\{t : y_{i,t} \leq 30\}$ trên các window OOF quan sát được. Lead time $L_i = T_i - a_i$ và độ trễ so với ngưỡng $D_i = a_i - b_i$ chỉ xác định khi có cảnh báo. $D_i < 0$, $D_i = 0$ và $D_i > 0$ lần lượt là cảnh báo trước, đúng và sau ngưỡng; trường hợp $a_i = T_i$ được ghi riêng là cảnh báo tại failure. Nếu không có $a_i$, trạng thái là không cảnh báo, không gán lead time bằng 0. Helper yêu cầu cycle liên tục và nhãn $y_{i,t} = T_i - t$ đến RUL bằng 0. Vì cùng OOF đã phục vụ model selection, đây không phải đánh giá độc lập sau chọn model.

False alarm ở cấp toàn trajectory được định nghĩa là có cảnh báo nhưng không có event RUL thấp trong lịch sử quan sát. Tất cả train engines đều đi đến RUL bằng 0 nên số engine âm tính bằng 0; false-alarm rate được lưu là null, không phải 0%. Điều này không ngăn phân tích riêng cảnh báo quá sớm hoặc thời gian ở trạng thái cảnh báo ngoài vùng RUL thấp; đó là một đại lượng khác và không thuộc phạm vi báo cáo. Không chọn thêm yêu cầu lead time tối thiểu khi chưa có thông tin chuẩn bị bảo trì.

**Bảng 9:** Cấu hình mô hình và evaluation protocol.

| Thành phần | Giá trị | Vai trò |
|---|---|---|
| Số fold | 5 | GroupKFold theo `engine_id`. |
| Seed | 42 | Tái lập bootstrap và các thành phần ngẫu nhiên của model; GroupKFold không shuffle. |
| Baseline | Weighted median | Đường cơ sở với tổng trọng số mỗi engine bằng 1. |
| Ridge | $\alpha = 1{,}0$ | Có StandardScaler bên trong pipeline của từng training fold. |
| HistGradientBoosting | learning rate 0,05; 200 iterations; 31 leaf nodes; 20 samples/leaf | Mô hình được chọn theo mean engine-level MAE. |
| Early stopping | Tắt | Giữ cấu hình huấn luyện cố định giữa các fold. |
| Test evaluation | 1 prediction/engine | Dự đoán tại cycle cuối quan sát; test labels được đọc sau khi ghi predictions. |

Các giá trị trong Bảng 9 mô tả cấu hình đã chạy, không phải một tuyên bố rằng đây là cấu hình tối ưu cho các subset C-MAPSS khác.

Với nhánh Health Index, cùng prefix 70% và suffix 30% được dùng cho ARIMA và hai baseline dự báo từng điểm. Baseline `last_value` giữ giá trị cuối prefix; baseline `drift` ngoại suy mức thay đổi trung bình từ giá trị đầu đến cuối prefix. Hai baseline không có khoảng dự đoán, nên chỉ được so sánh bằng MAE và RMSE; tỷ lệ bao phủ 95% chỉ thuộc về ARIMA.

## 4.8 Suy luận thống kê

Phân tích suy luận so sánh mean của 30 cycles đầu và 30 cycles cuối trong cùng engine train. Bảng cặp gồm 2.100 dòng (100 engines × 21 sensors), còn bảng suy luận gồm một dòng cho mỗi sensor. Protocol giữ đủ 21 sensor, dùng mean paired difference, bootstrap percentile 95%, Wilcoxon permutation và Benjamini–Hochberg FDR. Hình phân phối và effect size được đọc cùng khoảng tin cậy và số dấu của từng sensor; kết quả này mô tả thay đổi trong protocol đầu/cuối, không phải bằng chứng chọn feature hoặc giá trị dự đoán RUL ngoài mẫu.

# 5 Đọc, truy vấn và biến đổi dữ liệu

Phần này trả lời trực tiếp các câu hỏi về cách gom nhiều file, truy xuất dữ liệu, transform, chọn cột và quan hệ giữa các bảng. Mô tả bám theo code và artifact FD001 đã ghi; bốn subset được xử lý riêng, không ghép thành một bảng chung.

## 5.1 Từ file raw đến observations

Mỗi subset có hai file observations cùng schema là `train_FD00x.txt` và `test_FD00x.txt`, cùng file nhãn `RUL_FD00x.txt`. Reader yêu cầu đúng 26 trường trong mỗi dòng raw: `engine_id`, `cycle`, ba operational settings và 21 sensor measurements. Reader chuyển ID/cycle sang số nguyên, các giá trị đo sang số thực và thêm cột `split`. Sau validation, Pandas concat hoặc PySpark `unionByName` hai bảng observations theo chiều dòng. Đây là union, không phải join train với test.

FD001 có 33.727 observations sau bước này. Một dòng được định danh trong một subset bằng khóa $(split, engine_id, cycle)$. Vì các subset được lưu ở các thư mục riêng, khóa này không đủ để làm khóa cho một bảng hợp nhất FD001–FD004; muốn hợp nhất cần bổ sung `dataset_id`. Repository hiện không thực hiện bước hợp nhất đó.

## 5.2 Các boundary lưu trữ và truy vấn

Silver lưu `observations.parquet` và `train_targets.parquet`. Gold lưu `engine_summary.parquet` và một SQLite portable. SQLite hiện chỉ có hai bảng `engine_summary` và `train_targets`; raw observations được đọc từ Silver Parquet. Vì vậy, truy vấn engine summary có thể chạy bằng SQL, còn truy vấn sensor dùng reader Parquet và phép lọc/cột của Pandas. Đây chưa phải một query engine SQL trên Parquet hoặc partition pruning.

Ví dụ artifact hiện tại cho biết engine train 1 có 192 cycles. Lọc `sensor_11` của engine này ở cycles 71–100 lấy đúng 30 observations. Phép projection giữ các cột khóa và sensor cần xem; không sao chép dữ liệu thành bảng mới nếu chưa ghi artifact.

## 5.3 Transform và time window

Các transform được thực hiện theo thứ tự:

1. Reader kiểm tra width/type/key/cycle, thêm `split` và tạo bảng typed.
2. ETL sắp observations theo khóa và ghi Silver Parquet.
3. Với train, nhóm theo engine để tính $RUL = max_cycle - cycle$.
4. Nhóm theo $(split, engine_id)$ để tạo engine summary.
5. Với mỗi engine, tạo trailing window 30 cycles và tính sáu thống kê trên từng sensor: `last`, `mean`, sample `std`, `min`, `max` và linear `slope`.

6. Modeling join feature rows và train targets bằng đầy đủ ba cột khóa, sau đó mới fit model. Test labels chỉ được đọc sau khi ghi final predictions để đánh giá cuối.

Tại cycle 100 của train engine 1, window là cycles 71–100. Artifact ghi `sensor_11` last bằng 47,64 và mean bằng 47,395, còn RUL bằng $192 - 100 = 92$. Cycle 101 không ảnh hưởng feature tại cycle 100.

## 5.4 Chuẩn hóa và feature columns

Cần phân biệt hai nghĩa của chuẩn hóa. ETL chuẩn hóa schema và datatype; nó không fit một scaler chung cho toàn bộ sensor. Ridge fit `StandardScaler` trong từng training fold. Health Index fit `StandardScaler` và PCA trên 90 train engines còn lại trước khi transform 10 engine được chọn. HGB dùng 126 feature columns theo thang đo gốc.

Rolling artifact có 129 cột: ba cột khóa và 126 feature columns. Ba settings không nằm trong danh sách feature đưa vào model RUL hiện tại. Tạo 126 cột là feature engineering; repository chưa thực hiện feature selection dựa trên EDA hoặc p-value. Artifact có 17.731 train windows và 10.196 test windows.

## 5.5 Quan hệ và ranh giới join

**Bảng 10:** Quan hệ dữ liệu đã triển khai trong một subset

| Hai đối tượng | Quan hệ | Ý nghĩa |
|---|---|---|
| Engine summary–observations | 1:N | Một engine có nhiều cycle observations. |
| Observation–train target | 1:1 | Cùng khóa $(split, engine_id, cycle)$ ở train. |
| Observation endpoint–feature | 1:0..1 | 29 cycle đầu chưa đủ window; từ cycle 30 có một feature row. |
| Train feature–train target | 1:1 | Modeling yêu cầu join đầy đủ ba khóa và kiểm tra one-to-one. |
| Final prediction–test label | 1:1 | Join muộn theo $(split, engine_id)$ để tính metric. |

Một window dùng 30 observations và các window liên tiếp chồng lấn. Đây là dependency theo thời gian, không phải many-to-many join. Nếu join feature với target chỉ bằng `engine_id`, mọi cycle sẽ ghép với mọi cycle của engine đó và làm nhân dòng. Join bằng đầy đủ khóa trả đúng một target cho mỗi feature row. SQLite có index theo khóa nhưng chưa khai báo foreign key constraint.

## 5.6 Phạm vi Big Data

Project thể hiện các thao tác phù hợp với môn Phân tích dữ liệu lớn ở ranh giới batch ETL nhiều file, lưu Parquet theo lớp Silver/Gold, đối chiếu Pandas/PySpark và benchmark Pandas trên dữ liệu nhân bản 1×/10×/100×. PySpark hiện chạy local để kiểm tra parity; modeling và rolling features vẫn dùng Pandas/scikit-learn. Benchmark 100× chỉ đo `build_engine_summary` trong bộ nhớ, không đo I/O, Spark runtime hoặc cluster. Vì vậy báo cáo không claim hiệu năng distributed production, Airflow orchestration hoặc Power BI.

# 6 Protocol suy luận thống kê

## 6.1 Mục tiêu và phạm vi

Mục tiêu là đánh giá mức thay đổi của sensor giữa đầu và cuối vòng đời trong cùng engine trên tập train FD001. Phân tích dùng trung bình **30 cycles đầu và 30 cycles cuối**, chỉ đọc train và dùng engine làm đơn vị ghép cặp. Các giả thuyết phát sinh từ EDA được diễn giải là khám phá.

Phân tích ghép cặp (paired analysis), chênh lệch cặp trung bình, bootstrap 95%, Wilcoxon khi phù hợp, Benjamini–Hochberg và seed 42 thuộc cấu hình hiện có. Kết quả được tính bằng mean paired difference, percentile bootstrap, Wilcoxon permutation và BH trên họ 21 sensors; bảng và hình chỉ sử dụng train.

## 6.2 Định nghĩa cặp đầu/cuối và ví dụ

Với $x_{i,t,s}$ là giá trị sensor $s$ của engine $i$ ở cycle $t$, và $T_i$ là cycle cuối của train engine đó, báo cáo định nghĩa ba đại lượng:

$$E_{i,s} = \frac{1}{30} \sum_{t=1}^{30} x_{i,t,s}. \tag{6}$$

$$L_{i,s} = \frac{1}{30} \sum_{t=T_i-29}^{T_i} x_{i,t,s}. \tag{7}$$

$$D_{i,s} = L_{i,s} - E_{i,s}. \tag{8}$$

Trong đó:

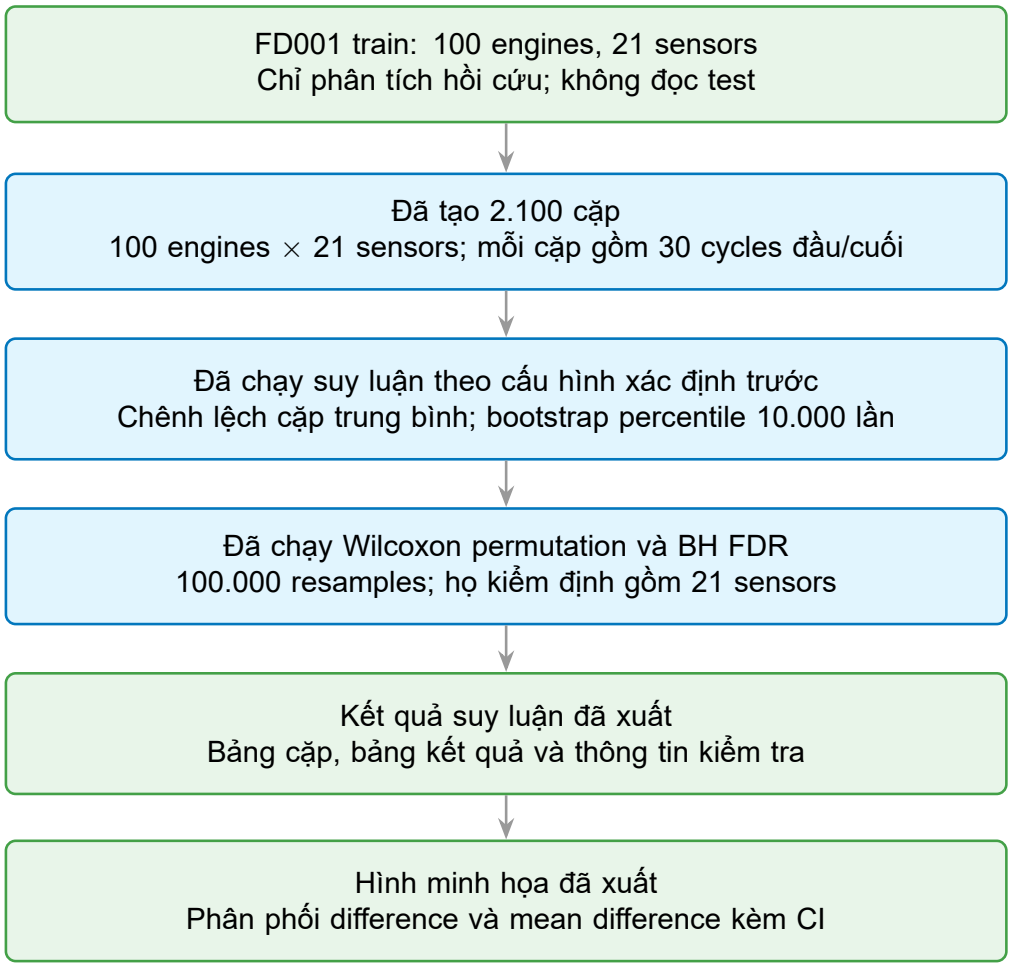
+ $x_{i,t,s}$: giá trị của sensor $s$ trên engine $i$ tại cycle $t$, giữ đơn vị gốc ẩn danh của sensor đó.
+ $T_i$: cycle cuối của engine $i$ trong tập train, tính bằng cycle.
+ $E_{i,s}$: mean của sensor $s$ trên 30 cycles đầu của engine $i$.
+ $L_{i,s}$: mean của sensor $s$ trên 30 cycles cuối của engine $i$.
+ $D_{i,s}$: chênh lệch giữa mean cuối và mean đầu của sensor $s$ trên engine $i$, cùng đơn vị với sensor $s$.

Các Công thức 6–8 là định nghĩa protocol của báo cáo, không phải công thức do bài báo C-MAPSS đề xuất. Chúng được dùng vì mục tiêu ở đây là so sánh cùng một sensor trong cùng engine giữa đầu và cuối vòng đời; lấy mean trên 30 cycles làm giảm phụ thuộc vào một điểm đo đơn lẻ vốn có noise trong mô phỏng C-MAPSS [10]. Nếu $D_{i,s} > 0$, mức trung bình cuối đời lớn hơn đầu đời. Mỗi engine đóng góp một cặp cho mỗi sensor, bất kể tuổi thọ. Hai đoạn phải đủ dữ liệu, liên tục và không chồng lấn. Tuổi thọ train nhỏ nhất là 128 cycles, nên hai đoạn 30 cycles không chồng lấn.

Ví dụ tính chỉ số: với engine có $T_i = 200$, đoạn đầu là cycles 1–30 và đoạn cuối là cycles 171–200. Không nhầm đoạn cuối đời này với window 141–170 dùng dự đoán tại cycle 170. $T_i$

được biết khi phân tích hồi cứu train; không được dùng để xác định đặc trưng ở thời điểm dự đoán trên test.

Giữ độ dài bằng nhau giúp so sánh hai mức tín hiệu trên cùng số cycles. Tuy nhiên, 30 cycles chiếm tỷ lệ vòng đời khác nhau giữa các engine. Protocol này trả lời câu hỏi về hai đoạn có độ dài tuyệt đối cố định, không phải so sánh cùng phần trăm tuổi thọ và cũng không tự xác định chính xác thời điểm bắt đầu suy giảm.




**Hình 2:** Thiết kế phân tích đầu/cuối vòng đời theo engine trên tập train FD001.

## 6.3 Đại lượng cần báo cáo và điều kiện diễn giải

Bảng kết quả giữ đủ 21 sensors, không chọn danh sách theo thứ hạng correlation của EDA. Ba operational settings không được gộp vào cùng họ giả thuyết sensor. Bảng ghi số cặp hợp lệ, số chênh lệch bằng 0, chênh lệch cặp trung bình, khoảng tin cậy, thống kê kiểm định, p-value gốc, p-value hiệu chỉnh và trạng thái có thể kiểm định.

Dùng chênh lệch cặp trung bình làm đại lượng chính theo đơn vị gốc:

$$\widehat{\Delta}_s = \frac{1}{m}\sum_{i=1}^{m} D_{i,s}. \tag{9}$$

Trong đó:

+ $s$: sensor đang được phân tích.
+ $m$: số engine có cặp đầu/cuối hợp lệ.
+ $D_{i,s}$: chênh lệch của sensor $s$ trên engine $i$, cùng đơn vị với sensor $s$.
+ $\widehat{\Delta}_s$: mean paired difference của sensor $s$, cùng đơn vị với sensor $s$.

Mean paired difference trong Công thức 9 được dùng vì nó trả lời trực tiếp câu hỏi "cuối đời thay đổi trung bình bao nhiêu so với đầu đời" theo đơn vị gốc. Đây là đại lượng mô tả của báo cáo, không phải một score chuẩn hóa được đề xuất riêng cho C-MAPSS. Vì các sensor có thang đo khác nhau, không so sánh trực tiếp độ lớn của $\widehat{\Delta}_s$ giữa hai sensor. Độ bất định được ước lượng bằng bootstrap: lấy mẫu lại các engine cùng cặp $E, L$ để tạo khoảng tin cậy 95% cho $\widehat{\Delta}_s$ theo phương pháp bootstrap của Efron và hàm SciPy đã khóa phiên bản [3, 12]. Cấu hình dùng 10.000 resamples và percentile interval.

Wilcoxon hai phía đánh giá giả thuyết phân phối chênh lệch đối xứng quanh 0; các cặp được giả định độc lập giữa engine [14]. Cách diễn giải theo median cần giả định đối xứng, không phải kiểm định median không điều kiện. Với `zero_method=wilcox`, chênh lệch bằng 0 không tham gia xếp hạng. Bootstrap của mean không thay thế giả định signed-rank. Sensor hằng hoặc có toàn bộ $D_{i,s} = 0$ vẫn xuất hiện dưới trạng thái không có biến thiên quan sát được. Không biến p-value không xác định thành 0 hay suy ra sensor không có giá trị dự đoán ngoài mẫu.

Benjamini–Hochberg áp dụng cho một họ kiểm định đã xác định trước [2, 13]. Họ gồm 21 sensors được giữ cố định, dùng giá trị 1 chỉ trong vector hiệu chỉnh cho trường hợp không kiểm định được, đồng thời giữ p-value gốc là không áp dụng và ghi rõ trạng thái trong bảng. Quy ước này tránh thu nhỏ họ giả thuyết theo kết quả thuận lợi; nó không sửa được p-value thiếu hợp lệ hoặc bảo đảm FDR dưới mọi dạng phụ thuộc giữa sensors. Các khoảng tin cậy bootstrap riêng lẻ không phải simultaneous intervals.

## 6.4 Cấu hình suy luận

Các giá trị sau là cấu hình sử dụng khi tính kết quả; không lấy default của thư viện làm quyết định ngầm.

- Đại lượng chính: mean paired difference; kèm median, số dấu dương, số dấu âm và số zero để xem phân phối lệch.
- Bootstrap: 10.000 lần lấy mẫu lại 100 engines có hoàn lại, seed 42; dùng percentile interval tại các quantile 2,5% và 97,5%. Ghi rõ giới hạn độ bao phủ hữu hạn; không mặc định tương đương BCa. Trường hợp phân phối bootstrap suy biến phải gắn nhãn, không diễn giải khoảng

bằng 0 là chắc chắn tuyệt đối.

- Wilcoxon: hai phía, zero method `wilcox`, không dùng continuity correction và không dùng `auto`. Dùng permutation với 100.000 resamples và RNG cố định cho sensors có thể kiểm định. Zero được xác định bằng `difference == 0.0` sau tính mean `float64`; không tự làm tròn bằng một ngưỡng tùy ý cho mọi sensor.
- All-zero và p-value thiếu: nếu toàn bộ $D_{i,s} = 0$, giữ sensor trong bảng với trạng thái all-zero, `raw_p=NA` và không diễn giải như một kiểm định thành công. Lỗi số bất ngờ phải làm lần chạy dừng thay vì biến thành p-value hợp lệ.
- FDR: dùng Benjamini–Hochberg với $q = 0{,}05$ trên đúng họ 21 sensors bằng hàm SciPy đã cố định trong metadata. Với p-value không áp dụng, chỉ dùng sentinel 1,0 bên trong vector hiệu chỉnh; output vẫn giữ `raw_p=NA` và trạng thái riêng.
- RNG: dùng seed 42 và tách luồng theo sensor và mục đích bootstrap/permutation để đổi thứ tự chạy không đổi kết quả của cùng sensor.

Cấu hình này được áp dụng nhất quán cho toàn bộ 21 sensor. Kiểm tra gồm chỉ số 30 cycles đúng trong từng engine, không chồng đoạn, ghép cặp một–một và trường hợp hằng/ties/zeros. Bootstrap lấy mẫu theo engine và giữ cặp; chạy lại với cùng input và seed phải tái lập kết quả.

Kết luận thống kê chỉ áp dụng cho thay đổi trên train mô phỏng theo protocol này. Phát hiện thay đổi không chứng minh quan hệ nhân quả hoặc hiệu quả dự đoán ngoài mẫu. Lựa chọn sensor cho mô hình vẫn phải học trong training fold; không dùng danh sách có ý nghĩa thống kê trên toàn train để chọn feature trước cross-validation.

# 7 Kết quả và diễn giải

Các kết quả chi tiết trong phần này dùng FD001 làm subset chính. Đánh giá bổ sung trên FD002–FD004 được trình bày riêng ở cuối phần để không trộn metric window 10 cycles với kết quả chính window 30 cycles.

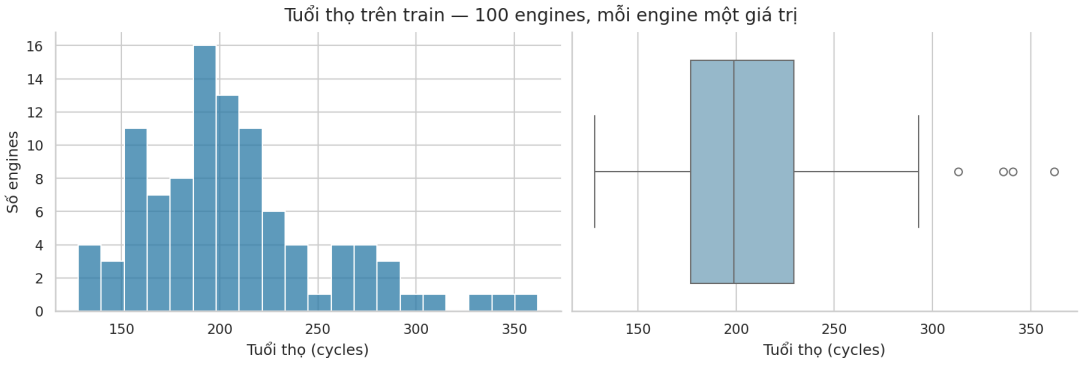
## 7.1 Kiểm tra dữ liệu

Validation đạt đối với observations train, nhãn RUL train và observations test. Tập train có 20.631 dòng, tập test có 13.096 dòng; mỗi tập gồm 100 engine. Một trăm test labels hợp lệ về cấu trúc, nhưng được giữ tách khỏi EDA và các phân tích trên train. Các kiểm tra schema, khóa duy nhất, kiểu số hữu hạn và cycle liên tục đều đạt.

## 7.2 Tuổi thọ động cơ trên train

**Bảng 11:** Thống kê tuổi thọ, đơn vị cycle.

| Thống kê | Giá trị | Thống kê | Giá trị |
|---|---|---|---|
| Trung bình | 206,31 | Độ lệch chuẩn mẫu | 46,34 |
| Nhỏ nhất | 128 | Lớn nhất | 362 |
| Tứ phân vị 25% | 177 | Trung vị | 199 |
| Tứ phân vị 75% | 229,25 | Số động cơ | 100 |




**Hình 3:** Phân phối tuổi thọ train; mỗi động cơ đóng góp một giá trị.

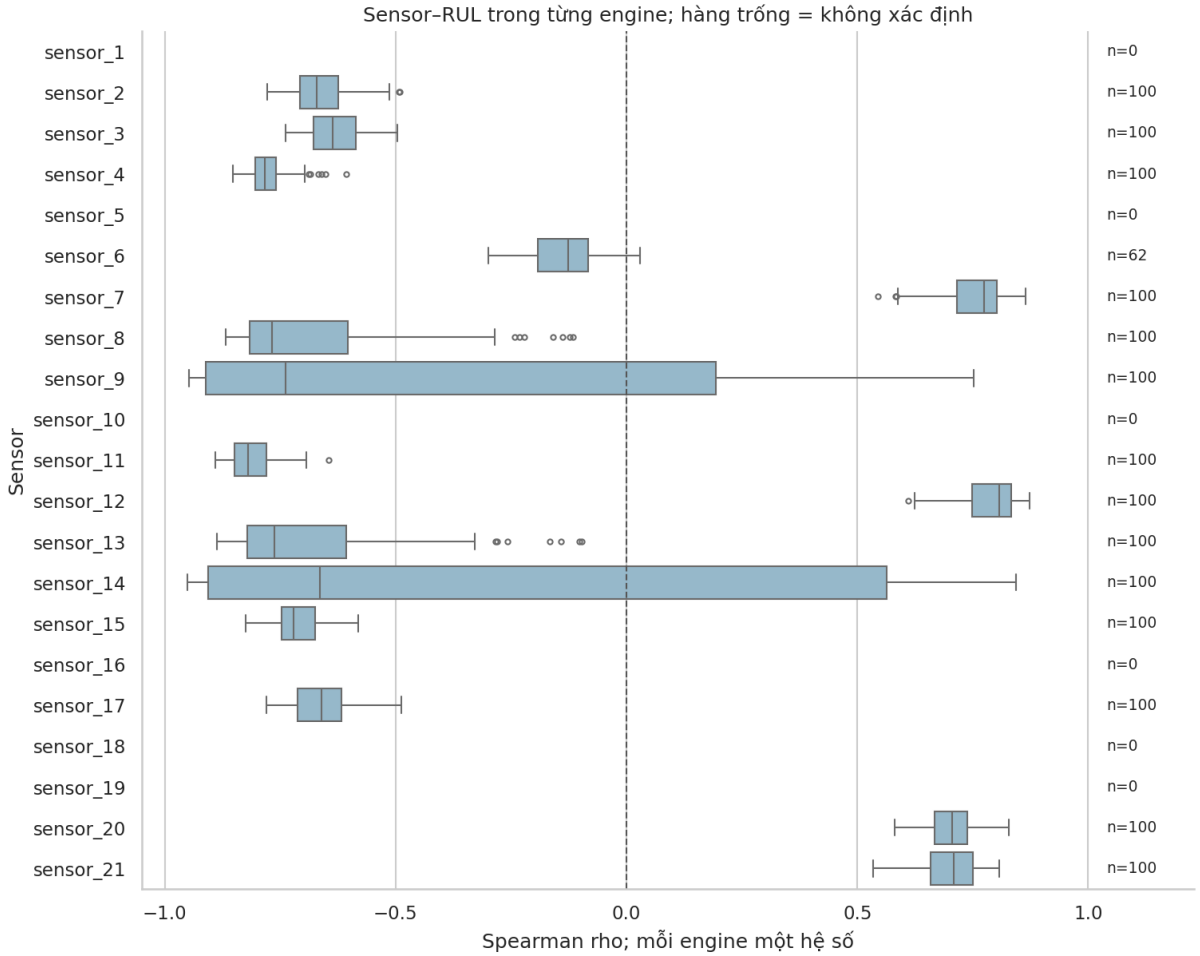
Tuổi thọ dao động từ 128 đến 362 cycles; trung bình lớn hơn trung vị. Vì độ dài chuỗi khác nhau, báo cáo phân biệt rõ tổng hợp theo observation và theo engine. Các con số không được diễn giải thành tuổi thọ theo giờ hoặc ngày.

## 7.3 Sensor hằng và correlation theo engine

**Bảng 12:** Một số dòng minh họa; bảng này không dùng để chọn sensor.

| Sensor | Động cơ xác định | Tương quan trung vị | Không xác định |
|---|---|---|---|
| 1 | 0 | Không xác định | 100 |
| 6 | 62 | −0,1264 | 38 |
| 11 | 100 | −0,8190 | 0 |
| 12 | 100 | 0,8075 | 0 |

Sensor 1, 5, 10, 16, 18 và 19 hằng trên train. Sensor 6 hằng trong 38/100 engine; correlation chỉ xác định trong 62 engine còn lại. Sensor 11 có tương quan trung vị âm, còn sensor 12 có tương quan trung vị dương với RUL. Đây là liên hệ mô tả trên train, không phải bằng chứng nhân quả hoặc hiệu quả ngoài mẫu.




**Hình 4:** Phân phối correlation Spearman giữa các engine train. Sensor hằng được giữ là không xác định.

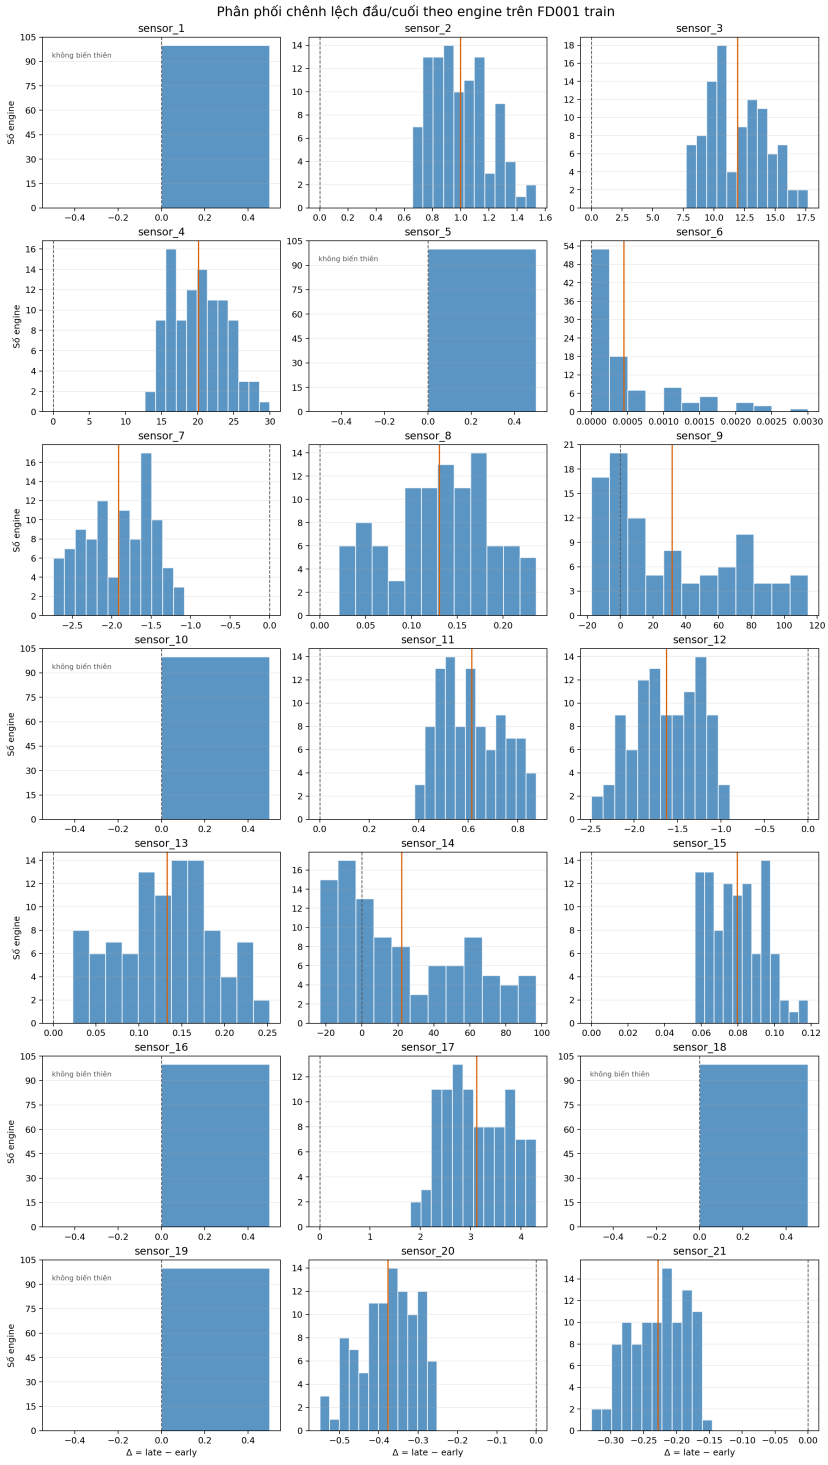
## 7.4 Suy luận đầu/cuối vòng đời trên train

Bảng cặp gồm 2.100 dòng, tương ứng 100 engine train nhân 21 sensor. Mỗi dòng dùng mean của 30 cycles đầu, mean của 30 cycles cuối và chênh lệch cuối trừ đầu. Bảng suy luận giữ đủ 21 sensor.

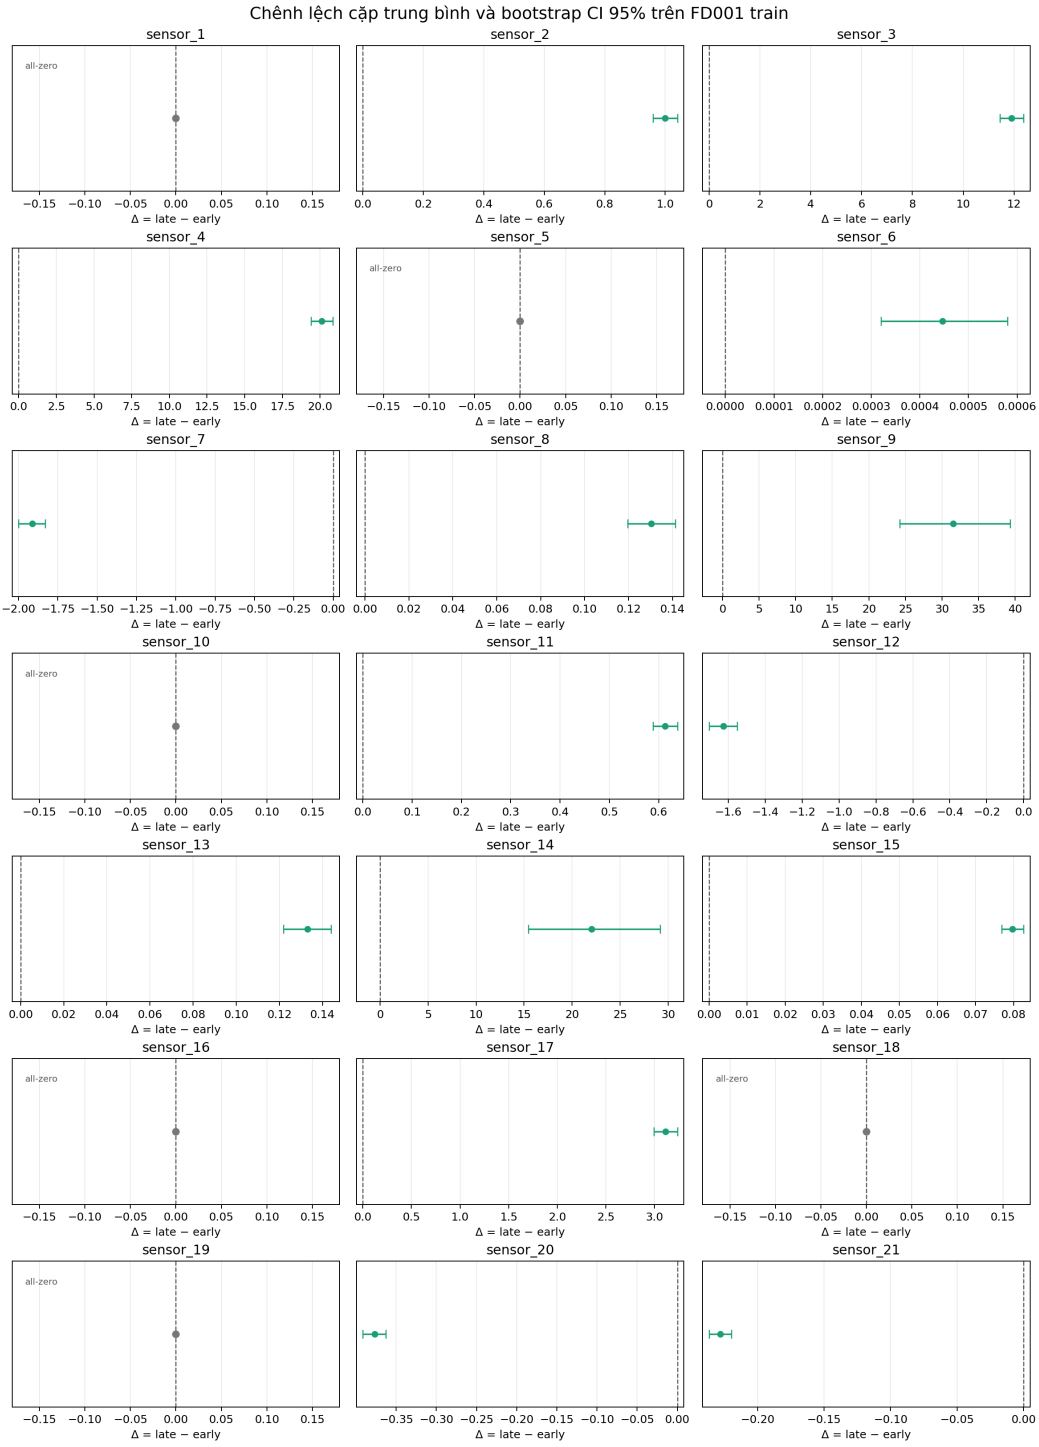
Trong 21 sensor, sáu sensor có toàn bộ chênh lệch bằng 0: `sensor_1`, `sensor_5`, `sensor_10`, `sensor_16`, `sensor_18` và `sensor_19`. Mười lăm sensor còn lại kiểm định được; với cấu hình Wilcoxon permutation và Benjamini–Hochberg trên họ 21 sensor, các p-value đã hiệu chỉnh đều xấp xỉ 0,000028. Giá trị lặp lại này phản ánh độ phân giải hữu hạn của permutation 100.000 lần và bước điều chỉnh BH; nó không có nghĩa là các sensor có cùng độ lớn hiệu ứng. Vì vậy, kết luận được đọc cùng mean difference, khoảng tin cậy và số dấu, thay vì dựa riêng vào p-value.

**Bảng 13:** Một số kết quả tiêu biểu. Giá trị là chênh lệch cuối trừ đầu theo đơn vị gốc của từng sensor.

| Sensor | Chênh lệch trung bình | Khoảng tin cậy bootstrap 95% | Dấu chính |
|---|---|---|---|
| `sensor_4` | 20,128097 | [19,402735; 20,865606] | Tăng |
| `sensor_7` | -1,913527 | [-1,999307; -1,829684] | Giảm |
| `sensor_11` | 0,613257 | [0,589017; 0,637944] | Tăng |
| `sensor_12` | -1,627190 | [-1,704288; -1,552119] | Giảm |
| `sensor_20` | -0,377007 | [-0,391534; -0,363173] | Giảm |




**Hình 5:** Phân phối chênh lệch cuối trừ đầu của 100 engine cho từng sensor.




**Hình 6:** Mean paired difference và bootstrap CI 95% theo từng sensor.

Theo protocol đầu/cuối đã chọn, nhiều sensor có chênh lệch khác 0 một cách có hệ thống trên train FD001. Sensor 4 tăng trung bình khoảng 20,13 đơn vị gốc, trong khi sensor 7 giảm khoảng 1,91 đơn vị; hai giá trị này không được xếp hạng trực tiếp vì sensor có thang đo khác nhau. Sensor 6 có 47 chênh lệch dương và 53 chênh lệch bằng 0, nhưng mean difference chỉ khoảng 0,00045. Trường hợp này minh họa rằng p-value nhỏ không tự cho biết độ lớn thực tiễn của thay đổi. Phân tích đầu/cuối vì vậy không được dùng như bằng chứng chọn đặc trưng hoặc giá trị sử dụng dự đoán RUL ngoài mẫu.

## 7.5 Rolling features

Rolling features dài 30 cycles gồm 17.731 train windows và 10.196 test windows, tổng cộng 27.927 dòng. Mỗi dòng có khóa `(split, engine_id, cycle)` và 126 feature columns cho 21 sensor, gồm `last`, `mean`, sample `std`, `min`, `max` và `slope`. Test labels không được ghép trong bước này.

**Bảng 14:** Số rolling windows theo split.

| Split | Engines | Rolling windows |
|---|---|---|
| Train | 100 | 17.731 |
| Test | 100 | 10.196 |
| Tổng | 200 | 27.927 |

Validator kiểm tra schema, khóa duy nhất, thứ tự canonical, số hữu hạn và đủ trailing window trong từng engine. Tests tính tay xác nhận sample standard deviation, slope, không dùng tương lai và không nối hai engine.

## 7.6 Mô hình RUL và đánh giá cuối

Pipeline modeling so sánh ba ứng viên trên 5 folds theo engine. Bảng 15 trình bày metric trung bình qua các fold. Theo tiêu chí mean engine-level MAE xác định trước, HistGradientBoostingRegressor được chọn vì đạt giá trị thấp nhất trong ba ứng viên.

**Bảng 15:** Kết quả grouped cross-validation trên 17.731 train windows. MAE và RMSE tính bằng cycles; độ lệch chuẩn MAE được tính giữa 5 fold, không phải độ lệch chuẩn giữa 100 engine.

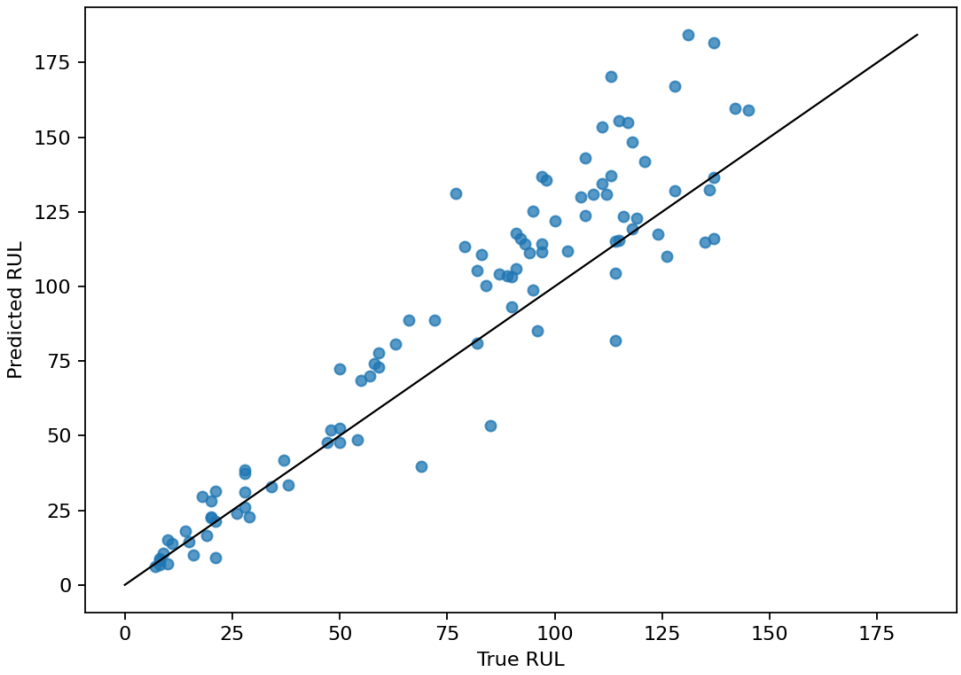
| Model | Mean engine MAE | RMSE trung bình | Chọn |
|---|---|---|---|
| `median_baseline` | 46,9543 | 62,9006 | Không |
| `ridge_alpha_1` | 23,9922 | 35,9467 | Không |
| `hist_gradient_boosting` | 20,2143 | 33,5479 | Có |

Sau khi refit trên toàn bộ train windows, pipeline ghi một final prediction tại cycle cuối cho mỗi trong 100 test engines. Nhãn NASA chỉ được ghép sau bước này; metric cuối được trình bày trong Bảng 16.

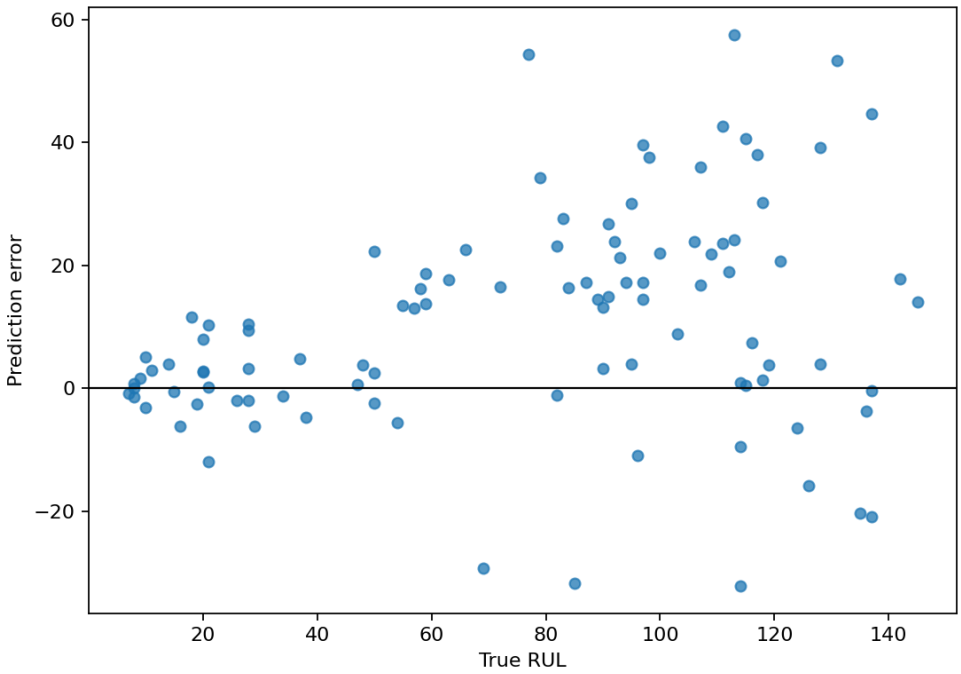
Độ lệch chuẩn giữa các fold của mean engine MAE lần lượt là 0,1193 cho median baseline, 0,9479 cho Ridge và 0,9821 cho HistGradientBoosting. Mỗi fold có 20 engine, nên mean MAE qua fold cũng bằng mean MAE qua 100 engine OOF trong lần chạy này. RMSE là row-level trong từng fold rồi lấy trung bình; nó không phải RMSE của toàn bộ OOF gộp lại. Không so trực tiếp các con số này với metric tại một điểm cắt của mỗi test engine.

**Bảng 16:** Đánh giá model được chọn trên 100 test engines; khoảng tin cậy bootstrap lấy mẫu lại engine có hoàn lại 10.000 lần, seed 42. Mỗi lần lấy mẫu giữ đúng multiplicity của engine.

| Metric | Giá trị | Bootstrap CI 95% |
|---|---|---|
| Mean engine MAE | 15,3490 | [12,7286; 18,0866] |
| RMSE | 20,5413 | [17,3442; 23,5850] |
| NASA score | 1.513,2577 | [743,4999; 2.476,2743] |




**Hình 7:** RUL thật và RUL dự đoán của 100 test engines. Đường chéo biểu diễn dự đoán hoàn hảo.




**Hình 8:** Sai số `prediction - true` theo RUL thật của 100 test engines.

Sai số tuyệt đối trung bình của nhóm RUL thật 0–30 cycles là 4,3830, thấp hơn ba nhóm còn lại (31–60, 61–90 và trên 90 cycles). Mười sai số lớn nhất đều là trường hợp dự đoán cao hơn nhãn thật, với độ lệch khoảng 37,6–57,5 cycles; những trường hợp này đóng góp đáng kể vào NASA score. Đây là kết quả trên FD001 mô phỏng; riêng metric FD001 này chưa cung cấp bằng chứng về khả năng khái quát sang dạng lỗi hoặc điều kiện vận hành khác.

## 7.7 Đánh giá bổ sung trên FD002–FD004

Để kiểm tra khả năng chuyển miền, repository đã bổ sung đủ raw data FD001–FD004 và chạy lại cùng pipeline với trailing window 10 cycles. Window này được chọn cho ma trận bổ sung vì test FD004 có engine ngắn nhất chỉ 19 cycles; kết quả không được so trực tiếp với metric chính của FD001 dùng window 30 cycles.

Mỗi subset có một evaluation nội bộ, trong đó train và test thuộc cùng subset. Ngoài ra, model được fit trên toàn bộ train FD001 rồi áp dụng trực tiếp lên test FD002, FD003 và FD004. Test labels chỉ được ghép sau khi final predictions đã được ghi. Bảng dưới lấy từ `outputs/cross_dataset/matrix.json`; bootstrap dùng 10.000 engine resamples với seed 42.

**Bảng 17:** Mean engine MAE, RMSE và NASA score trong ma trận bổ sung với window 10 cycles.

| Train | Test | Loại | MAE | RMSE | NASA score |
|---|---|---|---|---|---|
| FD001 | FD001 | Nội bộ | 21,9258 | 29,5936 | 8.103,0148 |
| FD002 | FD002 | Nội bộ | 22,3556 | 31,3077 | 34.004,9782 |
| FD003 | FD003 | Nội bộ | 28,3255 | 41,7606 | 4.109.107,7036 |
| FD004 | FD004 | Nội bộ | 27,2218 | 36,9311 | 492.703,0709 |
| FD001 | FD002 | Transfer | 60,3215 | 70,4603 | 14.193.434,0842 |
| FD001 | FD003 | Transfer | 47,3949 | 59,2140 | 59.380.624,2646 |
| FD001 | FD004 | Transfer | 58,5731 | 69,8148 | 14.691.764,3175 |

Kết quả transfer có MAE cao hơn evaluation nội bộ trên target subset. FD001 sang FD002 tăng lên 60,3215 cycles; FD001 sang FD003 đạt 47,3949 cycles; FD001 sang FD004 đạt 58,5731 cycles. Model fit trên FD001 vì vậy không được diễn giải là model dùng trực tiếp cho FD002–FD004.

### 7.7.1 Phân tích lỗi theo engine

Trên 100 test engines, absolute error có trung vị 13,3654 cycles, tứ phân vị 25% bằng 3,5666 và tứ phân vị 75% bằng 22,3412. Có 74 dự đoán cao hơn RUL thật và 26 dự đoán thấp hơn; không có trường hợp hai giá trị bằng nhau. Năm engine có absolute error lớn nhất được trình bày trong Bảng 18. Các dòng này được giữ lại để mô tả hành vi của mô hình, không bị loại khỏi metric cuối.

**Bảng 18:** Năm test engine có absolute error lớn nhất.

| Engine | RUL thật | RUL dự đoán | Absolute error | Sai số có dấu | Hướng |
|---|---|---|---|---|---|
| 23 | 113 | 170,4768 | 57,4768 | 57,4768 | Cao hơn |
| 67 | 77 | 131,2516 | 54,2516 | 54,2516 | Cao hơn |
| 73 | 131 | 184,2864 | 53,2864 | 53,2864 | Cao hơn |
| 83 | 137 | 181,6740 | 44,6740 | 44,6740 | Cao hơn |
| 22 | 111 | 153,5543 | 42,5543 | 42,5543 | Cao hơn |

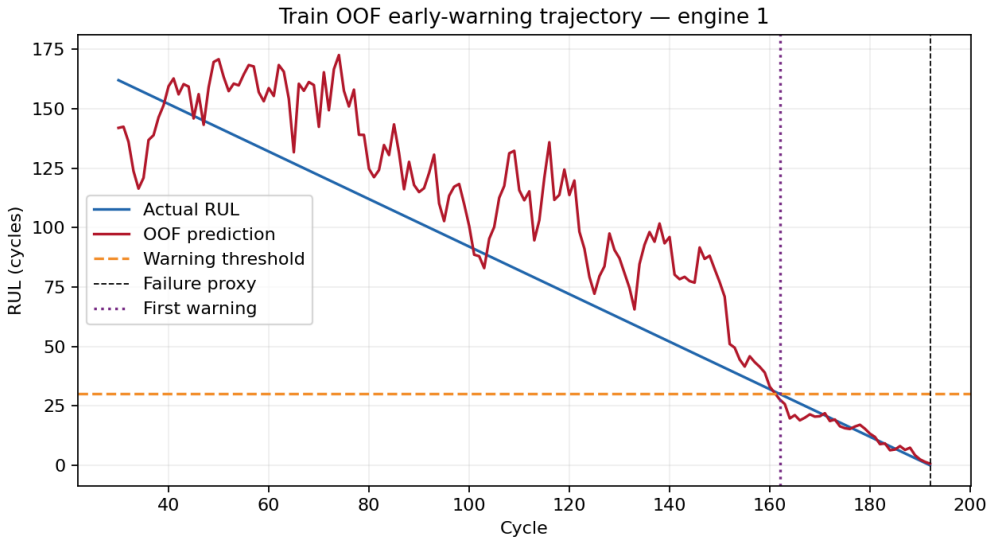
## 7.8 Cảnh báo sớm minh họa từ OOF

Để tách cảnh báo khỏi final test evaluation, pipeline dùng OOF predictions của HistGradientBoosting trên train với ngưỡng định trước RUL $\leq 30$ cycles. Bảng cảnh báo có một dòng cho mỗi engine, ghi cycle phát cảnh báo đầu, RUL thật tại thời điểm đó, lead time đến failure proxy và trạng thái bỏ lỡ. Lần chạy hiện tại có ít nhất một cảnh báo trên 100/100 engine. Có 44 engine cảnh báo trước ngưỡng, 7 đúng ngưỡng và 49 sau ngưỡng nhưng trước failure; không có cảnh báo đầu tiên tại failure hoặc engine không từng cảnh báo. `missed_warning=0` chỉ biểu thị không có engine hoàn toàn thiếu cảnh báo, không chứng minh mọi cảnh báo đều đáp ứng thời gian chuẩn bị bảo trì.

**Bảng 19:** Phân phối lead time tại cảnh báo đầu tiên trên 100 engine OOF train, đơn vị cycles.

| Nhỏ nhất | Q1 | Trung vị | Trung bình | Q3 | Lớn nhất |
|---|---|---|---|---|---|
| 19 | 26 | 30 | 31,22 | 35 | 55 |

Ví dụ, train engine 1 cảnh báo tại cycle 162 và kết thúc tại cycle 192, nên lead time là 30 cycles, đúng thời điểm RUL thật chạm ngưỡng. Các cycle này được tính từ trajectory OOF. OOF giữ engine được dự đoán ngoài training fold, nhưng cũng đã được dùng để chọn model; kết quả cảnh báo vì vậy chỉ là đánh giá nội bộ có điều kiện trên lựa chọn đó.




**Hình 9:** RUL thật, OOF prediction và ngưỡng cảnh báo 30 cycles trên engine 1. Đường thẳng đứng tím đánh dấu cảnh báo đầu tiên; đường thẳng đứng đen là failure proxy. Engine 1 được chọn theo ID nhỏ nhất, không theo chất lượng prediction.

## 7.9 Phân tích PCA–ARIMA trên Health Index

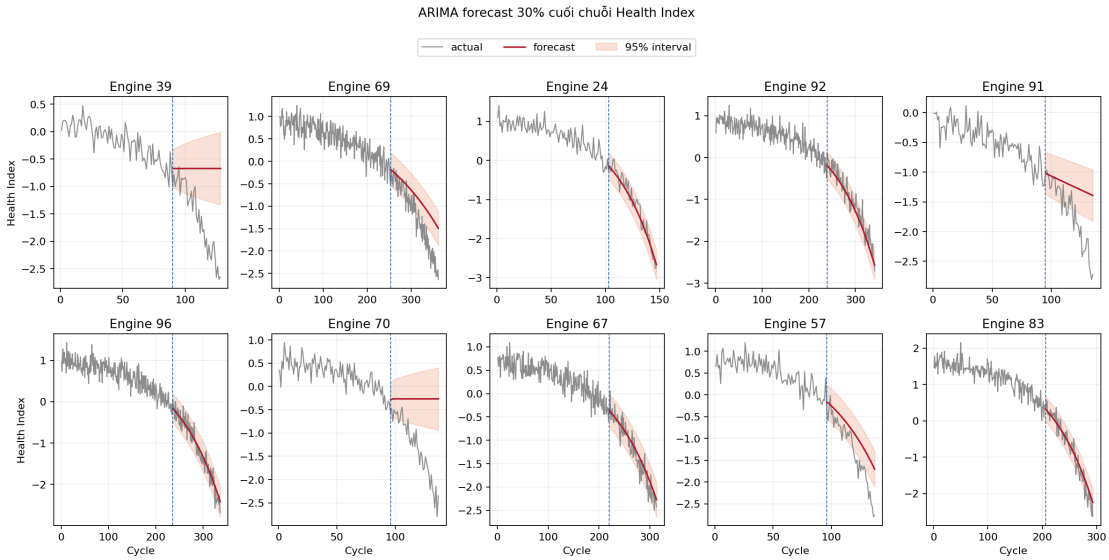
Phân tích phụ chỉ dùng 20.631 train observations. Danh sách 10 engine được xác định trước khi dự báo, gồm hai engine ở mỗi fold GroupKFold theo các vị trí lifetime cách đều. StandardScaler, PCA, hướng PC1 và tham số chuẩn hóa Health Index được fit trên 90 train engines còn lại; 10 engine được chọn chỉ được transform và dùng cho dự báo. Mỗi chuỗi dùng 70% đầu để huấn luyện ARIMA và 30% cuối để đánh giá; không có test observation hoặc test label trong bước này.

**Bảng 20:** Chỉ số dự báo trên 30% cuối chuỗi Health Index trên 10 engine validation được chọn trước.

| Engine | Fold | Order | MAE | RMSE | Coverage 95% |
|---|---|---|---|---|---|
| 39 | 1 | (0,1,1) | 0,8860 | 1,0788 | 35,90% |
| 69 | 1 | (1,0,1) | 0,4585 | 0,5645 | 50,46% |
| 24 | 2 | (1,0,1) | 0,1572 | 0,1897 | 95,56% |
| 92 | 2 | (1,0,1) | 0,1631 | 0,2066 | 89,32% |
| 91 | 3 | (1,0,1) | 0,4900 | 0,6422 | 48,78% |
| 96 | 3 | (1,0,1) | 0,1515 | 0,1832 | 97,03% |
| 70 | 4 | (2,1,2) | 1,0372 | 1,2205 | 21,43% |
| 67 | 4 | (2,0,1) | 0,1607 | 0,2018 | 93,62% |
| 57 | 5 | (1,0,2) | 0,4346 | 0,5230 | 50,00% |
| 83 | 5 | (1,0,1) | 0,1708 | 0,2171 | 87,50% |

Cả 10 engine đều có trạng thái fit hội tụ. MAE nằm trong khoảng 0,1515–1,0372 và tỷ lệ bao phủ 95% nằm trong khoảng 21,43%–97,03%. Với p-value từ 0,8606 đến 0,9990, ADF không bác bỏ giả thuyết gốc về nghiệm đơn vị trên các đoạn huấn luyện; do đó, chưa có bằng chứng đủ mạnh để kết luận các chuỗi là dừng theo kiểm định này. Ljung–Box được tính với bậc tự do điều chỉnh theo $p + q$; hai trong mười chuỗi (engine 69 và 70) có p-value dưới 0,05, nên không thể kết luận residual của toàn bộ các chuỗi không còn tự tương quan. Coverage thấp ở một số engine cho thấy khoảng dự đoán chưa được hiệu chỉnh đồng đều; kết quả này được giữ nguyên và không dùng để thay đổi danh sách engine.

Để so sánh kết quả ARIMA với đường cơ sở đơn giản trên cùng khoảng dự báo, báo cáo tính baseline theo từng engine. Trung bình theo 10 engine, ARIMA đạt MAE $0{,}4110$ và RMSE $0{,}5027$; baseline `drift` đạt lần lượt $0{,}7469$ và $0{,}9128$, còn `last_value` đạt $0{,}9478$ và $1{,}1553$. ARIMA có MAE thấp hơn `drift` trên 7/10 engine và thấp hơn `last_value` trên 8/10 engine. Đây là so sánh mô tả trong cùng protocol, không phải kiểm định statistical significance và không biến Health Index thành RUL.




**Hình 10:** Health Index thực tế, dự báo ARIMA và khoảng dự đoán 95% trên 30% cuối mỗi chuỗi được chọn.

## 7.10 ETL Silver/Gold và benchmark

Sau khi kiểm tra data contract, pipeline Pandas và PySpark ghi cùng một tập bảng dữ liệu. Silver gồm 33.727 observations train/test và 20.631 train targets. Gold gồm 200 dòng engine summary trong Parquet cùng bảng truy vấn tương ứng trong SQLite. Tất cả bảng đều được đọc lại sau khi ghi để kiểm tra round-trip.

**Bảng 21:** Benchmark tạo engine summary trên observations nhân bản trong bộ nhớ; dữ liệu nhân bản không dùng để huấn luyện.

| Scale | Input rows | Engine rows | Lần 1 (s) | Lần 2 (s) |
|---|---|---|---|---|
| 1× | 33.727 | 200 | 0,0195 | 0,0196 |
| 10× | 337.270 | 2.000 | 0,1589 | 0,1474 |
| 100× | 3.372.700 | 20.000 | 1,6752 | 1,6732 |

Benchmark chỉ đo chi phí của phép tổng hợp cục bộ, không phải năng lực xử lý phân tán. Trên ba bảng Silver/Gold, Pandas và PySpark khớp schema, khóa, số dòng và giá trị số; sai khác tuyệt đối lớn nhất bằng 0,0.

Đồng hồ chỉ bao quanh `build_engine_summary`: dữ liệu đã ở trong bộ nhớ và Pandas thực thi phép tổng hợp ngay. Thời gian không bao gồm đọc raw, nhân bản dữ liệu, ghi Parquet hay SQLite. Hai lần lặp liên tiếp được metadata gọi là cold/warm nhưng không có thao tác xóa cache hoặc khởi động process mới, nên bảng ghi là lần 1 và lần 2. Với hai lần đo mỗi scale, chưa thể ước lượng độ biến thiên runtime đáng tin cậy; cũng chưa có runtime PySpark để so tốc độ.

## 7.11 Dashboard đọc kết quả

Dashboard Streamlit cung cấp một lớp quan sát read-only cho các kết quả đã ghi. Trang tổng quan hiển thị MAE, RMSE, NASA score, số engine test, Health Index và đếm số điểm dự báo; trang RUL cho phép chọn một test engine để xem giá trị thật, giá trị dự đoán và absolute error; trang Health Index/ARIMA cho phép chọn một validation engine để xem lịch sử, dự báo trên đoạn giữ lại để kiểm tra, khoảng dự đoán 95% và diagnostics. Dashboard không fit model, không chạy lại ARIMA và không đọc nhãn test thô khi mở trang. Ví dụ, lựa chọn engine 39 chỉ truy vấn các dòng kết quả đã được tạo trước đó.

# 8 Thảo luận, giới hạn và hướng phát triển

## 8.1 Diễn giải các kết quả chính

Kết quả cho thấy việc đặt engine làm đơn vị chia dữ liệu và đánh giá giúp hạn chế việc đếm các window có phụ thuộc thời gian như những quan sát độc lập. Trong protocol đánh giá, HistGradientBoosting đạt MAE trung bình theo engine thấp nhất trên đánh giá chéo và được huấn luyện lại trước khi tạo một dự đoán cuối cho mỗi engine test. Metric cuối vì vậy phản ánh sai số ở điểm cắt của 100 engine test, không phải sai số của toàn bộ chuỗi theo thời gian.

Phân tích đầu/cuối vòng đời cho thấy nhiều sensor có thay đổi có hệ thống trong hai đoạn 30 cycles. Tuy nhiên, độ lớn chênh lệch nằm ở đơn vị gốc của từng sensor, nên không thể dùng các giá trị này để xếp hạng trực tiếp giữa các sensor. Wilcoxon signed-rank được diễn giải dưới giả định phân phối chênh lệch đối xứng quanh 0; không nên rút gọn thành kiểm định median cho mọi phân phối. Với sensor 6, 53 chênh lệch bằng 0 bị loại khỏi phép xếp hạng theo `zero_method=wilcox`, còn 47 chênh lệch dương tham gia kiểm định. P-value nhỏ không chứng minh quan hệ nhân quả hay giá trị dự báo ngoài mẫu.

PCA–ARIMA cung cấp một cách kiểm tra độc lập về diễn biến của Health Index. Tỷ lệ bao phủ của khoảng dự đoán 95% thay đổi đáng kể giữa các engine, từ 21,43% đến 97,03%. ADF trên các đoạn huấn luyện không bác bỏ giả thuyết gốc về nghiệm đơn vị; do đó, các chuỗi này chưa cung cấp bằng chứng đủ mạnh về tính dừng theo kiểm định ADF. Sau khi điều chỉnh bậc tự do theo bậc ARIMA, Ljung–Box vẫn cho thấy p-value dưới 0,05 ở engine 69 và 70. Dự báo Health Index vì vậy chỉ được giữ như một phân tích phụ, không được dùng để thay thế mô hình RUL.

So sánh với baseline trên cùng prefix và suffix cho thấy ARIMA có MAE trung bình 0,4110, thấp hơn `drift` (0,7469) và `last_value` (0,9478); RMSE tương ứng là 0,5027, 0,9128 và 1,1553. ARIMA chỉ thấp hơn `drift` ở 7/10 engine và `last_value` ở 8/10 engine, nên kết quả này phù hợp với một lợi thế mô tả trong subset được chọn hơn là bằng chứng về ưu thế tổng quát. Baseline không có khoảng dự đoán, vì vậy không được so tỷ lệ bao phủ với ARIMA.

Cảnh báo sớm minh họa trên OOF cho thấy ngưỡng 30 cycles có thể chuyển dự đoán thành một sự kiện theo engine thay vì đếm từng cycle như các quan sát độc lập. Tuy nhiên, 49/100 cảnh báo đầu tiên đến sau mốc RUL thật bằng 30; lead time thấp nhất là 19 cycles. Không có engine hoàn toàn thiếu cảnh báo không đồng nghĩa mọi cảnh báo đều đủ sớm. Các nhóm trước/đúng/sau ngưỡng chỉ mô tả thời điểm, chưa phản ánh chi phí hoặc giá trị sử dụng cho bảo trì. Không có engine âm tính theo định nghĩa sự kiện toàn vòng đời, nên tỷ lệ cảnh báo sai cấp engine không xác định. Vẫn có thể định nghĩa sai cảnh báo theo từng vùng thời gian, nhưng không được thay thế âm thầm đại lượng cần ước lượng hiện tại bằng phép đo đó.

Kết quả warning còn chịu ảnh hưởng của model selection: cùng tập OOF đã dùng để chọn HistGradientBoosting rồi mô tả event. Dự đoán mỗi engine không dùng engine đó trong fit, nhưng toàn bộ phân tích chưa độc lập với lựa chọn model. Đợt bổ sung nested GroupKFold đã

đánh giá cả quy trình lựa chọn bằng vòng ngoài riêng. Kết quả chưa cải thiện: cảnh báo trễ tăng từ 49 lên 53 engines. Tỷ lệ 100% từng phát cảnh báo không thay thế được phép đánh giá về thời điểm cảnh báo này.

## 8.2 Giới hạn phương pháp

Thứ nhất, FD001 chỉ gồm một điều kiện vận hành và một dạng suy giảm mô phỏng. Ma trận bổ sung với window 10 cycles cho thấy MAE transfer từ FD001 tăng lên 60,3215 cycles trên FD002, 47,3949 trên FD003 và 58,5731 trên FD004, trong khi evaluation nội bộ của các subset nằm khoảng 21,9258–28,3255 cycles. Kết quả này cho thấy khác biệt phân bố giữa các subset có ảnh hưởng đáng kể trong protocol đang xét; nó không cho phép suy ra một metric chung cho mọi điều kiện. Thứ hai, test evaluation chỉ có một điểm cắt cho mỗi engine; cách đánh giá này không mô tả sai số khi mô hình được gọi lặp lại ở nhiều cycle. Thứ ba, runtime benchmark hiện chỉ đo Pandas trên dữ liệu nhân bản trong bộ nhớ, với hai lần đo mỗi scale. PySpark mới được kiểm tra đối chiếu: kết quả tương đương trên input đã xét không phải bằng chứng về tốc độ hoặc khả năng mở rộng của hệ thống phân tán. Cuối cùng, dữ liệu không cung cấp chi phí bảo trì, downtime hoặc quy đổi cycle sang thời gian lịch; vì vậy báo cáo chưa thể chuyển metric RUL thành quyết định bảo trì.

## 8.3 Hướng nghiên cứu tiếp theo

Đợt thử window 10/20/30, 24 cấu hình HGB và ba phương án trọng số đã hoàn tất đánh giá vòng ngoài, nhưng chưa đạt các tiêu chí đã chốt. Một số cấu hình giảm MAE RUL thấp trong inner CV và làm tăng chỉ số khác. Đợt tiếp theo cần xác định trước mức đánh đổi có thể chấp nhận, hoặc thử biểu diễn đặc trưng khác trong training fold. Không suy ra từ kết quả này rằng mô hình không thể cải thiện. Với Health Index, cần huấn luyện transformer ngoài các engine được dự báo và báo cáo đồng thời tỷ lệ phát hiện lỗi, tỷ lệ bao phủ và khoảng thời gian dự báo.

Kết quả FD002–FD004 hiện đã cung cấp một phép kiểm tra chuyển sang subset khác. Các bước tiếp theo có thể đánh giá huấn luyện lại trên từng subset, chuẩn hóa theo operating condition hoặc điều chỉnh theo miền dữ liệu. Mô hình LSTM/Transformer cần một giả thuyết về biểu diễn thời gian và so sánh cùng protocol với baseline hiện tại. Khi thiếu cost, downtime và intervention, chưa thể chuyển kết quả RUL thành chính sách bảo trì.

# 9 Kết luận

Báo cáo trả lời năm câu hỏi nghiên cứu chính trên NASA C-MAPSS FD001 và một câu hỏi bổ sung về chuyển miền sang FD002–FD004. Thứ nhất, FD001 có 20.631 train observations và 13.096 test observations đáp ứng các kiểm tra schema, khóa và tính liên tục của cycle; điều này xác nhận khả năng xử lý dữ liệu theo contract, không xác nhận tính đại diện cho động cơ thực tế. Thứ hai, phân tích đầu/cuối 30 cycles ghi nhận 15 sensor bác bỏ giả thuyết không của Wilcoxon sau hiệu chỉnh BH trong cấu hình đã chọn; kết quả cần đọc cùng giả định signed-rank, độ lớn chênh lệch và số zero, không dùng làm feature selection ngoài training fold.

Thứ ba, Pandas và PySpark khớp ba boundary Silver/Gold đã kiểm tra, với sai khác tuyệt đối lớn nhất bằng 0. Runtime chỉ được đo cho Pandas; báo cáo chưa có bằng chứng so sánh tốc độ hai engine hoặc hiệu năng cluster. Thứ tư, HistGradientBoosting có mean engine MAE thấp nhất trong ba ứng viên trên GroupKFold. Sau refit, model đạt MAE 15,3490 cycles và RMSE 20,5413 cycles tại điểm cắt của 100 test engines; bootstrap CI 95% cho MAE là [12,7286; 18,0866]. Metric tại điểm cắt không mô tả toàn bộ trajectory.

Thứ năm, ngưỡng cảnh báo minh họa 30 cycles tạo ít nhất một event trên mỗi engine OOF train, nhưng chỉ 44 engine cảnh báo trước ngưỡng và 7 đúng ngưỡng; 49 engine cảnh báo sau ngưỡng. Lead time có trung vị 30 cycles, khoảng tứ phân vị 26–35 và miền 19–55. Vì OOF cũng dùng để chọn model, đây là đánh giá nội bộ, chưa chứng minh chất lượng cảnh báo độc lập hay giá trị sử dụng cho bảo trì. Ví dụ engine 1 cảnh báo tại cycle 162, trước failure proxy cycle 192 đúng 30 cycles; điều đó chưa quy định cần can thiệp khi nào.

Nhánh phụ PCA–ARIMA có MAE trung bình 0,4110, thấp hơn drift 0,7469 và last-value 0,9478 trên cùng 10 chuỗi giữ lại để kiểm tra. Tuy nhiên, ARIMA chỉ có MAE thấp hơn drift ở 7/10 engine, và tỷ lệ bao phủ thay đổi từ 21,43% đến 97,03%. Kết quả này hỗ trợ phân tích Health Index, không thay thế dự đoán RUL.

Đóng góp của báo cáo là một pipeline có thể tái lập, các phép so sánh được mô tả theo cùng evaluation protocol và các giới hạn được công bố. Ma trận bổ sung với window 10 cycles cho thấy model train trên FD001 có MAE 60,3215 trên FD002, 47,3949 trên FD003 và 58,5731 trên FD004, cao hơn evaluation nội bộ của các subset. Vì vậy, kết luận chính được giữ ở phạm vi FD001; các subset khác cho thấy cần huấn luyện lại hoặc xử lý khác biệt giữa các subset trước khi áp dụng. Phạm vi dữ liệu hiện tại chưa cho phép kết luận về lịch bảo trì tối ưu hoặc hiệu quả triển khai thực tế.

Đợt cải thiện bổ sung dùng nested GroupKFold đã kiểm tra window 10/20/30, 24 cấu hình HGB và ba phương án trọng số. Trên outer predictions, MAE RUL thấp thay đổi từ 3,6676 thành 3,6730 cycles; cảnh báo trễ tăng từ 49 lên 53 engines. Cấu hình cuối được chọn lại là baseline, nên MAE test giữ nguyên 15,3490 cycles. Kết quả này chưa đáp ứng tiêu chí cải thiện đã chốt. Các đánh đổi quan sát được trong inner CV là căn cứ cho thử nghiệm tiếp theo, không phải bằng chứng rằng dự đoán RUL không thể tốt hơn.

# Tài liệu tham khảo

[1] Apache Software Foundation. Spark SQL and DataFrames. Apache Spark documentation. Accessed 2026-09-22; implementation version not selected. URL: https://spark.apache.org/docs/latest/sql-programming-guide.html.

[2] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)*, 57(1):289–300, 1995. doi:10.1111/j.2517-6161.1995.tb02031.x.

[3] B. Efron. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1):1–26, 1979. doi:10.1214/aos/1176344552.

[4] Rob J. Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*. OTexts, Melbourne, Australia, 3 edition, 2021. Online edition, sections 5.4, 9.1, 9.5 and 9.7; accessed 2026-09-22. URL: https://otexts.com/fpp3/.

[5] Yaguo Lei, Naipeng Li, Liang Guo, Ningbo Li, Tao Yan, and Jing Lin. Machinery health prognostics: A systematic review from data acquisition to RUL prediction. *Mechanical Systems and Signal Processing*, 104:799–834, 2018. URL: https://www.sciencedirect.com/science/article/pii/S0888327017305988, doi:10.1016/j.ymssp.2017.11.016.

[6] Xiang Li, Qian Ding, and Jian-Qiao Sun. Remaining useful life estimation in prognostics using deep convolution neural networks. *Reliability Engineering & System Safety*, 172:1–11, 2018. doi:10.1016/j.ress.2017.11.021.

[7] NASA. CMAPSS jet engine simulated data. NASA Open Data Portal. Accessed 2026-09-20; project uses FD001. URL: https://data.nasa.gov/dataset/cmapss-jet-engine-simulated-data.

[8] Emmanuel Ramasso and Abhinav Saxena. Review and analysis of algorithmic approaches developed for prognostics on CMAPSS dataset. In *Annual Conference of the PHM Society*, volume 6, 2014. Issue 1. URL: https://papers.phmsociety.org/index.php/phmconf/article/view/2512, doi:10.36001/phmconf.2014.v6i1.2512.

[9] Abhinav Saxena, Jose Celaya, Bhaskar Saha, Sankalita Saha, and Kai Goebel. Metrics for offline evaluation of prognostic performance. *International Journal of Prognostics and Health Management*, 1(1), 2010. URL: https://papers.phmsociety.org/index.php/ijphm/article/view/1336, doi:10.36001/ijphm.2010.v1i1.1336.

[10] Abhinav Saxena, Kai Goebel, Don Simon, and Neil Eklund. Damage propagation modeling for aircraft engine run-to-failure simulation. In *2008 International Conference on Prognostics and Health Management*, pages 1–9. IEEE, 2008. doi:10.1109/PHM.2008.4711414.

[11] scikit-learn developers. Decomposing signals in components: Principal Component Analysis. User Guide. Accessed 2026-09-22; implementation version not selected. URL: https://scikit-learn.org/stable/modules/decomposition.html#pca.

[12] SciPy developers. scipy.stats.bootstrap. SciPy 1.16.2 Manual. Accessed 2026-09-22. URL: https://docs.scipy.org/doc/scipy-1.16.2/reference/generated/scipy.stats.bootstrap.html.

[13] SciPy developers. scipy.stats.false_discovery_control. SciPy 1.16.2 Manual. Accessed 2026-09-22. URL: https://docs.scipy.org/doc/scipy-1.16.2/reference/generated/scipy.stats.false_discovery_control.html.

[14] SciPy developers. scipy.stats.wilcoxon. SciPy 1.16.2 Manual. Accessed 2026-09-22. URL: https://docs.scipy.org/doc/scipy-1.16.2/reference/generated/scipy.stats.wilcoxon.html.

[15] statsmodels developers. statsmodels.tsa.stattools.adfuller. Online documentation. Accessed 2026-09-22; implementation version not selected. URL: https://www.statsmodels.org/stable/generated/statsmodels.tsa.stattools.adfuller.html.

[16] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945. doi:10.2307/3001968.

[17] Matei Zaharia, Mosharaf Chowdhury, Tathagata Das, Ankur Dave, Justin Ma, Murphy McCauley, Michael J. Franklin, Scott Shenker, and Ion Stoica. Resilient distributed datasets: A fault-tolerant abstraction for in-memory cluster computing. In *9th USENIX Symposium on Networked Systems Design and Implementation (NSDI 12)*, pages 15–28. USENIX Association, 2012. URL: https://www.usenix.org/conference/nsdi12/technical-sessions/presentation/zaharia.

[18] Shuai Zheng, Kosta Ristovski, Ahmed Farahat, and Chetan Gupta. Long short-term memory network for remaining useful life estimation. In *2017 IEEE International Conference on Prognostics and Health Management (ICPHM)*, pages 88–95. IEEE, 2017. doi:10.1109/ICPHM.2017.7998311.