TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP. HỒ CHÍ MINH

BÁO CÁO CUỐI KỲ

Môn học: Phân tích dữ liệu lớn

Phân tích dữ liệu cảm biến và dự đoán tuổi thọ hữu ích còn lại của động cơ

NASA C-MAPSS FD001

Đề tài 8: Phân tích dữ liệu IoT và bảo trì dự đoán

Học viên thực hiện:	Phan Nguyễn Mai Phương
Mã số học viên:	25002711
Ngành:	Khoa học máy tính

Bản đang thực hiện – cập nhật ngày 22/09/2026

TP. Hồ Chí Minh, tháng 9 năm 2026

Tóm tắt trạng thái báo cáo

Báo cáo nghiên cứu bài toán dự đoán Remaining Useful Life (RUL, tuổi thọ hữu ích còn lại) theo đơn vị cycle trên NASA C-MAPSS FD001. Đến ngày 22/09/2026, repository đã có dữ liệu nguồn, data contract (đặc tả dữ liệu và các điều kiện hợp lệ), package kiểm tra dữ liệu, nhãn RUL cho train và các artifact EDA (Exploratory Data Analysis, phân tích khám phá dữ liệu) ban đầu. Báo cáo validation ghi nhận 20.631 quan sát train và 13.096 quan sát test; mỗi tập có 100 động cơ.

Bản hiện tại trình bày bài toán, cơ sở lý thuyết và nghiên cứu liên quan, cách kiểm tra chất lượng, thiết kế phương pháp và một số quan sát EDA có nguồn đối chiếu. Protocol thống kê đã xác định so sánh trung bình 30 cycles đầu với 30 cycles cuối của từng động cơ; helper tạo cặp train theo engine–sensor đã được kiểm thử, nhưng kiểm định chưa được thực hiện. Pipeline Silver/Gold, mô hình RUL, ARIMA và dashboard chưa hoàn thành. Vì chưa có dự đoán và metric mô hình, báo cáo chưa đưa ra kết luận về độ chính xác hoặc hiệu quả bảo trì.

Tiến độ được ghi theo công việc và bằng chứng, không quy đổi thành phần trăm hoàn thành khi chưa có cơ sở ước lượng. Các ngày ghi nhận là mốc có tài liệu hoặc artifact hỗ trợ, không phải lịch sử giờ công được tái dựng. Nội dung về phương pháp chưa triển khai được đánh dấu rõ để tiếp tục cập nhật sau mỗi mốc.

Mục lục

Tóm tắt trạng thái báo cáo **i**

1 Tiến độ thực hiện và kế hoạch tiếp theo **1**
1.1 Cách ghi nhận tiến độ . . . 1
1.2 Các mốc tiếp theo và điều kiện hoàn thành . . . 2

2 Bài toán, mục tiêu và phạm vi **4**
2.1 Bài toán nghiên cứu . . . 4
2.2 Câu hỏi và giới hạn nghiên cứu . . . 4
2.3 Liên hệ với yêu cầu môn học . . . 4

3 Dữ liệu và kiểm soát chất lượng **5**
3.1 Nguồn dữ liệu và lý do lựa chọn . . . 5
3.2 Các kiểm tra đã triển khai và lý do . . . 5
3.3 Tính toàn vẹn và giới hạn của validation . . . 6

4 Cơ sở lý thuyết và nghiên cứu liên quan **7**
4.1 Prognostics, RUL và phạm vi so sánh . . . 7
4.2 Biểu diễn chuỗi bằng trailing window . . . 7
4.3 Baseline và Ridge regression . . . 8
4.4 Histogram gradient boosting . . . 8
4.5 Đơn vị độc lập và đánh giá theo engine . . . 8
4.6 Paired analysis, bootstrap và nhiều kiểm định . . . 9
4.7 Health Index từ PCA và phân tích ARIMA . . . 10
4.8 Spark, lưu trữ và giới hạn của benchmark . . . 10

5 Thiết kế phương pháp và lý do lựa chọn **11**
5.1 Luồng xử lý và trạng thái triển khai . . . 11
5.2 EDA theo đơn vị động cơ . . . 12
5.3 Đặc trưng từ window: phần dự kiến . . . 12
5.4 Mô hình và đánh giá: phần dự kiến . . . 12
5.5 Thống kê và ARIMA: phần dự kiến . . . 13

6 Protocol thống kê suy luận mốc 2 **14**
6.1 Mục tiêu, phạm vi và trạng thái quyết định . . . 14
6.2 Định nghĩa cặp đầu/cuối và ví dụ . . . 14
6.3 Đại lượng cần báo cáo và điều kiện diễn giải . . . 15
6.4 Cấu hình M2.0 đã chốt trước triển khai . . . 16
6.5 Đầu ra và điều kiện nghiệm thu . . . 16

7 Kết quả hiện có và diễn giải **18**
7.1 Kết quả validation . . . 18
7.2 Tuổi thọ động cơ trên train . . . 18
7.3 Sensor hằng và correlation theo engine . . . 19

7.4 Phạm vi bằng chứng EDA 20

8 Khó khăn, bài học và giới hạn hiện tại 21

9 Khai báo sử dụng AI/LLM 21

Tài liệu tham khảo 22

A Bảng đối chiếu nội dung và bằng chứng 24

B Thông tin cần bổ sung trước khi nộp 25

Danh mục hình

1 Luồng dữ liệu và trạng thái triển khai 11
2 Protocol thống kê đầu/cuối vòng đời 15
3 Phân phối tuổi thọ động cơ trên train 18
4 Phân phối correlation Spearman sensor–RUL theo engine 20

Danh mục bảng

1 Nhật ký công việc đến ngày 22/09/2026. 1
2 Công việc còn lại; thứ tự phụ thuộc, không phải lịch cam kết. 2
3 Quy mô FD001 đã ghi nhận trong báo cáo validation. 5
4 Thống kê tuổi thọ của 100 train engines 18
5 Correlation Spearman theo engine: các dòng minh họa 19

1 Tiến độ thực hiện và kế hoạch tiếp theo

1.1 Cách ghi nhận tiến độ

Mỗi mốc ghi rõ công việc, lý do thực hiện, đầu ra có thể kiểm tra, trạng thái và phần còn lại. Trạng thái "đã có bằng chứng" chỉ áp dụng cho phạm vi đã được kiểm tra; việc một file tồn tại chưa đủ để kết luận toàn bộ mốc đã hoàn thành. Báo cáo được cập nhật cùng kết quả phân tích, thay vì đợi hoàn tất mô hình mới tổng hợp.

Bảng 1: Nhật ký công việc đến ngày 22/09/2026.

Mốc ghi nhận	Công việc	Lý do và bằng chứng	Trạng thái / còn lại
20–21/09/2026	Chuẩn bị FD001 và tài liệu nền tảng	Giữ một nguồn dữ liệu có lịch sử đến khi hỏng để xác định RUL. Đã có file raw, ghi chú provenance, danh mục tài liệu và phạm vi nghiên cứu.	Đã có; cần tiếp tục đọc và đối chiếu nguồn khi viết cơ sở lý thuyết.
22/09/2026	Kiểm tra dữ liệu và tạo train RUL	Kiểm tra trước phân tích để tránh tính toán trên schema hoặc khóa sai. JSON validation đạt; 20.631 train targets khớp 20.631 observations.	Đã có bằng chứng cho raw và train targets; chưa bao gồm rolling features.
22/09/2026	EDA mô tả chỉ dùng train	Tìm hiểu phân phối và tín hiệu trước khi xây dựng đặc trưng. Biên bản EDA ghi 69 tests đạt; notebook chạy từ kernel mới, 12 CSV và 11 PNG tái lập được.	Hoàn thành mốc EDA mô tả; chưa có thống kê suy luận hoặc feature selection.
22/09/2026	Khởi tạo báo cáo LaTeX và nhật ký tiến độ	Lưu lập luận cùng bằng chứng ngay khi thực hiện để tránh mất lý do lựa chọn. Có nguồn theo phần, sơ đồ, bảng tiến độ và bản PDF.	Bản đang thực hiện; các kết quả mô hình và đánh giá cuối chưa có.
22/09/2026	Bổ sung cơ sở lý thuyết và protocol thống kê	Gắn nguồn cho phương pháp đã chọn; định nghĩa mean 30 cycles đầu/cuối, chênh lệch theo engine và giả định suy luận. Có phần lý thuyết, protocol và sơ đồ riêng.	Hoàn thành nội dung thiết kế của đợt này; kiểm định chưa chạy.

Mốc ghi nhận	Công việc	Lý do và bằng chứng	Trạng thái / còn lại
22/09/2026	Tạo contract dữ liệu cặp mốc 2	Hiện thực hóa helper chỉ nhận train, tạo một cặp 30 cycles đầu/cuối cho từng engine–sensor và kiểm tra khóa, ranh giới, thứ tự, số liệu. 17 tests tập trung và toàn bộ 86 tests đạt; test trên raw FD001 xác nhận 2.100 cặp trong bộ nhớ.	Đã có bằng chứng tạo cặp; chưa có artifact thống kê được lưu.
22/09/2026	Chốt cấu hình thống kê M2.0	Người dùng chốt mean paired difference, percentile bootstrap 10.000 resamples, Wilcoxon permutation 100.000 resamples, BH FDR $q = 0{,}05$, seed 42 và quy tắc all-zero/NA trước khi xem kết quả suy luận.	Cấu hình đã chốt trong protocol; chưa tạo bảng, hình hoặc p-value.
22/09/2026	Hiện thực hóa helper suy luận M2.2	Thêm cấu hình M2.0, bootstrap mean CI, Wilcoxon permutation, BH FDR, validator bảng suy luận và fixtures tính tay. Focused tests đạt 24 tests; full suite đạt 93 tests. Raw FD001 được kiểm bằng cấu hình resample nhỏ trong bộ nhớ.	Có helper/validator; chưa có notebook, CSV/PNG, metadata hoặc kết luận thống kê.

1.2 Các mốc tiếp theo và điều kiện hoàn thành

Bảng 2: Công việc còn lại; thứ tự phụ thuộc, không phải lịch cam kết.

Công việc	Vì sao cần thực hiện	Bằng chứng cần bổ sung
Phân tích thống kê suy luận	Phân biệt quan sát mô tả với kết luận thống kê; tránh chọn tín hiệu chỉ từ vài hình thuận lợi.	Đã có helper tạo cặp, helper suy luận và cấu hình M2.0; cần chạy notebook, xuất artifact, metadata, hình và diễn giải giới hạn.
ETL Pandas/PySpark	Thể hiện chuẩn hóa, tích hợp và lưu trữ; so sánh tính đúng giữa hai cách xử lý.	Parquet/SQLite; số dòng trước/sau; parity theo khóa và giá trị; benchmark có cấu hình máy và thời gian đo.

Công việc	Vì sao cần thực hiện	Bằng chứng cần bổ sung
Đặc trưng và validation	Chuyển chuỗi thành đầu vào mô hình trong khi giữ ranh giới động cơ và quá khứ.	Window đủ 30 cycles; fold không trùng engine; preprocessing chỉ fit training fold.
Mô hình và đánh giá cuối	Xác định khả năng dự đoán trên cùng protocol thay vì suy ra từ correlation.	Kết quả cross-validation, cấu hình được chọn, đúng 100 dự đoán test trước khi join nhãn; metric và khoảng tin cậy.
ARIMA và dashboard	Bổ sung phân tích chuỗi thời gian và cách đọc kết quả cảnh báo.	Forecast và diagnostics trên Health Index; dashboard kiểm tra được theo từng engine.
Hoàn thiện báo cáo	Liên kết kết quả, khó khăn và giới hạn với yêu cầu môn học.	PDF đủ citation/hình, demo và slide; kiểm tra tái lập toàn bộ.

Ví dụ cập nhật một mốc: khi ETL đã xuất Parquet nhưng chưa đối chiếu Pandas/PySpark, trạng thái vẫn là “đang thực hiện”. Chỉ khi có kết quả parity mới ghi hoàn thành phần tương đương dữ liệu; kết quả đó không đồng thời chứng minh PySpark nhanh hơn.

2 Bài toán, mục tiêu và phạm vi

2.1 Bài toán nghiên cứu

Đề tài phân tích chuỗi cảm biến động cơ nhằm ước lượng số cycle còn lại trước khi hỏng. Đầu vào tại cycle t là các quan sát đã có đến t của một động cơ; đầu ra là RUL dự đoán tại cycle đó. Supervised regression (hồi quy có giám sát) là cách mô hình hóa biến mục tiêu dạng số. Mục tiêu báo cáo là dự đoán RUL và giải thích bằng chứng cảnh báo sớm, không chỉ trình bày một thuật toán hồi quy.

Đối với train, đặt T_i là cycle cuối của động cơ i trong lịch sử đầy đủ đến khi hỏng. Nhãn được xác định bởi

$$y_{i,t} = T_i - t, \qquad 1 \leq t \leq T_i. \tag{1}$$

Ví dụ minh họa: một động cơ kết thúc ở cycle 200 có RUL bằng 30 cycles tại cycle 170 và bằng 0 tại cycle 200. Đây là ví dụ tính nhãn, không phải kết quả dự đoán.

Lịch sử test bị cắt trước khi hỏng nên không được lấy cycle cuối quan sát của test làm T_i. Mục tiêu đánh giá cuối là một dự đoán tại cycle cuối quan sát cho mỗi test engine. Bộ nhãn chính thức được tách khỏi quá trình lựa chọn mô hình.

2.2 Câu hỏi và giới hạn nghiên cứu

Các câu hỏi chính gồm: dữ liệu có đáp ứng contract không; cảm biến biến đổi thế nào theo vòng đời; đặc trưng từ 30 cycles gần nhất dự đoán RUL được đến mức nào; và kết quả có thể trình bày minh bạch ra sao. Bản hiện tại cung cấp bằng chứng cho câu hỏi chất lượng dữ liệu và một phần EDA, chưa trả lời được câu hỏi độ chính xác mô hình.

FD001 không có chi phí bảo trì, downtime hoặc lịch can thiệp. Do đó, RUL không tự động xác định thời điểm bảo trì tối ưu. Ngưỡng cảnh báo dự kiến 30 cycles chỉ dùng để minh họa cách đọc kết quả. Cycle cũng không được đổi thành giờ hoặc ngày vì chưa có thông tin quy đổi.

2.3 Liên hệ với yêu cầu môn học

Theo tài liệu môn học, tiêu chí quy trình xử lý dữ liệu chiếm 40%, trực quan hóa và phân tích 25%, chất lượng mã nguồn 20%, trình bày và phản biện 15%. Vì vậy, báo cáo dành nội dung riêng cho provenance, contract, ETL, lưu trữ và tái lập, bên cạnh mô hình dự đoán. Các trọng số này là tiêu chí chấm điểm, không phải tỷ lệ hoàn thành hiện tại.

Nguồn yêu cầu là hai tài liệu *Đề cương môn học Phân tích dữ liệu lớn* và *Danh sách đề tài báo cáo cuối kỳ*, được đối chiếu ngày 22/09/2026. Yêu cầu ghi rõ tiến độ được bổ sung theo trao đổi ngày này. Chưa có mẫu bìa bắt buộc hoặc tên giảng viên được xác nhận trong các nguồn đã đọc; bản hiện tại không tự điền các thông tin đó.

3 Dữ liệu và kiểm soát chất lượng

3.1 Nguồn dữ liệu và lý do lựa chọn

NASA C-MAPSS mô phỏng các chuỗi vận hành đến khi hỏng của động cơ turbofan. Nguồn dữ liệu được ghi nhận tại NASA Open Data [6]; tài liệu nền tảng đi kèm bộ dữ liệu là công trình của Saxena và cộng sự [9]. Mô tả đi kèm file raw xác định FD001 có một điều kiện vận hành và một dạng suy giảm High-Pressure Compressor (HPC, máy nén áp suất cao).

FD001 được chọn vì có lịch sử train đầy đủ đến khi hỏng, test bị cắt và nhãn đánh giá tách riêng, phù hợp với cách xây dựng bài toán RUL. Chỉ sử dụng một tập con giúp kiểm soát phạm vi thực nghiệm và làm rõ từng bước xử lý. Đổi lại, bằng chứng chỉ áp dụng trong điều kiện mô phỏng đang xét; không đủ để khẳng định khả năng khái quát trên động cơ thực tế hoặc điều kiện vận hành khác.

Bảng 3: Quy mô FD001 đã ghi nhận trong báo cáo validation.

Thành phần	Số dòng	Động cơ	Ý nghĩa
Train	20.631	100	Lịch sử đến khi hỏng
Test	13.096	100	Lịch sử bị cắt trước khi hỏng
Test labels	100	100	RUL tại cycle cuối quan sát

Mỗi dòng raw có 26 trường: engine ID, cycle, 3 operational settings và 21 sensors. Reader bổ sung cột `split`, tạo bảng observations có 27 cột. Khóa là bộ ba `(split, engine_id, cycle)`: train engine 1 và test engine 1 không phải cùng một thực thể. Nhãn test chỉ được kiểm tra cấu trúc riêng trong báo cáo integrity; việc này không phải đánh giá mô hình.

3.2 Các kiểm tra đã triển khai và lý do

Reader và validator thực hiện kiểm tra số trường, schema, kiểu số hữu hạn, bảng không rỗng, split hợp lệ, khóa duy nhất và cycle liên tục trong từng động cơ. Profile FD001 đối chiếu thêm số dòng, ID động cơ và cycle bắt đầu. Với train targets, validator kiểm tra đủ khóa và đối chiếu Công thức 1.

Các kiểm tra được đặt trước EDA vì dữ liệu sai có thể tạo ra thống kê hợp lệ về mặt tính toán nhưng sai về ý nghĩa. Chẳng hạn, chuỗi cycle $1, 2, 4$ không được coi là ba bước liên tiếp khi xây window. Hai dòng cùng khóa cũng không được giữ lại như hai phép đo độc lập. Khi phát hiện lỗi, package báo `ContractError`; không tự điền dữ liệu, xóa dòng hoặc chỉnh raw để làm validation đạt.

3.3 Tính toàn vẹn và giới hạn của validation

Báo cáo JSON lưu SHA-256 của input để nhận biết phiên bản dữ liệu đã đọc. Dấu vân tay này chỉ hỗ trợ đối chiếu; tự tính checksum không chứng minh nguồn gốc file là chính xác. Việc kiểm tra row count và cycle continuity cũng không đủ phát hiện mọi thay đổi giá trị sensor.

Đặc biệt, một chuỗi train bị cắt đuôi nhưng vẫn liên tục có thể tạo ra RUL sai nếu bị hiểu nhầm là lịch sử đầy đủ. Vì vậy, giữ raw bất biến và ghi nguồn dữ liệu là điều kiện đi kèm công thức tính nhãn. API test labels được tách riêng nhưng chưa có cơ chế phân quyền filesystem ngăn mọi chương trình đọc file; ranh giới không dùng test để chọn mô hình còn phải được kiểm tra khi xây pipeline mô hình.

4 Cơ sở lý thuyết và nghiên cứu liên quan

Phần này giải thích các phương pháp thuộc phạm vi đã chọn. Công thức và kết quả từ tài liệu được phân biệt với cấu hình của báo cáo; việc một phương pháp có cơ sở lý thuyết không đồng nghĩa đã có kết quả trên FD001 trong repository.

4.1 Prognostics, RUL và phạm vi so sánh

Prognostics nghiên cứu diễn biến suy giảm và thời gian còn lại đến trạng thái hỏng. Với FD001, lịch sử train chạy đến khi hỏng cho phép tạo nhãn theo Công thức 1; test chỉ cung cấp một phần lịch sử. Nghiên cứu của Saxena và cộng sự mô tả mô phỏng suy giảm và bài toán đánh giá prognostics [9]. Tổng quan C-MAPSS của Ramasso và Saxena giúp phân biệt các tập con, điều kiện vận hành và protocol [7]. Vì vậy, cùng dùng tên C-MAPSS chưa đủ để so sánh trực tiếp metric giữa hai nghiên cứu.

Li và cộng sự nghiên cứu CNN với đầu vào chuỗi đa cảm biến [5]. Báo cáo sử dụng công trình này để tham khảo cách tạo window và ảnh hưởng của nhãn, không xem CNN là mô hình đã triển khai. Window 30 cycles là lựa chọn ban đầu đã chốt, chưa phải độ dài tối ưu. Nhãn chính của báo cáo là raw RUL; cap 125 chỉ thuộc phân tích độ nhạy được tách riêng. Kết quả dùng nhãn có cap hoặc loại bớt test engines không được xếp hạng trực tiếp với đánh giá raw RUL trên toàn bộ test.

Đánh giá prognostics còn quan tâm dự đoán xuất hiện sớm đến mức nào và thay đổi ra sao theo thời gian [8]. Một dự đoán cuối chuỗi cho mỗi test engine đo chất lượng tại thời điểm cắt; nó không thay thế đánh giá cả trajectory. Báo cáo chưa có chi phí can thiệp, nên ngưỡng cảnh báo 30 cycles chỉ minh họa cách sử dụng đầu ra, không phải lịch bảo trì tối ưu.

4.2 Biểu diễn chuỗi bằng trailing window

Gọi $\mathbf{x}_{i,t} \in \mathbb{R}^p$ là vector gồm p sensor được giữ của engine i tại cycle t. Với $w = 30$, một mẫu đầu vào chỉ chứa các quan sát hiện có:

$$W_{i,t} = [\mathbf{x}_{i,t-w+1}, \ldots, \mathbf{x}_{i,t}]^\mathsf{T} \in \mathbb{R}^{w \times p}, \qquad t \geq w. \tag{2}$$

Khác cách đưa toàn bộ ma trận vào CNN [5], thiết kế hiện tại tổng hợp mỗi sensor thành sáu đặc trưng: last, mean, standard deviation, min, max và linear slope. Nếu giữ p sensor thì biểu diễn có $6p$ đặc trưng; p phải được xác định trong training fold, không lấy từ việc nhìn toàn bộ train để chọn biến trước cross-validation.

Với các giá trị $z_1, \ldots, z_w$ của một sensor trong window, slope của hồi quy tuyến tính theo vị trí k là

$$b = \frac{\sum_{k=1}^{w}(k - \bar{k})(z_k - \bar{z})}{\sum_{k=1}^{w}(k - \bar{k})^2}. \tag{3}$$

Slope mô tả xu hướng tuyến tính cục bộ; mean và độ phân tán mô tả mức tín hiệu và biến động. Đây là diễn giải của đặc trưng, chưa chứng minh lợi ích dự đoán. Ví dụ, tại cycle 170, window gồm cycles 141–170; không dùng cycle 171 hoặc tuổi thọ đầy đủ của engine làm đầu vào.

4.3 Baseline và Ridge regression

Naive baseline trả về median của các nhãn training được protocol cho phép. Nó tạo mốc so sánh khi không sử dụng sensor. Cách lấy mẫu và trọng số nhãn phải được ghi cùng cấu hình, vì engine có nhiều window sẽ đóng góp nhiều nhãn nếu gộp trực tiếp.

Ridge dùng hàm dự đoán tuyến tính $\widehat{y} = \beta_0 + \mathbf{z}^\mathsf{T}\boldsymbol{\beta}$ với vector đặc trưng $\mathbf{z}$. Hàm mục tiêu gồm sai số bình phương và L2 regularization [13]:

$$\min_{\beta_0,\boldsymbol{\beta}} \sum_{n=1}^{N} (y_n - \beta_0 - \mathbf{z}_n^\mathsf{T}\boldsymbol{\beta})^2 + \lambda \|\boldsymbol{\beta}\|_2^2, \qquad \lambda \geq 0. \tag{4}$$

Trong biểu thức này intercept không bị phạt. Regularization hạn chế độ lớn hệ số, hữu ích khi các đặc trưng liên quan với nhau. Scaler cần fit trong training fold để các thang đo không chi phối mức phạt. Giá trị λ chưa được chọn; việc tối ưu loss bình phương cũng không đồng nghĩa MAE validation đã được tối ưu.

4.4 Histogram gradient boosting

Gradient boosting xây dựng hàm dự đoán bằng cách cộng dần các cây hồi quy, mỗi cây bổ sung thông tin để giảm loss của mô hình hiện tại. Một biểu diễn khái quát là

$$F_M(\mathbf{z}) = F_0(\mathbf{z}) + \eta \sum_{m=1}^{M} h_m(\mathbf{z}), \tag{5}$$

với h_m là cây thứ m, M là số vòng boosting và η là learning rate. HistGradientBoosting chia giá trị đặc trưng thành các bins để tìm phép tách trên histogram [12]. Mô hình có thể biểu diễn quan hệ phi tuyến và tương tác mà Ridge không mô tả trực tiếp. Số cây, độ phức tạp cây và learning rate còn phải chọn bằng validation; chưa có cấu hình hoặc kết quả để khẳng định mô hình này tốt hơn Ridge.

4.5 Đơn vị độc lập và đánh giá theo engine

Các window của cùng engine có thể chồng lấn và phụ thuộc thời gian. GroupKFold giữ một group ngoài training ở mỗi fold [10]; trong báo cáo, group là engine ID. Việc này đánh giá khả năng áp dụng cho engine chưa xuất hiện trong training, còn scaler, lựa chọn sensor và PCA đều phải học lại bên trong mỗi fold.

Với một dự đoán tại cycle cuối của mỗi test engine, đặt $e_i = \widehat{y}_i - y_i$ và m là số engine được đánh giá:

$$\text{MAE} = \frac{1}{m}\sum_{i=1}^{m}|e_i|, \qquad \text{RMSE} = \sqrt{\frac{1}{m}\sum_{i=1}^{m}e_i^2}. \tag{6}$$

Hai metric đều có đơn vị cycle và càng nhỏ càng tốt; RMSE nhạy hơn với sai số lớn. NASA asymmetric score bổ sung cách phạt khác nhau cho dự đoán sớm và muộn. Theo Công thức (5) trong Li và cộng sự [5], với cùng quy ước $e_i = \widehat{y}_i - y_i$:

$$S = \sum_{i=1}^{m} s(e_i), \qquad s(e) = \begin{cases} \exp(-e/13) - 1, & e < 0, \\ \exp(e/10) - 1, & e \geq 0. \end{cases} \tag{7}$$

Score càng nhỏ càng tốt; dự đoán RUL quá lớn ($e > 0$) bị phạt mạnh hơn dự đoán quá nhỏ với cùng độ lớn sai số. Công thức cộng score theo engine, không lấy trung bình; vì vậy số engine phải giống nhau khi đối chiếu. Khi triển khai cần kiểm thử cả hai dấu sai số theo quy ước này. Với nhiều dự đoán trên một validation engine, cách tổng hợp MAE được quy định tại Mục 5.

4.6 Paired analysis, bootstrap và nhiều kiểm định

Paired analysis ghép hai phép đo của cùng engine để phân tích thay đổi trong engine. Đại lượng cần ước lượng phải được nêu trước, chẳng hạn trung bình chênh lệch cuối trừ đầu vòng đời. Effect size theo đơn vị gốc biểu diễn mức thay đổi; p-value trả lời một câu hỏi khác về mức tương thích với giả thuyết không.

Wilcoxon signed-rank sử dụng thứ hạng của độ lớn các chênh lệch và dấu của chúng [18, 16]. Kiểm định cần xem xét tính độc lập giữa các cặp và giả định đối xứng của phân phối chênh lệch; "nonparametric" không có nghĩa là không cần giả định. Ties và chênh lệch bằng 0 ảnh hưởng phân phối thống kê và cách tính p-value. Không diễn giải Wilcoxon thành kiểm định trực tiếp trung bình chênh lệch.

Bootstrap ước lượng biến thiên của một thống kê bằng lấy mẫu lại có hoàn lại [3, 14]. Trong thiết kế này, đơn vị lấy mẫu lại là engine: giữ cặp đầu/cuối cùng nhau để bảo toàn quan hệ ghép cặp. Khoảng tin cậy 95% mô tả tính bao phủ qua các lần lấy mẫu theo giả định; nó không phải xác suất 95% rằng một tham số cố định nằm trong khoảng đã tính. Không coi các cycles liên tiếp là các đơn vị độc lập để tạo khoảng tin cậy hẹp hơn.

Với nhiều sensor, Benjamini–Hochberg kiểm soát False Discovery Rate (FDR, tỷ lệ phát hiện sai kỳ vọng) dưới những điều kiện phù hợp [2, 15]. Nếu sắp K p-values thành $p_{(1)} \leq \cdots \leq p_{(K)}$, quy tắc step-up tìm chỉ số lớn nhất k thỏa $p_{(k)} \leq kq/K$, với q là mức FDR đã định trước. Bảo đảm không áp dụng cho mọi cấu trúc phụ thuộc; sensor tương quan cần được thảo luận khi diễn giải. Khoảng tin cậy riêng từng sensor không tự trở thành khoảng tin cậy đồng thời sau hiệu chỉnh p-value.

4.7 Health Index từ PCA và phân tích ARIMA

PCA tìm các phương chiếu trực giao có phương sai lớn từ dữ liệu đã được xử lý [11]. Nếu dùng thành phần đầu làm Health Index thì $h_{i,t} = \mathbf{v}_1^{\mathsf{T}} \widetilde{\mathbf{x}}_{i,t}$, với $\mathbf{v}_1$ và phép chuẩn hóa được học từ training fold. Đây là cách xây dựng ứng viên Health Index; số thành phần và quy ước chiều tăng/giảm còn cần đặc tả. Phương sai lớn không tự chứng minh ý nghĩa sức khỏe hoặc tính đơn điệu; dấu của vector riêng cũng không xác định ý nghĩa suy giảm.

ARIMA(p, d, q) kết hợp autoregression bậc p, sai phân bậc d và moving average bậc q [4]. Viết $u_t = (1 - B)^d h_t$, trong đó $Bh_t = h_{t-1}$, một dạng mô hình là

$$u_t = c + \sum_{j=1}^{p} \phi_j u_{t-j} + \varepsilon_t + \sum_{j=1}^{q} \theta_j \varepsilon_{t-j}. \tag{8}$$

Sai phân hỗ trợ xử lý tính không dừng nhưng không được tăng bậc tùy ý. ADF kiểm định giả thuyết có unit root [17]; Ljung–Box khảo sát autocorrelation của residual đến các lag được chọn [4]. Không bác bỏ giả thuyết không không chứng minh residual độc lập. Forecast MAE/RMSE và coverage của prediction interval cần được đánh giá trên đoạn chuỗi chưa dùng fit. Coverage là tỷ lệ quan sát nằm trong khoảng dự đoán, khác khoảng tin cậy của một metric tổng hợp.

4.8 Spark, lưu trữ và giới hạn của benchmark

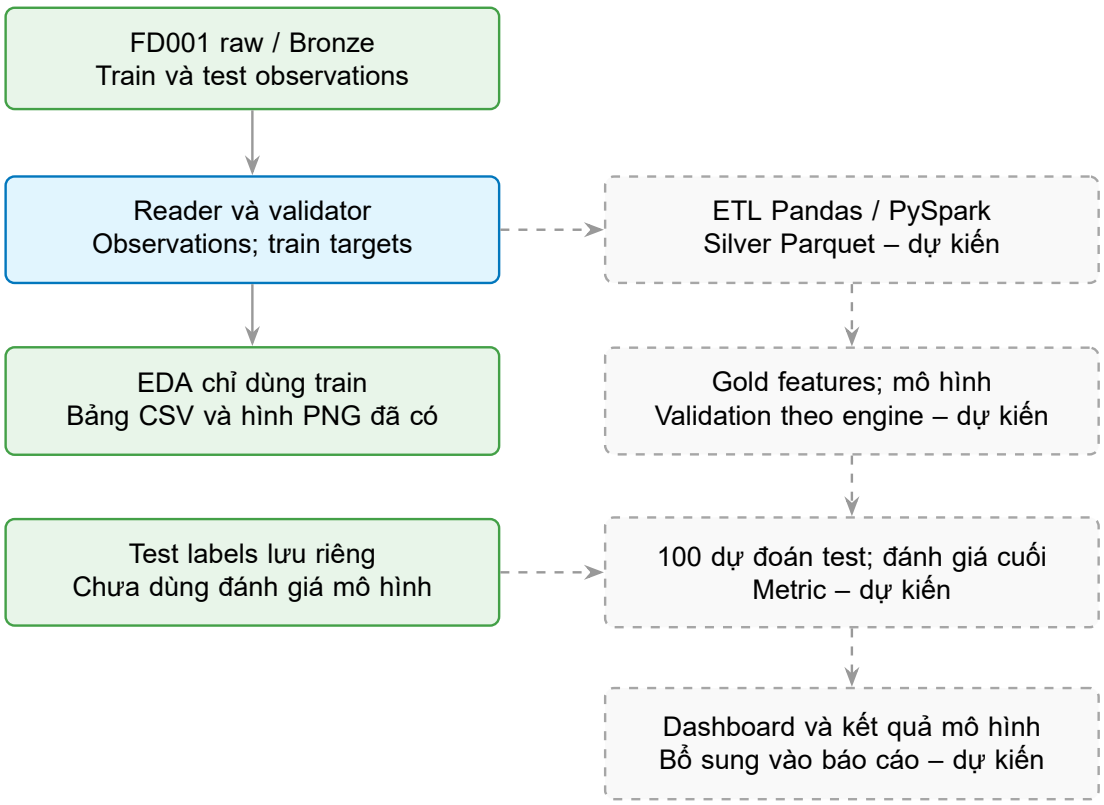
RDD là nền tảng trừu tượng của Spark cho xử lý dữ liệu phân tán và khả năng phục hồi tính toán [19]. Với dữ liệu có schema, Spark SQL/DataFrame cung cấp biểu diễn và các phép xử lý có cấu trúc [1]. Báo cáo dùng nguồn này cho phần ETL; không suy từ lý thuyết phân tán rằng Spark chắc chắn nhanh hơn Pandas trên FD001.

Bronze/Silver/Gold là cách tổ chức dữ liệu của báo cáo. Parquet phục vụ lưu bảng phân tích; SQLite phục vụ truy vấn và trình bày local. Bằng chứng cần có là khả năng đọc lại artifact, tính tương đương khóa/giá trị và thời gian đo theo cấu hình công bố. Dữ liệu nhân bản chỉ dùng benchmark xử lý, không tăng số mẫu khoa học độc lập. Streaming và LSTM vẫn là hướng đọc bổ sung, không mở rộng phạm vi thực nghiệm đã chốt.

5 Thiết kế phương pháp và lý do lựa chọn

5.1 Luồng xử lý và trạng thái triển khai

Hình 1 phân biệt phần đã có artifact với phần dự kiến. Dữ liệu raw là đầu vào bất biến. Hiện tại, reader/validator tạo observations và train targets trong bộ nhớ; EDA xuất bảng và hình trực tiếp từ train. Silver và Gold là thiết kế cho giai đoạn tiếp theo, chưa phải artifact đã được tạo.



Hình 1: Luồng dữ liệu: đường liền thể hiện nhánh đã có artifact; đường và khung nét đứt thể hiện phần dự kiến. Test labels chỉ nối vào bước đánh giá cuối.

Bronze giữ nguồn để truy vết; Silver dự kiến lưu observations có kiểu dữ liệu trong Parquet; Gold dự kiến lưu đặc trưng, dự đoán và metric trong Parquet/SQLite. Cách tách lớp giúp phân biệt dữ liệu gốc với dữ liệu suy ra và xác định bước gây mất hoặc nhân bản dòng. Pandas phục vụ xử lý local và EDA; PySpark dự kiến tái hiện ETL để so sánh tính đúng và khảo sát khả năng mở rộng. Chưa có phép đo để kết luận công cụ nào nhanh hơn.

FD001 có dung lượng nhỏ. Benchmark dự kiến ở mức $1\times$, $10\times$ và $100\times$ chỉ đánh giá chi phí xử lý dữ liệu; bản nhân dữ liệu sẽ đổi engine ID và tách khỏi phân tích khoa học. Nhân bản cùng quan sát không tạo thêm động cơ độc lập để huấn luyện hoặc thu hẹp khoảng tin cậy.

5.2 EDA theo đơn vị động cơ

EDA hiện chỉ sử dụng train nhằm tìm hiểu dữ liệu mà không dựa vào test để quyết định phương pháp. Phân phối tuổi thọ tính mỗi động cơ một lần. Ngược lại, histogram RUL theo observations cho động cơ sống lâu nhiều quan sát hơn; hai cách tổng hợp trả lời hai câu hỏi khác nhau và không được diễn giải thay thế nhau.

Correlation giữa sensor và RUL được tính bằng Spearman riêng trong từng engine, sau đó tóm tắt phân phối giữa các engine. Lựa chọn này khảo sát liên hệ đơn điệu và tránh để số dòng của một động cơ quyết định trực tiếp trọng số trong bảng tổng hợp correlation. Tuy vậy, dependence theo thời gian vẫn tồn tại; correlation mô tả chưa chứng minh quan hệ nhân quả hoặc hiệu quả dự đoán ngoài mẫu.

Sensor hằng có correlation không xác định, được giữ dưới dạng NaN thay vì gán 0. Ba engine minh họa được chọn gần các quartile tuổi thọ nhất, nếu hòa thì dùng ID nhỏ hơn. Quy tắc này được xác định theo tuổi thọ, không chọn dựa trên đường sensor đẹp. Quỹ đạo hiện có biểu diễn giá trị gốc theo cycle, không smooth; mỗi ô dùng thang đo riêng. Ba engine minh họa không được xem là mẫu đại diện thống kê. Tuổi thọ đầy đủ dùng trong phân tích sau khi quan sát toàn chuỗi không được đưa vào feature dự đoán tại cycle hiện tại.

5.3 Đặc trưng từ window: phần dự kiến

Biểu diễn chính đã chọn là trailing window (cửa sổ chỉ chứa hiện tại và quá khứ) dài 30 cycles. Ví dụ, dự đoán tại cycle 170 dùng các cycle 141–170 của cùng engine. Đặc trưng dự kiến gồm giá trị cuối, mean, standard deviation, min, max và linear slope của sensor không hằng được xác định trong training fold.

Window tổng hợp biến thiên gần thời điểm dự đoán và giảm phụ thuộc vào một quan sát nhiễu đơn lẻ. Độ dài 30 là cấu hình ban đầu trong phạm vi nghiên cứu, chưa được chứng minh tối ưu. Slope biểu diễn chiều và tốc độ thay đổi tuyến tính trong window; thống kê phân tán bổ sung thông tin biến động. Quy ước rolling standard deviation và cách xử lý test engine có ít hơn 30 cycles còn phải chốt trước triển khai. Quy ước sample standard deviation của EDA không tự động trở thành quy ước của feature transformer.

5.4 Mô hình và đánh giá: phần dự kiến

Naive median-RUL baseline cung cấp mốc so sánh khi không dùng tín hiệu sensor. Ridge là baseline tuyến tính có regularization; HistGradientBoostingRegressor là ứng viên phi tuyến. So sánh này nhằm đánh giá tín hiệu mang lại lợi ích gì so với dự đoán đơn giản và mức cải thiện khi cho phép quan hệ phi tuyến. Chưa có hyperparameter search hoặc kết quả để xếp hạng ba phương pháp.

Model selection dự kiến dùng 5-fold GroupKFold theo `engine_id`. Các window liền nhau của một engine có thể dùng chung phần lớn quan sát: hai window 141–170 và 142–171 dùng

chung 29 cycles. Nếu chia ngẫu nhiên theo dòng, những window gần như giống nhau có thể nằm ở cả train và validation, gây data leakage (rò rỉ dữ liệu). Vì vậy, toàn bộ window của một engine phải thuộc cùng fold; scaler, lựa chọn sensor và mô hình chỉ fit trên training fold.

Metric chọn mô hình dự kiến là mean engine-level MAE. Với m validation engines và n_i dự đoán được đánh giá của engine i, đặt

$$\mathrm{MAE}_{\mathrm{engine}} = \frac{1}{m}\sum_{i=1}^{m}\left[\frac{1}{n_i}\sum_{t\in\mathcal{E}_i}|y_{i,t}-\widehat{y}_{i,t}|\right], \tag{9}$$

trong đó $\mathcal{E}_i$ là tập cycle được protocol chọn để đánh giá. Cách lấy trung bình này cho mỗi engine trọng số bằng nhau. Quy tắc chọn $\mathcal{E}_i$ trong cross-validation còn phải được cụ thể hóa và lưu cùng cấu hình trước khi huấn luyện. RMSE và NASA asymmetric score dự kiến là metric phụ; chưa có số liệu cho các metric này.

Sau khi chọn cấu hình bằng train/validation, mô hình được refit trên toàn train và tạo một dự đoán cho mỗi test engine tại cycle cuối quan sát. Chỉ sau đó mới join nhãn test để đánh giá cuối. Khoảng tin cậy dự kiến dùng bootstrap theo engine nhằm giữ nguyên đơn vị chuỗi, thay vì giả định các window chồng lấn là mẫu độc lập.

5.5 Thống kê và ARIMA: phần dự kiến

Phân tích tiếp theo so sánh trung bình 30 cycles đầu và 30 cycles cuối trong cùng engine, theo quyết định ngày 22/09/2026. Helper tạo cặp và các hàm suy luận theo sensor đã được hiện thực hóa, kiểm bằng fixture và chỉ xử lý train trong bộ nhớ. Chúng chưa xuất artifact hoặc tạo kết quả báo cáo. Mục 6 định nghĩa cặp, chiều chênh lệch, đầu ra, giả định và cấu hình M2.0 đã chốt. Effect size, bootstrap 95% confidence interval, Wilcoxon khi phù hợp và Benjamini–Hochberg FDR có cơ sở tại Mục 4. Bản hiện tại chưa có notebook/output suy luận hoặc kết luận ý nghĩa thống kê.

ARIMA là phân tích phụ trên Health Index từ PCA fit trong training fold. Không áp dụng ARIMA trực tiếp lên nhãn train RUL vì Công thức 1 đã tạo một countdown tất định; dự báo lại countdown không chứng minh khả năng khai thác tín hiệu sensor. Kế hoạch hiện tại chọn 10 validation engines đại diện, dùng 70% đầu chuỗi để fit và 30% cuối để đánh giá. Cách chọn engine cụ thể và ARIMA order còn chưa triển khai. Kết quả sẽ cần ADF, Ljung–Box, forecast MAE/RMSE và coverage của khoảng dự đoán 95%.

6 Protocol thống kê suy luận mốc 2

6.1 Mục tiêu, phạm vi và trạng thái quyết định

Mục tiêu là đánh giá mức thay đổi của sensor giữa đầu và cuối vòng đời trong cùng engine trên tập train FD001. Ngày 22/09/2026 đã chốt dùng trung bình **30 cycles đầu và 30 cycles cuối**. Phân tích chỉ đọc train và dùng engine làm đơn vị ghép cặp. Đây là protocol trước khi chạy kiểm định, được viết sau EDA; các giả thuyết phát sinh từ EDA mang tính khám phá, không được mô tả là đã đăng ký trước khi xem dữ liệu.

Các phương pháp paired analysis, effect size, bootstrap 95%, Wilcoxon khi phù hợp, Benjamini–Hochberg và seed 42 thuộc kế hoạch hiện có. Cấu hình M2.0 đã được chốt trước khi chạy suy luận: dùng mean paired difference, percentile bootstrap, Wilcoxon permutation và BH trên họ 21 sensors. Chưa có p-value, khoảng tin cậy hoặc kết luận suy luận từ protocol này.

6.2 Định nghĩa cặp đầu/cuối và ví dụ

Với $x_{i,t,s}$ là giá trị sensor s của engine i ở cycle t, và T_i là cycle cuối của train engine đó, đặt

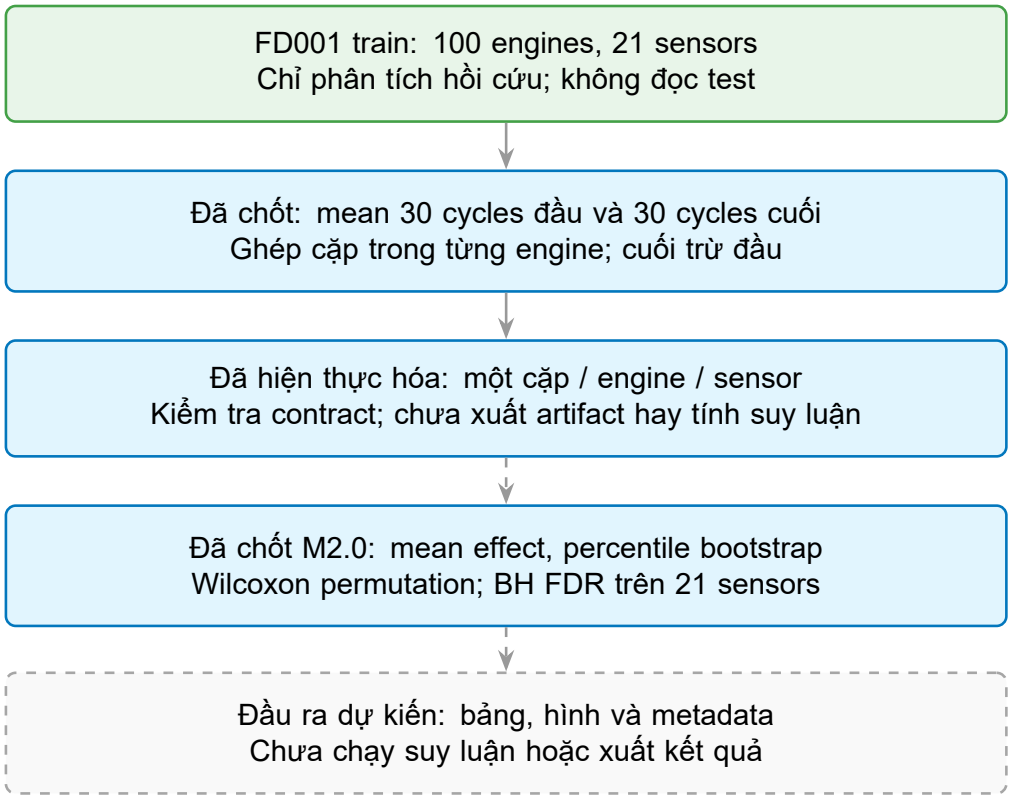
$$E_{i,s} = \frac{1}{30}\sum_{t=1}^{30} x_{i,t,s}, \qquad L_{i,s} = \frac{1}{30}\sum_{t=T_i-29}^{T_i} x_{i,t,s}, \tag{10}$$

$$D_{i,s} = L_{i,s} - E_{i,s}. \tag{11}$$

$D_{i,s} > 0$ biểu thị mức trung bình cuối đời lớn hơn đầu đời. Mỗi engine đóng góp một cặp cho mỗi sensor, bất kể tuổi thọ. Hai đoạn phải đủ dữ liệu, liên tục và không chồng lấn. Tuổi thọ train nhỏ nhất đã ghi nhận là 128 cycles, nên độ dài hiện tại đáp ứng điều kiện này; bước triển khai vẫn phải kiểm tra lại input contract.

Ví dụ tính chỉ số: với engine có $T_i = 200$, đoạn đầu là cycles 1–30 và đoạn cuối là cycles 171–200. Không nhầm đoạn cuối đời này với window 141–170 dùng dự đoán tại cycle 170. T_i được biết khi phân tích hồi cứu train; không được dùng để xác định đặc trưng ở thời điểm dự đoán trên test.

Giữ độ dài bằng nhau giúp so sánh hai mức tín hiệu trên cùng số cycles. Tuy nhiên, 30 cycles chiếm tỷ lệ vòng đời khác nhau giữa các engine. Protocol này trả lời câu hỏi về hai đoạn có độ dài tuyệt đối cố định, không phải so sánh cùng phần trăm tuổi thọ và cũng không tự xác định chính xác thời điểm bắt đầu suy giảm.



Hình 2: Thiết kế phân tích mốc 2; bước tạo một cặp đầu/cuối cho mỗi engine–sensor đã có helper và kiểm thử, cấu hình M2.0 đã chốt. Chưa xuất artifact hoặc chạy phép tính suy luận.

6.3 Đại lượng cần báo cáo và điều kiện diễn giải

Bảng kết quả dự kiến giữ đủ 21 sensors, không chọn danh sách từ thứ hạng correlation của EDA. Ba operational settings không được gộp vào cùng họ giả thuyết sensor. Bảng cần có số cặp hợp lệ, số chênh lệch bằng 0, mức thay đổi, khoảng tin cậy, thống kê kiểm định, p-value gốc, p-value hiệu chỉnh và trạng thái có thể kiểm định.

Dùng mean paired difference $\widehat{\Delta}_s = m^{-1} \sum_i D_{i,s}$ làm effect size chính theo đơn vị gốc, kèm median và phân phối $D_{i,s}$. Đây là đại lượng mô tả độ lớn thay đổi, không phải effect size chuẩn hóa và không so sánh trực tiếp độ lớn giữa các sensor khác thang đo. Không gán đơn vị vật lý nếu nguồn chưa xác nhận. Bootstrap lấy mẫu lại các engine cùng cặp E, L để tạo khoảng tin cậy 95% cho $\widehat{\Delta}_s$ [14]. Cấu hình M2.0 dùng 10.000 resamples và percentile interval.

Wilcoxon hai phía xét phân phối chênh lệch đối xứng quanh 0, với các cặp độc lập giữa engine [16]. Cần xem phân phối chênh lệch và ghi giới hạn đối xứng; bootstrap của mean không thay thế giả định này. Sensor hằng hoặc toàn bộ $D_{i,s} = 0$ vẫn phải xuất hiện trong bảng dưới trạng thái không có biến thiên quan sát được. Không biến p-value không xác định thành 0 và không tự kết luận rằng sensor có giá trị dự đoán bằng 0.

Benjamini–Hochberg áp dụng cho một họ kiểm định đã xác định trước [2, 15]. Cấu hình

M2.0 giữ họ gồm 21 sensors, dùng giá trị 1 chỉ trong vector hiệu chỉnh cho trường hợp không kiểm định được, đồng thời giữ p-value gốc là không áp dụng và ghi rõ trạng thái trong bảng. Quy ước này tránh thu nhỏ họ giả thuyết theo kết quả thuận lợi; nó không sửa được p-value thiếu hợp lệ hoặc bảo đảm FDR dưới mọi dạng phụ thuộc giữa sensors. Các khoảng tin cậy bootstrap riêng lẻ không phải simultaneous intervals.

6.4 Cấu hình M2.0 đã chốt trước triển khai

Các giá trị sau là cấu hình đã chốt ngày 22/09/2026 trước khi tính kết quả; không lấy default của thư viện làm quyết định ngầm.

- Effect size chính: mean paired difference; kèm median, số dấu dương, số dấu âm và số zero để nhìn phân phối lệch. Chưa bổ sung effect size chuẩn hóa nếu chưa có câu hỏi cần so sánh giữa sensors.
- Bootstrap: 10.000 lần lấy mẫu lại 100 engines có hoàn lại, seed 42; dùng percentile interval tại các quantile 2,5% và 97,5%. Ghi rõ giới hạn độ bao phủ hữu hạn; không mặc định tương đương BCa. Trường hợp phân phối bootstrap suy biến phải gắn nhãn, không diễn giải khoảng bằng 0 là chắc chắn tuyệt đối.
- Wilcoxon: hai phía, zero method `wilcox`, không dùng continuity correction và không dùng `auto`. Dùng permutation với 100.000 resamples và RNG cố định cho sensors có thể kiểm định. Zero được xác định bằng `difference == 0.0` sau tính mean `float64`; không tự làm tròn bằng một ngưỡng tùy ý cho mọi sensor.
- All-zero và p-value thiếu: nếu toàn bộ $D_{i,s} = 0$, giữ sensor trong bảng với trạng thái all-zero, `raw_p=NA` và không diễn giải như một kiểm định thành công. Lỗi số bất ngờ phải dừng thay vì biến thành p-value hợp lệ.
- FDR: dùng Benjamini–Hochberg với $q = 0{,}05$ trên đúng họ 21 sensors bằng hàm SciPy đã cố định trong metadata. Với p-value không áp dụng, chỉ dùng sentinel 1,0 bên trong vector hiệu chỉnh; output vẫn giữ `raw_p=NA` và trạng thái riêng.
- RNG và metadata: dùng seed 42 nhưng tách luồng RNG theo sensor và mục đích bootstrap/permutation để đổi thứ tự chạy không đổi kết quả của cùng sensor. `run_info.json` phải ghi cấu hình thực tế, phiên bản SciPy/NumPy/Pandas, data hash và commit hash.

Cấu hình này khóa cách tính trước khi xem p-value hoặc khoảng tin cậy thật. Nếu dùng phương án khác ở lượt sau, phải cập nhật protocol, lý do và thời điểm thay đổi trước khi tạo lại bảng kết quả; không trình bày lựa chọn mới như đã xác định từ đầu.

6.5 Đầu ra và điều kiện nghiệm thu

Đầu ra dự kiến gồm bảng cặp theo engine/sensor, bảng thống kê theo sensor, hình phân phối chênh lệch và effect size kèm khoảng tin cậy, cùng metadata ghi cấu hình và phiên bản. Cụm đầu tiên hiện có helper tạo/kiểm tra bảng cặp trong bộ nhớ theo đúng ranh giới 30 cycles; cấu

hình M2.0 đã chốt, nhưng chưa tạo CSV, hình hoặc metadata. Không tạo artifact rỗng để thay kết quả chưa chạy.

Kiểm tra phải bao gồm chỉ số 30 cycles đúng trong từng engine, không chồng đoạn, ghép cặp một–một, ví dụ tính tay và trường hợp hằng/ties/zeros. Bootstrap phải lấy mẫu theo engine và giữ cặp; FDR cần được kiểm tra trên một vector p-value nhỏ có đáp án biết trước. Chạy lại với cùng input và seed phải tái lập kết quả; raw và EDA gốc giữ nguyên. Khi có kết quả mới cập nhật phần kết quả, nhật ký và bằng chứng kiểm tra.

Kết luận thống kê chỉ áp dụng cho thay đổi trên train mô phỏng theo protocol này. Phát hiện thay đổi không chứng minh quan hệ nhân quả hoặc hiệu quả dự đoán ngoài mẫu. Lựa chọn sensor cho mô hình vẫn phải học trong training fold; không dùng danh sách có ý nghĩa thống kê trên toàn train để chọn feature trước cross-validation.

7 Kết quả hiện có và diễn giải

7.1 Kết quả validation

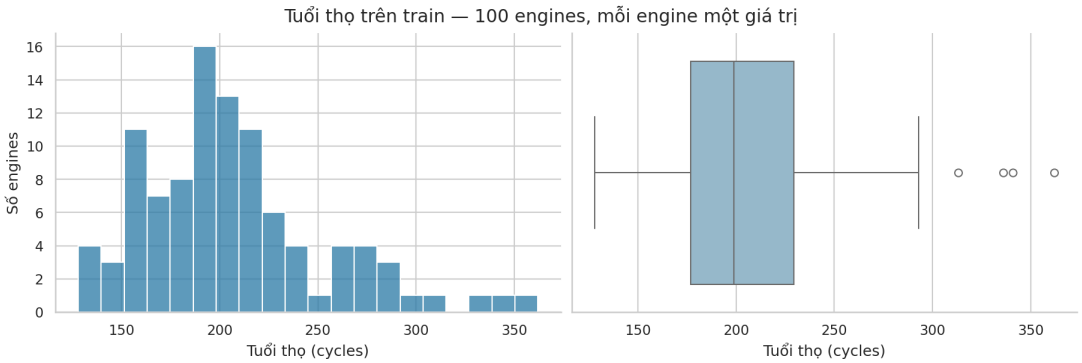
File `outputs/validation/fd001.json` ghi trạng thái `passed` cho train observations, train targets và test observations. Số dòng trước/sau tạo train targets đều là 20.631. Luồng mặc định ghi `test_labels_requested=false` và `test_labels_joined=false`. Báo cáo integrity riêng ghi nhận 100 nhãn hợp lệ về cấu trúc, không tính metric dự đoán.

Các kết quả này cho phép tiếp tục phân tích trên dữ liệu đạt contract đã định nghĩa. Chúng không chứng minh dữ liệu không có nhiễu, không có sai lệch mô phỏng hoặc mô hình sẽ dự đoán chính xác.

7.2 Tuổi thọ động cơ trên train

Bảng 4: Thống kê tuổi thọ của 100 train engines, đơn vị cycle. Nguồn: `lifetime_summary.csv`.

Thống kê	Giá trị	Thống kê	Giá trị
Mean	206,31	Sample standard deviation	46,34
Min	128	Max	362
Quartile 25%	177	Median	199
Quartile 75%	229,25	Số động cơ	100



Hình 3: Phân phối tuổi thọ train; mỗi engine đóng góp một giá trị. Hình lấy từ artifact EDA hiện có.

Tuổi thọ quan sát dao động từ 128 đến 362 cycles; mean lớn hơn median. Sự khác biệt độ dài chuỗi cho thấy cách lấy trung bình theo observations và theo engine có thể tạo trọng số khác nhau. Đây là cơ sở để ghi rõ đơn vị tổng hợp và dùng engine làm đơn vị đánh giá dự kiến. Các con số không được diễn giải thành tuổi thọ theo giờ hoặc ngày.

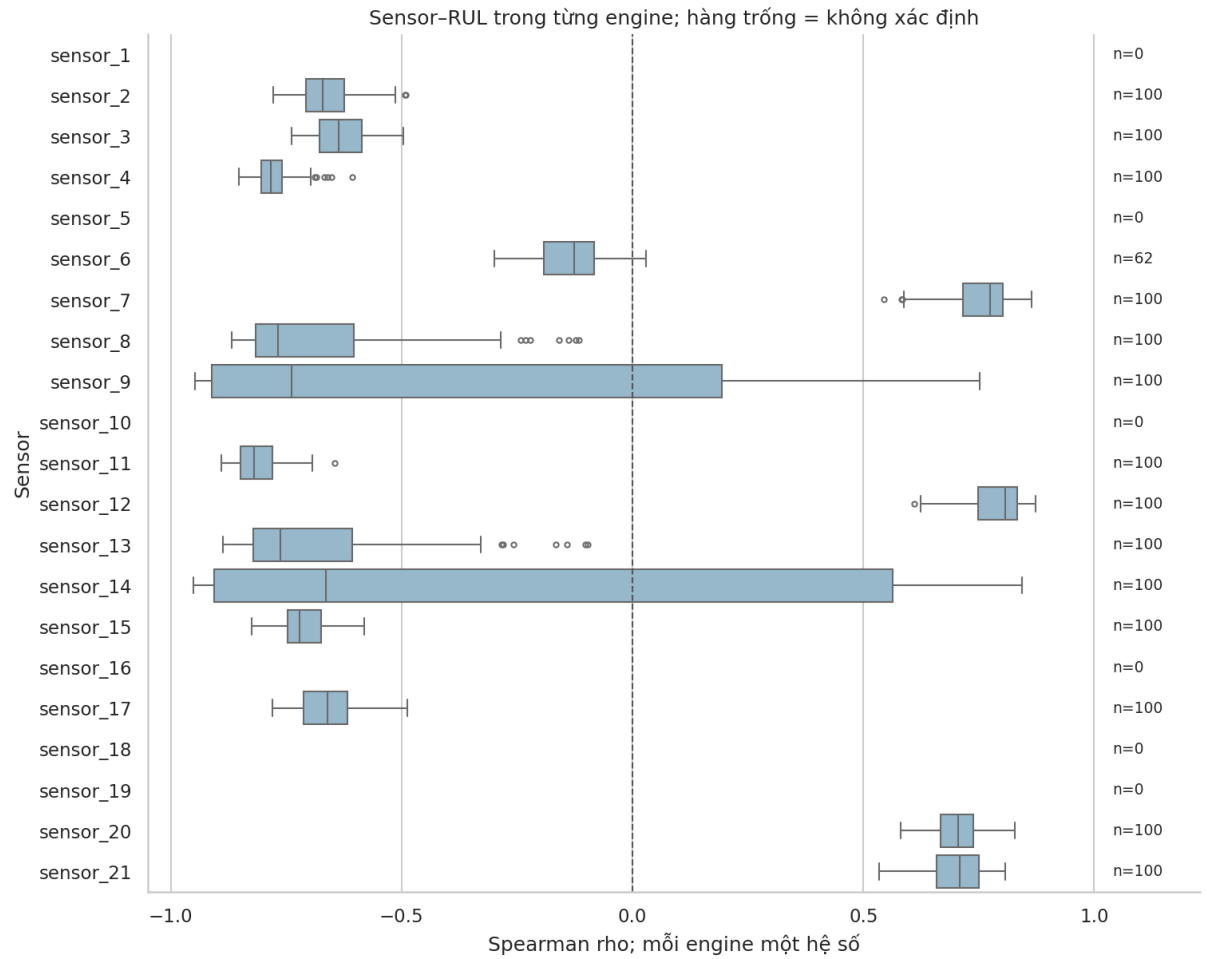
7.3 Sensor hằng và correlation theo engine

Metadata EDA ghi nhận `setting_3` và các sensor 1, 5, 10, 16, 18, 19 hằng trên train. Riêng sensor 6 hằng trong 38/100 engines; correlation sensor–RUL chỉ xác định trong 62 engines còn lại. Vì vậy, cần công bố cả số engine hợp lệ khi tóm tắt correlation.

Bảng 5: Một số dòng minh họa từ bảng correlation Spearman theo engine. Không dùng bảng này để xếp hạng hoặc chọn sensor cho mô hình.

Sensor	Engines xác định	Median correlation	Engines không xác định
1	0	Không xác định	100
6	62	$-0{,}1264$	38
11	100	$-0{,}8190$	0
12	100	$0{,}8075$	0

Sensor 11 có median correlation âm trong khi sensor 12 có median correlation dương với RUL. RUL giảm theo cycle, nên dấu âm gợi ý sensor có xu hướng tăng khi tiến gần cuối đời trong cách tổng hợp này. Đây là liên hệ mô tả trên train; chưa có kiểm định, chưa điều chỉnh multiple testing và chưa đo hiệu quả dự đoán ngoài mẫu.



Hình 4: Phân phối correlation Spearman sensor–RUL giữa các train engines. Sensor hằng được giữ là không xác định; mỗi hệ số hợp lệ tương ứng một engine.

7.4 Phạm vi bằng chứng EDA

Các số liệu trên được đối chiếu với bảng CSV và metadata hiện có, đồng thời kiểm tra lại các phép tổng hợp được trích từ train trong lượt tạo báo cáo. Bản PDF tham chiếu trực tiếp hai hình EDA; không vẽ lại giá trị hoặc thay số để minh họa.

Biên bản `outputs/eda/validation.json` ghi nhận 69 tests đạt, notebook chạy từ kernel mới và chạy kiểm tra độc lập trong thư mục chỉ có train input. Runtime audit chặn đọc hai file test trong lần kiểm tra; 12 CSV và 11 PNG của hai lần chạy giống nhau theo byte trong cùng môi trường. Đây là bằng chứng đã lưu của mốc EDA, không phải kết quả chạy lại notebook trong lượt viết báo cáo. Mốc EDA mô tả đã hoàn thành; thống kê suy luận và feature selection chưa thực hiện. Tính đồng nhất từng byte của PNG không được bảo đảm trên môi trường có font hoặc rendering khác.

8 Khó khăn, bài học và giới hạn hiện tại

Khó khăn đầu tiên là phân biệt dữ liệu đủ để tính nhãn với dữ liệu đủ để dự đoán trong thực tế. Train cho phép biết T_i sau khi chuỗi kết thúc, còn tại thời điểm dự đoán t thì T_i chưa biết. Bài học thiết kế là tách việc tạo nhãn khỏi feature và không dùng tuổi thọ đầy đủ để tạo biến đầu vào dự đoán.

Khó khăn thứ hai là xác định đơn vị phân tích. Một engine sống lâu tạo nhiều dòng hơn và các quan sát liền nhau có dependence theo thời gian. Việc tăng số dòng không tương đương tăng số mẫu độc lập. EDA vì vậy ghi rõ mức observation hoặc engine; validation và bootstrap dự kiến giữ đơn vị engine.

Khó khăn thứ ba là giới hạn bằng chứng của dữ liệu mô phỏng và quy mô nhỏ. Benchmark PySpark có thể chịu overhead lớn; chưa thể giả định phân tán sẽ nhanh hơn. Kết quả âm hoặc tốc độ thấp hơn Pandas vẫn cần được trình bày nếu phép đo hợp lệ. Báo cáo chỉ phân tích khả năng mở rộng sau khi có parity và thời gian đo thực tế.

Môi trường kiểm thử trước đó ghi nhận lỗi quyền truy cập thư mục Temp trên Windows. Cách xử lý đã được tài liệu hóa là dùng thư mục tạm riêng cho pytest; đây là vấn đề môi trường, không phải lỗi chất lượng FD001. Trong lượt khởi tạo báo cáo, TeX chưa có trên PATH nên dùng Tectonic portable để biên dịch; hướng dẫn tái lập được lưu cùng nguồn báo cáo.

Hiện chưa có kết quả huấn luyện, metric test, khoảng tin cậy, ARIMA diagnostics hoặc dashboard. Do đó, chưa thể kết luận mô hình nào phù hợp hơn, cảnh báo sớm chính xác đến đâu hoặc lịch bảo trì nào có lợi. Phần kết luận cuối sẽ được viết sau khi hoàn tất đánh giá theo protocol đã lưu.

9 Khai báo sử dụng AI/LLM

AI/LLM được sử dụng để hỗ trợ xây dựng cấu trúc bản báo cáo, diễn đạt nội dung, tổ chức nhật ký tiến độ, đối chiếu artifact trong repository và hỗ trợ kiểm tra biên dịch. Nội dung hỗ trợ này cần được kiểm tra với dữ liệu, mã nguồn và tài liệu gốc. Việc tạo văn bản bằng AI không được dùng làm bằng chứng về hiệu quả mô hình; các kết quả thực nghiệm chỉ được ghi nhận khi có artifact và quy trình kiểm chứng tương ứng.

Tài liệu tham khảo

[1] Apache Software Foundation. Spark SQL and DataFrames. Apache Spark documentation. Accessed 2026-09-22; implementation version not selected. URL: https://spark.apache.org/docs/latest/sql-programming-guide.html.

[2] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)*, 57(1):289–300, 1995. doi:10.1111/j.2517-6161.1995.tb02031.x.

[3] B. Efron. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1):1–26, 1979. doi:10.1214/aos/1176344552.

[4] Rob J. Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*. OTexts, Melbourne, Australia, 3 edition, 2021. Online edition, sections 5.4, 9.1, 9.5 and 9.7; accessed 2026-09-22. URL: https://otexts.com/fpp3/.

[5] Xiang Li, Qian Ding, and Jian-Qiao Sun. Remaining useful life estimation in prognostics using deep convolution neural networks. *Reliability Engineering & System Safety*, 172:1–11, 2018. doi:10.1016/j.ress.2017.11.021.

[6] NASA. CMAPSS jet engine simulated data. NASA Open Data Portal. Accessed 2026-09-20; project uses FD001. URL: https://data.nasa.gov/dataset/cmapss-jet-engine-simulated-data.

[7] Emmanuel Ramasso and Abhinav Saxena. Review and analysis of algorithmic approaches developed for prognostics on CMAPSS dataset. In *Annual Conference of the PHM Society*, volume 6, 2014. Issue 1. URL: https://papers.phmsociety.org/index.php/phmconf/article/view/2512, doi:10.36001/phmconf.2014.v6i1.2512.

[8] Abhinav Saxena, Jose Celaya, Bhaskar Saha, Sankalita Saha, and Kai Goebel. Metrics for offline evaluation of prognostic performance. *International Journal of Prognostics and Health Management*, 1(1), 2010. URL: https://papers.phmsociety.org/index.php/ijphm/article/view/1336, doi:10.36001/ijphm.2010.v1i1.1336.

[9] Abhinav Saxena, Kai Goebel, Don Simon, and Neil Eklund. Damage propagation modeling for aircraft engine run-to-failure simulation. In *2008 International Conference on Prognostics and Health Management*, pages 1–9. IEEE, 2008. doi:10.1109/PHM.2008.4711414.

[10] scikit-learn developers. Cross-validation iterators for grouped data. User Guide. Accessed 2026-09-22; implementation version not selected. URL: https://scikit-learn.org/stable/modules/cross_validation.html#cross-validation-iterators-for-grouped-data.

[11] scikit-learn developers. Decomposing signals in components: Principal Component Analysis. User Guide. Accessed 2026-09-22; implementation version not selected. URL: https://scikit-learn.org/stable/modules/decomposition.html#pca.

[12] scikit-learn developers. Histogram-Based Gradient Boosting. User Guide. Accessed 2026-09-22; implementation version not selected. URL: https://scikit-learn.org/stable/modules/ensemble.html#histogram-based-gradient-boosting.

[13] scikit-learn developers. Linear models: Ridge regression and classification. User Guide. Accessed 2026-09-22; implementation version not selected. URL: https://scikit-learn.org/stable/modules/linear_model.html#ridge-regression-and-classification.

[14] SciPy developers. scipy.stats.bootstrap. SciPy 1.16.2 Manual. Accessed 2026-09-22. URL: https://docs.scipy.org/doc/scipy-1.16.2/reference/generated/scipy.stats.bootstrap.html.

[15] SciPy developers. scipy.stats.false_discovery_control. SciPy 1.16.2 Manual. Accessed 2026-09-22. URL: https://docs.scipy.org/doc/scipy-1.16.2/reference/generated/scipy.stats.false_discovery_control.html.

[16] SciPy developers. scipy.stats.wilcoxon. SciPy 1.16.2 Manual. Accessed 2026-09-22. URL: https://docs.scipy.org/doc/scipy-1.16.2/reference/generated/scipy.stats.wilcoxon.html.

[17] statsmodels developers. statsmodels.tsa.stattools.adfuller. Online documentation. Accessed 2026-09-22; implementation version not selected. URL: https://www.statsmodels.org/stable/generated/statsmodels.tsa.stattools.adfuller.html.

[18] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945. doi:10.2307/3001968.

[19] Matei Zaharia, Mosharaf Chowdhury, Tathagata Das, Ankur Dave, Justin Ma, Murphy McCauley, Michael J. Franklin, Scott Shenker, and Ion Stoica. Resilient distributed datasets: A fault-tolerant abstraction for in-memory cluster computing. In *9th USENIX Symposium on Networked Systems Design and Implementation (NSDI 12)*, pages 15–28. USENIX Association, 2012. URL: https://www.usenix.org/conference/nsdi12/technical-sessions/presentation/zaharia.

A Bảng đối chiếu nội dung và bằng chứng

Các đường dẫn sau được tính từ thư mục gốc repository. Hai tài liệu yêu cầu môn học nằm trong thư mục Resources bên ngoài repository và chưa được sao chép vào gói báo cáo.

Nội dung	Nguồn kiểm tra
Quy mô và schema	`outputs/validation/fd001.json`; `data/CONTRACTS.md`.
Số nhãn test	`outputs/validation/fd001-integrity.json`; không sử dụng giá trị nhãn để phân tích trong bản này.
Nguồn và phạm vi FD001	`data/raw/DATA_SOURCE.md`; `data/raw/readme.txt`; `references/bibliography.bib`.
Cơ sở lý thuyết và mức đọc nguồn	`report/sections/theory.tex`; `references/README.md`; `references/reading-guide.md`. Các nguồn bài gốc chưa đọc toàn văn được ghi rõ.
Protocol mốc 2	`report/sections/statistical-protocol.tex`; mean 30 cycles đầu/cuối và cấu hình M2.0 đã chốt ngày 22/09/2026. Sơ đồ có nguồn tại `report/figures/statistical-protocol.tex`.
Tạo cặp và helper suy luận mốc 2	`src/cmapss/statistics.py`; `tests/test_statistics.py`; contract tại `data/CONTRACTS.md`. Test raw FD001 xác nhận bảng cặp trong bộ nhớ có 2.100 dòng và bảng suy luận đủ 21 sensors với cấu hình test nhỏ; chưa có artifact suy luận được lưu.
Tuổi thọ động cơ	`outputs/eda/tables/engine_lifetimes.csv`; `outputs/eda/tables/lifetime_summary.csv`.
Sensor hằng	`outputs/eda/run_info.json`; `outputs/eda/tables/constant_engine_counts.csv`.
Correlation theo engine	`outputs/eda/tables/sensor_rul_by_engine.csv`; `outputs/eda/tables/sensor_rul_summary.csv`.
Nguồn EDA	`notebooks/01_fd001_eda.ipynb`; `src/cmapss/eda.py`.
Nghiệm thu EDA mô tả	`outputs/eda/validation.json`; 69 tests, kernel mới, 12 CSV và 11 PNG tái lập trong cùng môi trường.
Kiểm tra số liệu được trích	`report/evidence/report-checks.txt`; kiểm tra chỉ đọc, không chạy huấn luyện hoặc sửa artifact EDA.
Nguồn từng phần báo cáo	`report/sections/`; hướng dẫn cập nhật và build tại `report/README.md`.

Ví dụ đối chiếu: giá trị mean tuổi thọ 206,31 trong Bảng 4 lấy từ dòng `mean` của `lifetime_summary.csv`; file chi tiết có một dòng cho mỗi engine. Không lấy trung bình

trực tiếp cột cycle trên toàn bộ observations vì đó là một đại lượng khác.

B Thông tin cần bổ sung trước khi nộp

Mẫu bìa chính thức, tên giảng viên, mã lớp và thông tin đăng ký thực hiện cá nhân chưa được xác nhận trong phạm vi tài liệu hiện có. Các mục này cần được đối chiếu trước khi nộp; không giả định đã được phê duyệt. Chưa có thời hạn theo ngày lịch để chuyển thành kế hoạch tuần cụ thể. Các mốc tại Bảng 2 vì vậy chỉ ghi thứ tự và điều kiện hoàn thành.