Industrial University of Ho Chi Minh City

BÁO CÁO CUỐI KỲ · PHÂN TÍCH DỮ LIỆU LỚN · ĐỀ TÀI 8

Phân tích dữ liệu IoT và bảo trì dự đoán

Phát hiện bất thường, dự đoán tuổi thọ còn lại (RUL) và cảnh báo sớm
trên dữ liệu cảm biến NASA C-MAPSS

100	86%	121	15,35
động cơ train FD001	dao động giảm nhờ EWMA	cycle báo trước khi hỏng (trung vị)	sai số MAE trên tập test (cycle)

Phan Nguyễn Mai Phương · MSHV 25002711

Học viên cao học ngành Khoa học máy tính · Tháng 10/2026

Cấu trúc bài trình bày

Đi theo thứ tự pipeline: chuẩn bị dữ liệu → phân tích tín hiệu → dự đoán → cảnh báo

1. **Bài toán và dữ liệu**
   Slide 3–5
2. **Pipeline dữ liệu**
   Slide 6–8
3. **Khử nhiễu và cửa sổ thời gian**
   Slide 9–10
4. **Xu hướng và bất thường**
   Slide 11–12
5. **Dự đoán RUL, cảnh báo, lịch bảo trì**
   Slide 13–16
6. **Mở rộng và kết luận**
   Slide 17–19
7. **Demo dashboard**
   Khoảng 2,5 phút

Câu hỏi nghiên cứu

- **Q1** Dữ liệu có đạt các kiểm tra chất lượng không; Pandas và PySpark có cho cùng kết quả không?
- **Q2** Làm mượt giảm được bao nhiêu nhiễu; dữ liệu được tổng hợp theo cửa sổ thời gian ra sao?
- **Q3** Tín hiệu thay đổi thế nào theo tuổi máy; có phát hiện được bất thường trước khi hỏng không?
- **Q4** Dự đoán RUL chính xác đến đâu trên tập test độc lập?
- **Q5** Cảnh báo sớm và lịch bảo trì hiệu quả đến đâu?

Innovation - Unity - Humanity

Nguồn: report/main.pdf; handoff/SPEECH_SCRIPT_VI.pdf

Phát biểu bài toán

Phát hiện dấu hiệu suy giảm và dự đoán thời điểm bảo trì từ dữ liệu cảm biến; đối chiếu yêu cầu Đề tài 8

Định nghĩa RUL



$$RUL(t) = T - t$$

RUL(170) = 200 − 170 = 30 cycle

T: cycle động cơ hỏng. Đầu vào: chuỗi 21 tín hiệu cảm biến theo cycle. Đầu ra: dấu hiệu bất thường, RUL dự đoán và mức cảnh báo.

Yêu cầu của đề tài	Cách thực hiện	Slide
Xử lý chuỗi thời gian cảm biến	Kiểm tra khóa, cycle liên tục; sắp theo động cơ và cycle	6, 9, 10
Xử lý nhiễu tín hiệu	Làm mượt EWMA span 10 theo từng động cơ, chỉ dùng quá khứ	9
Chuẩn hóa, tổng hợp theo cửa sổ	StandardScaler; cửa sổ 30 cycle → 126 đặc trưng	10
Phát hiện dấu hiệu bất thường	Health Index (chỉ số sức khỏe) giảm quá 3σ so với 30 cycle đầu	12
Trực quan hóa xu hướng suy giảm	Quỹ đạo sensor, kiểm định đầu/cuối, Health Index	11, 12
Dự đoán thời điểm bảo trì, cảnh báo sớm	Lịch bảo trì cho 100 động cơ test; hai mức cảnh báo	15, 16

Nguồn: references/context/assignment-brief.png; report/sections/problem-data.tex

Bộ dữ liệu NASA C-MAPSS

Chọn NASA Turbofan (C-MAPSS) trong gợi ý của đề vì có chuỗi cảm biến chạy đến khi hỏng của từng động cơ

FD001

Phân tích chính

1 điều kiện vận hành
1 dạng lỗi (HPC)

100 train / 100 test
33.727 quan sát

FD002

Thử nghiệm mở rộng

6 điều kiện vận hành
1 dạng lỗi (HPC)

260 train / 259 test
87.750 quan sát

FD003

Thử nghiệm mở rộng

1 điều kiện vận hành
2 dạng lỗi (HPC, Fan)

100 train / 100 test
41.316 quan sát

FD004

Thử nghiệm mở rộng

6 điều kiện vận hành
2 dạng lỗi (HPC, Fan)

249 train / 248 test
102.463 quan sát

Cấu trúc một bản ghi quan sát (26 trường)

engine_id	cycle	setting_1 … setting_3	sensor_1 … sensor_21

Khóa chính gồm split (train hoặc test, thêm khi ETL), engine_id và cycle. Không có giá trị thiếu. HPC: máy nén áp suất cao.

Innovation - Unity - Humanity

Nguồn: data/raw/readme.txt; outputs/cross_dataset/FD00x/etl/run_info.json

Xây dựng nhãn RUL và ranh giới tập test

Nhãn tập test chỉ được dùng sau khi đã lưu kết quả dự đoán, để tránh rò rỉ dữ liệu (data leakage)

Train

100 động cơ chạy đến khi hỏng



Test

Chuỗi của 100 động cơ bị cắt trước khi hỏng



Train: RUL(t) = cycle cuối − t; tổng cộng 20.631 nhãn

Test: một dự đoán tại cycle cuối của mỗi động cơ; ghép RUL_FD001.txt sau khi đã lưu dự đoán

Kiểm soát nhãn tập test

Không dùng sớm

nhãn test không dùng trong EDA, tạo đặc trưng hay chọn mô hình

Ghép sau dự đoán

nhãn chỉ được ghép khi dự đoán đã được lưu

Truy vết được

metadata ghi trạng thái ghép nhãn và mã băm SHA-256

Innovation - Unity - Humanity

Nguồn: data/CONTRACTS.md; outputs/modeling/run_info.json; outputs/modeling/tables/final_metrics.json

Kiến trúc pipeline dữ liệu Bronze–Silver–Gold

Ba bước chuẩn bị chung, rồi tách hai nhánh: dự đoán RUL và theo dõi tín hiệu



Ô nét đứt là kiểm tra phụ, không đi vào mô hình. Pandas và PySpark cho cùng kết quả ở A1–A2.

Innovation - Unity - Humanity

Nguồn: report/figures/pipeline.pdf; handoff/DATA_WALKTHROUGH.md; outputs/*/run_info.json

Đối chiếu Pandas, PySpark và Hadoop

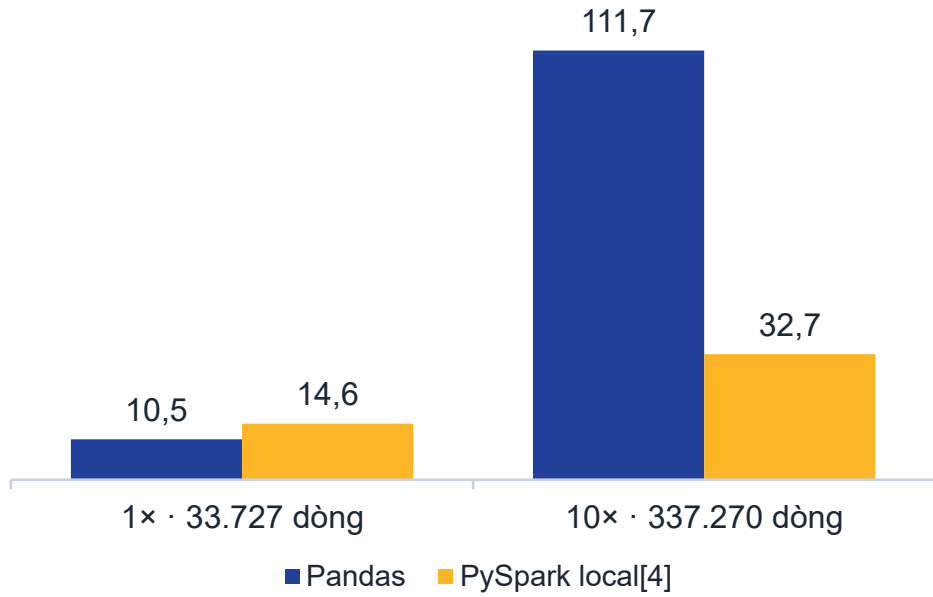
Pandas, PySpark và Hadoop cho cùng kết quả; với dữ liệu gấp 10 lần, PySpark nhanh hơn Pandas khoảng 3,4 lần

Bảng (so với Pandas)	Số dòng	Sai khác	Kết quả
Silver observations	33.727	0	Khớp
Silver train_targets	20.631	0	Khớp
Gold engine_summary	200	0	Khớp
Gold rolling_features	27.927	0	Khớp
Gold · MapReduce trên HDFS	200	0	Khớp
Gold · Spark trên HDFS	200	0	Khớp

Cụm Hadoop 3.4.3 một node trong Docker

Raw lên HDFS; MapReduce trên YARN: 3 map, 1 reduce; Spark ghi Silver Parquet 33.727 dòng lên HDFS; fsck: HEALTHY.

Thời gian pipeline gồm đọc, ghi (giây)



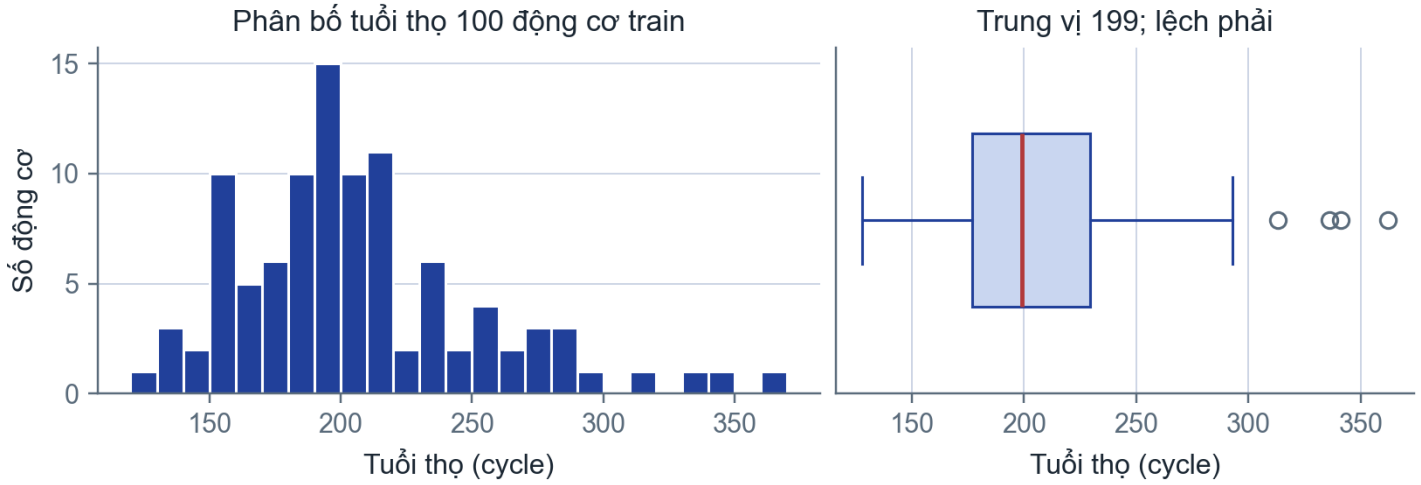
Trung vị ba lượt; không gồm thời gian khởi động Spark; đo trên một máy, chưa phải cluster.

Innovation - Unity - Humanity

Nguồn: outputs/etl/parity.json; outputs/hdfs/summary.json; outputs/benchmarks/20260929/measurements.csv

Phân tích khám phá dữ liệu

Tuổi thọ động cơ từ 128 đến 362 cycle; bảy cột không đổi trên toàn bộ tập train



128
Ngắn nhất (cycle)

199
Trung vị (cycle)

206,31
Trung bình (cycle)

362
Dài nhất (cycle)

Cột không đổi ở 100/100 động cơ

- sensor_1
- sensor_5
- sensor_10
- sensor_16
- sensor_18
- sensor_19
- setting_3

sensor_6 không đổi ở 38/100 động cơ.

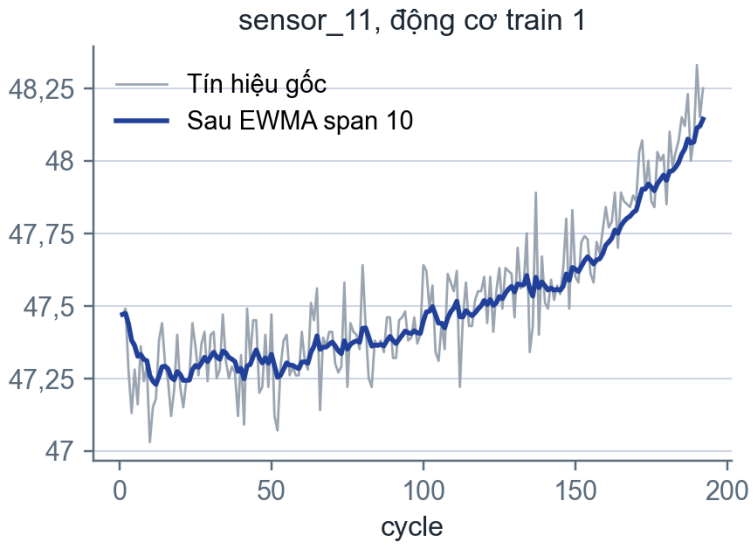
Làm mượt áp dụng cho 14 sensor có xu hướng: bỏ 6 sensor trên và sensor_6.

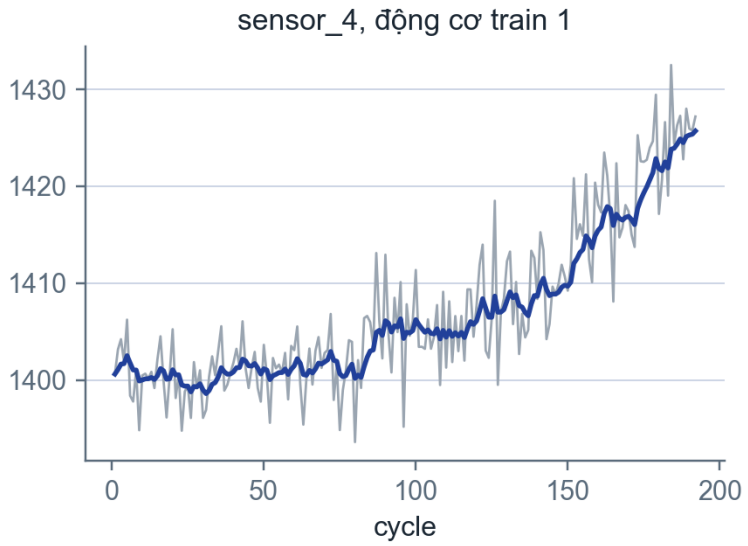
Innovation - Unity - Humanity

Nguồn: data/raw/train_FD001.txt; outputs/eda/tables/constant_engine_counts.csv; slides/slide_figures.py

Khử nhiễu tín hiệu bằng EWMA

Độ dao động ngắn hạn giảm khoảng 86% (trung vị trên 14 sensor); xu hướng suy giảm được bảo toàn





Sensor	Gốc	EWMA	Giảm
sensor_4	5,70	0,783	86,3%
sensor_9	5,90	0,924	84,3%
sensor_11	0,144	0,020	86,2%
sensor_12	0,425	0,059	86,2%
sensor_14	4,45	0,729	83,6%

Cách đo: độ lệch chuẩn của chênh lệch giữa hai cycle liền kề, tính riêng từng động cơ.

Công thức: $s_t = \alpha \cdot x_t + (1 - \alpha) \cdot s_{t-1}$, với $\alpha = 2 / (\text{span} + 1) \approx 0{,}18$ khi span = 10

Vai trò: tín hiệu đã làm mượt là đầu vào của Health Index và phát hiện bất thường (slide 12); mô hình RUL dùng đặc trưng cửa sổ trên tín hiệu gốc.

Nguồn: outputs/degradation/tables/signals.parquet; outputs/degradation/tables/noise_summary.csv

Tổng hợp đặc trưng theo cửa sổ thời gian

Cửa sổ trượt 30 cycle, chỉ dùng quá khứ; 21 sensor × 6 thống kê = 126 đặc trưng



21 sensor × 6 thống kê = 126 đặc trưng

last giá trị cuối, tại cycle t	**mean** giá trị trung bình	**std** độ lệch chuẩn mẫu
min giá trị nhỏ nhất	**max** giá trị lớn nhất	**slope** độ dốc (hệ số góc hồi quy)

17.731 cửa sổ train · 10.196 cửa sổ test · 29 cycle đầu bị bỏ, không bù giá trị

Chuẩn hóa

ETL: thống nhất schema và kiểu dữ liệu.

StandardScaler: đưa về trung bình 0, độ lệch chuẩn 1; chỉ học trên phần train của từng fold.

Dùng cho: Ridge và PCA khi tạo Health Index.

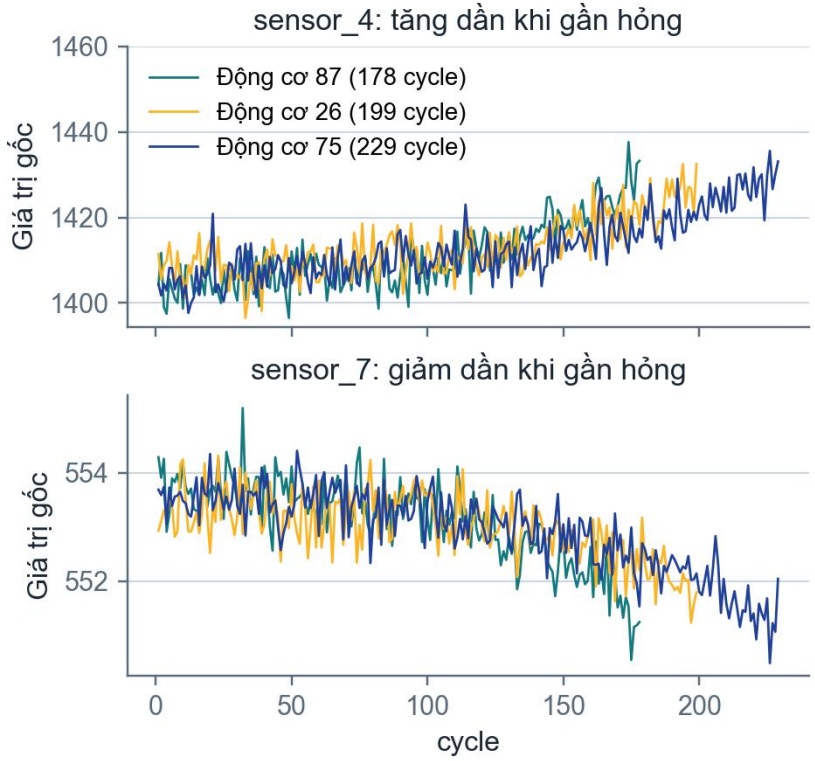
HGB: giữ thang đo gốc vì cây quyết định không phụ thuộc thang đo.

Innovation - Unity - Humanity

Nguồn: outputs/features/run_info.json; src/cmapss/features/rolling.py

Xu hướng suy giảm của tín hiệu cảm biến

15/21 sensor thay đổi có ý nghĩa thống kê giữa 30 cycle đầu và 30 cycle cuối của mỗi động cơ



1 Ghép cặp trong động cơ

Δ = trung bình 30 cycle cuối − 30 cycle đầu

2 Bootstrap và Wilcoxon

Lấy mẫu lại động cơ 10.000 lần

3 Hiệu chỉnh kiểm định bội

Benjamini–Hochberg (FDR) trên 21 sensor, q = 0,05

15/21

sensor thay đổi có ý nghĩa thống kê

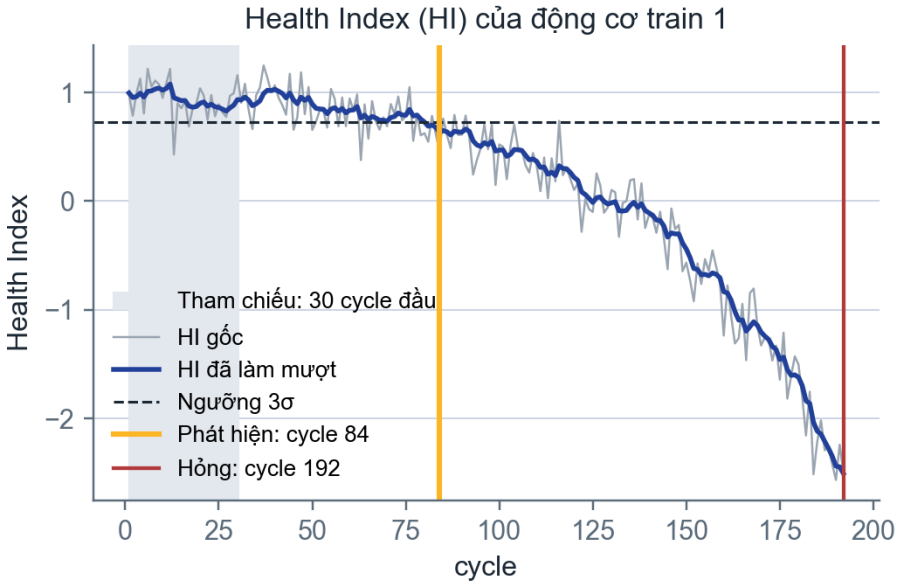
12 sensor thay đổi cùng chiều ở 100/100 động cơ, ví dụ sensor 4, 7, 11, 12, 20; 6 sensor không đổi nên không kiểm định được.

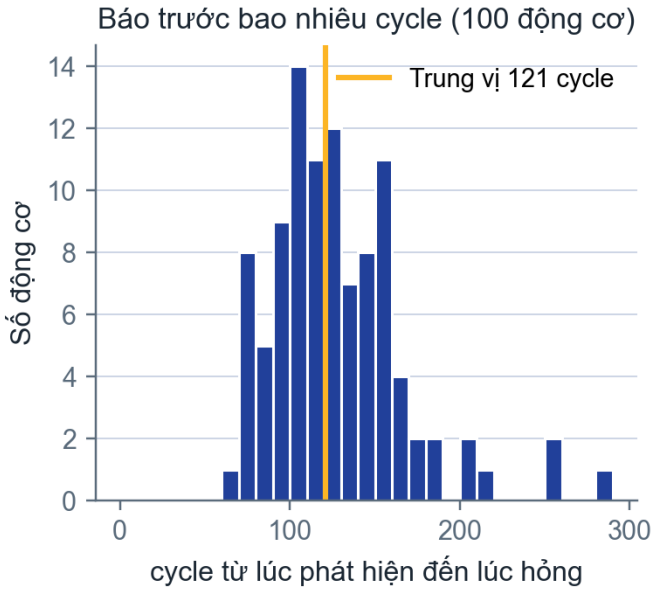
Innovation - Unity - Humanity

Nguồn: data/raw/train_FD001.txt; outputs/statistics/tables/sensor_inference.csv

Phát hiện dấu hiệu bất thường dựa trên Health Index

Ngưỡng 3σ so với 30 cycle đầu, duy trì 5 cycle: phát hiện 100/100 động cơ train, trung vị 121 cycle trước khi hỏng





100/100

động cơ train được phát hiện trước khi hỏng

121

cycle báo trước khi hỏng (trung vị); tứ phân vị 101–149

39%

vòng đời đã qua khi phát hiện (trung vị)

Thử 9 cấu hình (2/3/4σ × 3/5/10 cycle): đều phát hiện 100/100 động cơ, báo trước ít nhất 50 cycle. Nếu không làm mượt: trung vị chỉ còn 72,5 cycle. Giới hạn: chưa đo được báo động giả vì dữ liệu không ghi thời điểm bắt đầu suy giảm.

Innovation - Unity - Humanity

Nguồn: outputs/degradation/tables/anomaly_events.csv; outputs/degradation/summary.json

Mô hình dự đoán RUL

HistGradientBoosting (HGB), chọn bằng kiểm định chéo 5 fold chia theo động cơ (GroupKFold); MAE tập test 15,35 cycle

Mô hình (GroupKFold 5 fold)	MAE	Độ lệch chuẩn (5 fold)
Baseline trung vị	46,95	0,12
Ridge (α = 1)	23,99	0,95
HistGradientBoosting	**20,21**	**0,98**

15,35

MAE test (cycle)

khoảng tin cậy 95%: 12,73–18,09

20,54

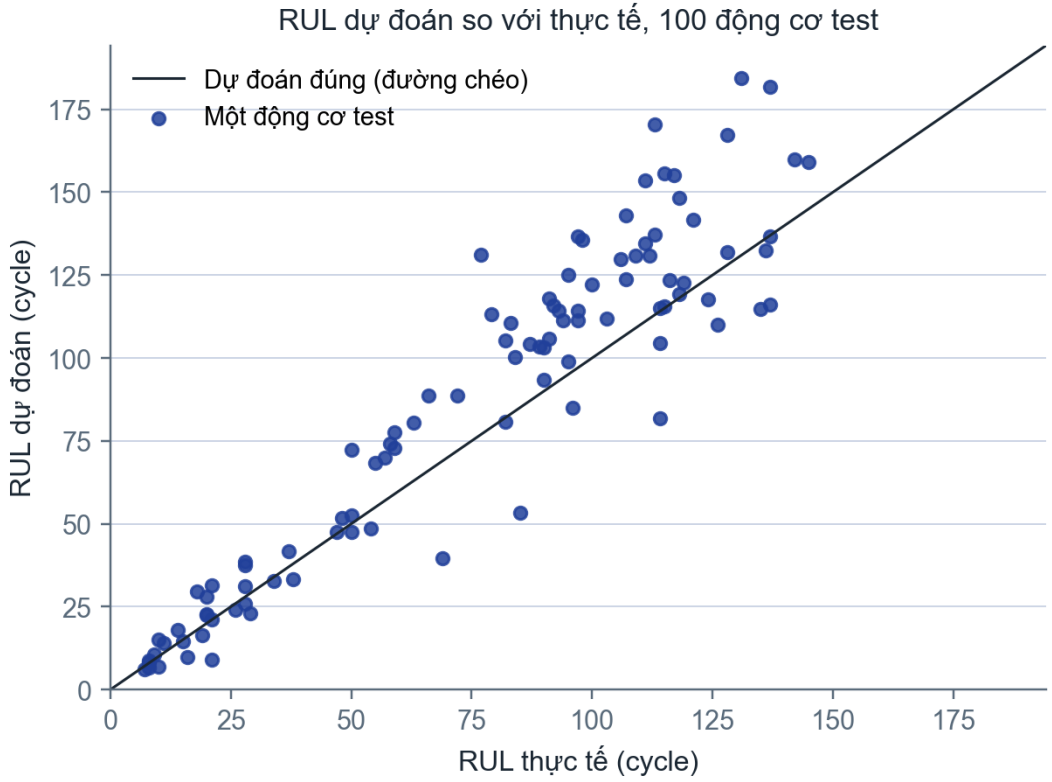
RMSE (cycle)

nhạy với sai số lớn

1.513

NASA score

phạt nặng hơn khi dự đoán cao hơn thực tế

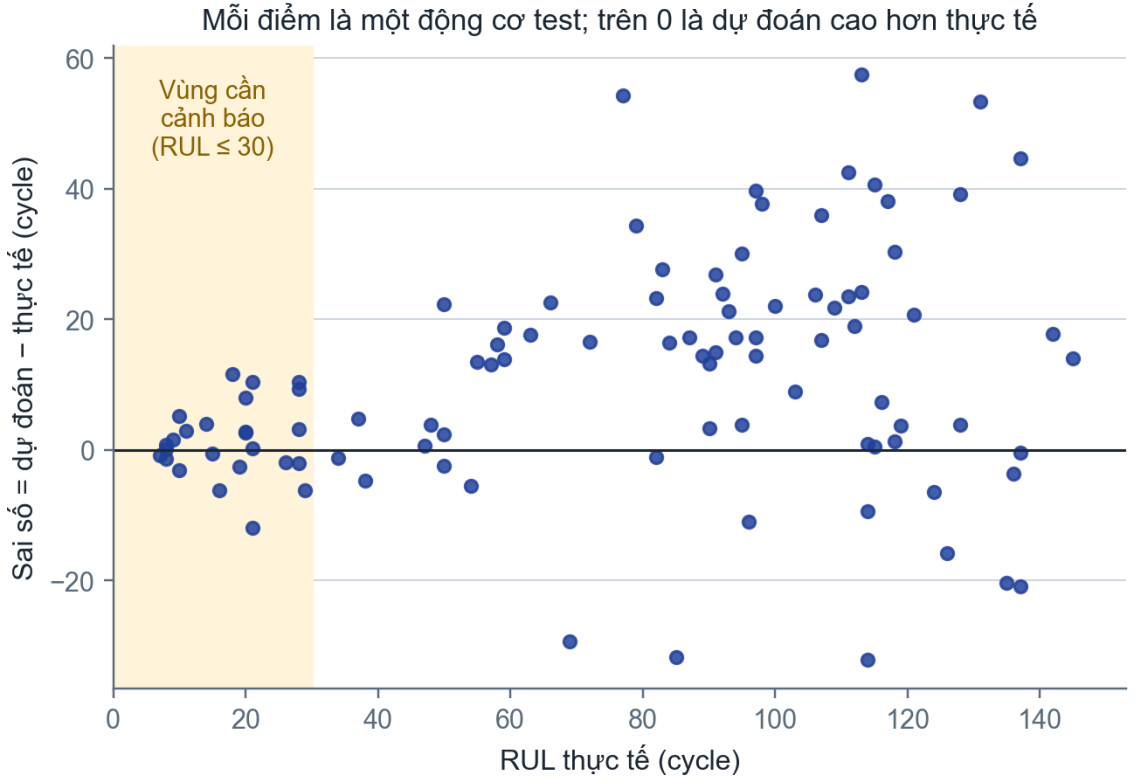


Innovation - Unity - Humanity

Nguồn: outputs/modeling/tables/model_metrics.csv; outputs/modeling/tables/final_metrics.json; outputs/modeling/predictions/final_evaluation.parquet

Phân tích sai số dự đoán

Sai số nhỏ hơn khi RUL thực tế nhỏ; mô hình hay dự đoán cao hơn thực tế, nên dễ cảnh báo muộn



Chiều của sai số (100 động cơ test)

74 dự đoán cao hơn thực tế	26 thấp hơn

Sai số lớn nhất: động cơ 23

113	170,5	57,5
RUL thực tế (cycle)	Dự đoán (cycle)	Sai số (cycle)

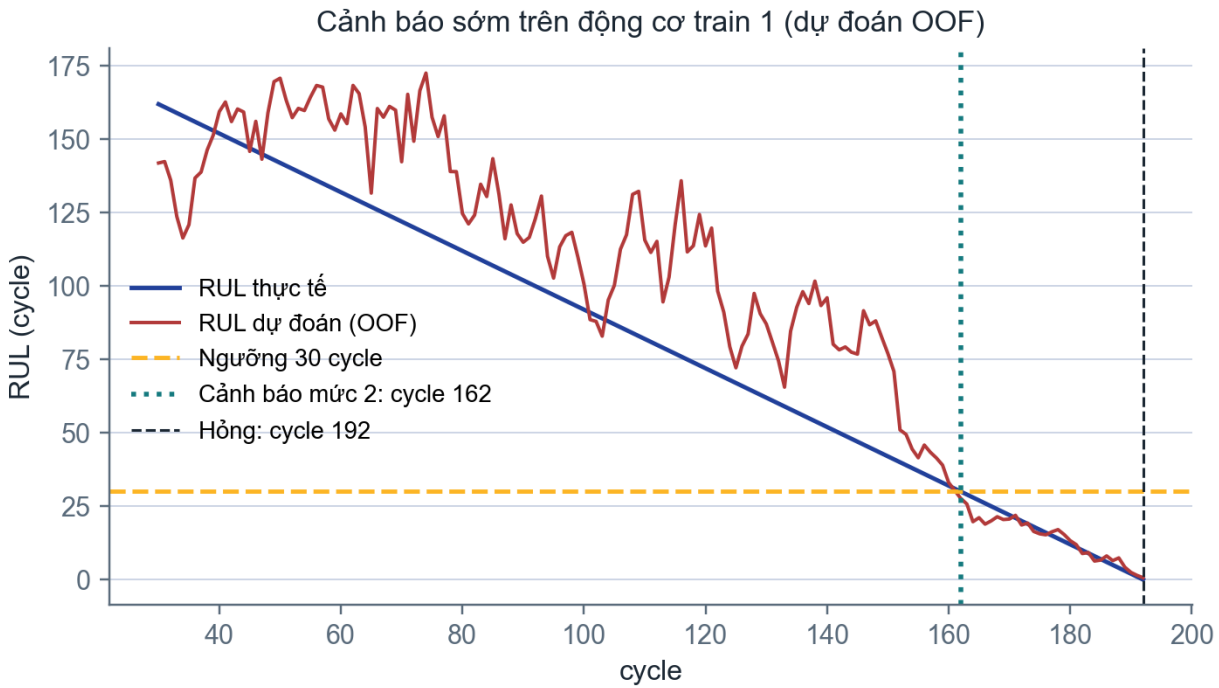
MAE chỉ 4,38 cycle khi RUL thực tế ≤ 30. 10 động cơ sai nhiều nhất đóng góp 75,5% tổng NASA score.

Innovation - Unity - Humanity

Nguồn: outputs/modeling/predictions/final_evaluation.parquet; outputs/diagnostics/error_diagnostics.json

Cơ chế cảnh báo sớm hai mức

Ngưỡng RUL dự đoán ≤ 30: không bỏ sót động cơ, báo trước trung vị 30 cycle, nhưng 49% báo muộn



Minh họa trên động cơ train 1: cảnh báo mức 2 tại cycle 162; hỏng tại cycle 192.

Dự đoán OOF trên 100 động cơ train

Ngưỡng RUL	Kịp thời	Muộn	Báo quá sớm
≤ 30 cycle	**51%**	**49%**	**1,3%**
≤ 40 cycle	94%	6%	5,3%

Kịp thời: báo trước ít nhất 30 cycle. Báo quá sớm: tỷ lệ cycle có cảnh báo khi RUL thực tế còn trên 30. OOF: dự đoán trên động cơ mô hình chưa thấy khi huấn luyện.

Hai mức cảnh báo trên động cơ 1

cycle 84 Mức 1 · Health Index bất thường

cycle 162 Mức 2 · RUL dự đoán ≤ 30

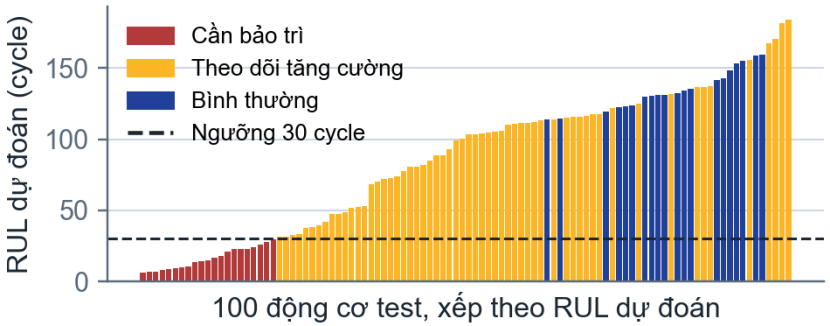
cycle 192 Hỏng

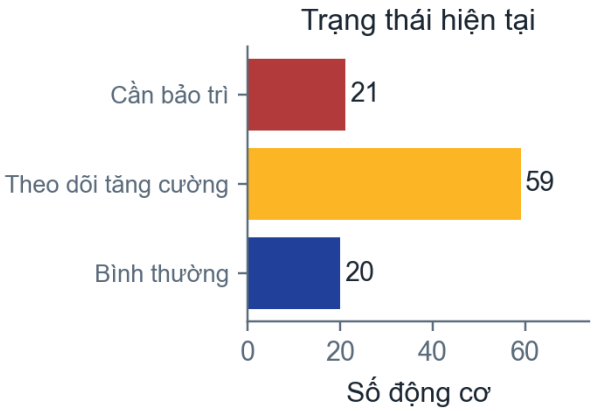
Innovation - Unity - Humanity

Nguồn: outputs/modeling/tables/warning_events.csv; outputs/course_alignment/20261007/warning_fixed_policies.csv

Báo cáo dự đoán thời điểm bảo trì

21/21 động cơ được xếp cần bảo trì đều có RUL thực tế ≤ 30, không báo nhầm; bắt được 21/25 động cơ cần bảo trì





Động cơ	Trạng thái	Cycle hiện tại	RUL dự đoán	Cycle cần bảo trì
34	Cần bảo trì	203	6,2	203
41	Cần bảo trì	123	29,6	123
90	Theo dõi tăng cường	146	31,2	147
91	Theo dõi tăng cường	234	33,4	237
11	Bình thường	83	114,2	167

Đối chiếu với RUL thực tế

Trạng thái	≤ 30	31–60	> 60
Cần bảo trì	**21**	**0**	**0**
Theo dõi tăng cường	4	14	41
Bình thường	0	0	20

21/25 động cơ có RUL thực tế ≤ 30 được xếp cần bảo trì; 4 động cơ còn lại đến hạn sau 1–8 cycle.

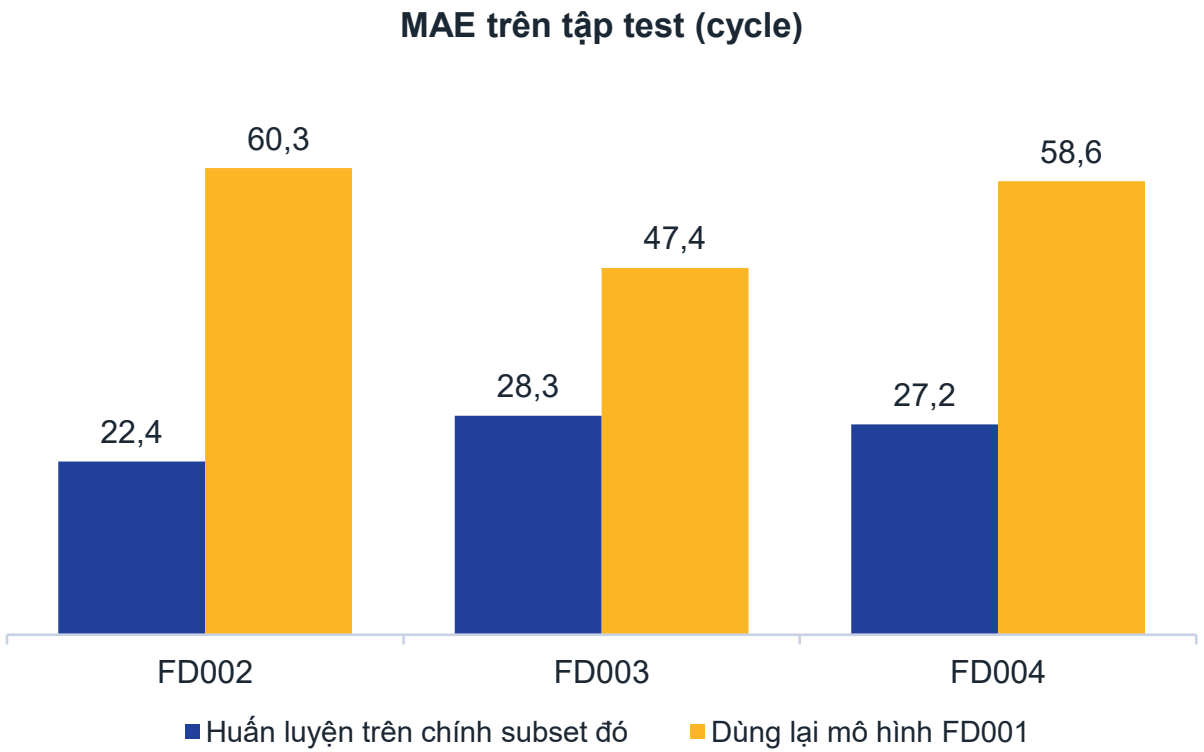
Giới hạn: 12 động cơ còn xa mới hỏng có lịch muộn hơn lúc hỏng 4–27 cycle.

Innovation - Unity - Humanity

Nguồn: outputs/maintenance/tables/maintenance_schedule.csv; outputs/maintenance/summary.json

Các thử nghiệm mở rộng

Mô hình FD001 không dùng tốt được cho FD002–FD004 (cửa sổ 10 cycle); ba hướng cải tiến không thay mô hình chính



Nested CV: cửa sổ, siêu tham số, trọng số

Chọn lại đúng cấu hình gốc; số cảnh báo muộn tăng từ 49 lên 53/100.

Thêm cột cycle và 42 đặc trưng lịch sử

169 đặc trưng: MAE OOF 20,21 → 17,00; tỷ lệ cảnh báo kịp thời (ngưỡng 30) giảm từ 51% xuống 45%.

ARIMA dự báo Health Index

MAE 0,41 so với 0,75 của cách kéo thẳng xu hướng (drift); tốt hơn ở 7/10 động cơ.

Innovation - Unity - Humanity

Nguồn: outputs/cross_dataset/matrix.json; outputs/experiments/; outputs/course_alignment/20261007/summary.json

Kết luận

Trả lời năm câu hỏi nghiên cứu; kết luận chỉ áp dụng cho dữ liệu mô phỏng C-MAPSS FD001

Q1 Pipeline dữ liệu

0 sai khác

đạt mọi kiểm tra; Pandas và PySpark khớp; PySpark nhanh hơn khoảng 3,4 lần khi dữ liệu gấp 10

Q2 Làm mượt, cửa sổ

−86%

dao động sau EWMA; 126 đặc trưng từ cửa sổ 30 cycle

Q3 Xu hướng, bất thường

100/100

động cơ train được phát hiện, trung vị 121 cycle trước khi hỏng

Q4 Dự đoán RUL

15,35

MAE tập test (cycle); chỉ 4,38 khi RUL ≤ 30

Q5 Cảnh báo, lịch bảo trì

21/21

báo cần bảo trì trên test đều đúng, bắt 21/25; OOF train: không bỏ sót, 49% muộn

Sản phẩm đặc thù

Lịch dự đoán thời điểm cần bảo trì cho 100 động cơ test (slide 16), kèm biểu đồ xu hướng cảnh báo sớm (slide 15).

Nguồn: report/sections/conclusion.tex; các artifact đã dẫn ở slide 6–16

Khó khăn, bài học và giới hạn

Các vấn đề phát sinh trong quá trình thực hiện, cách xử lý và bài học rút ra

Khó khăn	Cách xử lý	Bài học
Thiếu nhãn thời điểm bất thường	Lấy 30 cycle đầu của từng động cơ làm mức tham chiếu	Nói rõ mức tham chiếu và phần chưa kiểm chứng được
Rò rỉ dữ liệu khi chia tập	GroupKFold theo động cơ; cửa sổ và EWMA chỉ dùng quá khứ	Chia tập theo từng động cơ, không chia theo từng dòng
PySpark thiếu winutils trên Windows; Hadoop một node	Ghi Parquet qua Arrow; image Hadoop có sẵn Python; replication = 1	Đối chiếu từng giá trị giữa các cách làm; kiểm tra HDFS bằng fsck sau khi ghi
Dễ sa vào tối ưu mô hình	Cố định tiêu chí đánh giá trước; tách thử nghiệm sang phần mở rộng	Ưu tiên pipeline đúng và cảnh báo dễ hiểu hơn việc giảm thêm vài cycle MAE

Giới hạn: dữ liệu mô phỏng; chưa có chi phí bảo trì để chọn ngưỡng; Hadoop và Spark chạy trên một máy, chưa có cluster nhiều node hay streaming; kết quả cảnh báo trên OOF train hơi lạc quan.

Nguồn: report/sections/discussion.tex (Mục Khó khăn và bài học rút ra)

Industrial University of Ho Chi Minh City



Trân trọng cảm ơn quý thầy cô đã lắng nghe

Kính mời quý thầy cô đặt câu hỏi

Demo dashboard: uv run --extra dashboard streamlit run app.py

Phan Nguyễn Mai Phương · MSHV 25002711