BÁO CÁO CUỐI KỲ · PHÂN TÍCH DỮ LIỆU LỚN

Dự đoán tuổi thọ còn lại và cảnh báo sớm cho động cơ turbofan

Pipeline dữ liệu chuỗi thời gian trên NASA C-MAPSS FD001–FD004

100	21	169	17,00
train engines FD001	sensor mỗi cycle	features HGB169 · FD001	MAE trajectory candidate

Phan Nguyễn Mai Phương · MSHV 25002711

Học viên cao học ngành Khoa học máy tính · Tháng 10/2026

Nội dung trình bày và sáu câu hỏi nghiên cứu

18–20 phút gồm demo dashboard; kết luận ở slide 19 trả lời lần lượt Q1–Q6

1. **Bài toán và dữ liệu**
   Slide 2–5 · 3 phút
2. **Pipeline Big Data**
   Slide 6–7 · 3 phút
3. **Phân tích chuỗi thời gian**
   Slide 8–11 · 3 phút
4. **Mô hình và đánh giá**
   Slide 12–16 · 5 phút
5. **Mở rộng và kết luận**
   Slide 17–20 · 3 phút
6. **Demo dashboard**
   Artifact đã tạo · 3 phút

Câu hỏi nghiên cứu

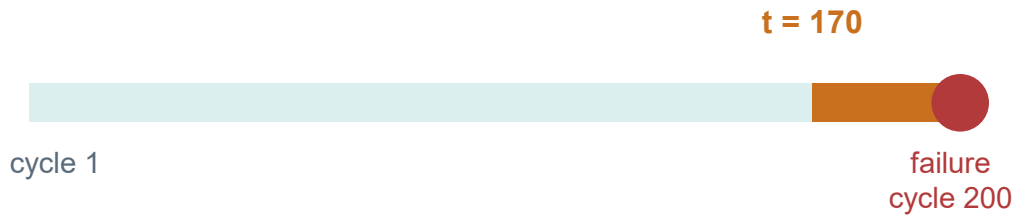
- **Q1** FD001 có hợp lệ về schema, khóa và tính liên tục của cycle không?
- **Q2** Sensor thay đổi thế nào giữa đầu và cuối vòng đời engine?
- **Q3** ETL bằng Pandas và PySpark có cho kết quả giống nhau không?
- **Q4** HGB126 hay HGB169 ổn định hơn trên cùng panel và các mốc vòng đời?
- **Q5** RUL có chuyển thành cảnh báo sớm với chất lượng chấp nhận được không?
- **Q6** Model huấn luyện trên FD001 hoạt động thế nào khi áp dụng FD002–FD004?

Nguồn: report/main.pdf; handoff/SPEECH_SCRIPT_VI.pdf

Bài toán: ước lượng số cycle còn lại trước failure

Đề tài 8 yêu cầu phát hiện dấu hiệu suy giảm và dự đoán thời điểm cần bảo trì từ dữ liệu cảm biến

Ví dụ trên một train engine



RUL(t) = cycle cuối − t

RUL(170) = 200 − 170 = 30 cycles

Supervised regression: input là chuỗi 21 sensor theo cycle, output là một số RUL. Đơn vị là cycle, không quy đổi ra giờ.

Yêu cầu của đề tài	Cách đáp ứng trong báo cáo	Slide
Xử lý chuỗi thời gian cảm biến	Kiểm tra schema, khóa, cycle liên tục; window theo từng engine	6, 10
Xử lý nhiễu tín hiệu	Thống kê trên window 30 và Health Index PCA; chưa dùng bộ lọc riêng	10, 11
Chuẩn hóa, tổng hợp theo window	Chuẩn hóa schema; StandardScaler trong fold; 126 đặc trưng	10
Trực quan xu hướng suy giảm	Quỹ đạo sensor, kiểm định đầu/cuối vòng đời, Health Index	9, 11
Dự đoán thời điểm bảo trì, cảnh báo sớm	Dự đoán RUL; cảnh báo khi RUL dự đoán ≤ 30 cycles	14, 16

Nguồn: references/context/assignment-brief.png; report/sections/problem-data.tex; data/CONTRACTS.md

NASA C-MAPSS: bốn subset, hai trục khác biệt

Hai trục là số điều kiện vận hành và số fault mode; FD001 là protocol chính, FD002–FD004 dùng ở slide 18

FD001

Protocol chính

1 điều kiện vận hành
1 fault mode (HPC)

100 train / 100 test engines
33.727 observations

FD002

Kiểm tra chuyển miền

6 điều kiện vận hành
1 fault mode (HPC)

260 train / 259 test engines
87.750 observations

FD003

Kiểm tra chuyển miền

1 điều kiện vận hành
2 fault mode (HPC, Fan)

100 train / 100 test engines
41.316 observations

FD004

Kiểm tra chuyển miền

6 điều kiện vận hành
2 fault mode (HPC, Fan)

249 train / 248 test engines
102.463 observations

Một dòng observation có 26 trường



Khóa trong một subset: (split, engine_id, cycle). Bốn subset được xử lý riêng vì khóa chưa có dataset_id.

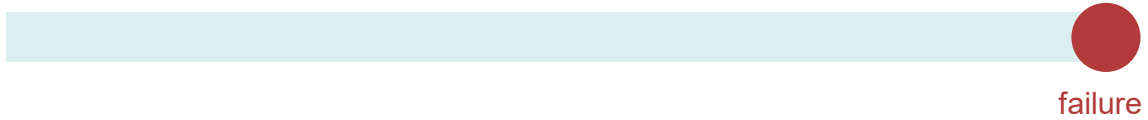
Nguồn: data/raw/readme.txt; outputs/cross_dataset/FD00x/etl/run_info.json; data/CONTRACTS.md

Nhãn RUL tạo từ train; nhãn test chỉ mở sau khi đã dự đoán

Ranh giới này ngăn data leakage (rò rỉ dữ liệu) từ test vào EDA, đặc trưng và chọn mô hình

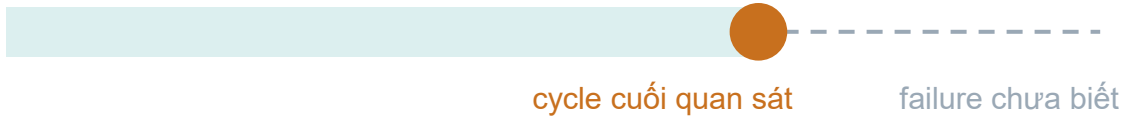
Train

100 engines chạy đến failure



Test

100 engines bị cắt trước failure



Train: RUL(t) = cycle cuối − t → 20.631 nhãn

Test: 1 dự đoán/engine tại cycle cuối → ghi final predictions → mới ghép RUL_FD001.txt

Kiểm soát nhãn test

Không dùng

trong EDA, đặc trưng, chọn model

Ghép muộn

sau khi đã ghi final predictions

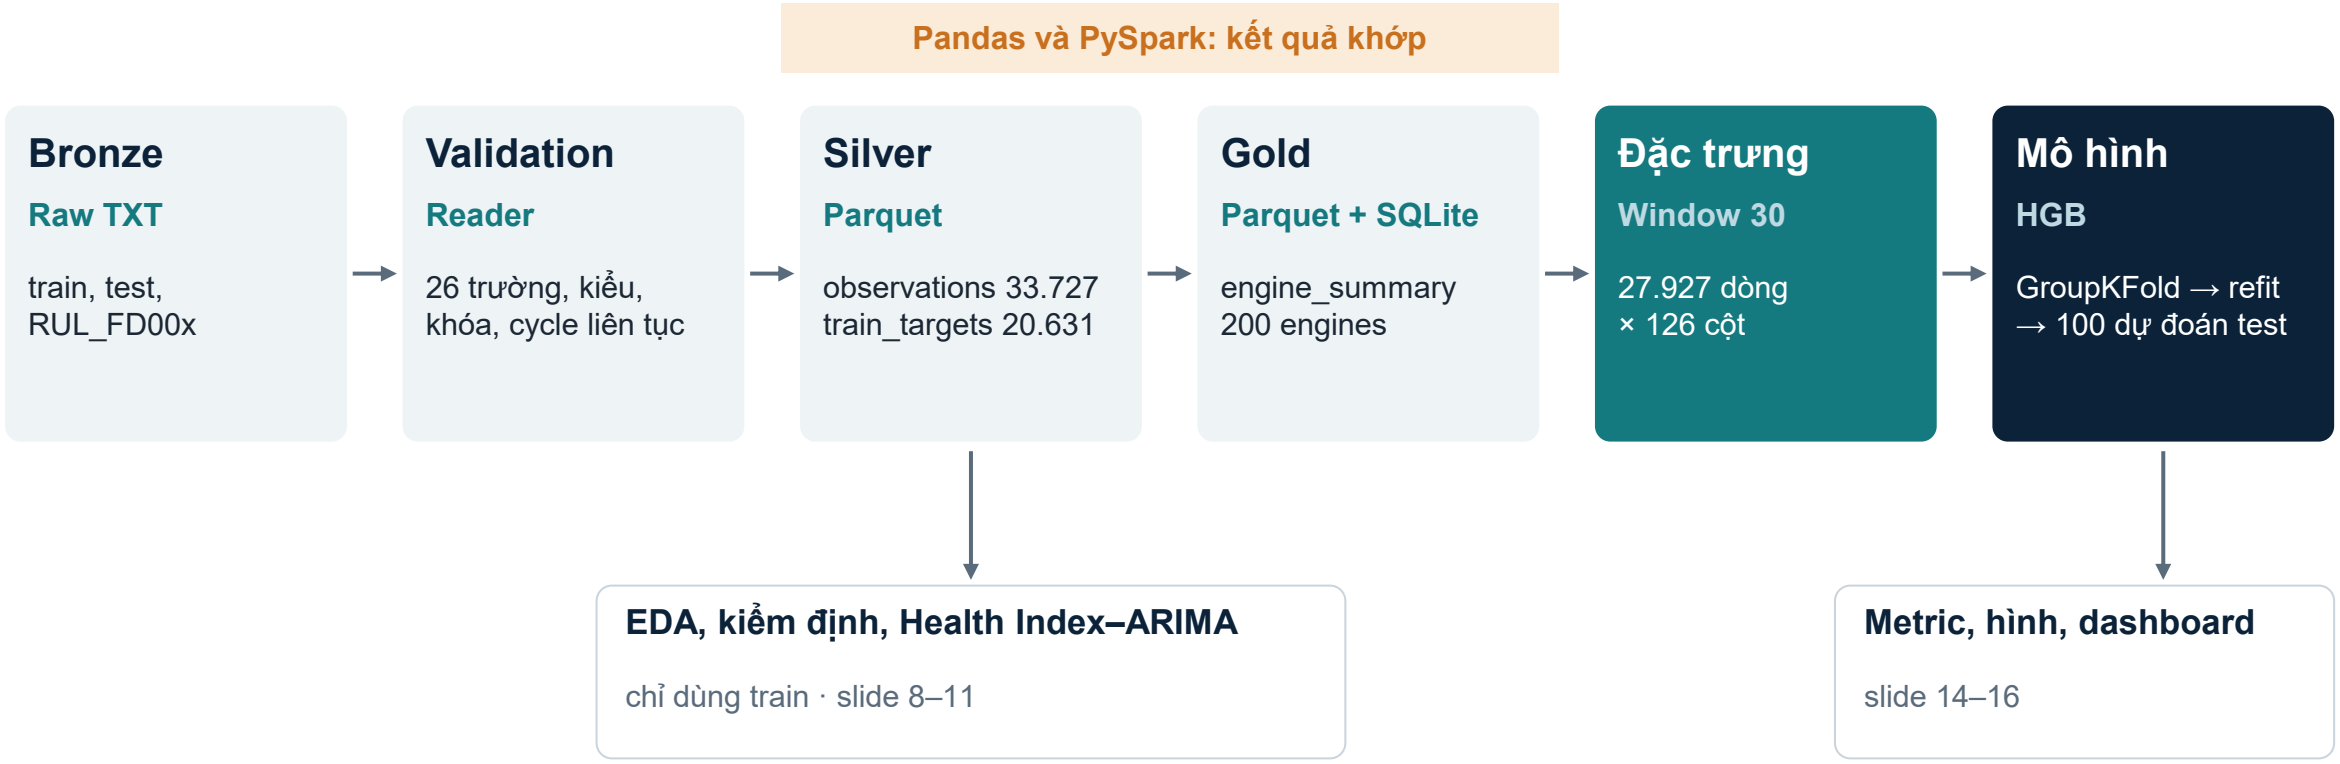
Có dấu vết

run_info ghi trạng thái join; final_metrics ghi SHA-256 của nhãn

Nguồn: data/CONTRACTS.md; outputs/etl/parity.json; outputs/modeling/run_info.json; outputs/modeling/tables/final_metrics.json

Pipeline Bronze → Silver → Gold → đặc trưng → mô hình

Mỗi bước ghi artifact kèm hash và run_info để truy vết và chạy lại



Khóa observation: (split, engine_id, cycle). Feature và target được join bằng đủ ba cột khóa và kiểm tra quan hệ 1:1.

Nguồn: assets/diagrams/fd001-pipeline.drawio; handoff/DATA_WALKTHROUGH.md; outputs/*/run_info.json

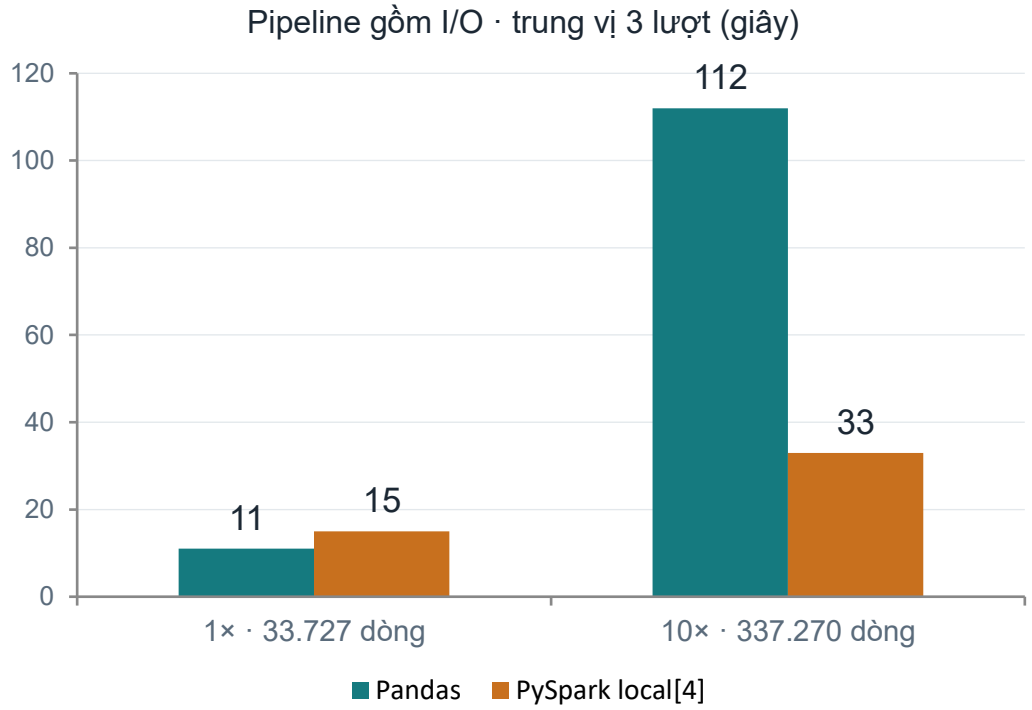
Pandas và PySpark cho cùng kết quả tại ba boundary

Đã bổ sung parity 126 rolling features và benchmark local 1×/10×: đọc, tổng hợp, tạo feature, ghi file

Boundary	Số dòng	Sai khác lớn nhất	Kết quả
silver_observations	33.727	0	Khớp
silver_train_targets	20.631	0	Khớp
gold_engine_summary	200	0	Khớp

Kiểm tra cùng một input bằng hai engine xử lý

Rolling features: so toàn bộ 27.927 dòng × 126 features, tolerance 10^{-7}. Cùng window 30, std ddof=1 và slope nhân quả theo từng engine.

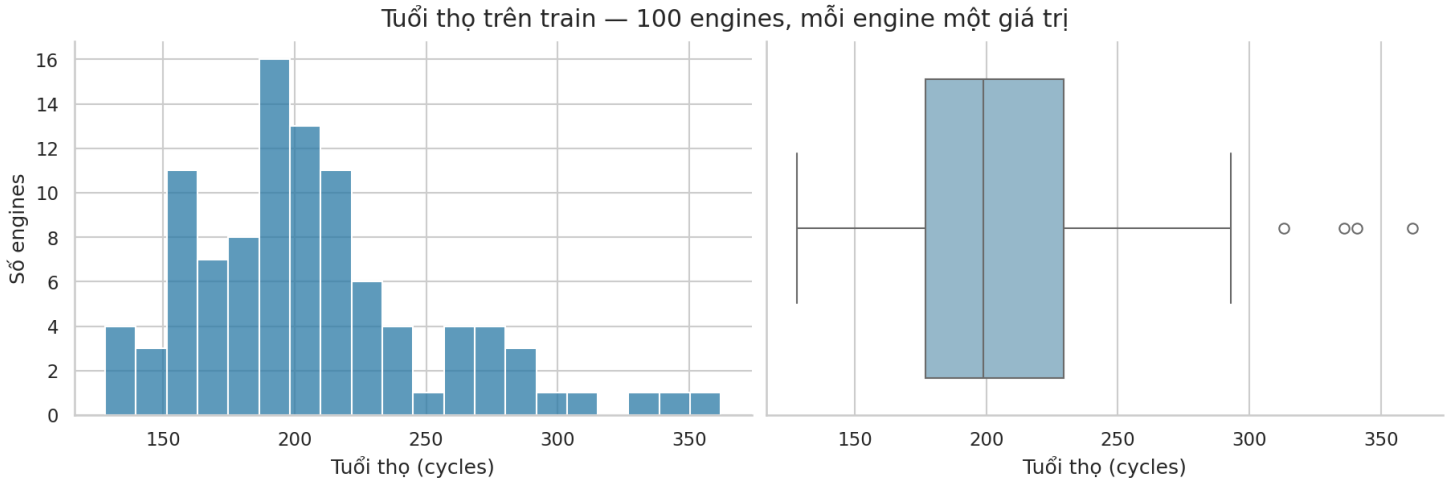


Chưa gồm startup Spark. Ghi qua Arrow trên driver; chưa suy rộng hiệu năng sang cluster.

Nguồn: outputs/etl/parity.json; outputs/benchmarks/20260929/{measurements.csv,run_info.json}

EDA: tuổi thọ phân tán rộng và 7 cột không đổi

EDA chỉ dùng train để hiểu dữ liệu trước khi xây dựng đặc trưng



128
Ngắn nhất (cycles)

199
Trung vị (cycles)

206,31
Trung bình (cycles)

362
Dài nhất (cycles)

Không đổi trong cả 100 engine

- sensor_1
- sensor_5
- sensor_10
- sensor_16
- sensor_18
- sensor_19
- setting_3

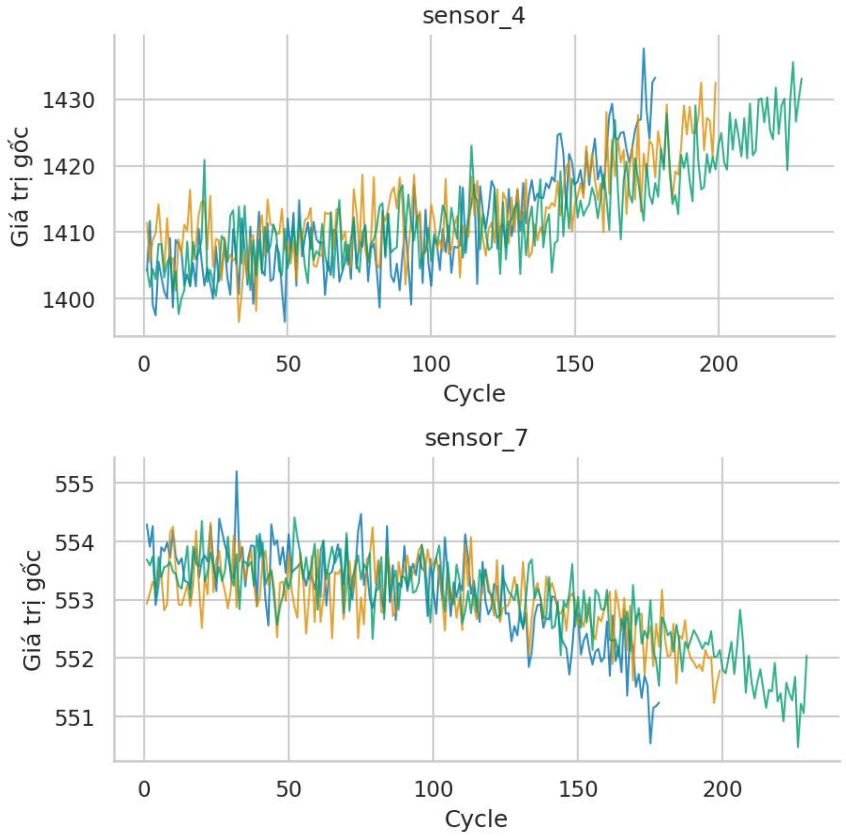
sensor_6 không đổi trong 38/100 engine.

Chưa loại cột nào: 126 đặc trưng vẫn gồm đủ 21 sensor; không làm feature selection từ EDA.

Nguồn: outputs/eda/figures/engine_lifetimes.png; outputs/eda/tables/constant_engine_counts.csv; lifetime_summary.csv

Nhiều sensor thay đổi rõ khi engine tiến gần failure

So sánh 30 cycle đầu và 30 cycle cuối trên cùng engine: 15/21 sensor có thay đổi sau hiệu chỉnh FDR



Engine 87 (178 cycles), 26 (199), 75 (229); giá trị gốc chưa chuẩn hóa.

1. **Ghép cặp trong engine**
   Δ = mean(30 cycle cuối) − mean(30 cycle đầu)

2. **Bootstrap và Wilcoxon**
   Lấy mẫu lại engine 10.000 lần; Wilcoxon signed-rank

3. **Hiệu chỉnh đa kiểm định**
   Benjamini–Hochberg cho 21 sensor, q = 0,05

15/21

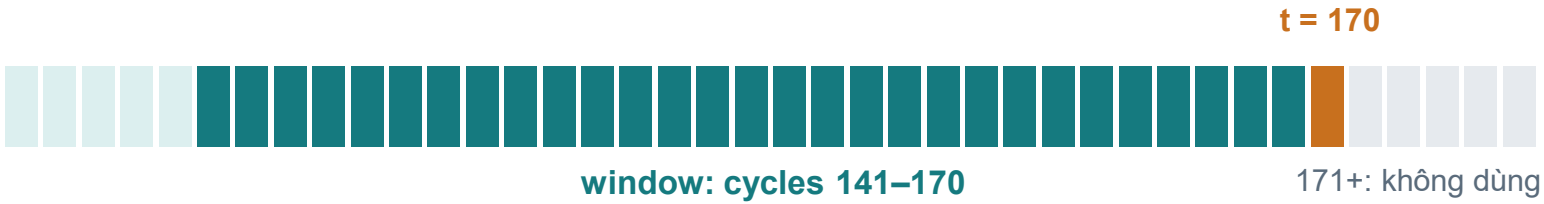
sensor bác bỏ giả thuyết không sau hiệu chỉnh

6 sensor hằng số nên không kiểm định. Kết quả mô tả khác biệt đầu/cuối vòng đời, không chứng minh nhân quả.

Nguồn: outputs/eda/figures/sensor_trajectories_1.png; outputs/statistics/tables/sensor_inference.csv; report/sections/methodology.tex

Trailing window 30 cycle biến chuỗi sensor thành 126 đặc trưng

Mỗi dòng đặc trưng chỉ dùng quá khứ của chính engine đó; không dùng cycle tương lai hoặc engine khác



21 sensor × 6 thống kê = 126 cột

last
trạng thái hiện tại

mean
mức trung bình

std
độ dao động

min
cận dưới

max
cận trên

slope
xu hướng tăng/giảm

17.731 train windows · 10.196 test windows · 29 cycle đầu mỗi engine chưa đủ window, không padding

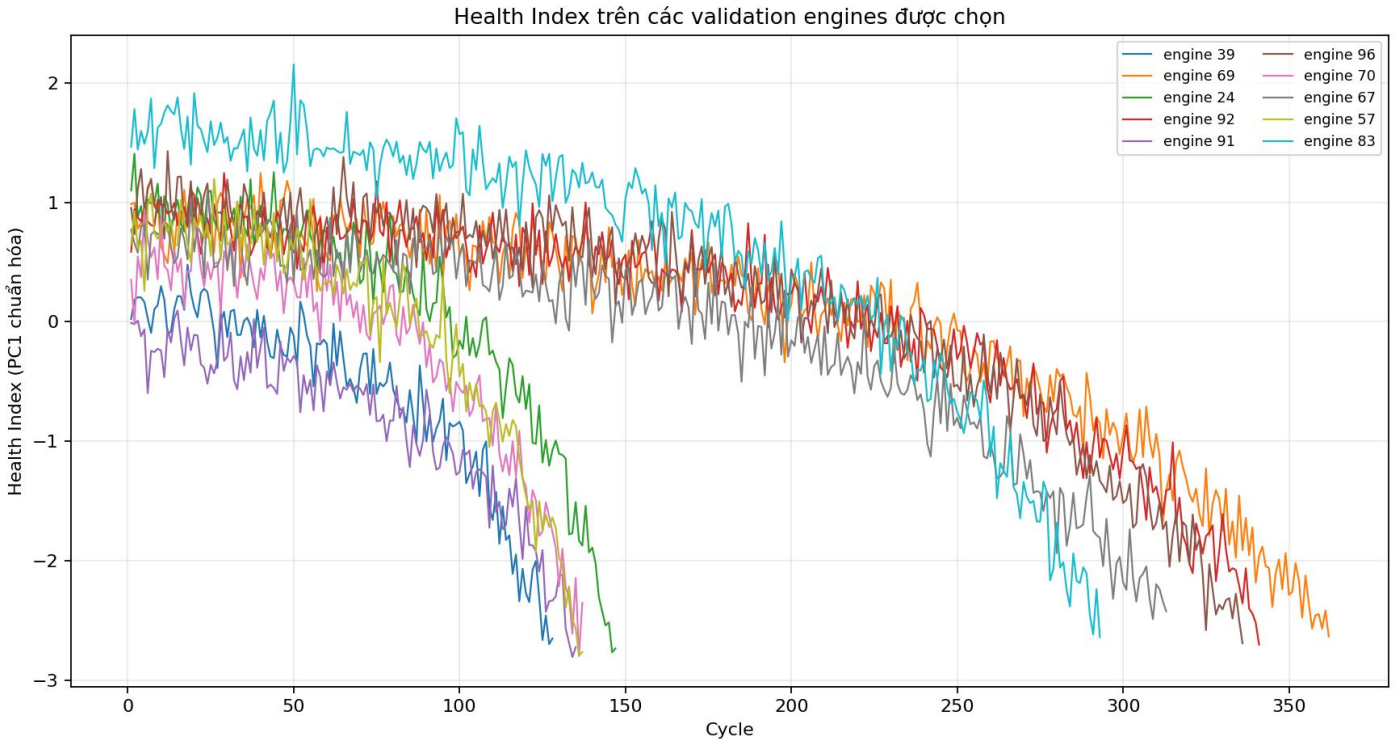
Nhiễu và chuẩn hóa

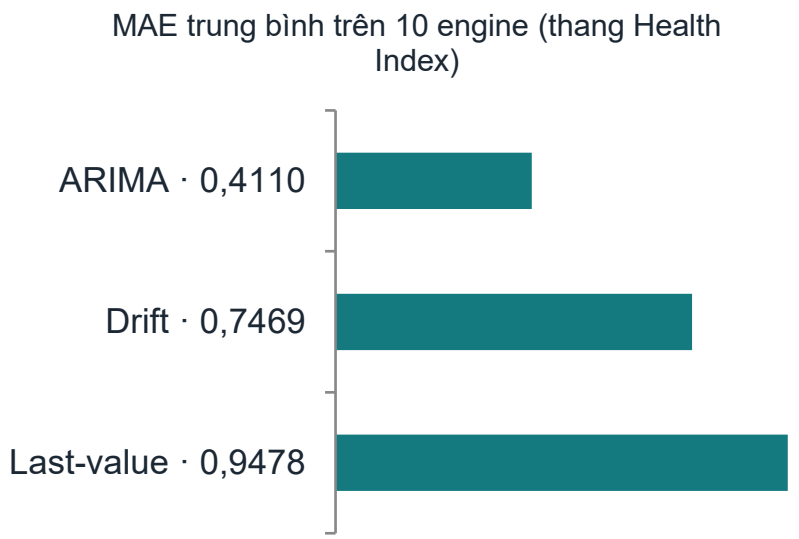
- Thống kê trên 30 cycle tóm tắt dao động từng cycle; chưa dùng bộ lọc tín hiệu riêng.
- ETL chuẩn hóa schema và kiểu dữ liệu.
- StandardScaler fit trong training fold (Ridge) và trên 90 engine (Health Index).
- HGB dùng thang đo gốc.

Nguồn: outputs/features/run_info.json; src/cmapss/features/rolling.py; handoff/DATA_WALKTHROUGH.md

Health Index gom 21 sensor thành một đường suy giảm

PCA fit trên 90 train engines; ARIMA dự báo 30% cuối chuỗi của 10 engine giữ riêng



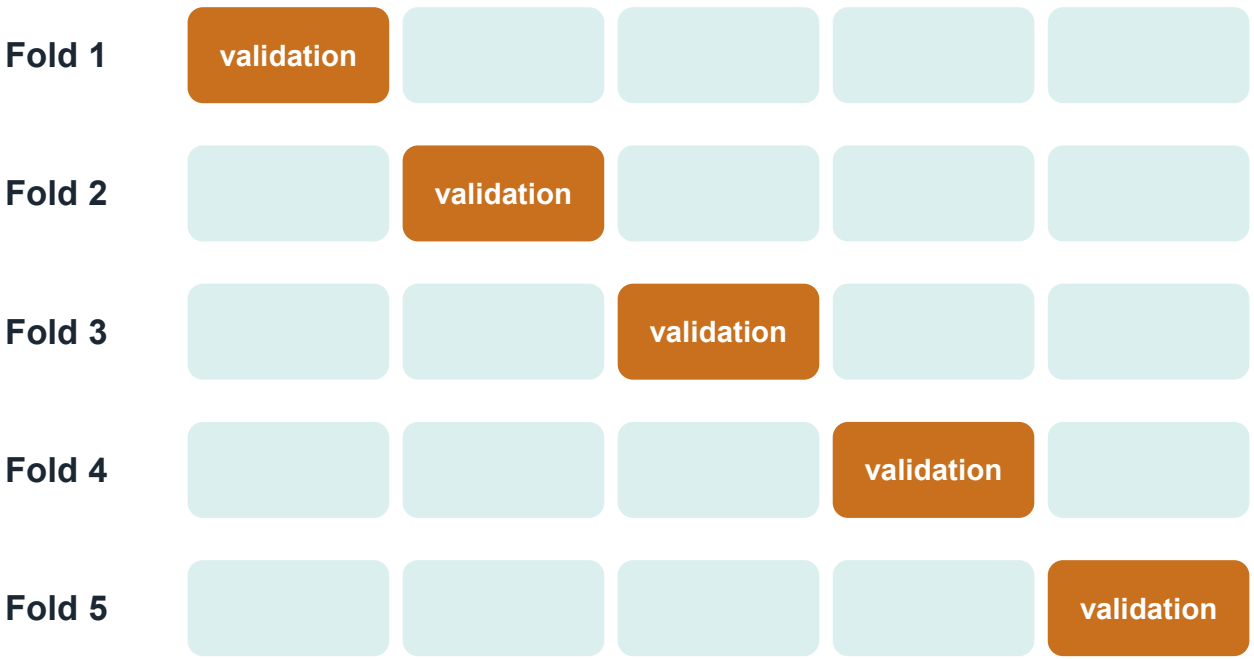


Coverage khoảng dự đoán 95%: 21,43%–97,03% giữa các engine. Health Index không phải RUL; đây là phân tích phụ.

Nguồn: outputs/timeseries/figures/health_index_selected_engines.png; tables/forecast_metrics.csv; tables/baseline_metrics.csv

Đánh giá theo engine để tránh data leakage

5-fold GroupKFold: mọi window của một engine nằm cùng một phía của phép chia



Mỗi ô là một nhóm 20 train engines; màu nhạt là phần fit.

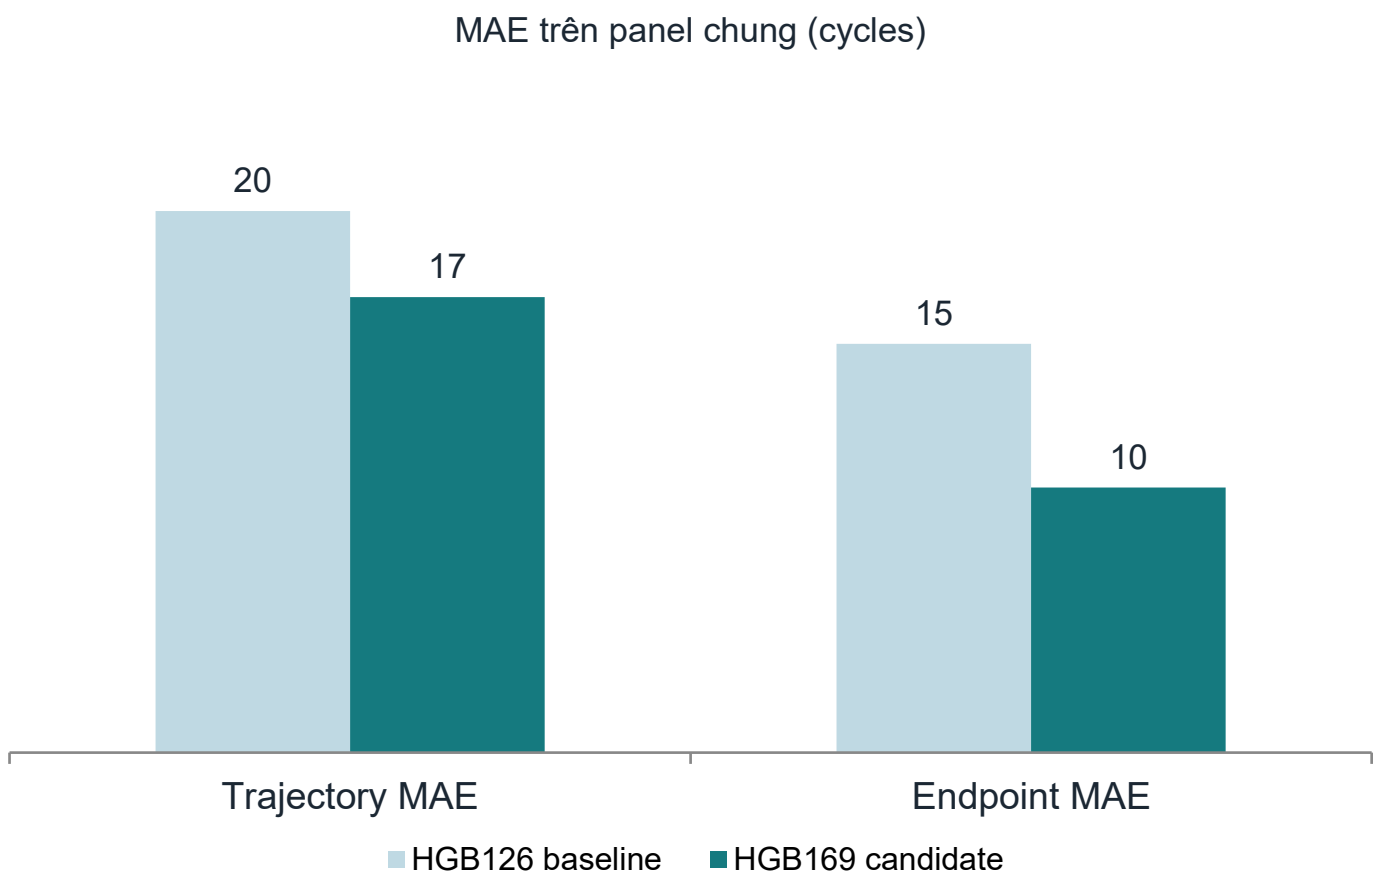
1. **Chọn model**
   mean engine-level MAE trên dự đoán OOF
2. **Cân bằng engine**
   tổng sample weight mỗi engine bằng 1 trong fold
3. **Refit**
   toàn bộ 17.731 train windows
4. **Dự đoán test**
   1 điểm/engine tại cycle cuối, sau đó mới ghép nhãn

Hai window liền kề trùng 29/30 cycle; chia ngẫu nhiên theo dòng làm metric lạc quan.

Nguồn: outputs/modeling/tables/evaluation_protocol.csv; outputs/modeling/run_info.json; report/sections/methodology.tex

HGB169 là predictor candidate trên panel chung

HGB169 giảm MAE trajectory 3,2134 cycles; audit có điều kiện



Panel / chỉ số	HGB126	HGB169	Delta
Trajectory MAE	20,21	17,00	-3,21
Trajectory RMSE	33,64	29,81	-3,83
Endpoint MAE	**15,26**	**9,89**	**-5,37**
Endpoint RMSE	22,35	14,99	-7,35

Cách đọc kết quả

Âm ở cột Delta nghĩa là HGB169 thấp hơn HGB126. Hai panel dùng cùng engine, fold và prediction đã lưu; chưa có blind refit độc lập, còn historical test readout chỉ dùng để báo cáo.

Nguồn: outputs/course_alignment/20261007/summary.json; outputs/course_alignment/20261007/paired_bootstrap_ci.csv

Metric test lịch sử của HGB126: MAE 15,35 cycles

HGB126 là baseline lịch sử; metric test được giữ riêng vì HGB169 chưa có refit mù độc lập

15,35

MAE (cycles)

CI 95%: [12,73; 18,09]

20,54

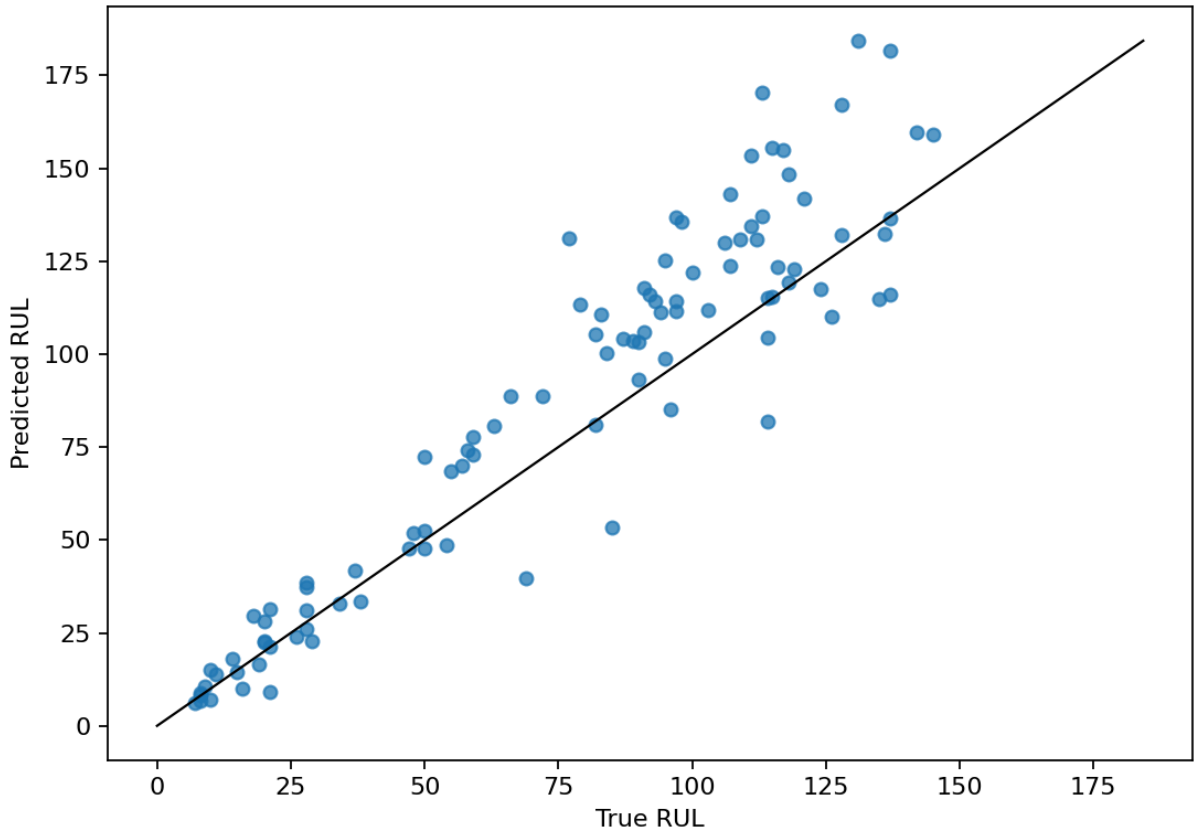
RMSE (cycles)

Phạt sai số lớn mạnh hơn MAE

1.513,26

NASA score

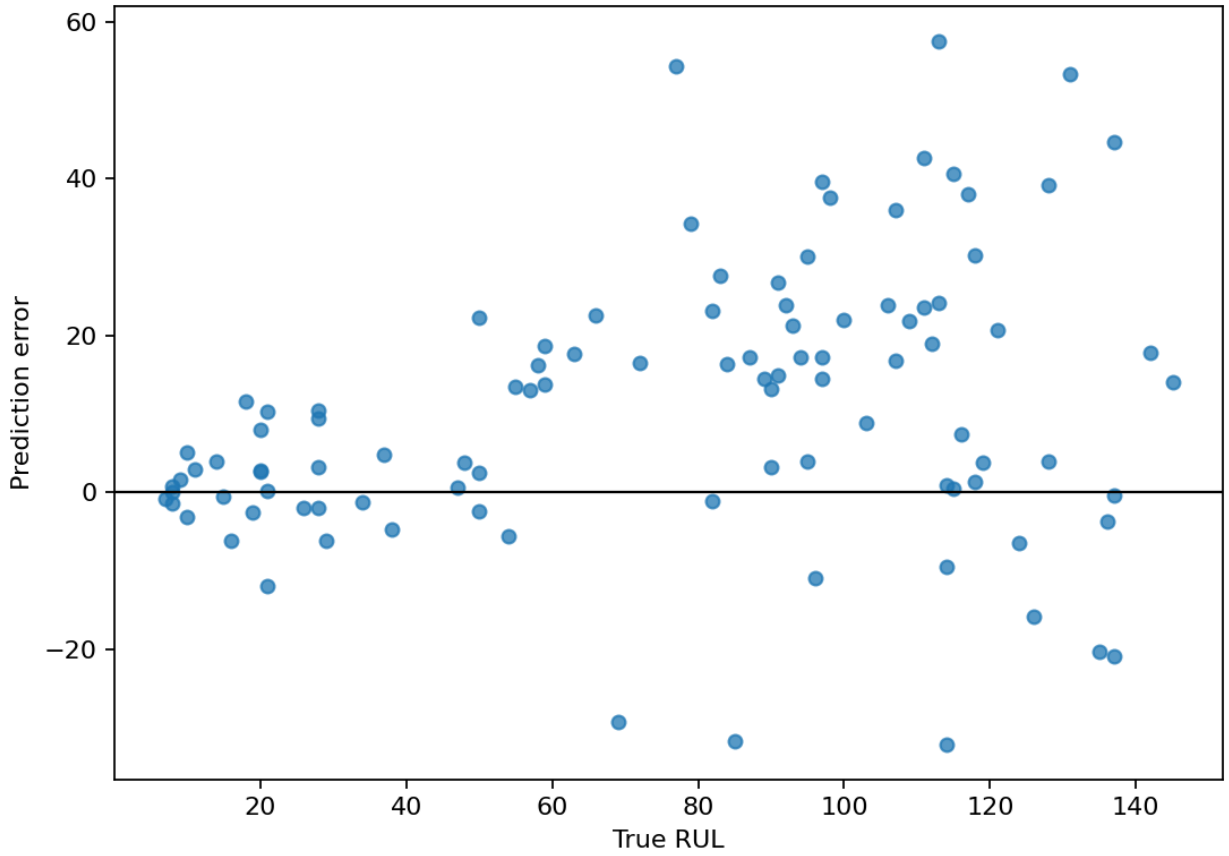
Phạt dự đoán trễ nặng hơn; không có đơn vị



Nguồn: outputs/modeling/tables/final_metrics.json; outputs/modeling/figures/final_true_vs_predicted.png

Phân tích sai số của HGB126 baseline lịch sử

Dự đoán cao hơn RUL thật tương ứng cảnh báo muộn; NASA score phạt loại sai số này nặng hơn



Hướng sai số trên 100 test engines

74 cao hơn	26 thấp hơn

Trường hợp sai lớn nhất: engine 23

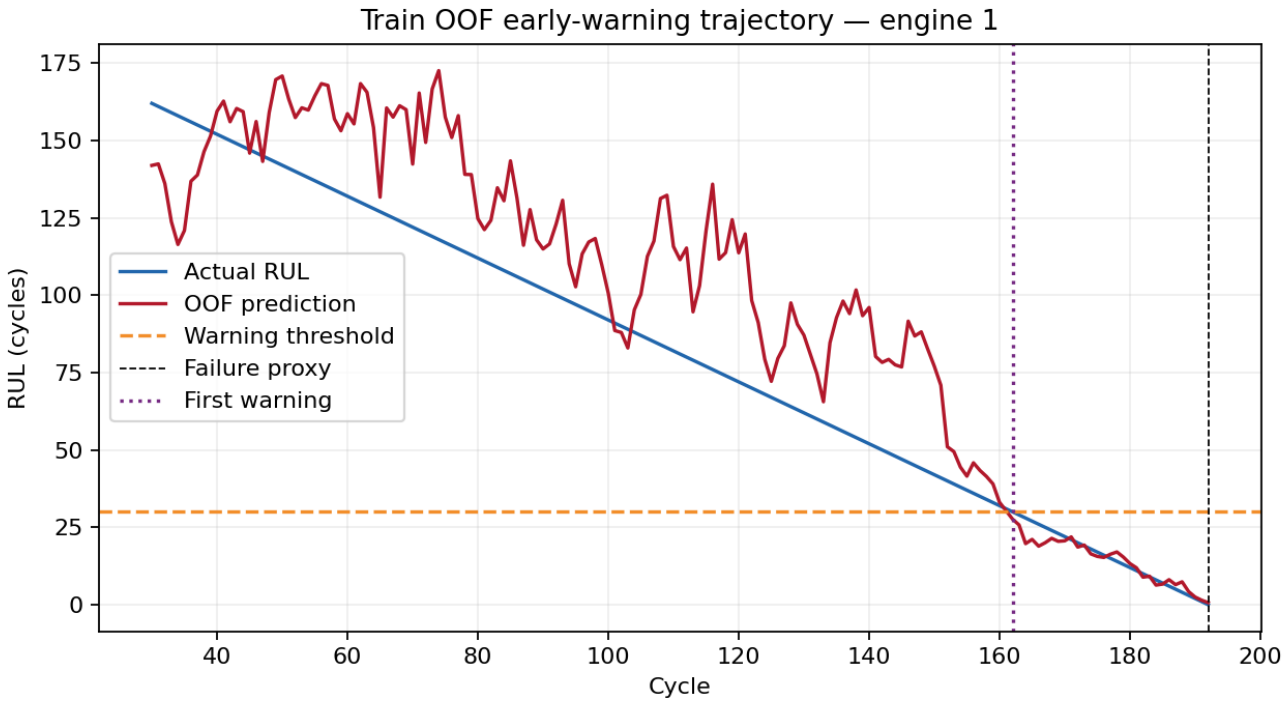
113	170,48	57,48
RUL thật (cycles)	Dự đoán (cycles)	Sai số (cycles)

10 trường hợp sai lớn nhất chiếm 75,5% NASA score. Trên OOF, dự đoán dừng quanh 145–147 cycles khi RUL thật > 150.

Nguồn: outputs/modeling/predictions/final_evaluation.parquet; outputs/modeling/figures/final_residuals_by_rul.png; outputs/diagnostics/error_diagnostics.json

Warning policy phải được đánh giá riêng với predictor

Threshold 30: HGB126 51%, HGB169 45%; threshold 40: 94% và 96%



Engine 1: cảnh báo tại cycle 162, failure tại cycle 192.

Model	Ngưỡng	Đúng lúc	Trễ/bỏ lỡ	Burden
HGB126	30	51%	49%	1,293%
HGB169	30	45%	55%	1,070%
HGB126	40	94%	6%	5,329%
HGB169	40	96%	4%	5,553%

Fixed-policy sensitivity trên cùng prediction panel

Burden = tỷ lệ cảnh báo sớm; threshold chưa được hiệu chuẩn theo chi phí. Predictor selection và warning policy là hai quyết định riêng.

HGB126 threshold 30: 51/100 đúng lúc; median lead 30 cycles.

Hình bên trái là mô tả nội bộ trên OOF.

Nguồn: outputs/course_alignment/20261007/warning_fixed_policies.csv; outputs/modeling/figures/warning_trajectory.png

Nested CV: kiểm tra cải thiện trên engine được giữ riêng

Kết quả gốc và thí nghiệm bổ sung; chỉ thay baseline khi đạt tiêu chí đã chốt trước

Nested GroupKFold

5 vòng ngoài

giữ riêng một nhóm engine

↓

3 vòng trong

chọn cấu hình chỉ từ train

↓

CI nghiên cứu gốc

ΔMAE RUL ≤ 30: +0,0054
CI 95% [-0,0506; 0,0639]

FD001 gốc: thử window, tham số và trọng số

Chỉ số	Baseline	Quy trình chọn mới
MAE toàn bộ (cycles)	20,21	20,25
MAE khi RUL ≤ 30 (cycles)	3,6676	3,6730
Cảnh báo trễ hoặc bỏ lỡ	49/100	53/100

Bổ sung 29/09: outer MAE của quy trình chọn (cycles)

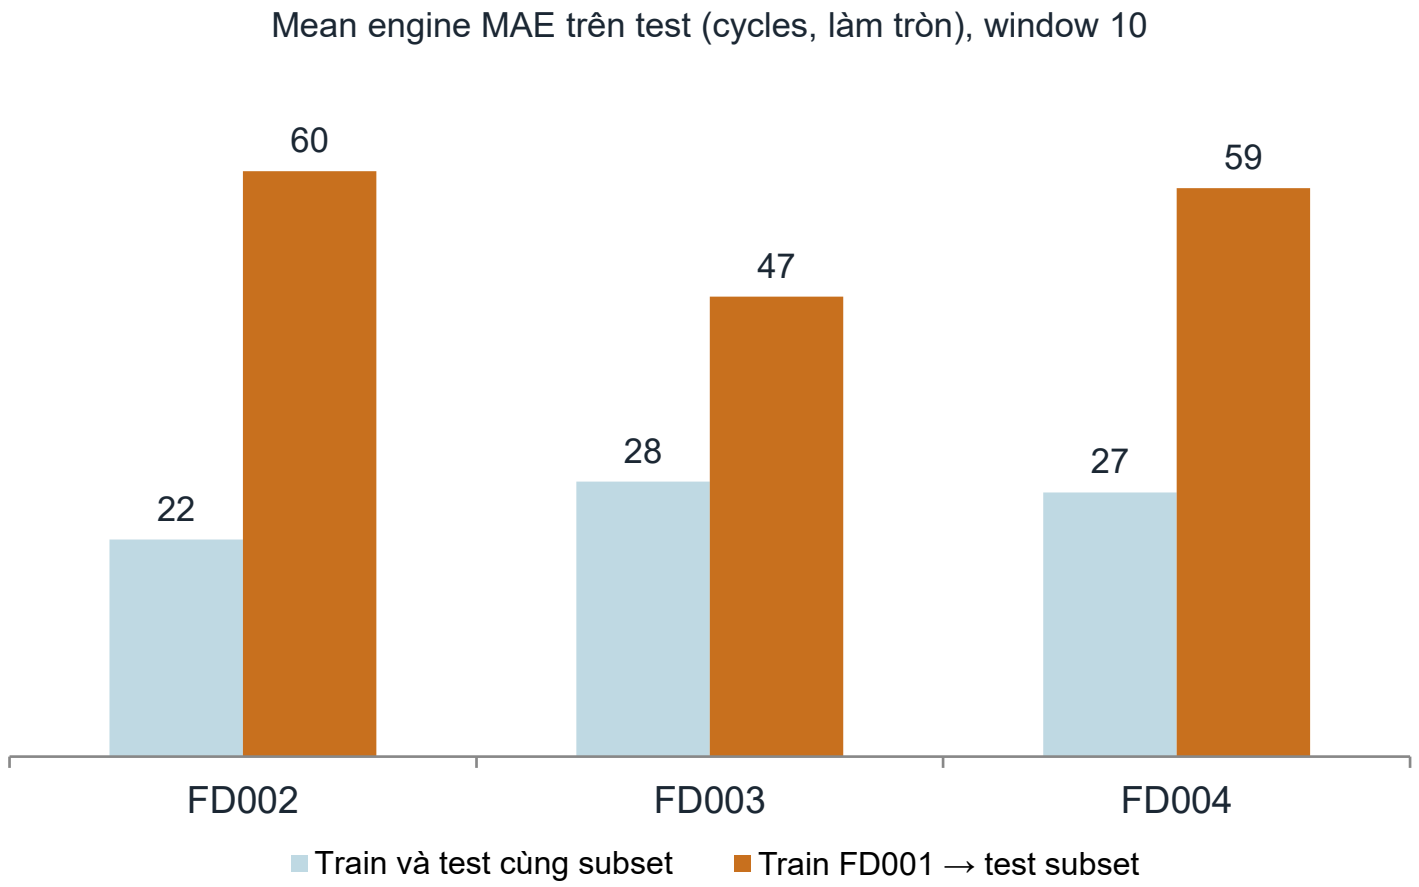
Dataset	Baseline	Quy trình chọn	Tiêu chí
FD001	20,21	20,30	Chưa đạt
FD002	29,29	28,04	Đạt
FD004	36,74	35,45	Đạt

FD001: window 30; FD002/FD004: window 10, huấn luyện trong từng subset.

Nguồn: outputs/experiments/rul_improvement/20260928_rebuild/; outputs/experiments/followup/20260929/

Model FD001 không chuyển trực tiếp sang FD002–FD004

Cùng pipeline với window 10; MAE tăng 1,7–2,7 lần khi đổi điều kiện vận hành hoặc fault mode



FD002 — 6 điều kiện · 15% trong miền FD001
22,36 → 60,32 cycles (×2,7)

FD003 — fault Fan · 95% trong miền FD001
28,33 → 47,39 cycles (×1,7)

FD004 — cả hai · 14% trong miền FD001
27,22 → 58,57 cycles (×2,2)

Cần huấn luyện lại hoặc domain adaptation trước khi dùng model FD001 cho subset khác.

Nguồn: outputs/cross_dataset/matrix.json; outputs/diagnostics/error_diagnostics.json

Trả lời sáu câu hỏi nghiên cứu

Kết luận chỉ áp dụng cho protocol và dữ liệu mô phỏng đã nêu

Q1 Dữ liệu hợp lệ

Đạt

Schema, khóa và cycle của FD001 qua kiểm tra

Q2 Xu hướng sensor

15/21

sensor thay đổi đầu/cuối; Health Index giảm rõ

Q3 Parity ETL

0 sai khác

Ba artifact Pandas–PySpark khớp tuyệt đối

Q4 HGB comparison

-3,21

delta trajectory MAE; HGB169 là candidate có điều kiện

Q5 Warning policy

51% / 45%

threshold 30: HGB126 / HGB169; policy tách khỏi predictor

Q6 Chuyển miền

Không

FD001 cần huấn luyện lại hoặc domain adaptation

Đóng góp Big Data: batch ETL nhiều file, Parquet Silver/Gold, parity Pandas–PySpark và artifact có hash, run_info để tái lập.

Nguồn: report/sections/conclusion.tex; các artifact đã dẫn ở slide 9–18

Giới hạn và hướng tiếp theo

Giới hạn đã biết

- Dữ liệu mô phỏng; FD001 chỉ có một điều kiện vận hành và một fault mode.
- Mỗi test engine chỉ được đánh giá tại một điểm cắt.
- Không có chi phí, downtime, intervention records: chưa tối ưu được lịch bảo trì.
- Benchmark Pandas/PySpark chạy local; ghi qua driver, chưa đo cluster.

Đã bổ sung và hướng tiếp theo

- Refit mù HGB169 trên cùng protocol để xác nhận candidate bằng một lần chạy độc lập.
- Hiệu chuẩn warning policy riêng với chi phí báo sớm, báo trễ và tiêu chí vận hành.
- Đánh giá sai số theo toàn quỹ đạo trên engine chưa thấy và kèm khoảng không chắc chắn.
- Benchmark PySpark trên cluster thực; benchmark local hiện chỉ là bằng chứng khả năng chạy.

Xin cảm ơn thầy/cô. Xin nhận câu hỏi.

Dashboard: uv run --extra dashboard streamlit run app.py · Kịch bản demo: handoff/DEMO_SCRIPT.md