BÁO CÁO CUỐI KỲ · PHÂN TÍCH DỮ LIỆU LỚN

Dự đoán tuổi thọ còn lại và cảnh báo sớm cho động cơ turbofan

Pipeline dữ liệu chuỗi thời gian trên NASA C-MAPSS FD001–FD004

100	21	126	15,35
train engines FD001	sensor mỗi cycle	đặc trưng từ window 30	MAE (cycles) trên test

Phan Nguyễn Mai Phương · MSHV 25002711

Học viên cao học ngành Khoa học máy tính · Tháng 9/2026

Nội dung trình bày và ba câu hỏi nghiên cứu

30 phút, 5 phần; kết luận ở cuối trả lời lần lượt từng câu hỏi

1. **Bài toán và dữ liệu**
   Slide 2–5 · 6 phút
2. **Pipeline Big Data**
   Slide 6–7 · 4 phút
3. **Phân tích chuỗi thời gian**
   Slide 8–11 · 6 phút
4. **Mô hình và đánh giá**
   Slide 12–16 · 8 phút
5. **Mở rộng và kết luận**
   Slide 17–20 · 5 phút

Câu hỏi nghiên cứu

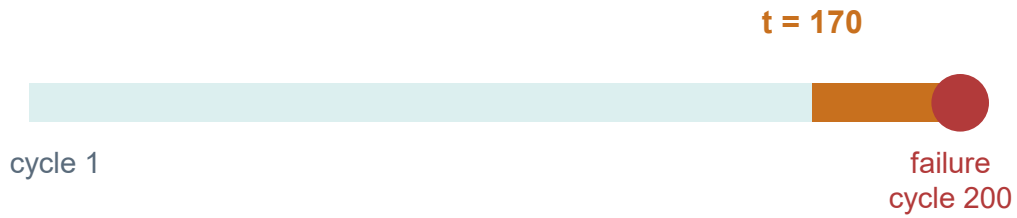
- **Q1** Dữ liệu sensor có thể hiện xu hướng suy giảm theo vòng đời engine không?
- **Q2** Từ 30 cycle gần nhất, RUL của engine chưa thấy được dự đoán với sai số bao nhiêu?
- **Q3** Có thể phát cảnh báo trước khi RUL xuống dưới 30 cycles không, và model có dùng được cho subset khác không?

Nguồn: report/main.pdf; handoff/SPEECH_SCRIPT_VI.pdf

Bài toán: ước lượng số cycle còn lại trước failure

Đề tài 8 yêu cầu phát hiện dấu hiệu suy giảm và dự đoán thời điểm cần bảo trì từ dữ liệu cảm biến

Ví dụ trên một train engine



RUL(t) = cycle cuối − t

RUL(170) = 200 − 170 = 30 cycles

Supervised regression: input là chuỗi 21 sensor theo cycle, output là một số RUL. Đơn vị là cycle, không quy đổi ra giờ.

Yêu cầu của đề tài	Cách đáp ứng trong báo cáo	Slide
Xử lý chuỗi thời gian cảm biến	Kiểm tra schema, khóa, cycle liên tục; window theo từng engine	6, 10
Xử lý nhiễu tín hiệu	Thống kê trên window 30 và Health Index PCA; chưa dùng bộ lọc riêng	10, 11
Chuẩn hóa, tổng hợp theo window	Chuẩn hóa schema; StandardScaler trong fold; 126 đặc trưng	10
Trực quan xu hướng suy giảm	Quỹ đạo sensor, kiểm định đầu/cuối vòng đời, Health Index	9, 11
Dự đoán thời điểm bảo trì, cảnh báo sớm	Dự đoán RUL; cảnh báo khi RUL dự đoán ≤ 30 cycles	14, 16

Nguồn: references/context/assignment-brief.png; report/sections/problem-data.tex; data/CONTRACTS.md

NASA C-MAPSS: bốn subset, hai trục khác biệt

Hai trục là số điều kiện vận hành và số fault mode; FD001 là protocol chính, FD002–FD004 dùng ở slide 18

FD001

Protocol chính

1 điều kiện vận hành
1 fault mode (HPC)

100 train / 100 test engines
33.727 observations

FD002

Kiểm tra chuyển miền

6 điều kiện vận hành
1 fault mode (HPC)

260 train / 259 test engines
87.750 observations

FD003

Kiểm tra chuyển miền

1 điều kiện vận hành
2 fault mode (HPC, Fan)

100 train / 100 test engines
41.316 observations

FD004

Kiểm tra chuyển miền

6 điều kiện vận hành
2 fault mode (HPC, Fan)

249 train / 248 test engines
102.463 observations

Một dòng observation có 26 trường



Khóa trong một subset: (split, engine_id, cycle). Bốn subset được xử lý riêng vì khóa chưa có dataset_id.

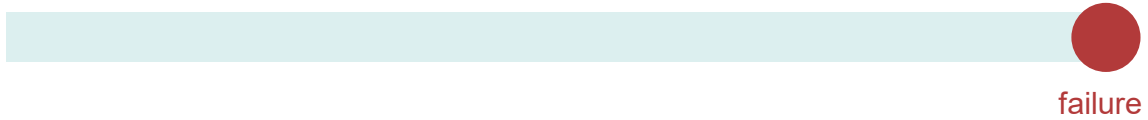
Nguồn: data/raw/readme.txt; outputs/cross_dataset/FD00x/etl/run_info.json; data/CONTRACTS.md

Nhãn RUL tạo từ train; nhãn test chỉ mở sau khi đã dự đoán

Ranh giới này ngăn data leakage (rò rỉ dữ liệu) từ test vào EDA, đặc trưng và chọn mô hình

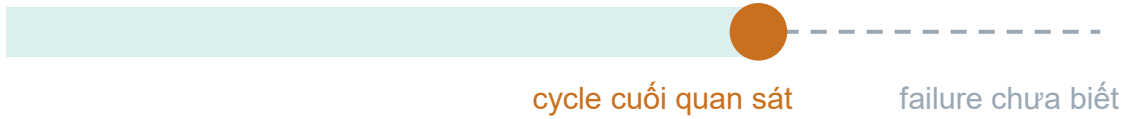
Train

100 engines chạy đến failure



Test

100 engines bị cắt trước failure



Train: RUL(t) = cycle cuối − t → 20.631 nhãn

Test: 1 dự đoán/engine tại cycle cuối → ghi final predictions → mới ghép RUL_FD001.txt

Kiểm soát nhãn test

Không dùng

trong EDA, đặc trưng, chọn model

Ghép muộn

sau khi đã ghi final predictions

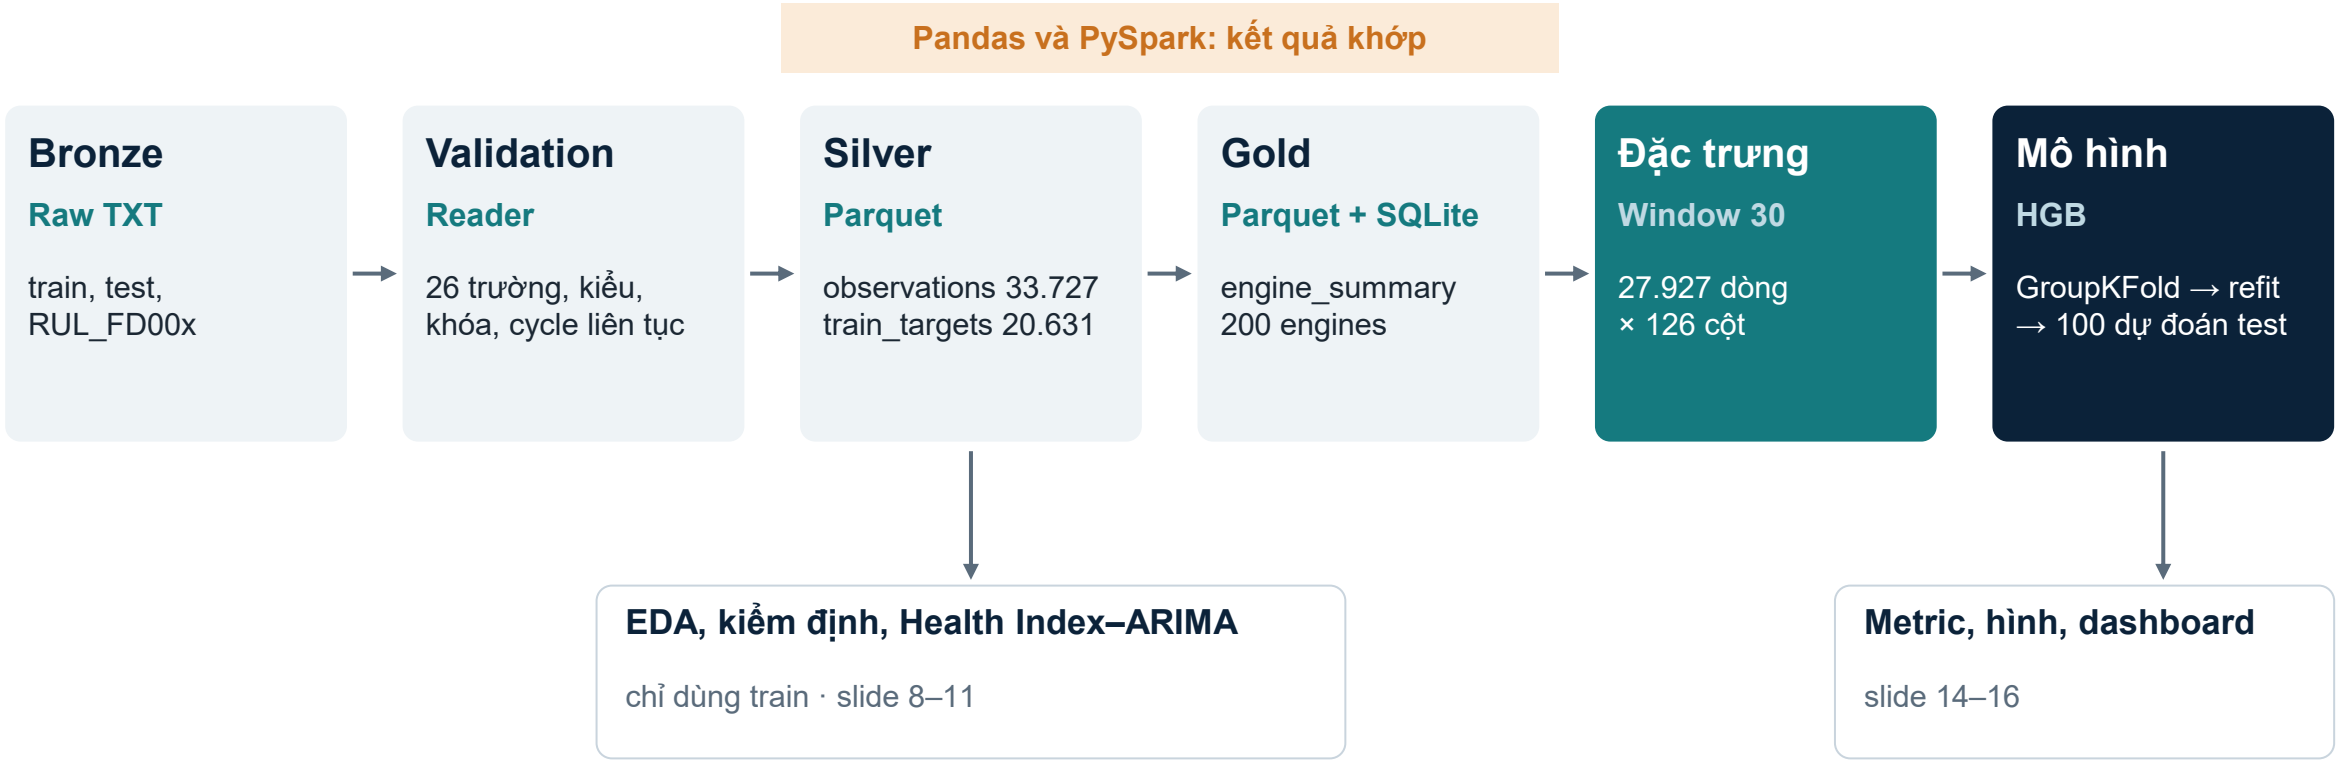
Có dấu vết

run_info ghi trạng thái join; final_metrics ghi SHA-256 của nhãn

Nguồn: data/CONTRACTS.md; outputs/etl/parity.json; outputs/modeling/run_info.json; outputs/modeling/tables/final_metrics.json

Pipeline Bronze → Silver → Gold → đặc trưng → mô hình

Mỗi bước ghi artifact kèm hash và run_info để truy vết và chạy lại



Khóa observation: (split, engine_id, cycle). Feature và target được join bằng đủ ba cột khóa và kiểm tra quan hệ 1:1.

Nguồn: assets/diagrams/fd001-pipeline.drawio; handoff/DATA_WALKTHROUGH.md; outputs/*/run_info.json

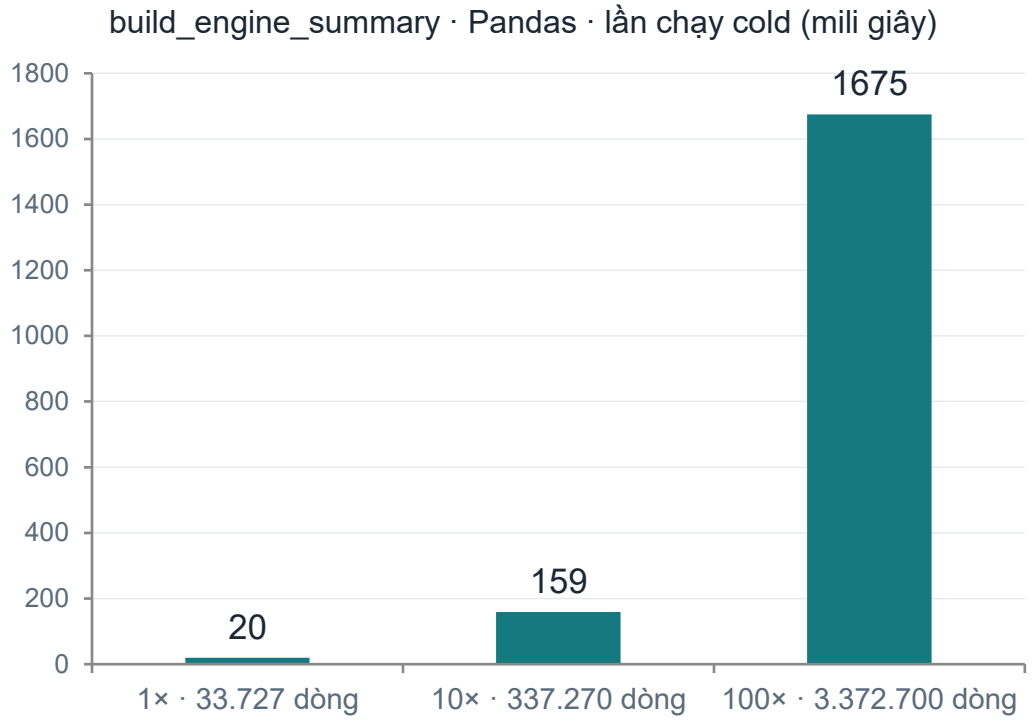
Pandas và PySpark cho cùng kết quả tại ba boundary

Thử nghiệm khả năng mở rộng hiện chỉ đo Pandas in-memory; chưa có benchmark Spark hoặc cluster

Boundary	Số dòng	Sai khác lớn nhất	Kết quả
silver_observations	33.727	0	Khớp
silver_train_targets	20.631	0	Khớp
gold_engine_summary	200	0	Khớp

Kiểm tra cùng một input bằng hai engine xử lý

So khớp schema, khóa (split, engine_id, cycle), số dòng và giá trị số. PySpark chạy local; modeling và rolling features dùng Pandas/scikit-learn.

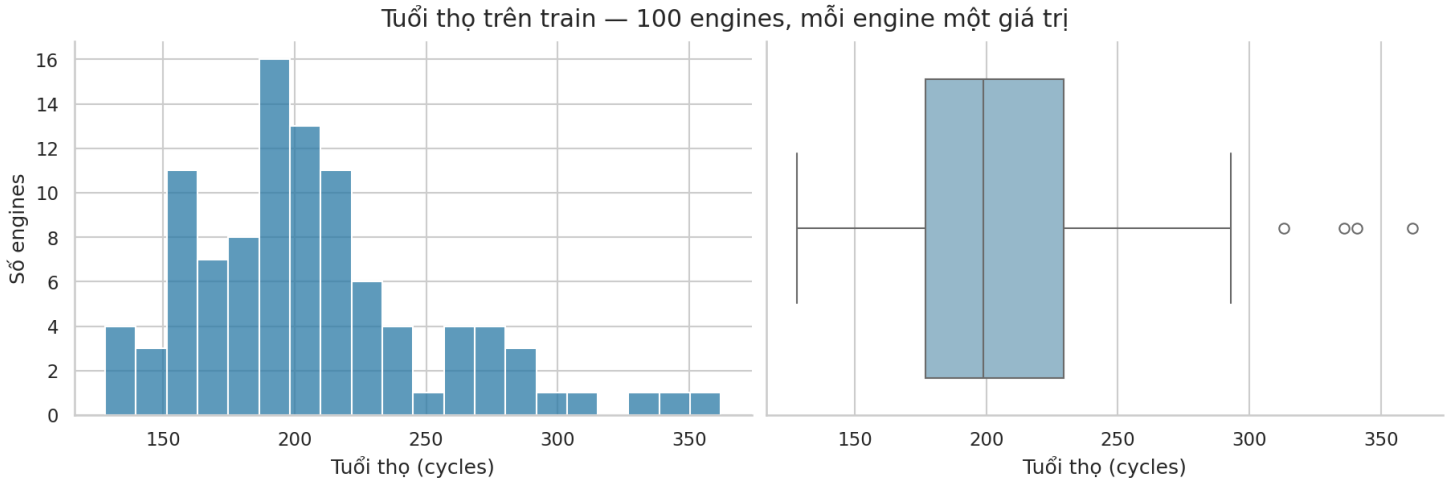


Số dòng tăng 100×, thời gian tăng khoảng 86× (0,0195 → 1,6752 giây).

Nguồn: outputs/etl/parity.json; outputs/etl/benchmark.json; handoff/DATA_WALKTHROUGH.md

EDA: tuổi thọ phân tán rộng và 7 cột không đổi

EDA chỉ dùng train để hiểu dữ liệu trước khi xây dựng đặc trưng



128
Ngắn nhất (cycles)

199
Trung vị (cycles)

206,31
Trung bình (cycles)

362
Dài nhất (cycles)

Không đổi trong cả 100 engine

- sensor_1
- sensor_5
- sensor_10
- sensor_16
- sensor_18
- sensor_19
- setting_3

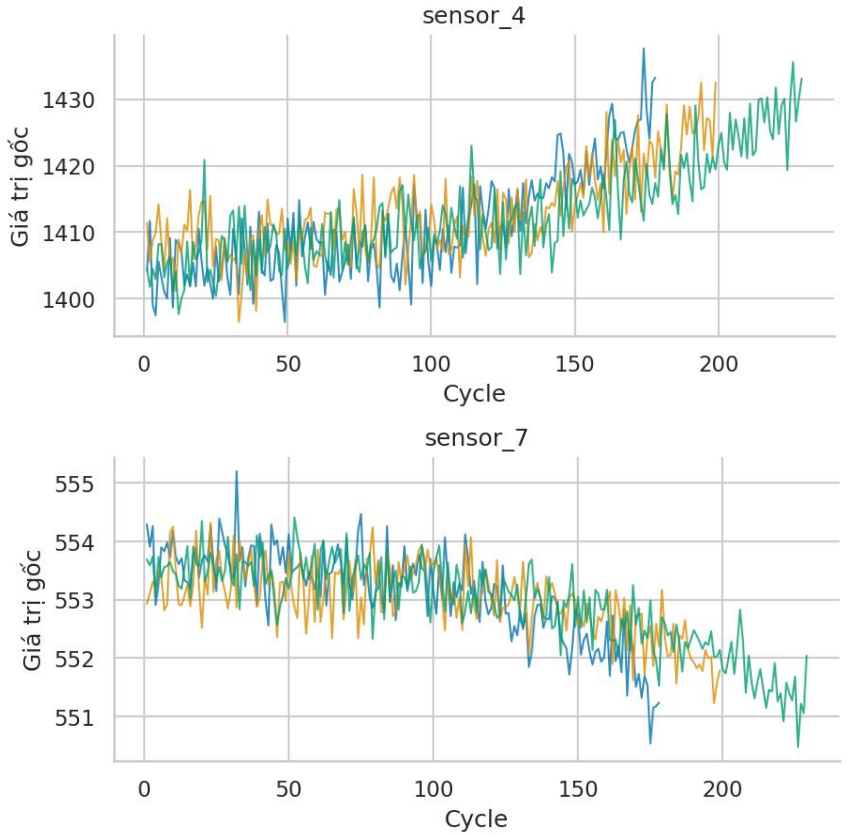
sensor_6 không đổi trong 38/100 engine.

Chưa loại cột nào: 126 đặc trưng vẫn gồm đủ 21 sensor; không làm feature selection từ EDA.

Nguồn: outputs/eda/figures/engine_lifetimes.png; outputs/eda/tables/constant_engine_counts.csv; lifetime_summary.csv

Nhiều sensor thay đổi rõ khi engine tiến gần failure

So sánh 30 cycle đầu và 30 cycle cuối trên cùng engine: 15/21 sensor có thay đổi sau hiệu chỉnh FDR



Engine 87 (178 cycles), 26 (199), 75 (229); giá trị gốc chưa chuẩn hóa.

1. **Ghép cặp trong engine**
   Δ = mean(30 cycle cuối) − mean(30 cycle đầu)

2. **Bootstrap và Wilcoxon**
   Lấy mẫu lại engine 10.000 lần; Wilcoxon signed-rank

3. **Hiệu chỉnh đa kiểm định**
   Benjamini–Hochberg cho 21 sensor, q = 0,05

15/21

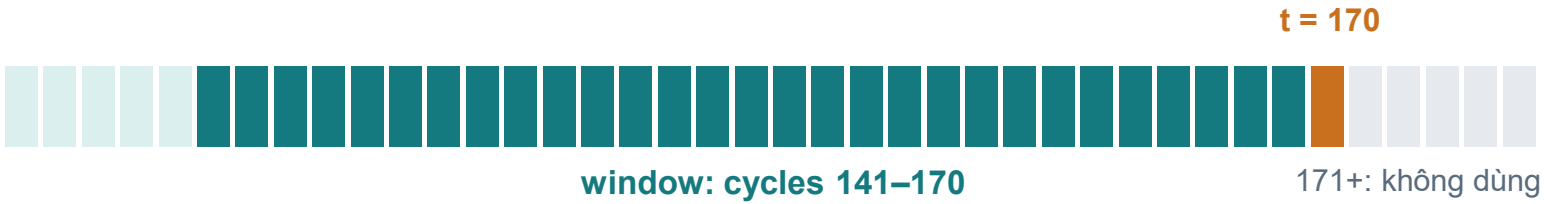
sensor bác bỏ giả thuyết không sau hiệu chỉnh

6 sensor hằng số nên không kiểm định. Kết quả mô tả khác biệt đầu/cuối vòng đời, không chứng minh nhân quả.

Nguồn: outputs/eda/figures/sensor_trajectories_1.png; outputs/statistics/tables/sensor_inference.csv; report/sections/methodology.tex

Trailing window 30 cycle biến chuỗi sensor thành 126 đặc trưng

Mỗi dòng đặc trưng chỉ dùng quá khứ của chính engine đó; không dùng cycle tương lai hoặc engine khác



21 sensor × 6 thống kê = 126 cột

last
trạng thái hiện tại

mean
mức trung bình

std
độ dao động

min
cận dưới

max
cận trên

slope
xu hướng tăng/giảm

17.731 train windows · 10.196 test windows · 29 cycle đầu mỗi engine chưa đủ window, không padding

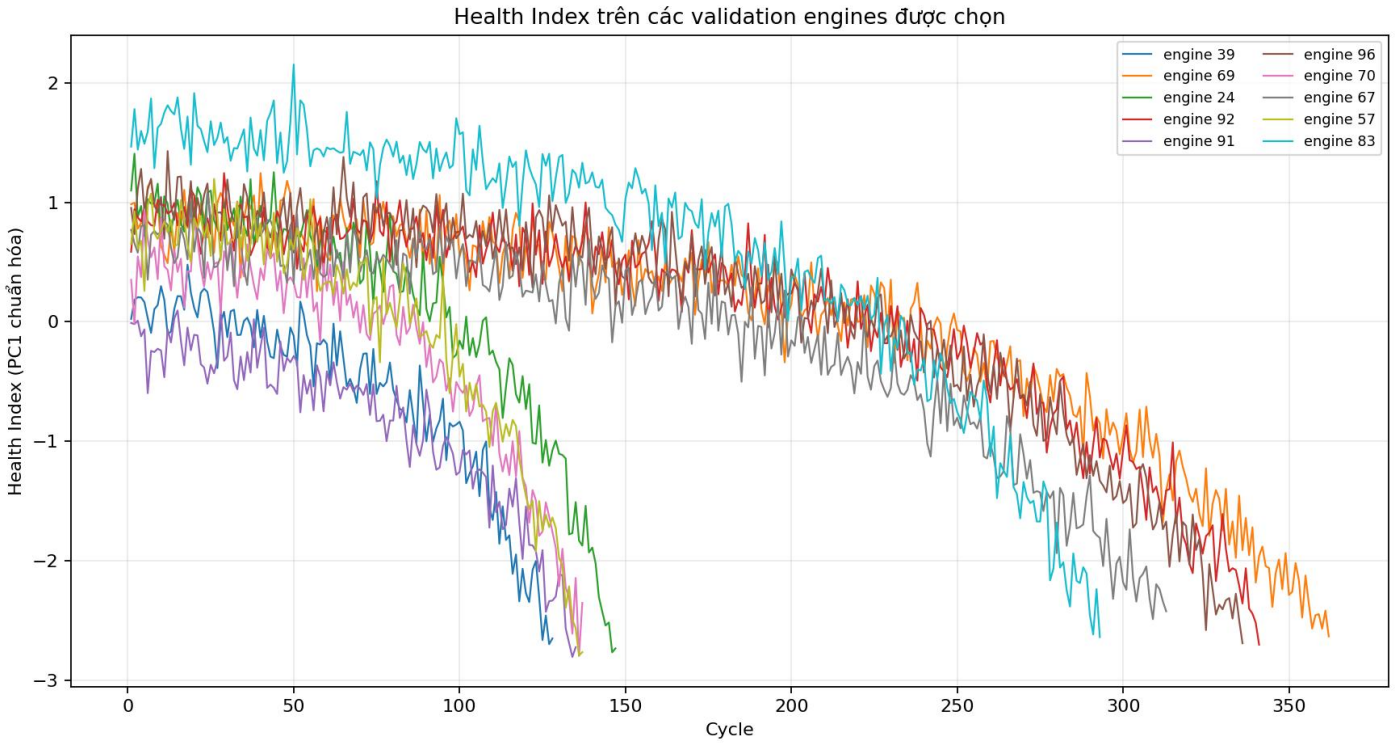
Nhiễu và chuẩn hóa

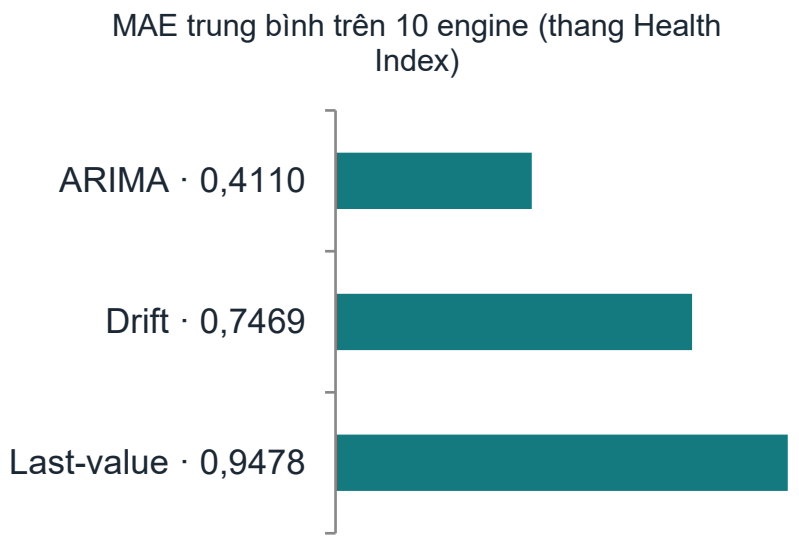
- Thống kê trên 30 cycle tóm tắt dao động từng cycle; chưa dùng bộ lọc tín hiệu riêng.
- ETL chuẩn hóa schema và kiểu dữ liệu.
- StandardScaler fit trong training fold (Ridge) và trên 90 engine (Health Index).
- HGB dùng thang đo gốc.

Nguồn: outputs/features/run_info.json; src/cmapss/features/rolling.py; handoff/DATA_WALKTHROUGH.md

Health Index gom 21 sensor thành một đường suy giảm

PCA fit trên 90 train engines; ARIMA dự báo 30% cuối chuỗi của 10 engine giữ riêng



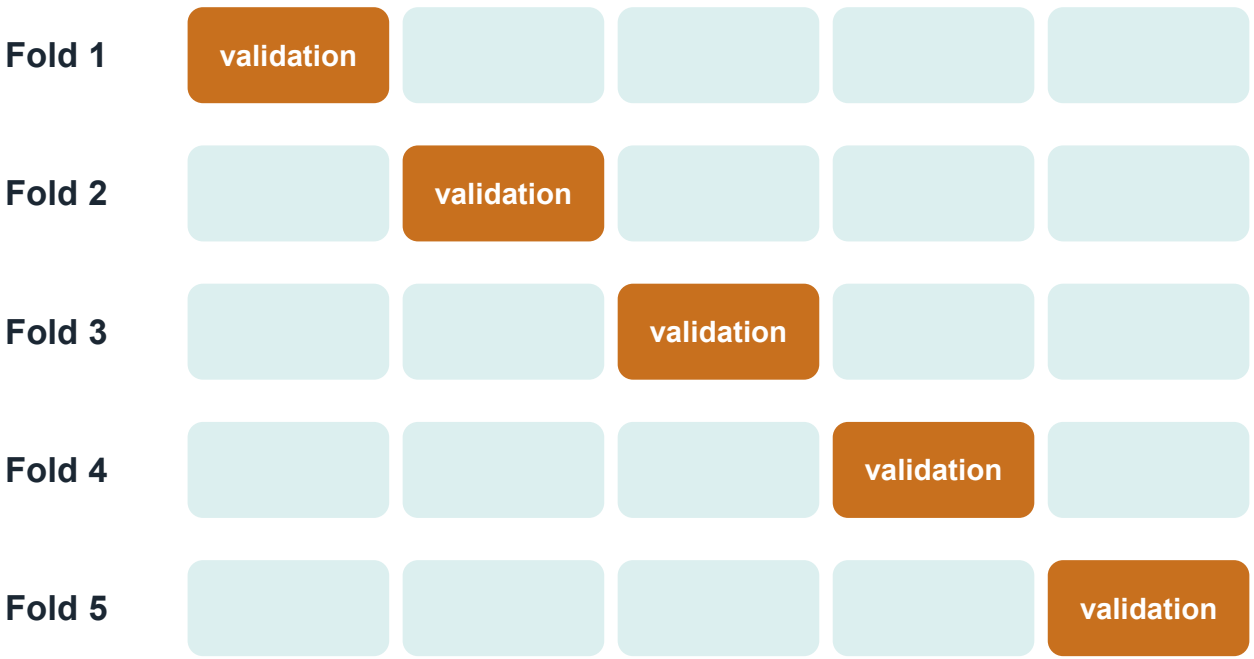


Coverage khoảng dự đoán 95%: 21,43%–97,03% giữa các engine. Health Index không phải RUL; đây là phân tích phụ.

Nguồn: outputs/timeseries/figures/health_index_selected_engines.png; tables/forecast_metrics.csv; tables/baseline_metrics.csv

Đánh giá theo engine để tránh data leakage

5-fold GroupKFold: mọi window của một engine nằm cùng một phía của phép chia



Mỗi ô là một nhóm 20 train engines; màu nhạt là phần fit.

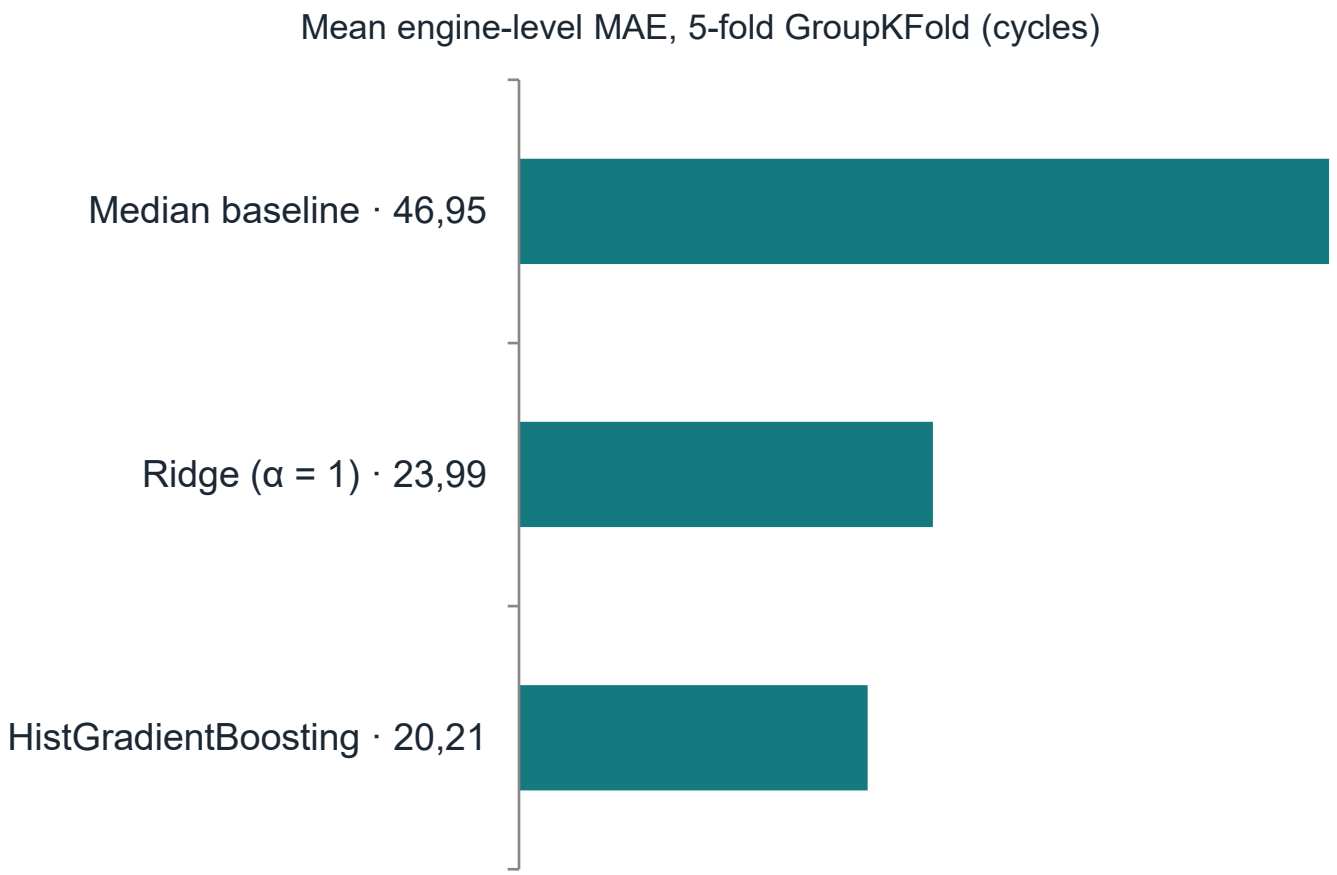
1. **Chọn model**
   mean engine-level MAE trên dự đoán OOF
2. **Cân bằng engine**
   tổng sample weight mỗi engine bằng 1 trong fold
3. **Refit**
   toàn bộ 17.731 train windows
4. **Dự đoán test**
   1 điểm/engine tại cycle cuối, sau đó mới ghép nhãn

Hai window liền kề trùng 29/30 cycle; chia ngẫu nhiên theo dòng làm metric lạc quan.

Nguồn: outputs/modeling/tables/evaluation_protocol.csv; outputs/modeling/run_info.json; report/sections/methodology.tex

HistGradientBoosting có MAE thấp nhất trong cross-validation

Ba ứng viên được so sánh trên cùng 5 fold và cùng metric đã định trước



Model	MAE ± std giữa fold
HistGradientBoosting	**20,21 ± 0,98**
Ridge (α = 1)	23,99 ± 0,95
Median baseline	46,95 ± 0,12

CV và test chấm trên tập điểm khác nhau

CV chấm mọi train window từ cycle 30 đến failure; test chỉ chấm một điểm cắt mỗi engine. Không so trực tiếp hai con số.

Nguồn: outputs/modeling/tables/model_metrics.csv; outputs/modeling/run_info.json

Trên 100 test engines: MAE 15,35 cycles

Mỗi engine đóng góp một dự đoán tại cycle cuối được quan sát; nhãn test chỉ được dùng ở bước này

15,35

MAE (cycles)

CI 95%: [12,73; 18,09]

20,54

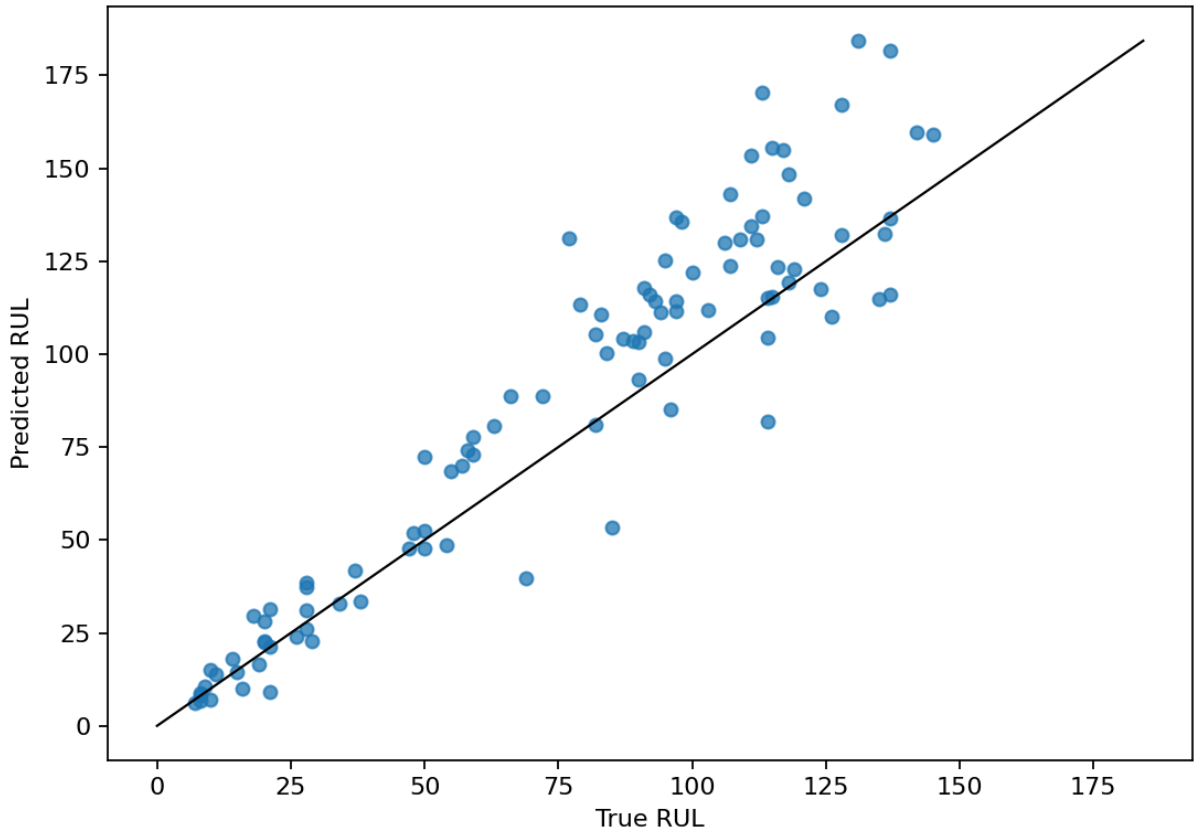
RMSE (cycles)

Phạt sai số lớn mạnh hơn MAE

1.513,26

NASA score

Phạt dự đoán trễ nặng hơn; không có đơn vị

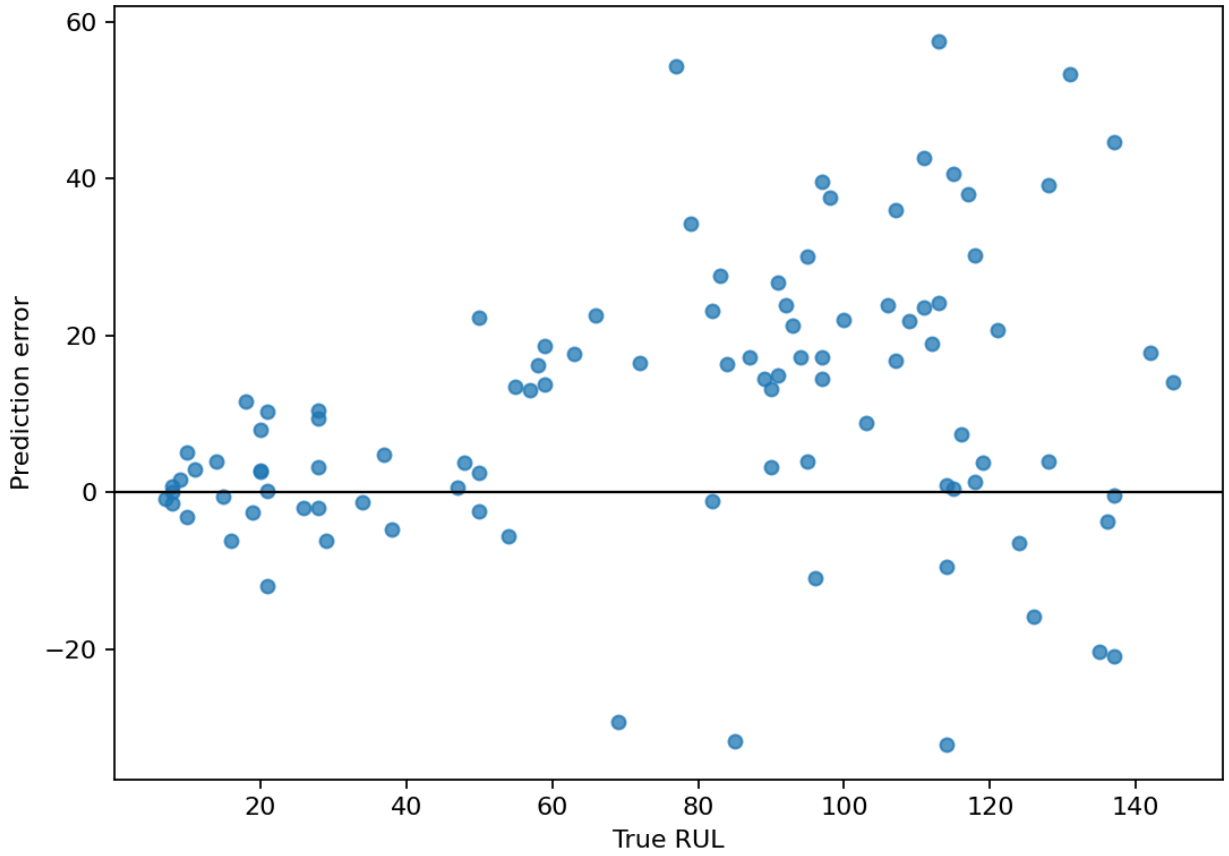


Nguồn: outputs/modeling/tables/final_metrics.json; outputs/modeling/figures/final_true_vs_predicted.png

PHẦN 4 · MÔ HÌNH VÀ ĐÁNH GIÁ

Sai số lớn tập trung ở dự đoán cao hơn RUL thật

Dự đoán cao hơn RUL thật tương ứng cảnh báo muộn; NASA score phạt loại sai số này nặng hơn



Hướng sai số trên 100 test engines

74 cao hơn	26 thấp hơn

Trường hợp sai lớn nhất: engine 23

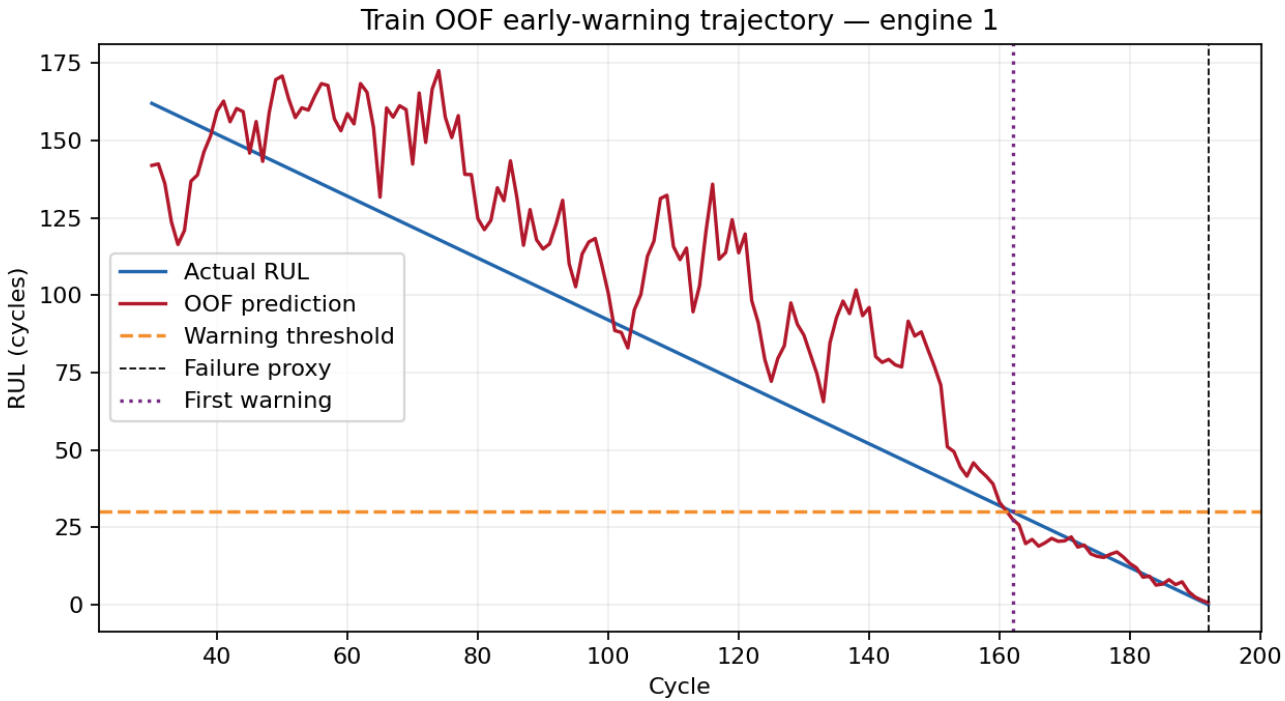
113	170,48	57,48
RUL thật (cycles)	Dự đoán (cycles)	Sai số (cycles)

10 trường hợp sai lớn nhất chiếm 75,5% NASA score. Trên OOF, dự đoán dừng quanh 145–147 cycles khi RUL thật > 150.

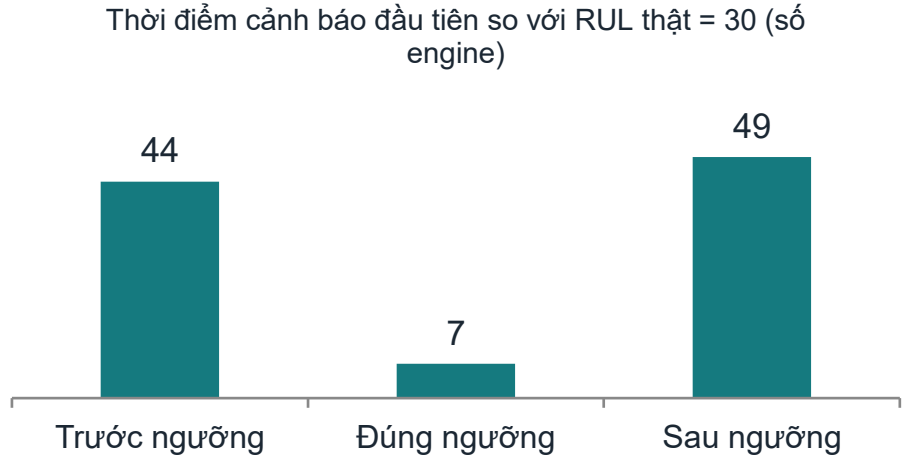
Nguồn: outputs/modeling/predictions/final_evaluation.parquet; outputs/modeling/figures/final_residuals_by_rul.png; outputs/diagnostics/error_diagnostics.json

Cảnh báo sớm: báo động khi RUL dự đoán ≤ 30 cycles

Trên dự đoán OOF của 100 train engines, mọi engine được cảnh báo trước failure; 49 engine cảnh báo sau ngưỡng thật



Engine 1: cảnh báo tại cycle 162, failure tại cycle 192.



30 cycles
Trung vị lead time

26–35
Tứ phân vị

19–55
Miền

Cảnh báo trễ tập trung ở engine ngắn đời: tuổi thọ TB 182,8 so với 229,1 cycles (r = -0,56).

OOF đã dùng để chọn model; chưa có chi phí bảo trì.

Nguồn: outputs/modeling/tables/warning_summary.json; outputs/modeling/figures/warning_trajectory.png; outputs/diagnostics/error_diagnostics.json

Thử cải thiện bằng nested CV: chưa đạt tiêu chí, giữ baseline

Window 10/20/30, 24 cấu hình HGB, 3 cách đặt trọng số; test không dùng để chọn cấu hình

Nested GroupKFold

5 vòng ngoài

giữ riêng 20 engine để đánh giá

↓

3 vòng trong

chọn window, tham số, trọng số

↓

So với baseline

ΔMAE RUL ≤ 30: +0,0054
CI 95% [-0,0506; 0,0639]

Vòng ngoài: đánh giá cả quy trình chọn

Chỉ số	Baseline	Quy trình chọn mới
MAE toàn bộ (cycles)	20,21	20,25
MAE khi RUL ≤ 30 (cycles)	3,6676	3,6730
Cảnh báo trễ hoặc bỏ lỡ	49/100	53/100

Inner CV trên toàn train: đánh đổi giữa các chỉ số

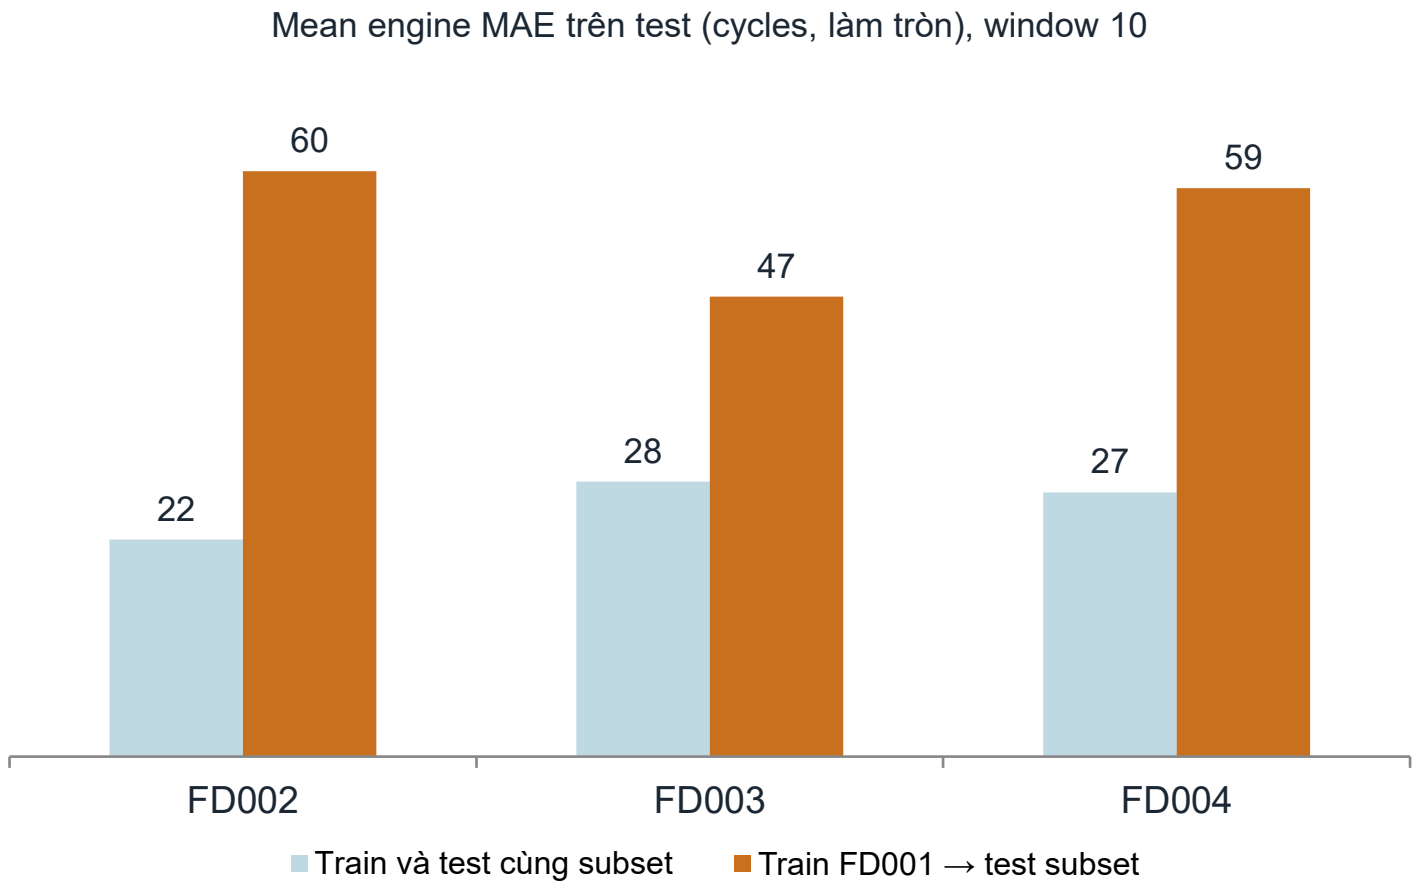
Ứng viên	MAE toàn bộ	MAE RUL ≤ 30	Trễ/bỏ lỡ
Baseline	20,36	3,61	50/100
hgb_08	20,68	3,26	49/100
Trọng số RUL thấp cao	20,41	3,39	47/100

hgb_08 giảm MAE RUL thấp khoảng 9,75% nhưng tăng MAE toàn bộ 0,32 cycles.

Nguồn: outputs/experiments/rul_improvement/20260927_full/ (ablation_metrics.csv, paired_comparison.csv, final_selection_metrics.csv, decision.json)

Model FD001 không chuyển trực tiếp sang FD002–FD004

Cùng pipeline với window 10; MAE tăng 1,7–2,7 lần khi đổi điều kiện vận hành hoặc fault mode



FD002 — 6 điều kiện · 15% trong miền FD001
22,36 → 60,32 cycles (×2,7)

FD003 — fault Fan · 95% trong miền FD001
28,33 → 47,39 cycles (×1,7)

FD004 — cả hai · 14% trong miền FD001
27,22 → 58,57 cycles (×2,2)

Cần huấn luyện lại hoặc domain adaptation trước khi dùng model FD001 cho subset khác.

Nguồn: outputs/cross_dataset/matrix.json; outputs/diagnostics/error_diagnostics.json

Trả lời ba câu hỏi nghiên cứu

Kết luận chỉ áp dụng cho protocol và dữ liệu mô phỏng đã nêu

Q1 Xu hướng suy giảm

15/21

sensor thay đổi đầu/cuối vòng đời; Health Index giảm rõ ở cuối vòng đời

Q2 Dự đoán RUL

15,35

cycles MAE trên 100 test engines; CI 95% [12,73; 18,09]

Q3 Cảnh báo và chuyển miền

30

cycles lead time trung vị (OOF); 49/100 cảnh báo sau ngưỡng; không chuyển trực tiếp sang FD002–FD004

Đóng góp Big Data: batch ETL nhiều file, Parquet Silver/Gold, parity Pandas–PySpark và artifact có hash, run_info để tái lập.

Nguồn: report/sections/conclusion.tex; các artifact đã dẫn ở slide 9–18

Giới hạn và hướng tiếp theo

Giới hạn đã biết

- Dữ liệu mô phỏng; FD001 chỉ có một điều kiện vận hành và một fault mode.
- Mỗi test engine chỉ được đánh giá tại một điểm cắt.
- Không có chi phí, downtime, intervention records: chưa tối ưu được lịch bảo trì.
- PySpark chạy local để kiểm tra parity; benchmark chỉ đo Pandas.

Hướng tiếp theo (đề xuất, chưa thực hiện)

- Cắt ngưỡng nhãn RUL, chọn ngưỡng trong vòng trong của nested CV.
- Chuẩn hóa sensor theo điều kiện vận hành cho FD002 và FD004.
- So sánh CNN 1D hoặc LSTM với HGB trên cùng fold và cùng cách xử lý nhãn.
- Chuyển bước tạo đặc trưng sang PySpark, đo cả pipeline gồm I/O.

Xin cảm ơn thầy/cô. Xin nhận câu hỏi.

Dashboard: uv run --extra dashboard streamlit run app.py · Kịch bản demo: handoff/DEMO_SCRIPT.md