Industrial University of Ho Chi Minh City

BÁO CÁO CUỐI KỲ · PHÂN TÍCH DỮ LIỆU LỚN · ĐỀ TÀI 8

Phân tích dữ liệu IoT và bảo trì dự đoán

Phát hiện bất thường, dự đoán RUL và cảnh báo sớm trên dữ liệu cảm biến NASA C-MAPSS

100	86%	121	15,35
động cơ train FD001	mức giảm độ dao động (EWMA)	cycle phát hiện trước hỏng hóc	MAE trên tập kiểm tra (cycle)

Phan Nguyễn Mai Phương · MSHV 25002711

Học viên cao học ngành Khoa học máy tính · Tháng 10/2026

Cấu trúc bài trình bày

Trình bày theo trình tự pipeline quản lý dữ liệu: xử lý, phân tích tín hiệu, dự đoán và cảnh báo

1. **Bài toán và dữ liệu**
   Slide 3–5
2. **Pipeline dữ liệu**
   Slide 6–8
3. **Khử nhiễu và cửa sổ thời gian**
   Slide 9–10
4. **Xu hướng và bất thường**
   Slide 11–12
5. **Dự đoán RUL, cảnh báo, lịch bảo trì**
   Slide 13–16
6. **Mở rộng và kết luận**
   Slide 17–19
7. **Demo dashboard**
   Khoảng 2,5 phút

Câu hỏi nghiên cứu

- **Q1** Dữ liệu có đạt ràng buộc chất lượng; hai cách triển khai ETL có tương đương?
- **Q2** Mức giảm nhiễu đạt được; dữ liệu được tổng hợp theo cửa sổ thời gian thế nào?
- **Q3** Xu hướng biến đổi của tín hiệu; khả năng phát hiện bất thường trước hỏng hóc?
- **Q4** Độ chính xác dự đoán RUL trên tập kiểm tra độc lập?
- **Q5** Hiệu quả của cảnh báo sớm và lịch bảo trì dựa trên dự đoán?

Innovation - Unity - Humanity

Nguồn: report/main.pdf; handoff/SPEECH_SCRIPT_VI.pdf

Phát biểu bài toán

Phát hiện dấu hiệu suy giảm và dự đoán thời điểm bảo trì từ dữ liệu cảm biến; đối chiếu yêu cầu Đề tài 8

Định nghĩa RUL



$$RUL(t) = T - t$$

RUL(170) = 200 − 170 = 30 cycle

T: cycle hỏng hóc của động cơ. Đầu vào: chuỗi 21 tín hiệu cảm biến theo cycle. Đầu ra: dấu hiệu bất thường, ước lượng RUL và mức cảnh báo.

Yêu cầu của đề tài	Phương pháp thực hiện	Slide
Xử lý chuỗi thời gian cảm biến	Kiểm tra schema, khóa, cycle liên tục; ETL Pandas–PySpark	6, 7
Xử lý nhiễu tín hiệu	EWMA span 10 theo từng động cơ, chỉ dùng quá khứ	9
Chuẩn hóa, tổng hợp theo window	StandardScaler cho Health Index; window 30 → 126 đặc trưng	10
Phát hiện dấu hiệu bất thường	Health Index giảm quá 3σ so với 30 cycle đầu	12
Trực quan hóa xu hướng suy giảm	Quỹ đạo sensor, kiểm định đầu/cuối, Health Index	11, 12
Dự đoán thời điểm bảo trì, cảnh báo sớm	Lịch bảo trì cho 100 động cơ test; hai mức cảnh báo	15, 16

Innovation - Unity - Humanity

Nguồn: references/context/assignment-brief.png; report/sections/problem-data.tex

Bộ dữ liệu NASA C-MAPSS

Bốn subset khác nhau về số điều kiện vận hành và số dạng lỗi; FD001 là đối tượng phân tích chính

FD001

Phân tích chính

1 điều kiện vận hành
1 dạng lỗi (HPC)

100 train / 100 test
33.727 quan sát

FD002

Thử nghiệm mở rộng

6 điều kiện vận hành
1 dạng lỗi (HPC)

260 train / 259 test
87.750 quan sát

FD003

Thử nghiệm mở rộng

1 điều kiện vận hành
2 dạng lỗi (HPC, Fan)

100 train / 100 test
41.316 quan sát

FD004

Thử nghiệm mở rộng

6 điều kiện vận hành
2 dạng lỗi (HPC, Fan)

249 train / 248 test
102.463 quan sát

Cấu trúc một bản ghi quan sát (26 trường)

engine_id	cycle	setting_1 … setting_3	sensor_1 … sensor_21

Khóa chính: (split, engine_id, cycle). Dữ liệu không có giá trị thiếu.

Innovation - Unity - Humanity

Nguồn: data/raw/readme.txt; outputs/cross_dataset/FD00x/etl/run_info.json

Xây dựng nhãn RUL và ranh giới tập kiểm tra

Nhãn tập kiểm tra chỉ được sử dụng sau khi đã lưu kết quả dự đoán, nhằm tránh rò rỉ dữ liệu (data leakage)

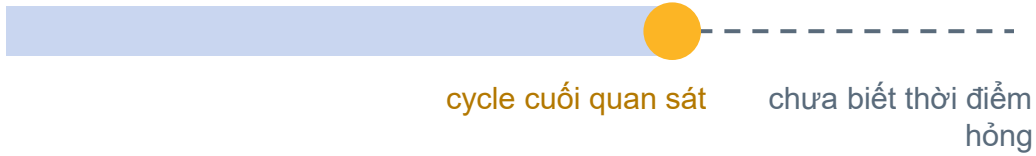
Train

100 động cơ vận hành đến hỏng hóc



Test

100 động cơ bị cắt trước hỏng hóc



Train: RUL(t) = cycle cuối − t → 20.631 nhãn

Test: một dự đoán tại cycle cuối của mỗi động cơ; ghép RUL_FD001.txt sau khi đã lưu dự đoán

Kiểm soát nhãn tập kiểm tra

Không sử dụng

trong EDA, xây dựng đặc trưng và lựa chọn mô hình

Ghép sau dự đoán

nhãn chỉ được ghép khi dự đoán đã được lưu

Truy vết được

metadata ghi trạng thái ghép nhãn và mã băm SHA-256

Innovation - Unity - Humanity

Nguồn: data/CONTRACTS.md; outputs/modeling/run_info.json; outputs/modeling/tables/final_metrics.json

Kiến trúc pipeline dữ liệu Bronze–Silver–Gold

Mỗi tầng lưu kết quả kèm mã băm và metadata, bảo đảm khả năng truy vết và tái lập



Đặc trưng và nhãn được ghép bằng đủ ba cột khóa, kiểm tra quan hệ 1:1.

Innovation - Unity - Humanity

Nguồn: report/figures/pipeline.pdf; handoff/DATA_WALKTHROUGH.md; outputs/*/run_info.json

Đối chiếu Pandas, PySpark và Hadoop

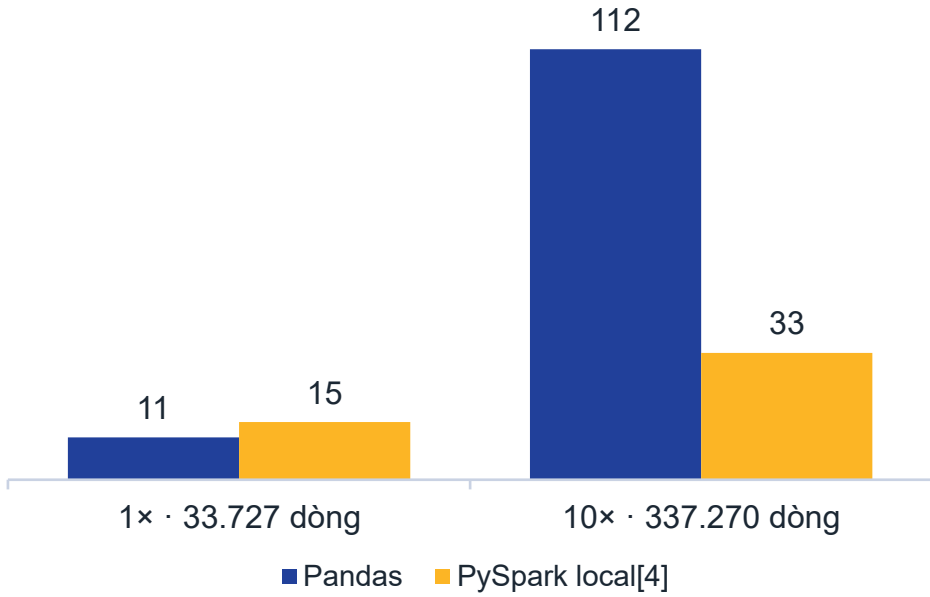
Ba cách triển khai trùng khớp ở mọi tầng; ở quy mô 10×, PySpark nhanh hơn Pandas khoảng 3,4 lần

Bảng so với Pandas	Số dòng	Sai khác	Kết quả
Silver observations	33.727	0	Khớp
Silver train_targets	20.631	0	Khớp
Gold engine_summary	200	0	Khớp
Gold · MapReduce trên HDFS	200	0	Khớp
Gold · Spark trên HDFS	200	0	Khớp

Cụm Hadoop 3.4.3 một node trong Docker

Raw lên HDFS; MapReduce trên YARN: 3 map, 1 reduce; Spark ghi Silver Parquet 33.727 dòng lên HDFS; fsck: HEALTHY.

Thời gian pipeline gồm I/O (giây)



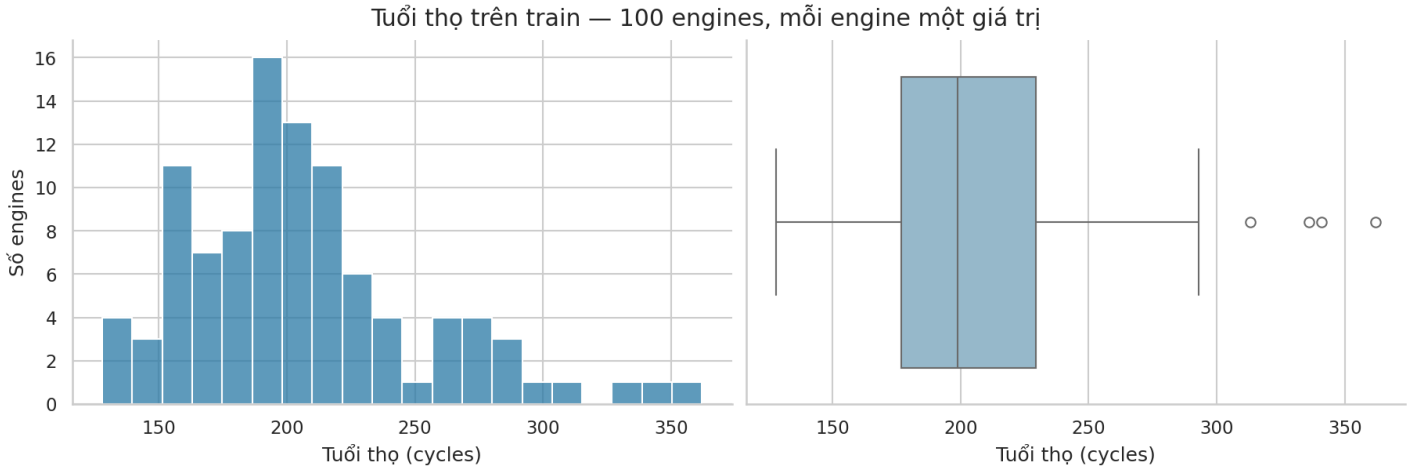
Không gồm thời gian khởi động Spark; đo trên một máy, chưa phải cluster.

Innovation - Unity - Humanity

Nguồn: outputs/etl/parity.json; outputs/hdfs/summary.json; outputs/benchmarks/20260929/measurements.csv

Phân tích khám phá dữ liệu

Tuổi thọ động cơ dao động từ 128 đến 362 cycle; bảy cột không biến thiên trên toàn bộ tập train



128
Ngắn nhất (cycle)

199
Trung vị (cycle)

206,31
Trung bình (cycle)

362
Dài nhất (cycle)

Cột hằng trên 100/100 động cơ

- sensor_1
- sensor_5
- sensor_10
- sensor_16
- sensor_18
- sensor_19
- setting_3

sensor_6 không đổi ở 38/100 động cơ.

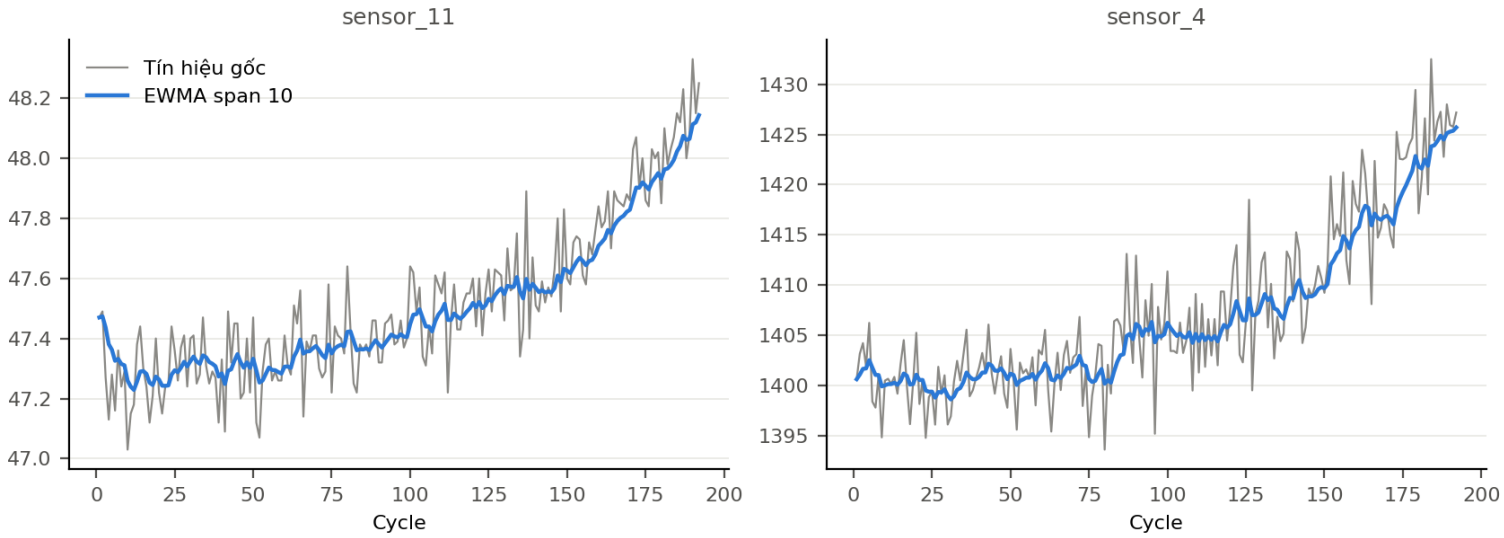
Khử nhiễu được áp dụng cho 14 sensor còn lại.

Innovation - Unity - Humanity

Nguồn: outputs/eda/figures/engine_lifetimes.png; outputs/eda/tables/constant_engine_counts.csv

Khử nhiễu tín hiệu bằng EWMA

Độ dao động ngắn hạn giảm khoảng 86% (trung vị trên 14 sensor); xu hướng suy giảm được bảo toàn



Sensor	Gốc	EWMA	Giảm
sensor_4	5,70	0,783	86,3%
sensor_9	5,90	0,924	84,3%
sensor_11	0,144	0,020	86,2%
sensor_12	0,425	0,059	86,2%
sensor_14	4,45	0,729	83,6%

Độ lệch chuẩn bước nhảy giữa hai cycle liền kề, trong từng động cơ.

Công thức: $s_t = \alpha \cdot x_t + (1 - \alpha) \cdot s_{t-1}$, $\alpha = 2 / (\text{span} + 1) \approx 0{,}18$

Vai trò: tín hiệu EWMA là đầu vào của Health Index và phát hiện bất thường (slide 12); mô hình RUL dùng đặc trưng cửa sổ trên tín hiệu gốc.

Innovation - Unity - Humanity

Nguồn: outputs/degradation/figures/denoise_before_after.png; outputs/degradation/tables/noise_summary.csv

Tổng hợp đặc trưng theo cửa sổ thời gian

Cửa sổ trượt nhân quả 30 cycle; 21 sensor × 6 thống kê = 126 đặc trưng



21 sensor × 6 thống kê = 126 đặc trưng

last giá trị tại cycle t	**mean** giá trị trung bình	**std** độ lệch chuẩn mẫu
min giá trị nhỏ nhất	**max** giá trị lớn nhất	**slope** hệ số góc hồi quy

17.731 window train · 10.196 window test · không padding 29 cycle đầu

Chuẩn hóa

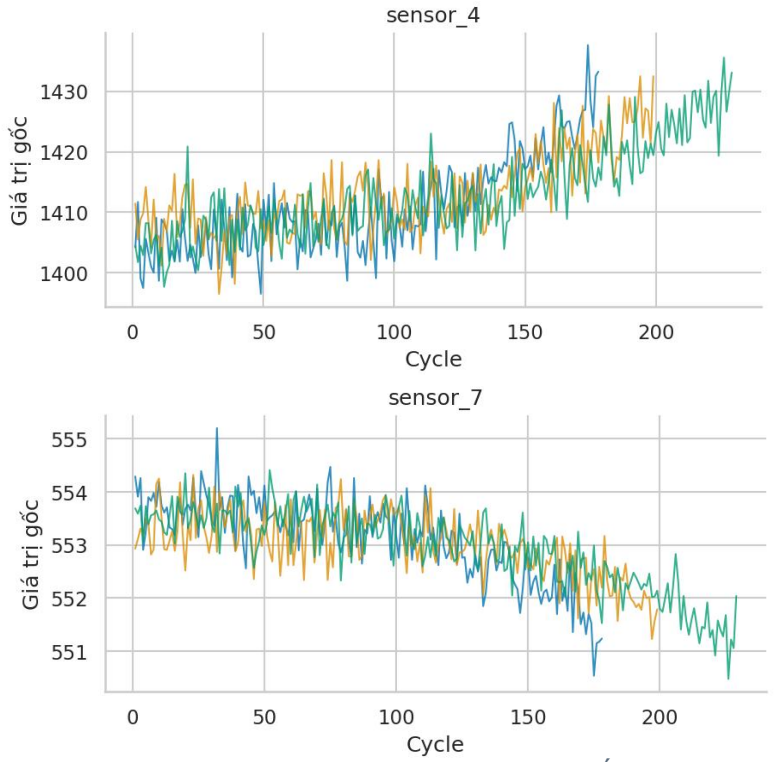
- ETL chuẩn hóa schema và kiểu dữ liệu.
- StandardScaler fit trong training fold (Ridge) và trước PCA (Health Index).
- HGB dùng thang đo gốc do mô hình cây bất biến với phép biến đổi đơn điệu.
- Các thống kê trên cửa sổ có tác dụng làm trơn bổ sung.

Innovation - Unity - Humanity

Nguồn: outputs/features/run_info.json; src/cmapss/features/rolling.py

Xu hướng suy giảm của tín hiệu cảm biến

15/21 sensor thay đổi có ý nghĩa thống kê giữa 30 cycle đầu và cuối vòng đời (Wilcoxon, hiệu chỉnh FDR)



Động cơ 87 (178 cycle), 26 (199), 75 (229); giá trị gốc.

1 **Ghép cặp trong động cơ**

Δ = trung bình 30 cycle cuối − 30 cycle đầu

2 **Bootstrap và Wilcoxon**

Lấy mẫu lại động cơ 10.000 lần

3 **Hiệu chỉnh đa kiểm định**

Benjamini–Hochberg trên 21 sensor, q = 0,05

15/21

sensor thay đổi có ý nghĩa thống kê (q = 0,05)

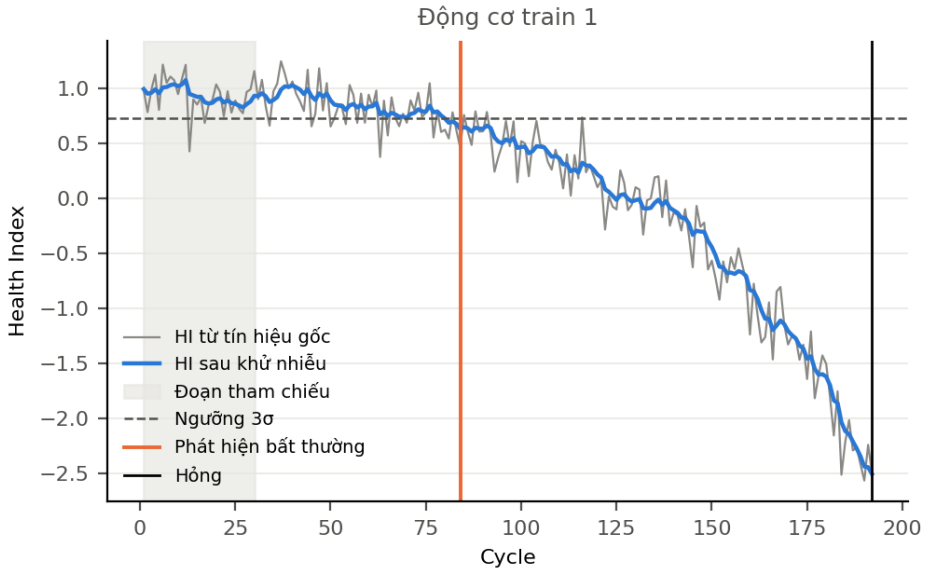
Sensor 4, 7, 11, 12, 20 thay đổi cùng chiều ở 100/100 động cơ; 6 sensor hằng không kiểm định được.

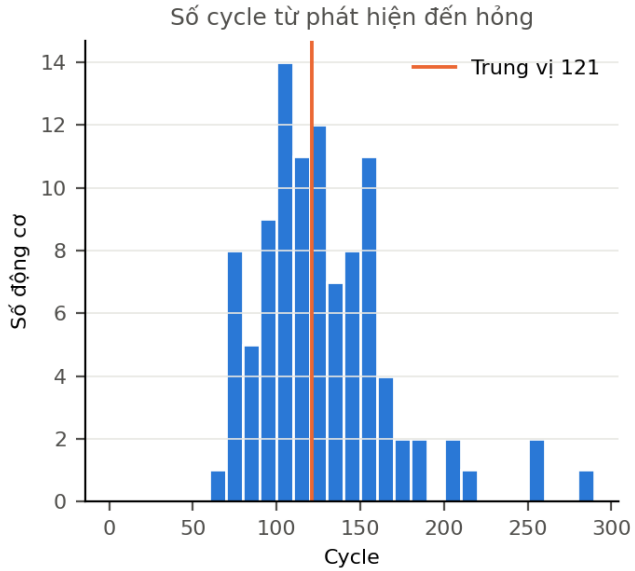
Innovation - Unity - Humanity

Nguồn: outputs/eda/figures/sensor_trajectories_1.png; outputs/statistics/tables/sensor_inference.csv

Phát hiện dấu hiệu bất thường dựa trên Health Index

Ngưỡng 3σ so với 30 cycle đầu, duy trì 5 cycle: phát hiện 100/100 động cơ, trung vị 121 cycle trước hỏng hóc





100/100

động cơ được phát hiện trước hỏng hóc

121

cycle phát hiện trước hỏng hóc (trung vị); IQR 101–149

39%

vòng đời tại thời điểm phát hiện (trung vị)

Độ nhạy: với 9 cấu hình (2/3/4σ × 3/5/10 cycle), quy tắc đều phát hiện 100/100 động cơ, lead time nhỏ nhất ≥ 50 cycle. Không khử nhiễu: trung vị còn 72,5 cycle. Giới hạn: chưa ước lượng được tỷ lệ dương tính giả do thiếu nhãn thời điểm bắt đầu suy giảm.

Innovation - Unity - Humanity

Nguồn: outputs/degradation/figures/anomaly_health_index.png; outputs/degradation/summary.json

Mô hình dự đoán RUL

HistGradientBoosting, lựa chọn bằng GroupKFold 5 fold theo động cơ; MAE trên tập kiểm tra: 15,35 cycle

Mô hình (GroupKFold 5 fold)	MAE	Độ lệch chuẩn
Median baseline	46,95	0,12
Ridge (α = 1)	23,99	0,95
HistGradientBoosting	**20,21**	**0,98**

15,35

MAE (cycle)

CI 95%: 12,73–18,09

20,54

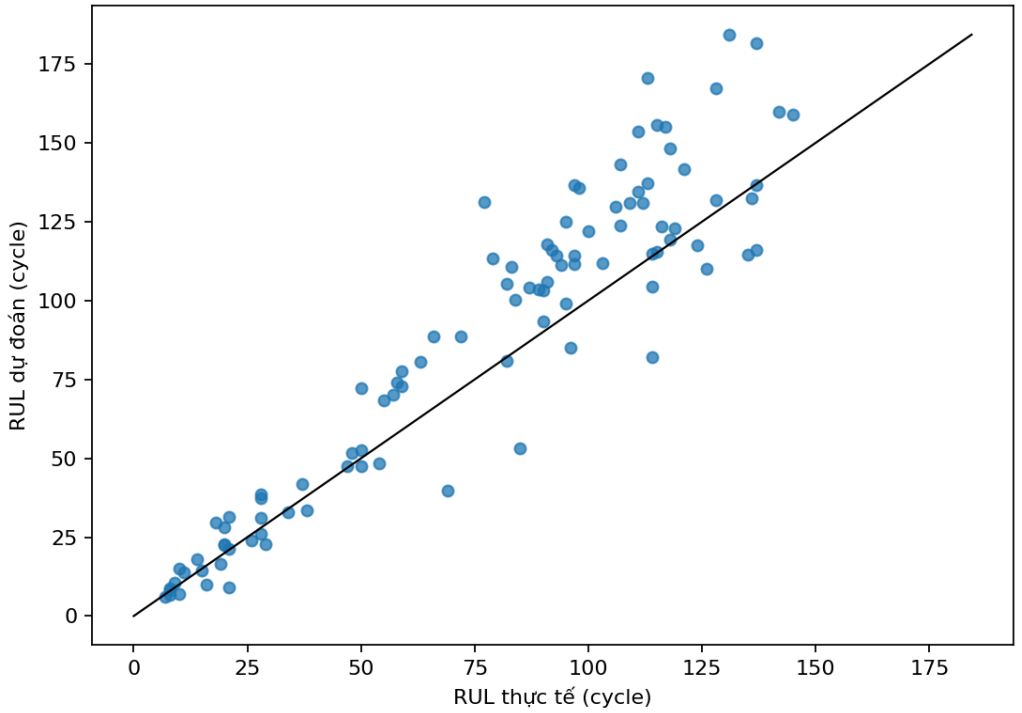
RMSE (cycle)

nhạy với sai số lớn

1.513

NASA score

phạt nặng hơn khi ước lượng cao

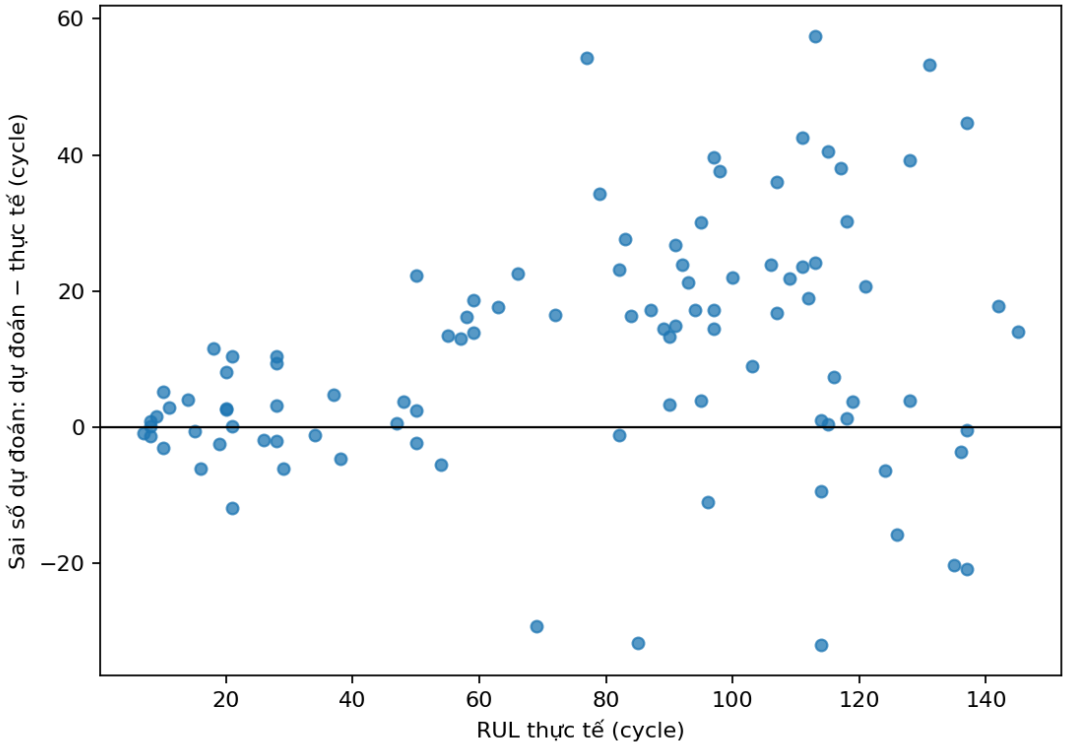


Innovation - Unity - Humanity

Nguồn: outputs/modeling/tables/{model_metrics.csv,final_metrics.json}; figures/final_true_vs_predicted.png

Phân tích sai số dự đoán

Sai số giảm khi RUL nhỏ; mô hình có xu hướng ước lượng cao, tương ứng với cảnh báo muộn



Phân bố dấu của sai số (100 động cơ kiểm tra)

74 ước lượng cao	26 thấp

Sai số lớn nhất: động cơ 23

113	170,5	57,5
RUL thật (cycle)	Dự đoán (cycle)	Sai số (cycle)

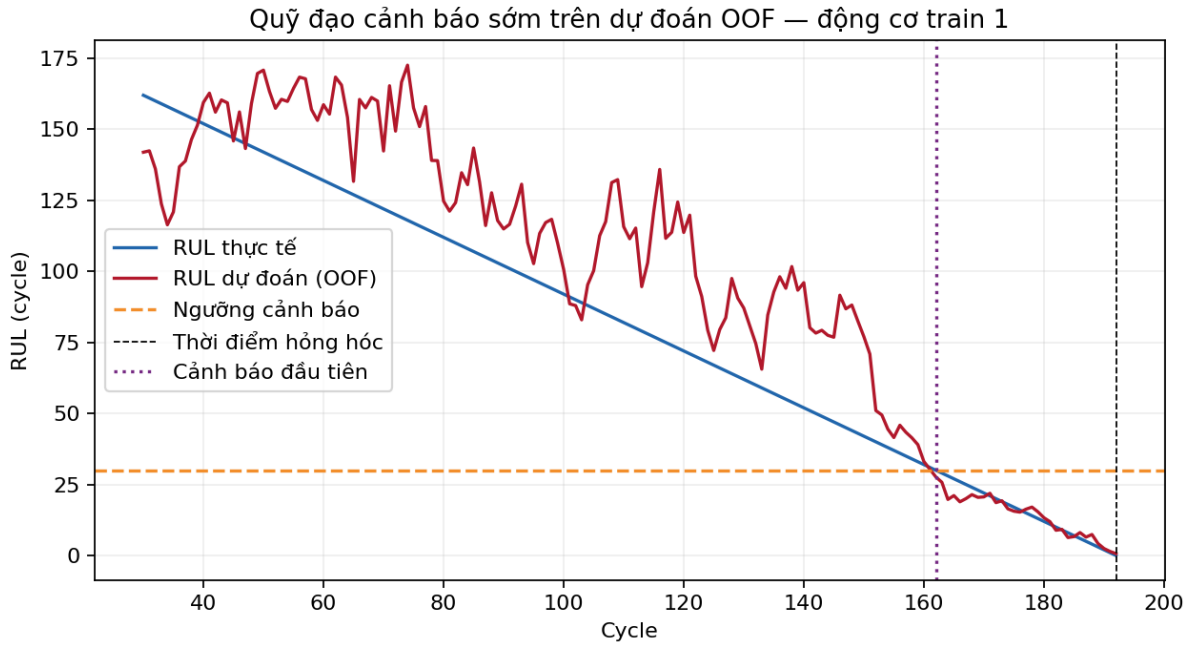
MAE 4,38 cycle khi RUL thật ≤ 30. Mười sai số lớn nhất chiếm 75,5% NASA score.

Innovation - Unity - Humanity

Nguồn: outputs/modeling/figures/final_residuals_by_rul.png; outputs/diagnostics/error_diagnostics.json

Cơ chế cảnh báo sớm hai mức

Ngưỡng RUL ≤ 30: không bỏ sót động cơ, lead time trung vị 30 cycle; 49% cảnh báo muộn so với ngưỡng



Động cơ train 1: cảnh báo mức 2 tại cycle 162; hỏng hóc tại cycle 192.

Ngưỡng RUL	Kịp thời	Muộn	Báo sớm
≤ 30 cycle	**51%**	**49%**	**1,3%**
≤ 40 cycle	94%	6%	5,3%

Kịp thời: lead time ≥ 30 cycle. Báo sớm: tỷ lệ cycle có cảnh báo khi RUL thực tế lớn hơn 30.

Hai mức cảnh báo trên động cơ 1

cycle 84 Mức 1 · Health Index bất thường

cycle 162 Mức 2 · RUL dự đoán ≤ 30

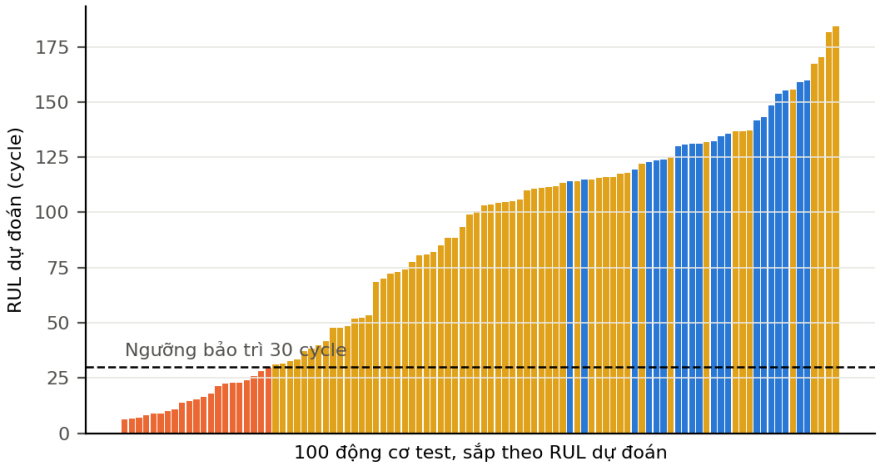
cycle 192 Hỏng hóc

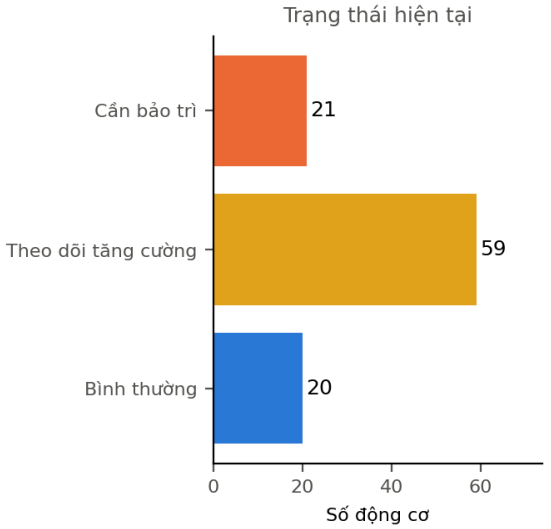
Innovation - Unity - Humanity

Nguồn: outputs/modeling/figures/warning_trajectory.png; outputs/course_alignment/20261007/warning_fixed_policies.csv

Báo cáo dự đoán thời điểm bảo trì

21/21 động cơ được xếp mức cần bảo trì có RUL thực tế ≤ 30; không có trường hợp dương tính giả





Đối chiếu với RUL thực tế

Trạng thái	≤ 30	31–60	> 60
Cần bảo trì	**21**	**0**	**0**
Theo dõi tăng cường	4	14	41
Bình thường	0	0	20

21 cần bảo trì ngay

14 đến hạn trong 1–25 cycle tới

8 đến hạn trong 26–50 cycle

21/25 động cơ có RUL thực tế ≤ 30 được xếp mức cần bảo trì

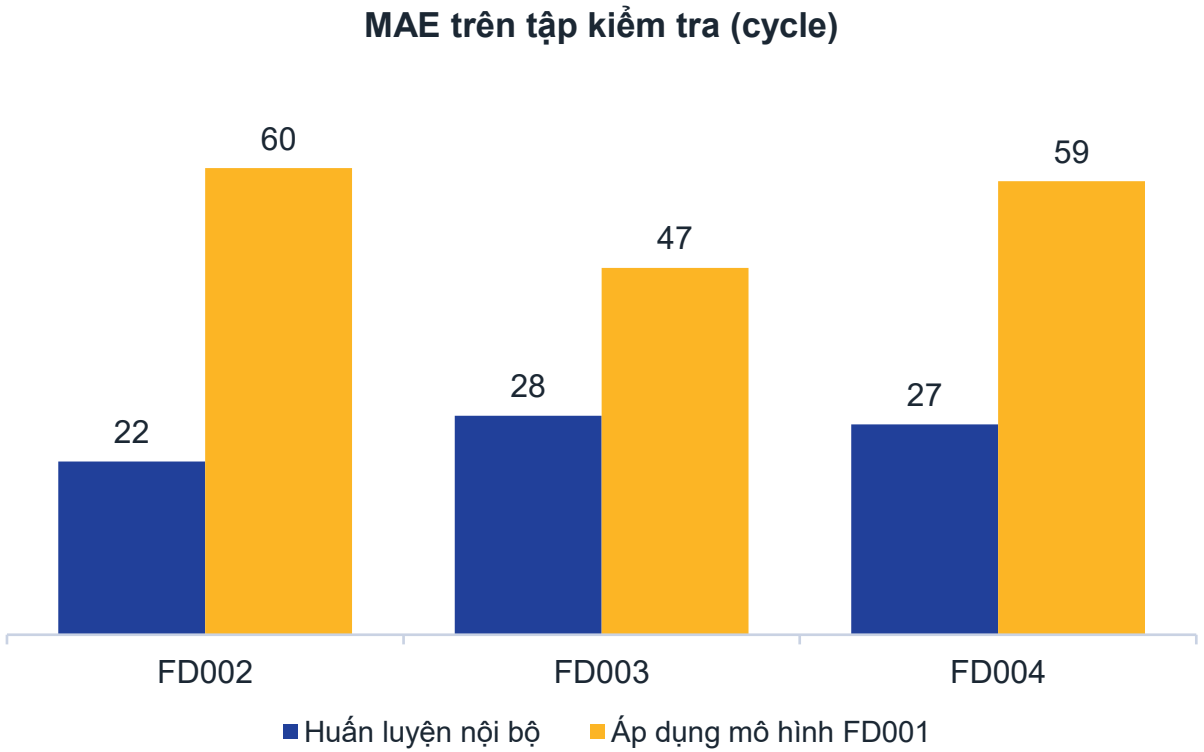
4 trường hợp còn lại được xếp đến hạn sau 1–8 cycle, ở mức theo dõi tăng cường.

Innovation - Unity - Humanity

Nguồn: outputs/maintenance/tables/maintenance_schedule.csv; outputs/maintenance/summary.json

Các thử nghiệm mở rộng

Khả năng tổng quát hóa sang FD002–FD004 (cửa sổ 10 cycle) và các phương án cải tiến; kết luận chính không đổi



Nested CV: window, siêu tham số, trọng số

Quy trình lựa chọn hội tụ về cấu hình gốc; số cảnh báo muộn 49 → 53/100.

Thêm 42 đặc trưng lịch sử (169 đặc trưng)

MAE OOF 20,21 → 17,00; tỷ lệ cảnh báo kịp thời (ngưỡng 30) giảm 51% → 45%.

ARIMA dự báo Health Index

MAE 0,41 so với 0,75 của phương pháp drift; vượt trội ở 7/10 động cơ.

Innovation - Unity - Humanity

Nguồn: outputs/cross_dataset/matrix.json; outputs/experiments/; outputs/course_alignment/20261007/summary.json

Kết luận

Trả lời năm câu hỏi nghiên cứu; kết luận giới hạn trong dữ liệu mô phỏng C-MAPSS FD001

Q1 Pipeline dữ liệu

0 sai khác

Pandas và PySpark trùng khớp; PySpark nhanh hơn ~3,4× ở quy mô 10×

Q2 Khử nhiễu, window

−86%

độ dao động sau EWMA; 126 đặc trưng cửa sổ 30 cycle

Q3 Xu hướng, bất thường

100/100

động cơ được phát hiện, trung vị 121 cycle trước hỏng hóc

Q4 Dự đoán RUL

15,35

MAE trên tập kiểm tra (cycle); 4,38 khi RUL ≤ 30

Q5 Cảnh báo, lịch bảo trì

21/21

dự báo cần bảo trì chính xác; không bỏ sót; lead time trung vị 30 cycle

Sản phẩm đặc thù

Lịch dự đoán thời điểm cần bảo trì cho từng động cơ, kèm biểu đồ xu hướng cảnh báo sớm.

Innovation - Unity - Humanity

Nguồn: report/sections/conclusion.tex; các artifact đã dẫn ở slide 6–16

Khó khăn, bài học và giới hạn

Các vấn đề phát sinh trong quá trình thực hiện, cách xử lý và bài học rút ra

Khó khăn	Cách xử lý	Bài học
Thiếu nhãn thời điểm bất thường	Lấy 30 cycle đầu của từng động cơ làm tham chiếu	Xác định rõ trạng thái tham chiếu; nêu rõ phần chưa kiểm chứng được
Rò rỉ dữ liệu khi chia tập	GroupKFold theo động cơ; window, EWMA chỉ dùng quá khứ	Với dữ liệu chuỗi thời gian, đơn vị phân chia là thực thể, không phải bản ghi
Hạ tầng: PySpark trên Windows, Hadoop trong Docker	Ghi qua Arrow; dùng image Hadoop có Python; đặt replication 1 cho Spark	Đối chiếu từng giá trị giữa các cách triển khai; kiểm tra HDFS bằng fsck sau khi ghi
Nguy cơ tập trung quá mức vào tối ưu mô hình	Cố định tiêu chí đánh giá trước; tách thử nghiệm sang phần mở rộng	Tính đúng đắn của pipeline và khả năng diễn giải cảnh báo được ưu tiên hơn mức giảm nhỏ của MAE

Giới hạn: dữ liệu mô phỏng; chưa có dữ liệu chi phí để tối ưu ngưỡng cảnh báo; Hadoop và Spark chạy trên một máy, chưa triển khai cluster nhiều node hay streaming.

Innovation - Unity - Humanity

Nguồn: report/sections/discussion.tex (Mục Khó khăn và bài học rút ra)

Industrial University of Ho Chi Minh City



Trân trọng cảm ơn quý thầy cô đã lắng nghe

Kính mời quý thầy cô đặt câu hỏi

Demo dashboard: uv run --extra dashboard streamlit run app.py

Phan Nguyễn Mai Phương · MSHV 25002711